天津大學

《认知科学导论》大作业报告

基于深度学习的 PVT 疲劳检测算法与应用场景调研——Collet、Compute and Conclude

任课教师 张高燕

2025 年 6 月 27 日

目　录

一、摘要.....1
二、引言.....1
三、疲劳检测算法设计.....2
3.1 题意理解.....2
3.1.1 数据集数据组成.....2
3.1.2 实验思路.....4
3.2 实验设计.....4
3.2.1 特征融合.....4
3.2.2 模型结构设计.....5
3.2.3 训练方案.....10
3.3 实验测试与调优.....11
3.3.1 LOSO 交叉验证.....11
3.3.2 集成学习.....11
四、技术应用场景调研.....13
4.1 PVT 范式的疲劳检测方法调研.....13
4.1.1 PVT 范式的核心地位与疲劳敏感度.....13
4.1.2 EEG 成为疲劳客观监测的关键技术.....14
4.1.3 多场景应用.....14
4.2 交通运输：构建前瞻性主动安全系统.....15
4.3 医疗健康：保障患者安全，优化人力资源管理.....16
4.4 高风险工业与军事：保障关键任务认知可靠性.....16
4.5 科研探索与个人健康：量化认知状态的潜在应用.....17
五、结论.....17
六、成员贡献.....18

一、摘要

针对基于脑电图（EEG）的精神疲劳监测任务，本研究提出 FusionNet 深度学习模型，通过融合时间与频域双维度特征提升分类性能。模型处理功率谱（Power）与微分熵（DE）融合数据，采用双分支 1D 卷积分别提取时域/频域特征，并嵌入通道注意力和空间注意力机制优化特征权重。为解决小样本数据下个体差异问题，采用留一被试交叉验证（LOSO） 训练策略，结合集成学习方法融合 10 个子模型的预测概率。实验表明：优化学习率（lr=0.04）后，集成方法显著提升测试准确率（最高提升 27.8%），验证了模型对未见个体的泛化能力。该技术为交通运输、医疗手术等高危场景提供无扰、实时的疲劳预警支持，推动主动安全系统发展。

二、引言

精神疲劳，作为神经系统因持续认知活动而导致的功能性暂时下降状态，是日常工作和生活中普遍存在且具有重要影响的现象。其显著削弱警觉性、信息处理能力和决策质量，在诸多需要高度专注力的环境中构成重大的安全隐患。因此，开发能够精准、实时监测精神疲劳状态的技术，对于保障人员安全和提升作业效率至关重要。

精神运动警觉任务（Psychomotor Vigilance Task, PVT）是一种广泛应用于神经行为学研究的测试范式，通过测量受试者对随机视觉刺激的反应时间来评估警觉性水平。PVT 因其标准化和高敏感性，在评估警觉性水平和疲劳研究中被视为“黄金标准”。在长时间执行 PVT 过程中，受试者会经历精神疲劳，表现为反应时间延长、错误率增加等。

PVT 的疲劳检测应用场景极其广泛，既包括神经科学、认知科学、医学这样的科研领域，也包括交通运输、医疗领域、高风险工业、军事行动这样的职业领域，此外，还可以用于评估健康状况这样的日常领域。

但是传统的 PVT 评估主要依赖行为表现指标，评估只有在任务结束后才能对行为指标进行统计分析，而无法评估执行具体的工作任务中的状态，因为 PVT 本身是一个主动反应任务，需要实时按键，这会干扰主任务比如驾驶、手术，不适用于真正的在具体工作中的监测。

针对上述挑战，利用被动式神经生理信号进行疲劳监测显示出巨大潜力。其中，脑电图（Electroencephalogram, EEG） 以其极高的时间分辨率、设备穿戴便捷性、以及提供脑电动态丰富信息的独特优势，成为构建实时、非侵入性疲劳监测系统的理想信号源。通过分析 EEG，有望在明显的行为变化显现前，捕捉到潜在的神经生理疲劳标记物。

然而，传统的基于 EEG 的疲劳检测方法常依赖于研究者手动设计特征（如特定频带功率、时域统计量、复杂度指标等）并应用支持向量机（SVM）等分类器。这些方法虽有一定效果，但往往面临着特征设计主观性强、依赖特定数据集或实验范式、模型泛化能力受限等挑战。

深度学习技术的兴起为解决这些问题提供了新视角。其强大的端到端学习能力，能够自动从原始或预处理数据中挖掘最优的、层次化的特征表示，有望超越

人工设计的限制，构建出更具鲁棒性和泛化能力的疲劳评估模型。

因此，在本报告中，我们实现了基于脑电信号(EEG)的深度学习方法，通过分析 PVT 实验中的 EEG 特征，预测疲劳程度，可以为开发实时疲劳监测系统提供支持。

三、疲劳检测算法设计

在本节中，将要介绍此任务使用到的深度学习方法，以及使用到的数据集。

3.1 题意理解

3.1.1 数据集数据组成

同时计算给出了每一个电极下，五个频段（'Delta': (0.5, 4), 'Theta': (4, 8), 'Alpha': (8, 13), 'Beta': (13, 30), 'Gamma': (30, 50)，单位Hz）的Power（功率）特征与DE（微分熵）特征

Power计算公式为：

$$\frac{1}{N} * abs(x)^2$$

x为信号值，N为数据点个数

微分熵DE特征，公式推导简化后为：

$$\frac{1}{2}(2 * \pi * \sigma^2)$$

其中σ^2为这个样本数据的方差

图 3-1 – 数据集特征值含义

readme 说明文档给出了每个电极下，5 个频段的 Power 与 DE 特征。

特征值意义

（1）微分熵（DE）

基于信息论，描述信号复杂度，公式简化为：

$$DE=1/2*\ln(2\pi e\cdot\sigma^2)$$

其中 $\sigma 2$ 是频段信号的方差（等价于功率）。

数据经过标准化处理（如 Z-score），使均值接近 0，标准差为 1，便于模型收敛。

频段与认知状态的会有所关联，查阅资料，获知 Theta 频段与疲劳的有一定正相关关系存在，Beta 频段则关联警觉，还有 Gamma 频段与高认知任务的激活相关。

（2）功率特征（Power）

定义：频段内信号能量的积分，反映神经元同步化活动强度。

计算方式：对滤波后信号进行傅里叶变换（FFT）或 Welch 法，计算功率谱密度（PSD），再在指定频段积分.

数据集数据（特征与含义）

首先阅读原代码，load_data.py 文件定义了 EGGDataset 类，完成了数据的导入、过滤和区分训练测试集的操作。

特征张量（59×5 矩阵）

```
        [-0.0655, -0.4161, -1.0277, -1.0184, -0.9527],
        [-0.2471, -0.5523, -0.8814, -0.4754, -0.9436],
        [ 0.0256, -0.2481, -0.7698, -0.3779, -1.1450],
        [ 0.1072, -0.2879, -0.8739, -0.5093, -1.0032],
        [-0.0383, -0.4391, -0.7685, -0.1182, -0.8628],
        [-0.0921, -0.3264, -1.0253, -0.6162, -0.9765],
        [-0.0152, -0.5764, -0.7286, -0.1261, -0.7358],
        [-0.0767, -0.3957, -1.0430, -0.9822, -0.9871],
        [-0.2565, -0.6086, -0.8712, -0.6846, -1.0350],
        [-0.1491, -0.4886, -0.9460, -0.3531, -1.1156],
        [-0.2015, -0.2967, -0.9652, -0.3631, -1.1862],
        [-0.2584, -0.5902, -0.8436, -0.5349, -0.9685],
        [-0.1697, -0.3247, -1.0091, -0.5392, -1.0903],
        [-0.2870, -0.5628, -0.8417, -0.6198, -0.8502],
        [-0.1196, -0.3581, -1.0412, -0.8138, -1.0536],
        [-0.1901, -0.5778, -0.9564, -0.8183, -0.9630],
        [-0.1888, -0.4120, -1.0344, -0.7408, -0.9716],
        [-0.1609, -0.3409, -1.0293, -0.6472, -1.0452],
        [-0.2232, -0.5114, -1.0163, -0.8097, -0.9571]]), tensor(0))
2908
(tensor([[-0.0441, -0.4670, -0.6089, -0.5713, -0.5385],
        [ 0.0666, -0.4437, -0.6148, -0.5679, -0.5328],
```

图 3-2 – 数据集数据特征

运行 load_data 文件，观察输出结果，输出为一个两个 tensor 组成的元组，第一个是一个 56*5 的矩阵，第二个为 tensor(0).

特征张量为 59*5 矩阵。行数表示时间点数目，每个时间点对应个一个采样时刻。59 个点依据采样率（Hz）来确定这一个 tensor 能覆盖多长时间。

列数对应 5 个频段：

- ✧ Delta (0.5-4 Hz)
- ✧ Theta (4-8 Hz)
- ✧ Alpha (8-13 Hz)
- ✧ Beta (13-30 Hz)
- ✧ Gamma (30-50 Hz)

Data 中有两个 train 数据集，打印了 3 个数据文件中的第一个数据，则第一个是 DE 特征，第二个是 Power 特征， 第三个则是测试集。DE 和 Power 的数据集长度都为 2908。Test 的数据集长度则为 318。

训练集与测试集存在的主要区别就在于第二的 Tensor 也就是标签的有无。对于训练集，10 个被试者每个数据段内有一个标签，其值为 0/1 推测代表着此次测试被试者的疲劳状态为 Normal / Fatigue。我们要进行的是一个分类任务。由此就知道了分类的目标类为 0/1 两类。

总结一下，现有的数据包括训练集和测试集，他们的第一维 Tensor 都是 59*5 的二维 Tensor。59 代表时段，5 代表频段，DE 和 Power 两个特征的数据

结构都是如此，分别存放在两个文件中。训练集则多出一个第二维 Tensor，代表此组数据所属于类别，类别有两个，以 0 或 1 表示。测试集则没有标签。

3.1.2 实验思路

试运行

由上所述，测试集没有标签，因此无法得到测试集的测试结果。所以对训练集进行划分，划分出训练集中的训练集和验证集，验证集用于模型初步的性能验证。阅读 train.py，原代码选用下标 1 作为训练时剔除的验证集，并使用 DE 的数据集进行训练。于是我们修改之，先用一个循环看看初始代码的效果。在终端查看后，发现 3、4、6、8 几个被试数据的准确率低于目标标准，也即是我们要重点关注的对象。

```
[0] Final model weights saved at ./models\final_model.pth, with accuracy: 0.7933
[1] Final model weights saved at ./models\final_model.pth, with accuracy: 0.8187
[2] Final model weights saved at ./models\final_model.pth, with accuracy: 0.7537
[3] Final model weights saved at ./models\final_model.pth, with accuracy: 0.6905
[4] Final model weights saved at ./models\final_model.pth, with accuracy: 0.8678
[5] Final model weights saved at ./models\final_model.pth, with accuracy: 0.5619
[6] Final model weights saved at ./models\final_model.pth, with accuracy: 0.8715
[7] Final model weights saved at ./models\final_model.pth, with accuracy: 0.6659
[8] Final model weights saved at ./models\final_model.pth, with accuracy: 0.8277
[9] Final model weights saved at ./models\final_model.pth, with accuracy: 0.8371
```

图 3-3 – 试运行结果

实验思路

原代码使用 DE 数据集进行训练，并仅对下标为 1 的被试进行验证集验证。经过循环设置每个被试为验证集的尝试后，很自然地想到，我们应该利用上 Power 数据集。以及本次实验的场景与机器学习中所授“集成学习”十分契合，将两种方法与单独的模型优化结合，应该能取得不错的性能。

下面就此思路展开实验。

3.2 实验设计

3.2.1 特征融合

特征融合是指将来自不同来源、不同层次或不同模态的特征进行整合，以提升模型对复杂信息的鲁棒性、准确率等。

在该任务中，数据集分为两个，是 Power（功率）与 DE（微分熵），这两个特征在两个数据文件中，因此可以采用特征融合方法，将 Power 直接拼接在 DE 后面，形成一个数据集，由图 3-4 所示。

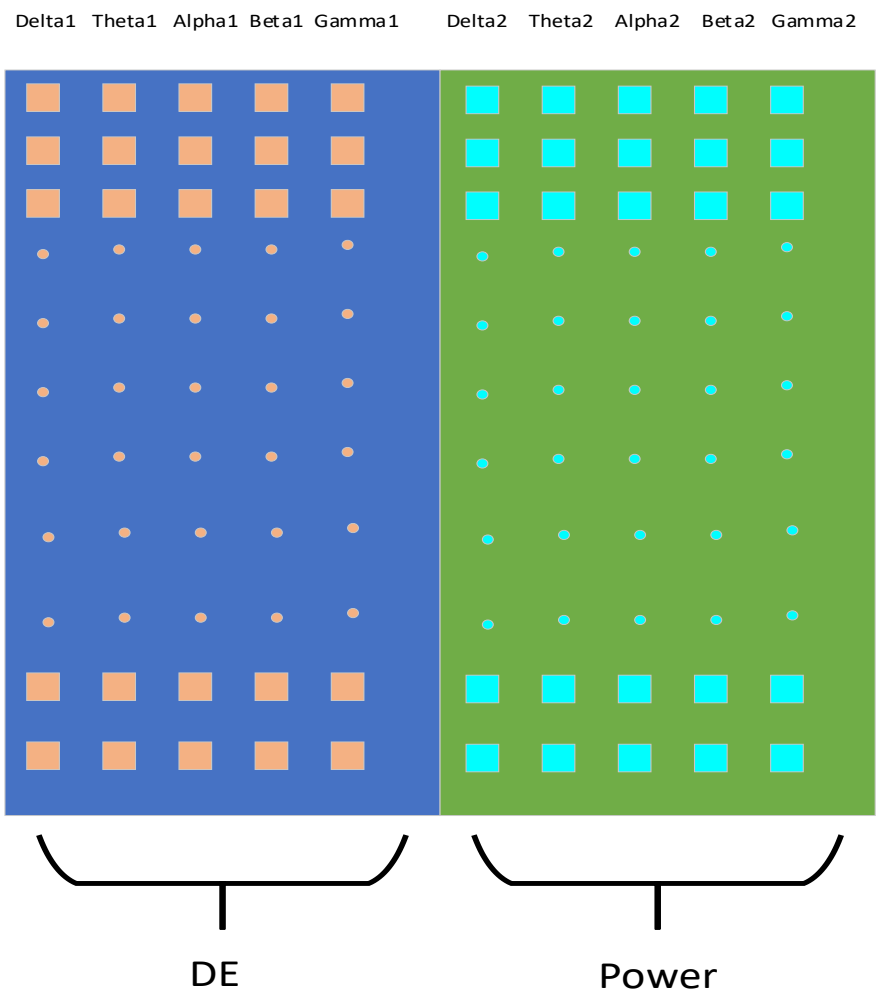

图 3-4 - 特征融合数据集

3.2.2 模型结构设计

由于一般的全连接网络参数过多，所以在一般的计算机视觉中，较多的使用 CNN 来进行特征提取。在本任务中可以参考使用 CNN，计算机视觉的一个样本是一张图片作为 2 维矩阵，矩阵的各个元素在行、列的特征都是一样的，因此可以使用 2 维卷积。但是在此任务中，矩阵的行表示时间戳，列表示不同频域，因此，行、列并不相同，所以不能使用 2 维卷积，而是使用 1 维卷积。

另一方面，由于数据集较小，因此，对于大规模数据适用的 Transformer 模型也被排除，因为 Transformer 所基于的自注意力计算复杂度很高，参数量很大，极容易造成过拟合。并且，对于这个任务本身来说，每个测试者之间个体的差异较大，对于 Transformer 也同样不友好。

FusionNet

由于数据集包含了两方面的内容，时间上的和频域上的，因此，可以考虑使用 1 维卷积，分别在时间维度上和频域维度上两个维度进行滑动，这样就可以提取这两方面的特征，然后将这两方面特征进行融合。因此，该网络叫做 FusionNet，表示在时间和频域上的融合。

具体来说，首先将输入看作有列数个通道，如图 3-5 所示。

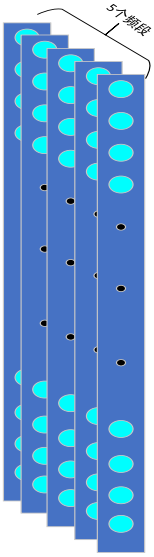

图 3-5 - 输入特征

然后应用通道注意力模块，将这几个通道赋予注意力权重，由图 3-6 所示。首先对每个通道求平均也就是在时间维度上求平均值，然后应用两个全连接层，首先降维，然后升维，得到注意力权重，然后将输入乘以这个权重，得到加权的特征。

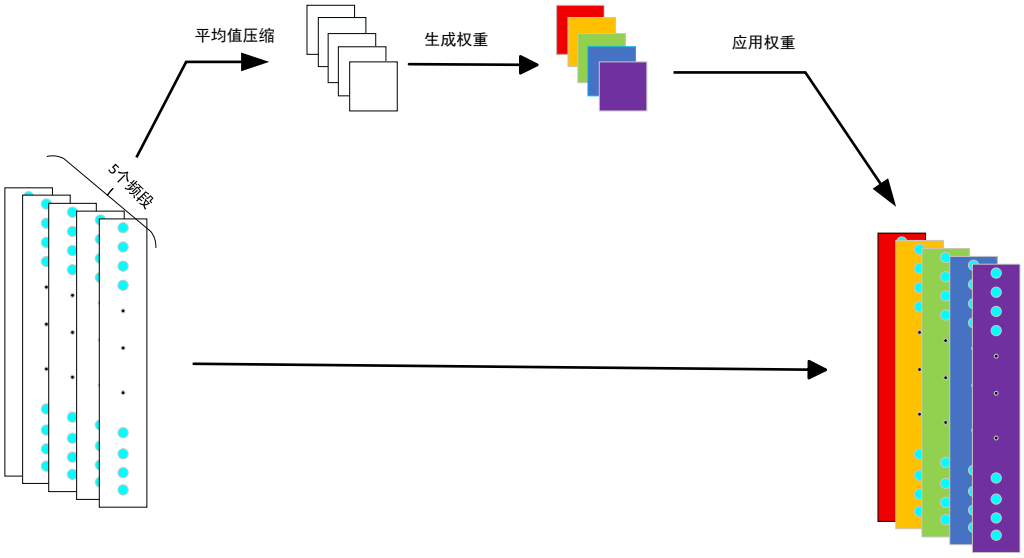

图 3-6 - 通道注意力

第二步是分别提取时间维度，以及频域维度上的特征。

对于时间特征提取，首先把各个频段看成通道，应用两次卷积以及池化，最终得到 128 通道的特征，如图 3-7 所示。

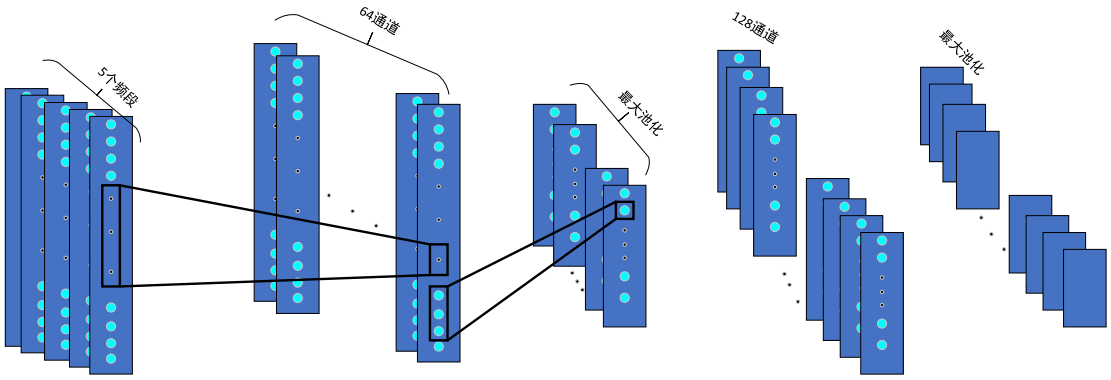

图 3-7 - 时间特征提取

其次，对于频域维度的特征提取，则是把 59 个时间看成 59 个通道，使用 1 维卷积在频域维度上滑动，如图 3-8 所示。

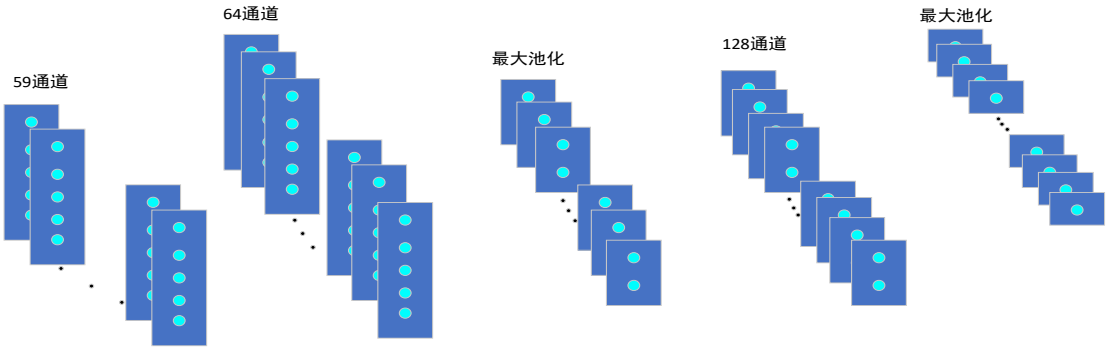

图 3-8 - 频段特征提取

第三步，分别对时间特征和频段特征使用自适应全局平均池化转变为 128x1 的特征，然后将这两个特征从通道维度上拼接，由图 3-9 所示。

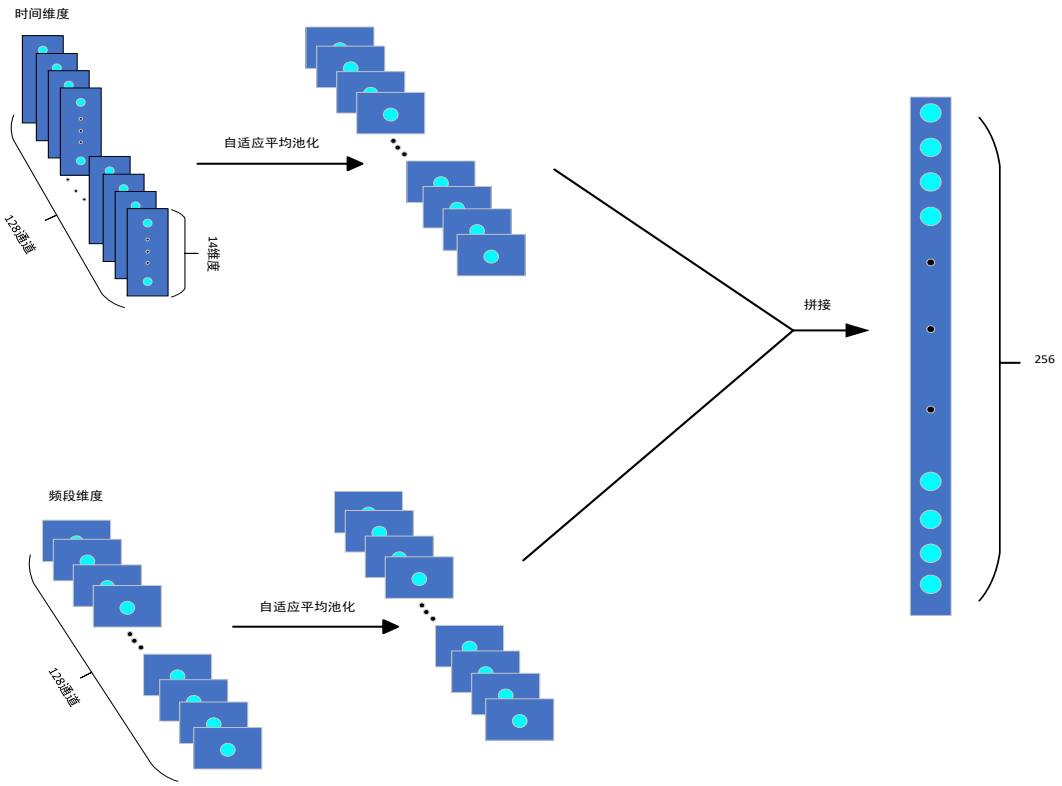

图 3-9 - 融合

第四步，使用空间注意力，应用两个全连接层，将第三步得到的向量先降维再升维，得到注意力权重，并加权，由图 3-10 所示。

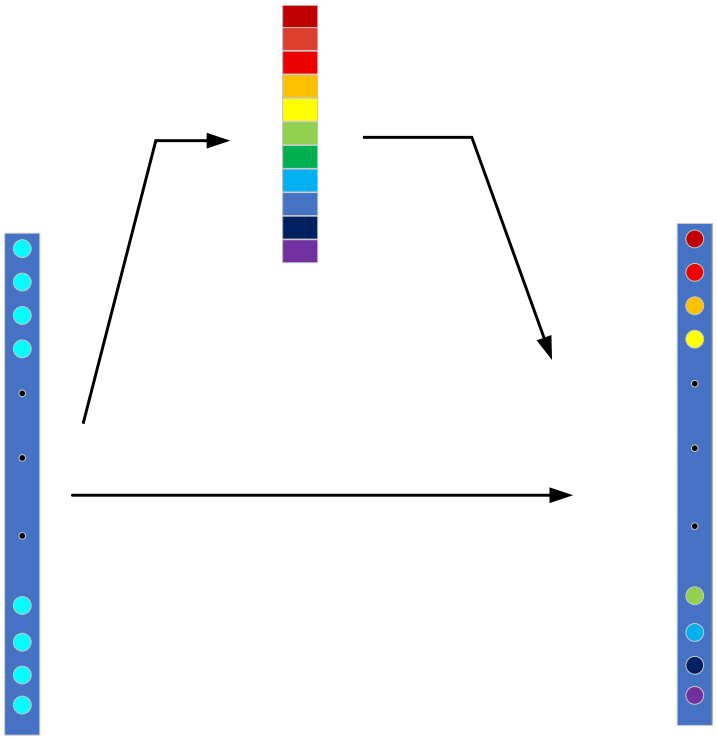

图 3-10 - 空间注意力

第五步，将得到的加权向量输入到全连接网络中，输出最终的两个类别，由图 3-11 所示。

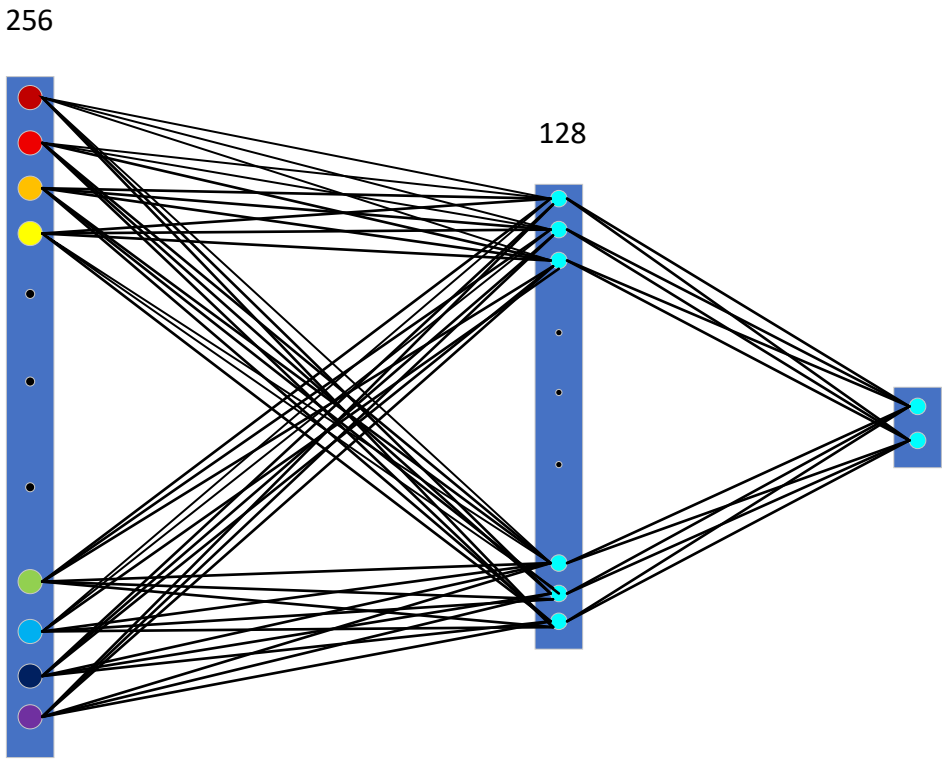

图 3-11 - 全连接输出类别

模型的流程图如图 3-12 所示。

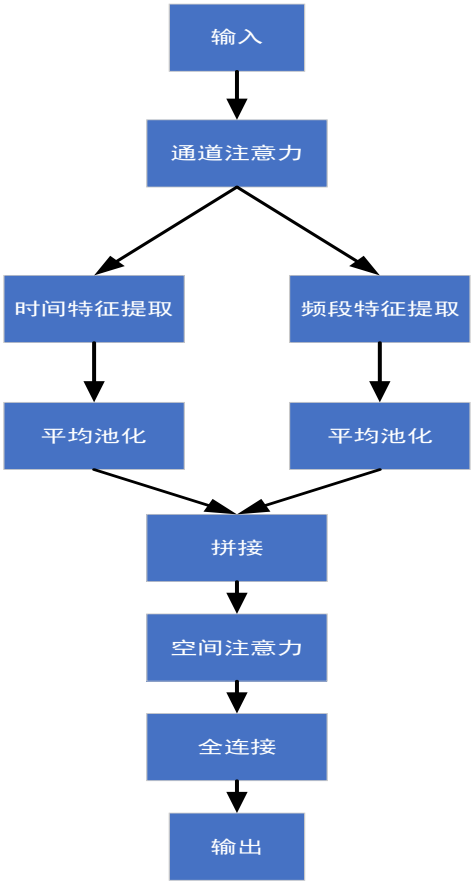

图 3-12 - 流程图

3.2.3 训练方案

由于不同的测试者的个体差异很大，并且数据集较小，因此，如果只凭 10 个训练集，对测试集进行预测，效果可能不是很好，因此，考虑使用 LOSO 交叉验证方法，直译为留一被试交叉验证，意思是将训练集中的 10 位测试者分成 10 份，每份 1 位测试者，进行 10 次训练和验证循环，在第 i 次循环中：

（1）从训练集中排除第 i 位参与者的所有数据

（2）使用剩下所有 9 个参与者的所有数据进行模型训练。

（3）使用刚刚被排除的第 i 位参与者的所有数据进行模型测试评估，作为验证集。

经过 10 次循环后，我们可以得到 10 个训练好的模型。

LOSO 确保在测试阶段评估的是模型对完全未见过的、独立的新个体的表现。这在本次任务所属的领域至关重要，因为目标是开发能够在不同人身上工作的模型。在有 n 个测试者时，模型需要训练 n 次，因此 LOSO 的计算成本在有大量参与者时尤其很高。但是，在本任务中，参与者数量相对较少，那么 LOSO 会特别有价值，因为每个训练集包含几乎所有可用数据，提供了尽可能大的训练样本。

在最后进行预测测试集的时候，我们将使用集成学习的方法，这样才能将之前得到的 10 个模型全部使用上，提供最可靠的预测。

具体来说，我们的集成方法是对于第 11 位测试者，我们将使用 10 个模型分别预测这位测试者的各个数据点的类别，并不输出类别，而是输出概率分布，然

后对所有模型的概率取平均，选择平均概率最高的类别。

例如，假设有 3 个模型，2 个类别，输入批次大小=2。在某一次预测中，模型的输出为：

模型 1 输出: [[0.9, 0.1], [0.4, 0.6]]

模型 2 输出: [[0.6, 0.4], [0.1, 0.9]]

模型 3 输出: [[0.7, 0.3], [0.3, 0.7]]

那么，对于第一个样本，第一个类别，我们计算平均概率(0.9+0.6+0.7)/3，第二个类别也同样计算平均概率(0.1+0.4+0.3)/3，得到[0.73，0.27]，因此，对于第一个样本，输出的最终类别就是 0，第二个样本同理输出 1。

其他的超参数包括，优化器使用 Adam 方法；调度器为 ReduceLROnPlateau，对于在验证集上预测的准确率指标，如果在 5 个 epoch 内没有提升，那么会将学习率 lr 乘以因子 0.9；设置了早停机制，如果在 30 个 epoch 内，准确率没有提升，那么对于这次训练直接停止，这可以很好的节省资源。

3.3 实验测试与调优

3.3.1 LOSO 交叉验证

首先，调优初始学习率参数 lr，我们使用不同的初始学习率，进行 LOSO 交叉验证，得到的结果如表 5-1 所示。

lr	id0	id1	id2	id3	id4	id5	id6	id7	id8	id9
0.07	0.8184	0.8516	0.9236	0.7341	0.9255	0.7216	0.8603	0.8582	0.8818	0.8447
0.06	0.7933	0.8544	0.9261	0.7659	0.9087	0.7320	0.8408	0.8750	0.8682	0.8523
0.05	0.8296	0.8049	0.9113	0.7540	0.8846	0.7526	0.8631	0.8822	0.8750	0.8409
0.04	0.8184	0.8269	0.9138	0.8294	0.9014	0.7784	0.8631	0.8173	0.8514	0.8750
0.03	0.8268	0.8049	0.9212	0.7460	0.8990	0.7629	0.8799	0.8798	0.8750	0.8523
0.02	0.8380	0.8242	0.9089	0.7897	0.8990	0.7423	0.8464	0.8702	0.8750	0.8674
0.01	0.8324	0.8462	0.9261	0.7738	0.9111	0.7474	0.8743	0.8630	0.8615	0.8561
0.009	0.8324	0.8599	0.9138	0.7857	0.8966	0.7113	0.8408	0.8774	0.8716	0.8712
0.008	0.8240	0.8049	0.9187	0.7738	0.9231	0.7577	0.8659	0.8606	0.8446	0.8523
0.007	0.8408	0.8049	0.9015	0.7937	0.9351	0.7165	0.8743	0.8438	0.8581	0.8561
0.006	0.8436	0.8049	0.9064	0.8254	0.9159	0.7216	0.8408	0.8486	0.8581	0.8447

表 3-13 - 不同学习率下 LOSO 结果

由表 3-13 可知，当 lr 为 0.04 时，各个测试者的准确率预测均是较优的水平。

3.3.2 集成学习

为了验证集成学习的可靠性，我们将分别使用传统的方法和集成学习的方法，进行 LOSO 交叉验证，具体来说，对于训练集的 10 位测试者，我们循环 10 次，在第 i 次循环中，调出第 i 位测试者作为验证集，然后分别进行两种预测，第一种预测是直接使用除去 i 的训练集进行训练，并测试，第二种方法是使用集成学习，也就是说，在去除了 i 的训练集上再用一次 LOSO 交叉验证，然后得到 9 个模型，将这 9 个模型集成，来预测 i，算法 1 描述了这种方法。

Algorithm 1 LOSO交叉验证与集成学习比较算法

输入: 训练集 $D = \{D_1, D_2, \ldots, D_{10}\}$, 其中 D_i 表示第 i 位测试者的数据
输出: 传统方法和集成方法在每个测试者上的准确率比较结果
for $i = 1$ to 10 **do**
  提取验证集 $V_i = D_i$
  构建训练集 $T_i = D \setminus D_i$
  传统方法:
  使用训练集 T_i 训练模型 M_i
  在验证集 V_i 上测试模型 M_i，得到准确率 $acc_{traditional}(i)$
  集成学习方法:
  初始化集成模型 $Ensemble_i = \{\}$
  for $j = 1$ to 9 **do**
    提取子验证集 $V_{i,j} = T_i[j]$ (第 j 位测试者在 T_i 中)
    构建子训练集 $T_{i,j} = T_i \setminus T_i[j]$
    使用子训练集 $T_{i,j}$ 训练模型 $M_{i,j}$
    在子验证集 $V_{i,j}$ 上测试模型 $M_{i,j}$，得到准确率 $acc_{i,j}$
    将模型 $M_{i,j}$ 添加到集成模型 $Ensemble_i$ 中
  end for
  使用集成模型 $Ensemble_i$ 对验证集 V_i 进行预测，得到准确率 $acc_{ensemble}(i)$
  比较:
  计算传统方法和集成方法在第 i 位测试者上的准确率差异 $\Delta acc(i) = acc_{ensemble}(i) - acc_{traditional}(i)$
end for
输出最终结果

表 3-14，图 3-15 是进行训练和测试，得到的结果。

test_subject	traditional_acc	ensemble_acc	improvement
0	0.8184	1	0.1815
1	0.8104	0.9972	0.1868
2	0.9162	1	0.0837
3	0.8214	0.9960	0.1746
4	0.8990	0.9975	0.0985
5	0.7216	1	0.2783
6	0.8938	1	0.1061
7	0.8677	1	0.1322
8	0.8445	0.9966	0.1520
9	0.8636	0.9924	0.1287

表 3-14 - 集成方法与传统方法对比

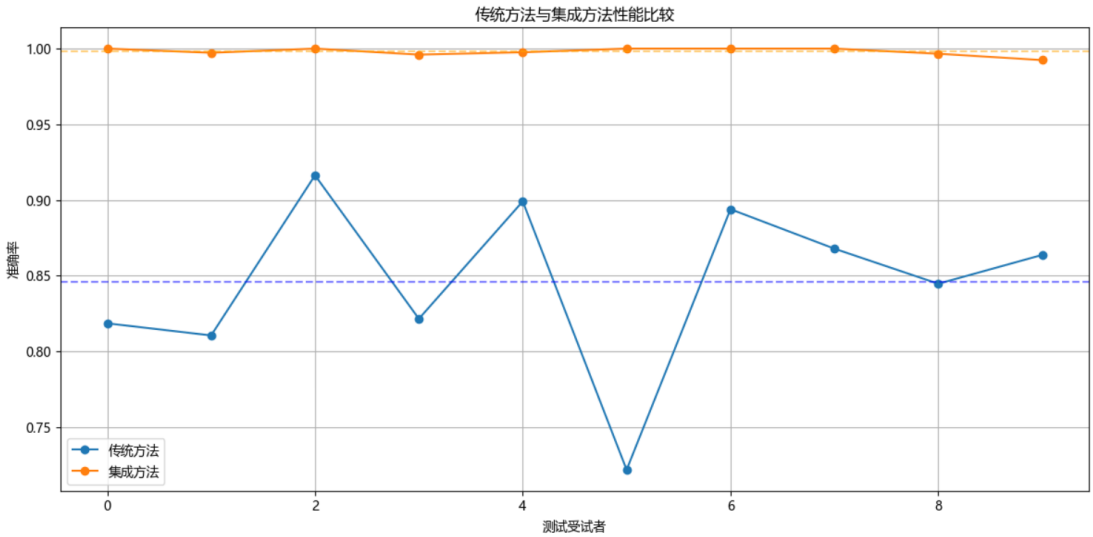

图 3-15 - 集成方法与传统方法对比

由图 3-14，表 3-15 可知，相较于传统方法，集成方法具有相当大的提升。

四、技术应用场景调研

精神疲劳作为一种普遍的亚健康状态，其本质是持续认知负荷下神经系统功能的暂时性失调，直接引致警觉性水平下降、信息处理效率衰减与决策能力受损。这一状态是众多领域中人为差错与安全事故的关键诱因。

本项目所构建的基于脑电图（EEG）与深度学习的 FusionNet 模型，旨在通过解码与疲劳状态相关的神经标记物，实现对个体警觉性水平的客观、无扰与前瞻性评估，从而赋能一系列关键应用领域。

4.1 PVT 范式的疲劳检测方法调研

4.1.1 PVT 范式的核心地位与疲劳敏感度

PVT（心理运动警觉任务）通过测量对随机视觉刺激的反应时间（RT）量化疲劳，被广泛验证为疲劳监测的"黄金标准"。文献 1（Tian 等）在 36 小时睡眠剥夺实验中证明，PVT 平均 RT 随清醒时间显著延长（从 323ms 增至 474ms），且与主观疲劳感同步上升，表明其对疲劳积累高度敏感：

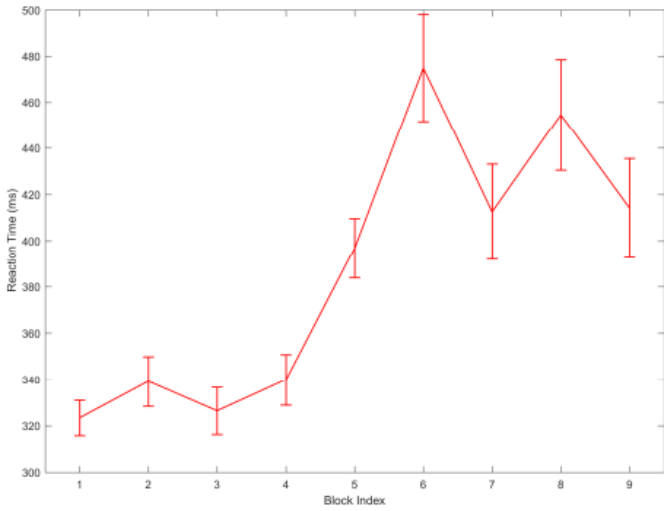

图 4-1 - 睡眠剥夺过程中 PVT 平均反应时（RT）的上升趋势

类似地，文献 4（Witkowski 等）发现大学生长期睡眠不足导致 PVT 反应速度显著下降（p<.018），证实 PVT 对慢性疲劳的敏感性。

4.1.2 EEG 成为疲劳客观监测的关键技术

传统帽式 EEG 的验证优势

文献 1 证明 EEG 特征（如功率谱密度 PSD、事件相关电位 ERP）通过多元线性回归模型预测 PVT-RT 的相关系数高达 0.81（PVT 任务），显著优于静息态数据（相关系数 0.50-0.65）。其中，额叶和枕叶通道的 ERP 成分（如 P3 振幅）与疲劳负相关（p<.046），而 alpha 波功率在闭眼时下降、睁眼时上升，可作为特异性生物标志物（图 4）：

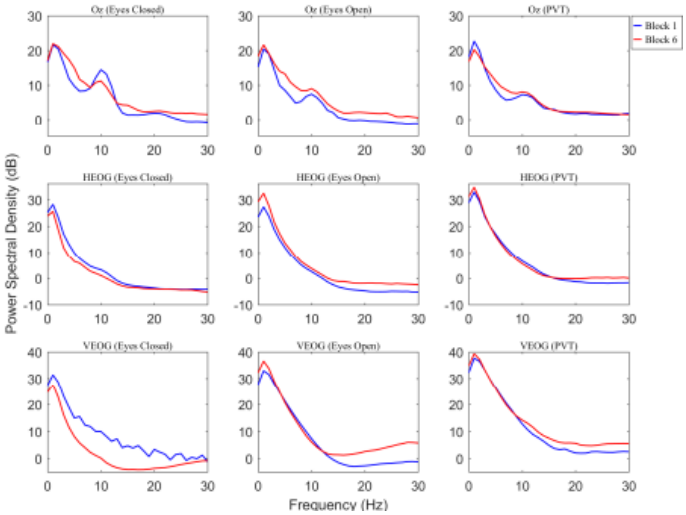

图 4-2 - EEG 预测 RT 的 LOSO 验证 PVT 任务相关系数

4.1.3 多场景应用

在军事领域，干电极 EEG 有着良好的野战适应性文献 2（Morrone 等）在

军事潜水员训练中应用干电极 EEG，发现睡眠限制后 PVT 任务中 theta/alpha 功率显著增加（$p<0.05$），且与睡眠倾向指标（ORP）同步恶化，证实其在野战环境下监测疲劳的可行性。

在临床诊断领域，可用于肝性脑病的诊断与驾驶能力评估。评估文献 3（Formentin 等）证明 PVT 参数如反应延迟，与肝性脑病严重程度显著相关（$p<0.001$），且能预测事故风险，凸显其在临床安全评估中的价值（F-11）。

在教育领域，PVT 范式疲劳检测方法可用于长期疲劳的累积效应。文献 4 指出大学生慢性睡眠限制导致静息态 alpha 反应性降低（$p<0.001$）和 P3 波幅下降（$p<0.001$），反映皮质唤醒度受损：

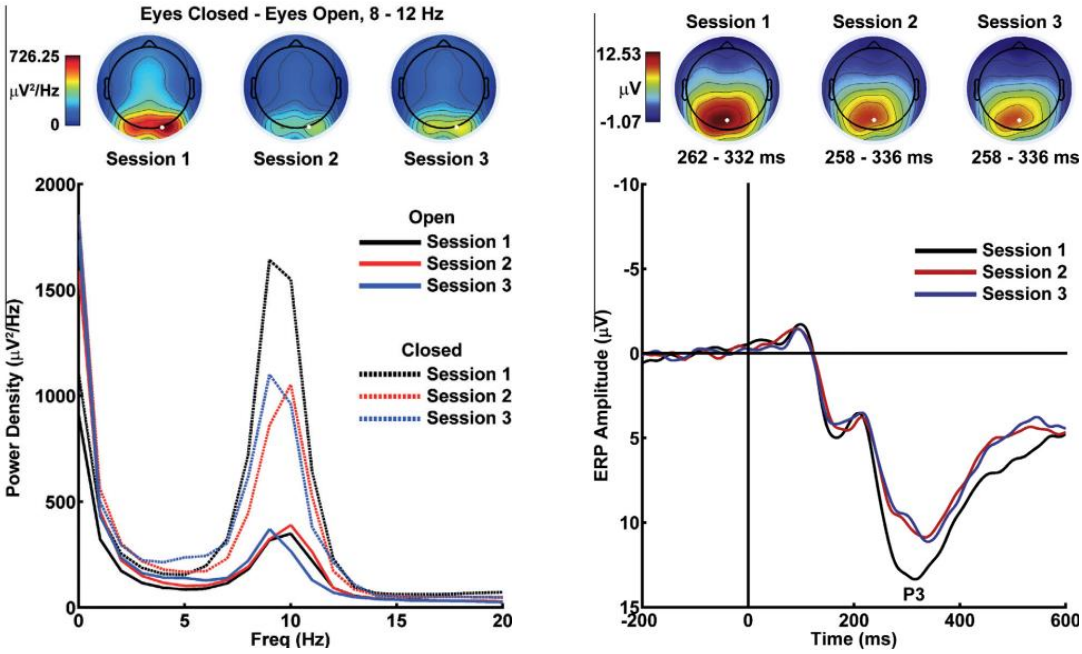

图 4-3、4-4 - 静息态 EEG 频谱分析 & PVT-ERP 波形图

4.2 交通运输：构建前瞻性主动安全系统

在交通运输领域，操作员的警觉性是保障安全运行的基石，而疲劳则是导致事故最主要的生理因素之一。该技术的应用旨在将当前以行为表征（如打瞌睡、头部姿态）为基础的滞后性、反应式干预，转变为以神经生理前兆为依据的前瞻性、预测性干预。

在公路运输中，商用车驾驶员因其工作特性成为疲劳驾驶的高发群体。现有的监管手段，如工时法规与基于机器视觉的驾驶员监控系统（DMS），存在局限。前者难以精确监管，后者则在检测到疲劳的外部行为体征（如眼睑闭合）时，驾驶员的认知功能早已显著下降，系统干预的延迟性使其难以有效规避所有风险。本研究提出的 EEG 监测系统，通过集成于头戴设备或座椅中的传感器，能够直接捕获大脑活动的内在变化，如特定频段（α 波、θ 波）功率谱密度的改变。FusionNet 模型能够实时解析这些先于行为表现的神经信号，实现对疲劳状态的早期预警。这种基于神经生理的预警机制，可触发分级干预策略：从初期的警觉性下降提醒，到深度疲劳状态下与车辆高级驾驶辅助系统（ADAS）联动，主动采取风险规避措施（如调整跟车距离、辅助保持车道），从而构筑一道真正意义

上的主动安全防线。

在轨道交通与民用航空领域，尽管存在严格的多人机组制度，但单调巡航环境下的操作员警觉性下降仍是不可忽视的安全隐患。将 EEG 监测技术应用于飞行员或机车司机的标准装备中，可建立一个客观、连续的认知状态监测范式。该系统不仅能评估主操作员的警觉性，还能为机组成员间的状态互检提供客观依据。此外，长期积累的个体疲劳数据，可作为一种重要的生物信息资源，用于优化排班方案、评估不同线路或时段的认知负荷，实现从宏观制度到微观个体层面的精细化、数据驱动式疲劳风险管理。

4.3 医疗健康：保障患者安全，优化人力资源管理

医疗环境的高强度与高风险特性，对从业人员的认知效能提出了严苛要求。医护人员的疲劳是诱发医疗差错、影响诊疗质量的关键变量。本技术旨在为此类高负荷场景提供客观的认知状态评估工具。

在外科手术等高精尖操作场景中，术者在长时间手术过程中不可避免地会经历疲劳累积，这直接威胁到操作的精准性与患者安全。通过在手术帽中集成 EEG 传感器，系统可实时量化术者的疲劳指数。当该指数超出安全阈值时，系统能够向团队发出非干扰性警示，提示进行即时干预，如关键步骤的交叉核对或由精力更充沛的副手接替。这为保障手术质量和患者安全增加了一重客观的技术保障。

对于医护人员的排班与健康管理，该技术同样具有重要价值。住院医师与护士的轮班制度是疲劳研究的重点。通过对医护人员进行常态化的 EEG 监测，管理者能够获得关于疲劳累积模式的客观数据，从而超越当前基于工时限制的粗放式管理。基于这些数据，可发展出更为科学、动态及个性化的排班模型，识别并干预高风险个体与班组，这不仅能直接降低因疲劳导致的医疗差错率，亦有助于改善医护人员的职业健康与福祉，构建更具韧性的医疗服务体系。

4.4 高风险工业与军事：保障关键任务认知可靠性

在核电、空管等关键基础设施的控制中心，以及现代军事行动中，操作员的持续警觉性与认知可靠性是确保系统安全与任务成功的核心。在这些领域，单次的认知失误可能导致灾难性后果。

对于工业流程控制与关键系统监控岗位，长时间的单调监视任务极易诱发警觉性衰退。本技术可作为增强“人机回路”（Human-in-the-loop）可靠性的关键模块。通过连续监测操作员的认知状态，系统可在其警觉性下降时，智能地调整人机交互界面，例如，通过增强视觉提示或引入认知激活任务，来维持其有效的工作状态。在检测到深度疲劳时，系统可自动触发更高层级的监督与干预程序，确保关键决策与操作的万无一失。

在军事应用中，该技术可用于评估与提升士兵的“认知战备状态”（Cognitive Readiness）。无论是需要长时间分析海量情报的无人机操作员，还是在极端环境下执行任务的特种作战人员，其认知效能都是决定性的战斗力要素。EEG 监测系统能够为指挥官提供关于士兵精神状态的客观数据，辅助进行任务分配、人员轮换等战术决策，并可作为一种客观评估工具，用于高压环境下认知韧性的选拔与训练。

航空安全领域对疲劳检测的需求推动了便携式 EEG 技术与 PVT 的结合。

针对民航飞行员的研究显示，cEEGrids（耳戴式 EEG）在睡眠限制（提前 3 小时唤醒）和工作日后，部分电极通道（如 L01、L04、R04）的 alpha 功率显著增加，但与主观嗜睡量表（KSS）和 PVT 反应速度无显著相关性。这反映出耳 EEG 技术的潜力与局限：虽能捕捉局部脑电变化，但电极位置（如颞叶附近）与传统帽式 EEG 的顶枕区优势位点存在差异，需进一步优化电极配置以提升敏感性。军事场景中，干电极 EEG 在男性军事学员中的应用表明，5.4 小时睡眠限制后，PVT 任务中的 theta（4-8Hz）和 alpha（8-12Hz）功率谱密度显著升高，且 Odds Ratio Product（ORP）值下降，验证了干电极技术在野外环境下监测疲劳相关神经变化的可行性。此类研究为飞行员和军事人员的疲劳预警系统开发提供了技术路径。

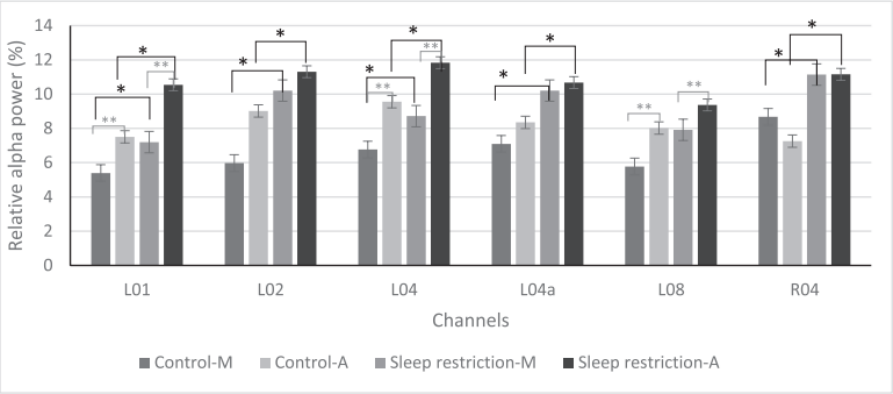

图 4-5 - 耳戴式 cEEGrids 的 alpha 功率变化

此研究表明睡眠限制后部分电极（L01, L02, L04）alpha 功率显著上升（$p<0.5$）cEEGrids 对轻度疲劳敏感，但与 PVT/KSS 无显著相关性（$p>0.05$）也就是说类似的电极功率数据测试法也有不起效果的方法存在。

4.5 科研探索与个人健康：量化认知状态的潜在应用

除上述职业场景外，该技术在基础科学研究与消费级健康领域亦展现出广阔的应用潜力，其核心在于将主观的“精神状态”转化为可量化的客观生物标志物。

在认知神经科学与药理学研究中，该技术提供了一种高时间分辨率、生态效度更高的因变量测量工具，可用于深入探究疲劳、注意力和睡眠剥夺的神经机制，或作为评估促认知药物与干预措施有效性的客观生物指标，克服了传统行为测试与主观量表的部分局限性。

在消费级健康管理市场，随着可穿戴技术的进步，存在将专业级 EEG 分析技术轻量化、普适化的巨大潜力。集成该技术的消费电子产品，能够为用户提供关于其日间认知资源波动的客观数据，从而辅助个人进行高效的时间管理、学习规划与作息调整，实现基于神经生理数据的个性化认知效能优化与健康管理。

五、结论

在本文中，我们基于 EEG 脑电图的数据集，构建了用于预测测试者状态的神经网络 FusionNet，该网络使用了通道、空间注意力，以及在时间和频段两个

维度上提取特征；并使用特征融合；LOSO 交叉验证；集成学习方法以提高模型的性能，最终在验证集上达到很高的准确率。

基于 EEG 信号和深度学习的实时疲劳监测技术，凭借其被动、客观、前瞻性的核心优势，在交通运输、医疗健康、高风险工业及军事行动等多个关键领域具有重大的应用价值。它旨在将安全管理范式从基于事故后分析和行为表征的被动响应，推向基于神经生理前兆的主动预防。本研究验证了该技术路线的可行性，为开发能够有效保障高风险岗位人员安全、提升社会整体运行效率的下一代认知状态监测系统奠定了重要基础。

六、成员贡献

参考文献

[1] Tian, S., Wang, Y., Dong, G., Pei, W., & Chen, H. (2018). *Mental Fatigue Estimation Using EEG in a Vigilance Task and Resting States*. IEEE

[2] Morrone, J., Coakley, S., Blacker, S., Myers, S., Hough, P., Vine, C., Maroni, T., Stanley, N., Halson, S.,

Siddall, A., Patterson, S., Jones, M., Chillingsworth, K., & Pedlar, C. R. (2025). Neural indicators of sleep loss and sleep propensity in male military trainees: Insights from dry-electrode EEG—An exploratory study. *Physiological Reports*, *13*(7), e70301.

[3] Tosetti, G., Soru, P., La Mura, V., Degasperi, E., D'Ambrosio, R., Arsiè, E., Borghi, M., Soffredini, R., & Primignani, M. (2018). Non-invasive prediction of high-risk varices in HCV-related cirrhosis after SVR. *Digestive and Liver Disease*.

[4] Tosetti, G., Soru, P., La Mura, V., Degasperi, E., D'Ambrosio, R., Arsiè, E., Borghi, M., Soffredini, R., Primignani, M., & Lampertico, P. (2018). Incidence and prognostic factors of “de novo” development/worsening of esophageal varices in HCV-related chronic advanced liver disease after sustained virologic response achieved by direct oral antiviral agents. *Digestive and Liver Disease*.

[5] Formentin, C., De Rui, M., Zoncape, M., Ceccato, S., Zarantonello, L., Senzolo, M., Burra, P., Angeli, P., Amodio, P., & Montagnese, S. (2018). The psychomotor vigilance task: Role in the diagnosis of hepatic encephalopathy and relationship with driving ability. *Digestive and Liver Disease*.

[6] Witkowski, S., Trujillo, L. T., Sherman, S. M., Carter, P., Matthews, M. D., & Schnyer, D. M. (2014). An examination of the association between chronic sleep restriction and electrocortical arousal in college students. *Clinical Neurophysiology*, *125*(8), 1650–1659.