3 脑电数据预处理实验

1、 **实验目的**

1．了解脑电数据的处理流程。

2．绘制可视化图像进行分析。

二、实验介绍：

本实验使用的数据是通过 PVT 范式（即上节实验课展示的范式）来采集的脑电数据。被试需要在对应刺激下进行反应。

三、实验要求

1. 利用 mne 库对脑电数据进行加载、滤波、重参考、去除伪迹，观察处理前后数据的差异。

2. 利用对处理后的数据在被试受到刺激（即 annotation 中为“1”的事件代表刺激开始，“2”事件代表做出反应，“3”事件代表反应缺失，“4”事件代表意外反应）前 0.5s 到受到刺激后 2s 的数据进行可视化，展示其时域、频域、和空域的特征图。

四、实验结果

```
# TODO 展示预处理前的一段数据
raw.plot(start=130)
plt.show()
```

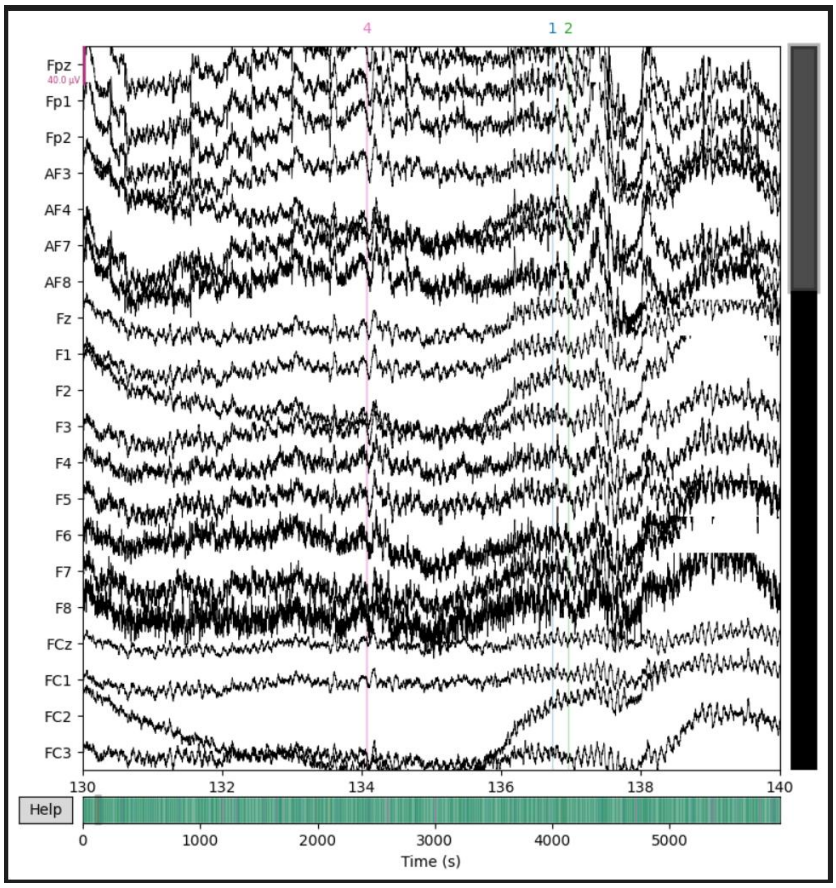


```python
# TODO 使用raw.filter函数进行1～100hz带通滤波
raw.filter(1, 100, fir_design='firwin', verbose=False)
# TODO 使用raw.notch_filter 陷波50hz
raw.notch_filter(50, fir_design='firwin', verbose=False)
# TODO 使用set_eeg_reference进行重参考
raw.set_eeg_reference(ref_channels='average', verbose=False)
```

General	
Filename(s)	subject_02.set
MNE object type	RawEEGLAB
Measurement date	Unknown
Participant	Unknown
Experimenter	Unknown
Acquisition	
Duration	01:39:00 (HH:MM:SS)
Sampling frequency	1000.00 Hz
Time points	5,940,000
Channels	
EEG	59
Head & sensor digitization	62 points
Filters	
Highpass	1.00 Hz
Lowpass	100.00 Hz

```python
# TODO 去除伪迹 自动ICA
ica = mne.preprocessing.ICA(
    n_components=15,
    max_iter="auto",
    method="infomax",
    random_state=97,
    fit_params=dict(extended=True),
)
ica.fit(raw)


ica
```

Method	infomax
Fit parameters	extended=True max_iter=500
Fit	500 iterations on raw data (5940000 samples)
ICA components	15
Available PCA components	59
Channel types	eeg
ICA components marked for exclusion	—

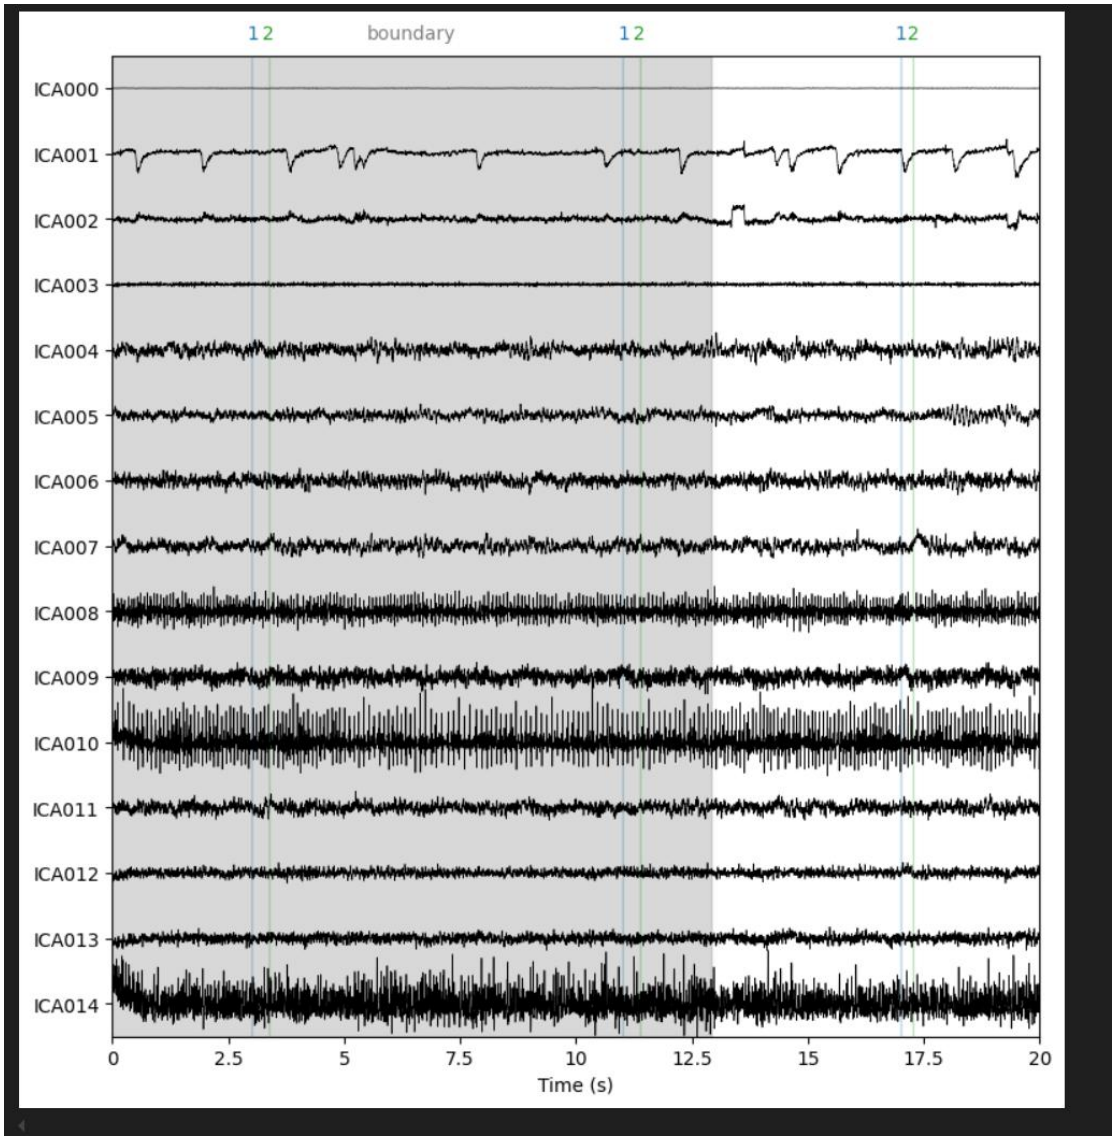
1 2
boundary
1 2
12
ICA000
ICA001
ICA002
ICA003
ICA004
ICA005
ICA006
ICA007
ICA008
ICA009
ICA010
ICA011
ICA012
ICA013
ICA014
0
2.5
5
7.5
10
12.5
15
17.5
20
Time (s)

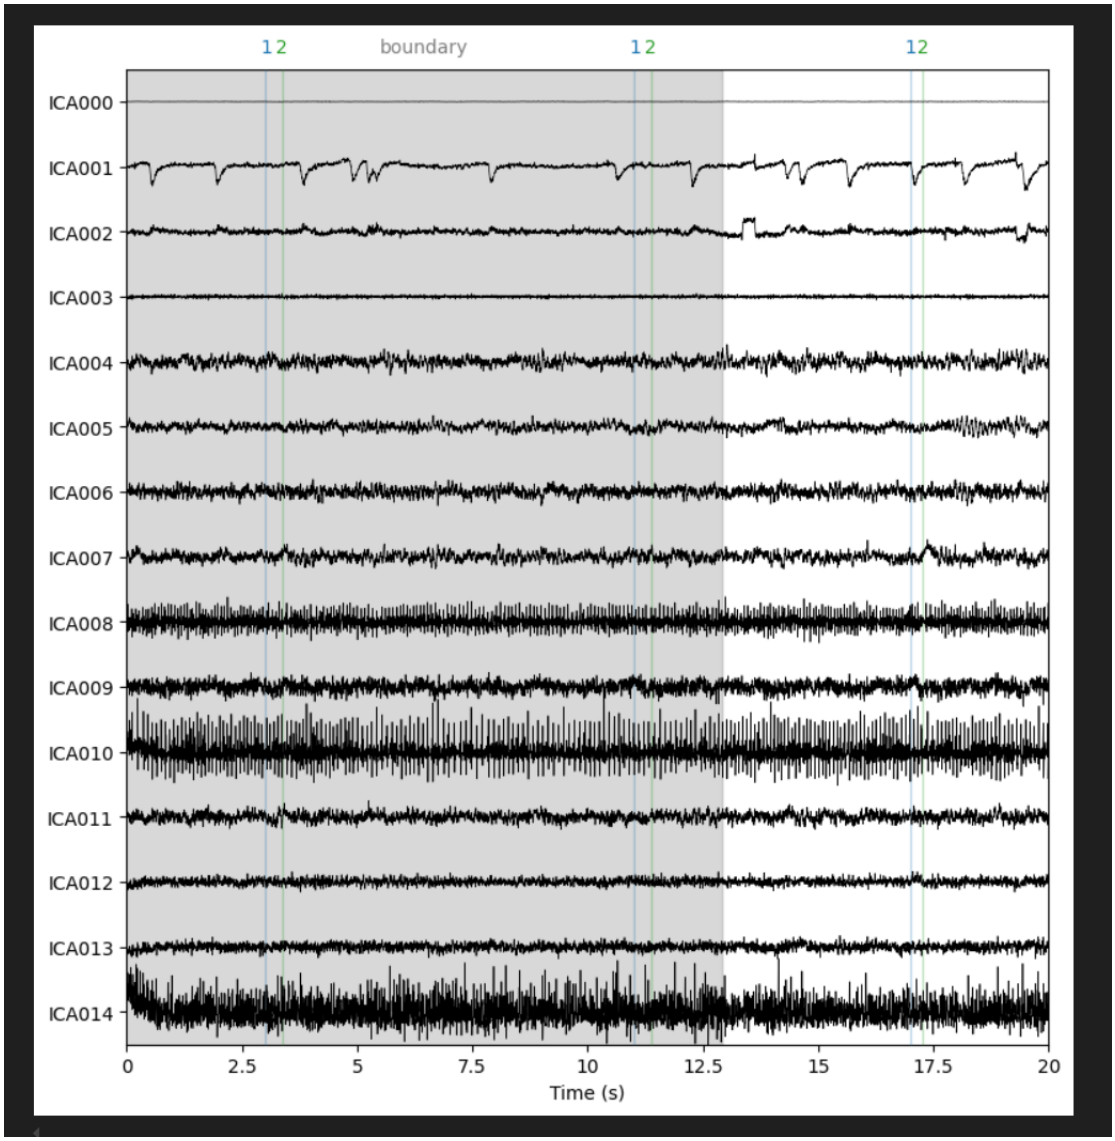
1 2
boundary
1 2
1 2
ICA000
ICA001
ICA002
ICA003
ICA004
ICA005
ICA006
ICA007
ICA008
ICA009
ICA010
ICA011
ICA012
ICA013
ICA014
0
2.5
5
7.5
10
12.5
15
17.5
20
Time (s)

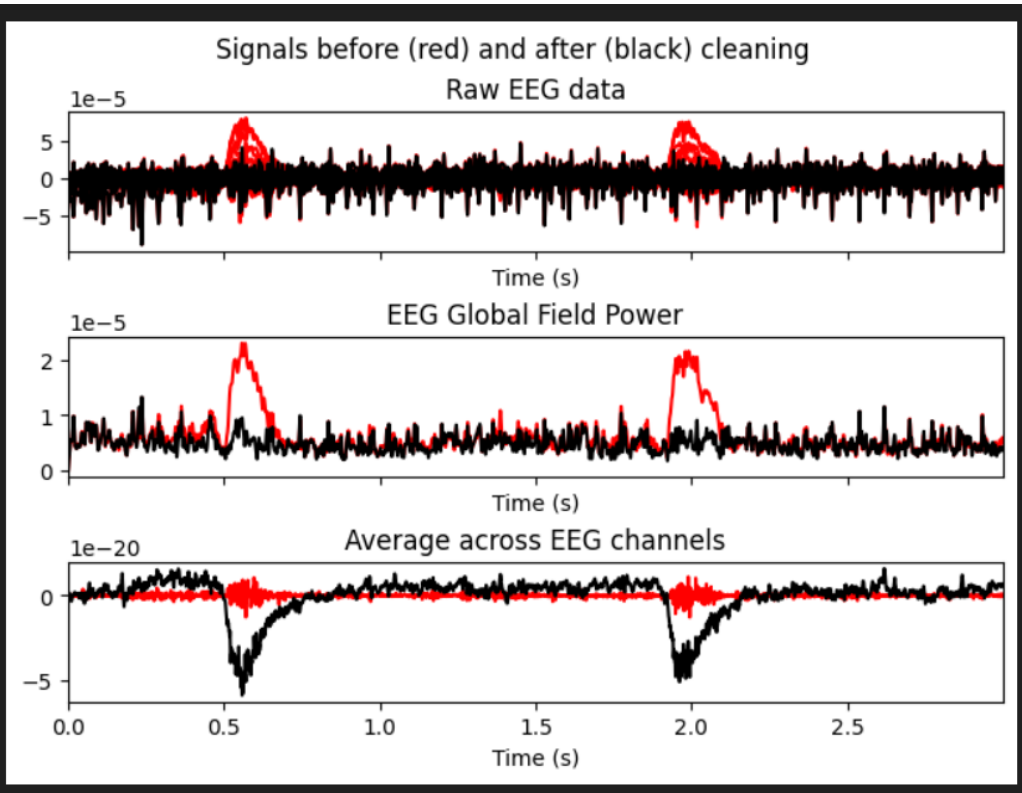
Signals before (red) and after (black) cleaning
Raw EEG data
1e−5
5
0
−5
Time (s)
EEG Global Field Power
1e−5
2
1
0
Time (s)
Average across EEG channels
1e−20
0
−5
0.0
0.5
1.0
1.5
2.0
2.5
Time (s)

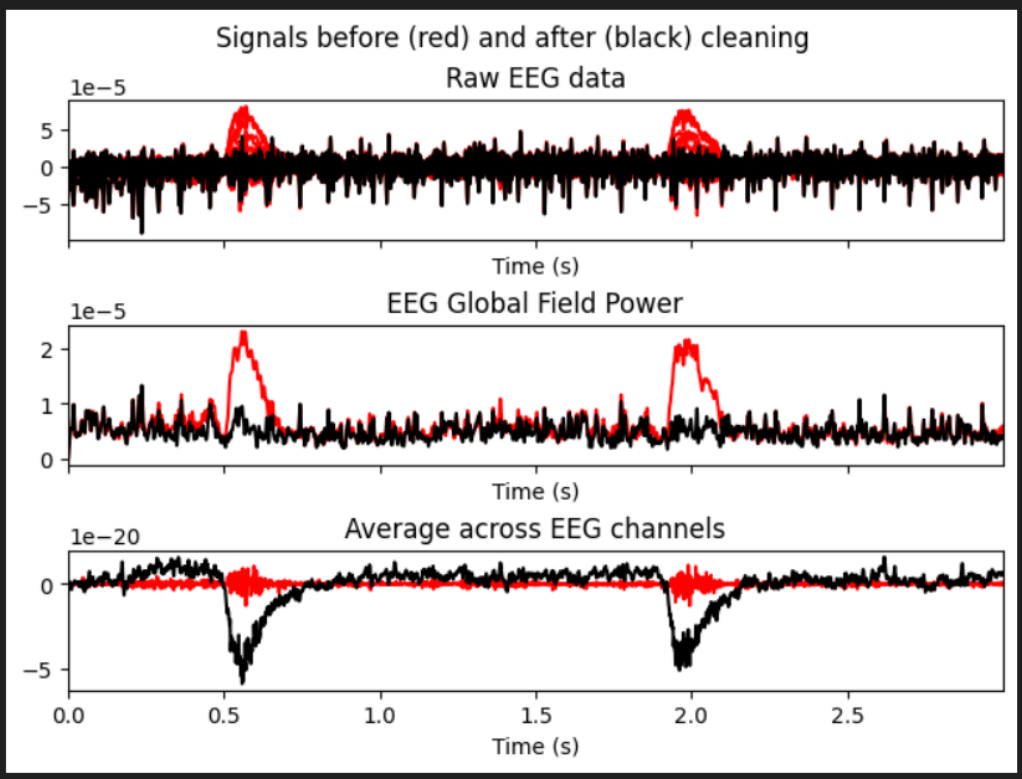
Signals before (red) and after (black) cleaning
Raw EEG data
1e−5
5
0
−5
Time (s)
EEG Global Field Power
1e−5
2
1
0
Time (s)
Average across EEG channels
1e−20
0
−5
0.0
0.5
1.0
1.5
2.0
2.5
Time (s)

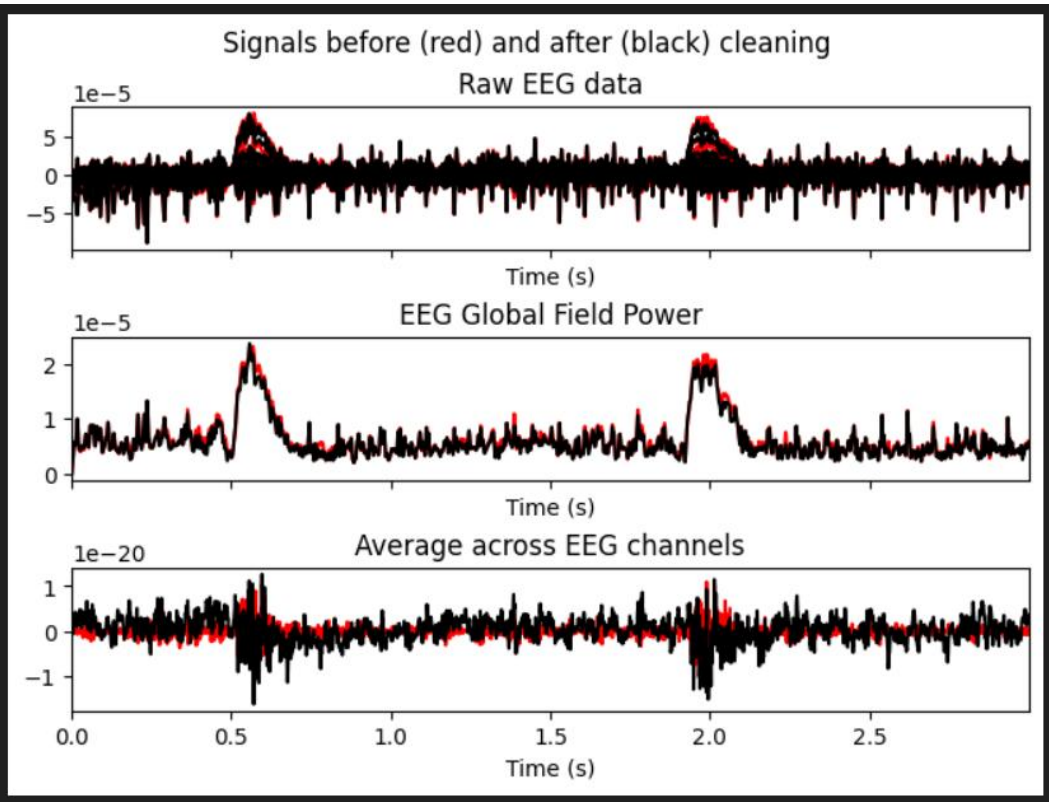
Signals before (red) and after (black) cleaning
Raw EEG data
1e−5
5
0
−5
Time (s)
EEG Global Field Power
1e−5
2
1
0
Time (s)
Average across EEG channels
1e−20
1
0
−1
0.0
0.5
1.0
1.5
2.0
2.5
Time (s)

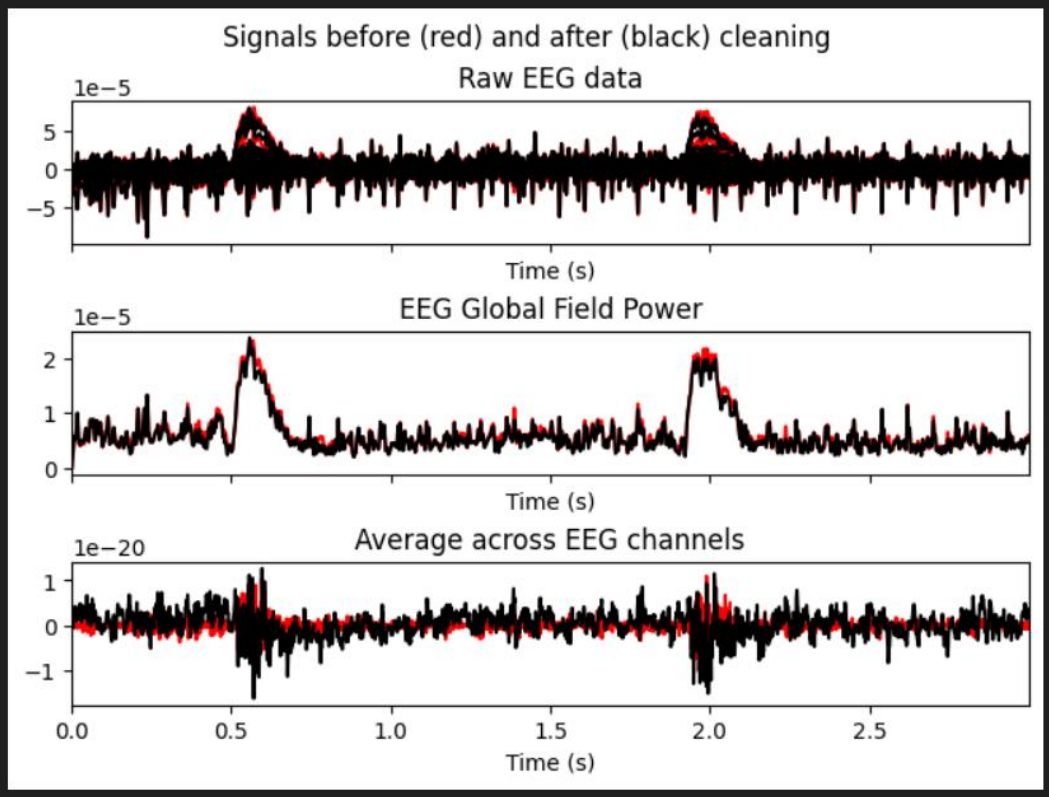
Signals before (red) and after (black) cleaning
Raw EEG data
1e−5
5
0
−5
Time (s)
EEG Global Field Power
1e−5
2
1
0
Time (s)
Average across EEG channels
1e−20
1
0
−1
0.0
0.5
1.0
1.5
2.0
2.5
Time (s)

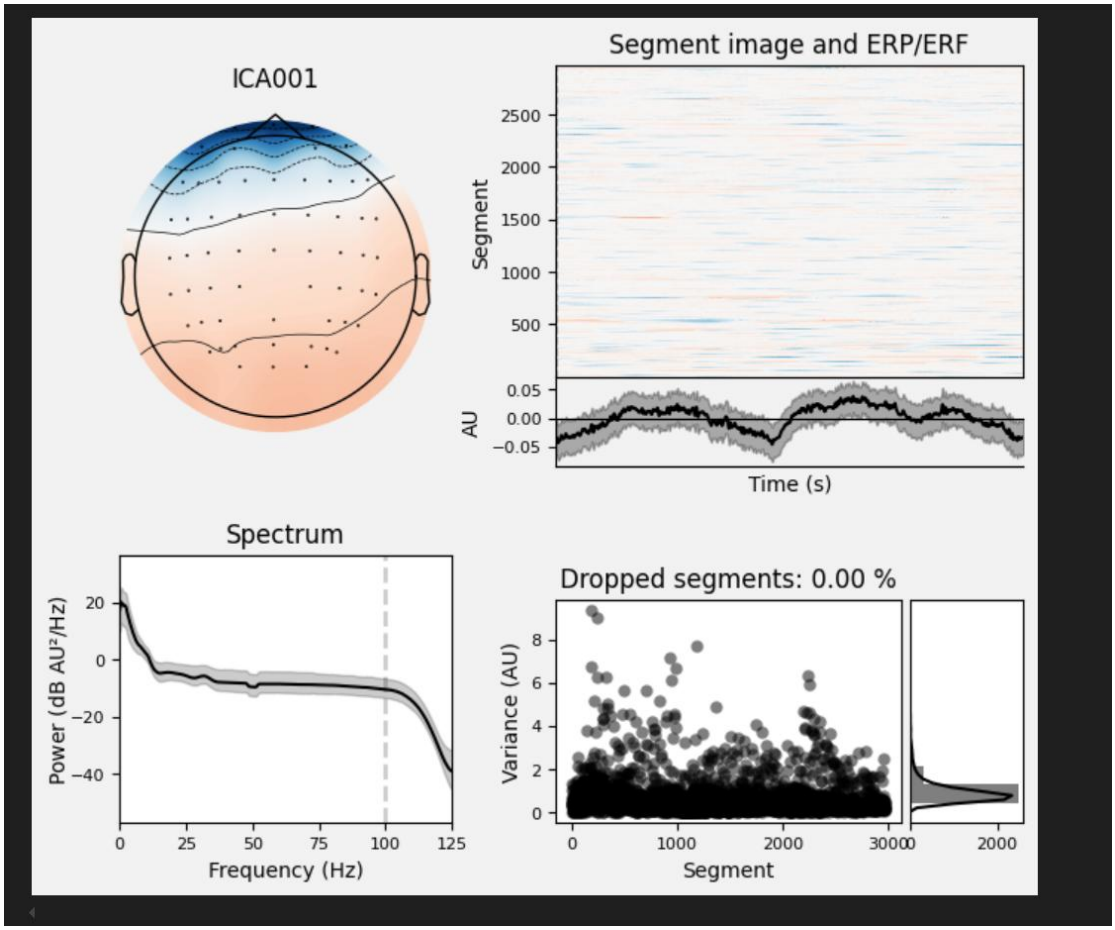
ICA001
Segment image and ERP/ERF
Segment
2500
2000
1500
1000
500
AU
0.05
0.00
−0.05
Time (s)
Spectrum
Power (dB AU²/Hz)
20
0
−20
−40
0
25
50
75
100
125
Frequency (Hz)
Dropped segments: 0.00 %
Variance (AU)
8
6
4
2
0
0
1000
2000
3000
0
2000
Segment

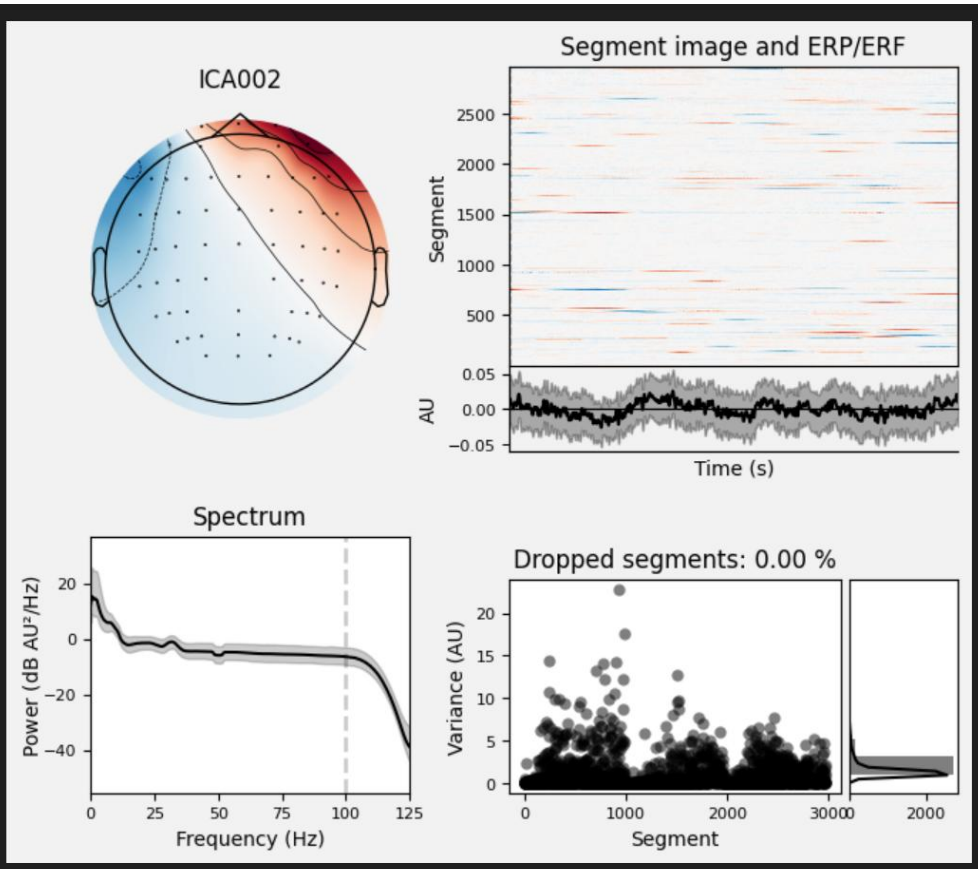


```python
# TODO 参考：https://mne.tools/mne-icalabel/stable/generated/examples/00_iclabel.html#sphx-glr-generated-examples-00-iclabel-py
# https://blog.csdn.net/qq_44930039/article/details/127734713


ic_labels = label_components(raw, ica, method="iclabel")

# classified as a muscle artifact.
print(ic_labels["labels"])
# ica.plot_properties(raw, picks=[0, 12], verbose=False)

# 我们可以提取每个组件的标签，并排除非脑部分类的组件，保留“脑部”和“其他”。
# “其他”是一个总称，用于非分类组件。我们将保持谨慎，假设我们不能盲目地移除这些。
labels = ic_labels["labels"]
exclude_idx = [
    idx for idx, label in enumerate(labels) if label not in ["brain", "other"]
]
print(f"Excluding these ICA components: {exclude_idx}")
```

[30]

```
['other', 'eye blink', 'eye blink', 'channel noise', 'brain', 'brain', 'brain', 'brain', 'brain', 'other', 'muscle artifact', 'brain', 'brain', 'brain', 'brain']
Excluding these ICA components: [1, 2, 3, 10]
```

```python
# TODO apply应用到原始数据上，并exclude不是脑成分的下标成分
filter_data = raw.copy()
ica.apply(filter_data, exclude=exclude_idx)
```

[31]

```
Applying ICA to Raw instance
    Transforming to ICA space (15 components)
    Zeroing out 4 ICA components
    Projecting back using 59 PCA components
```

General

Filename(s)	subject_02.set
MNE object type	RawEEGLAB
Measurement date	Unknown
Participant	Unknown
Experimenter	Unknown

Acquisition

Duration	01:39:00 (HH:MM:SS)
Sampling frequency	1000.00 Hz
Time points	5,940,000

Channels

EEG	59
Head & sensor digitization	62 points

Filters

Highpass	1.00 Hz
Lowpass	100.00 Hz

```python
# TODO 使用resample函数进行降采样，降采样到250hz
data = filter_data.resample(250)
```

[32]

```python
# TODO 预处理后的数据展示,start从130开始
fig = data.plot(start=130)
```

[33]

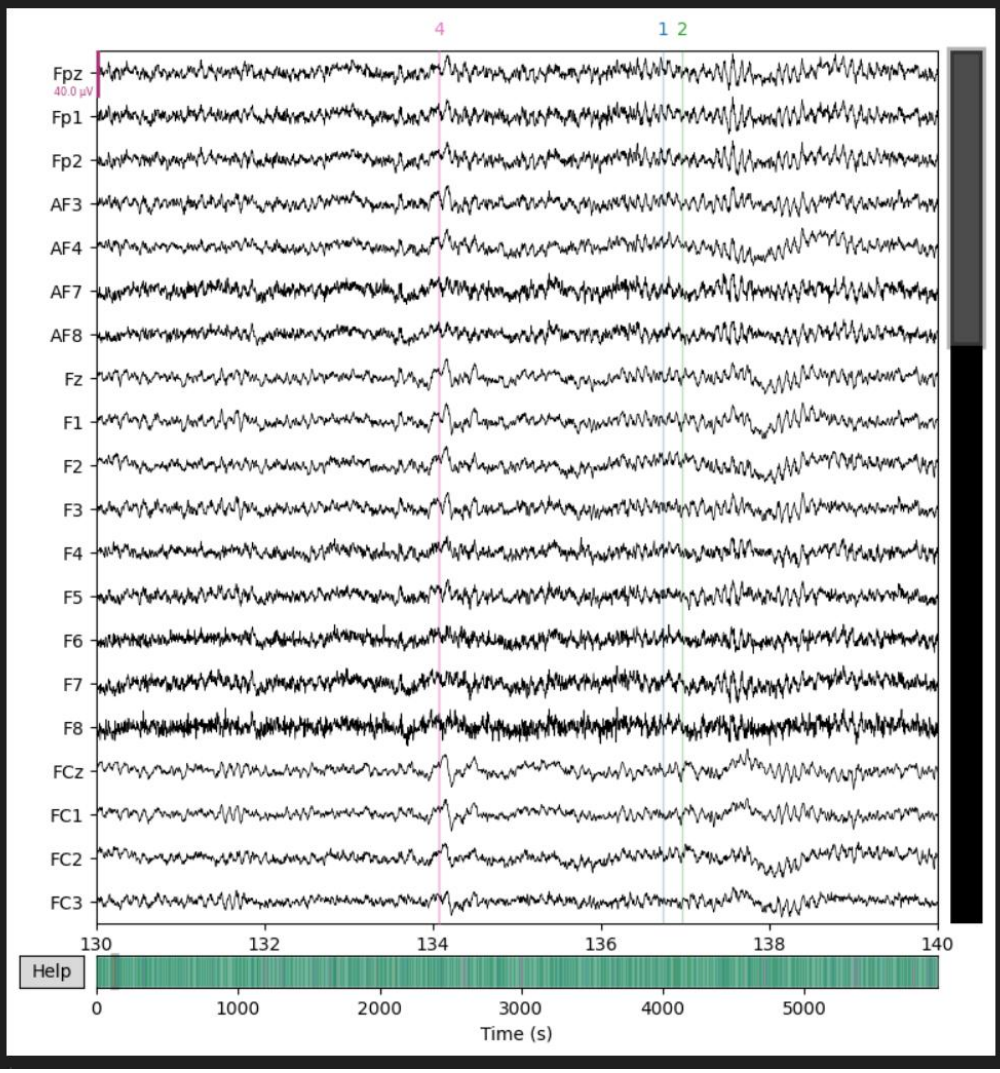

```python
bands = {'Delta (1-4 Hz)': (1, 4), 'Theta (4-8 Hz)': (4, 8),
         'Alpha (8-12 Hz)': (8, 12), 'Beta (12-30 Hz)': (12, 30),
         'Gamma (30-50 Hz)': (30, 50)}


# TODO 计算各频段的功率谱密度，取fmin=1, fmax=50
psd = epochs.compute_psd(fmin=1, fmax=50)



print("Power spectral density:", psd)
psd.plot_topomap(bands=bands, normalize=True)
```

[36]

```
Using multitaper spectrum estimation with 7 DPSS windows
Power spectral density: <Power Spectrum (from Epochs, multitaper method) | 990 epochs x 59 channels x 123 freqs, 1.2-49.9 Hz>
Averaging across epochs before plotting...
```

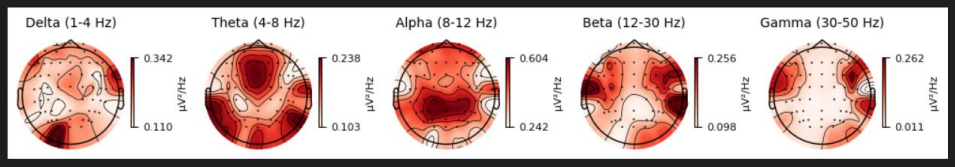

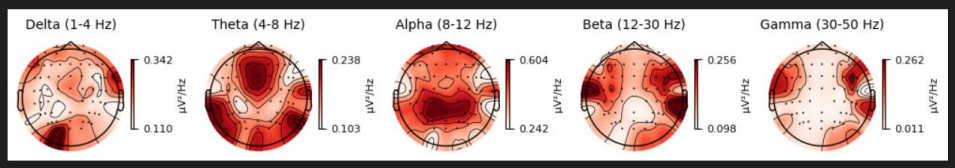


```python
# TODO 计算平均plv
for epoch in epochs:
    plv_matrix += calculate_plv(epoch)
plv_matrix /= len(epochs)
```

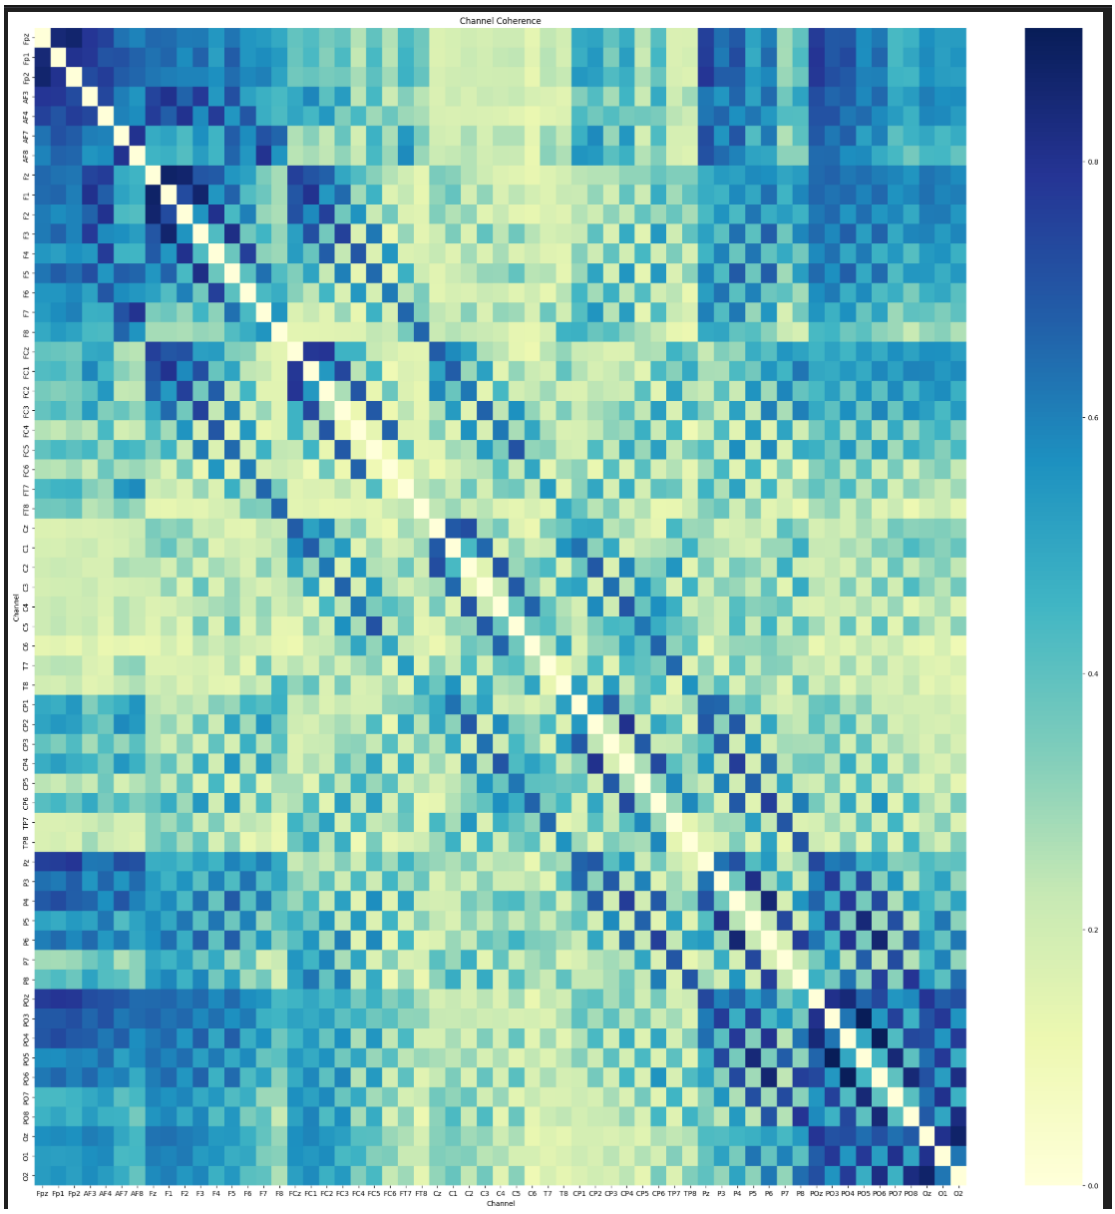

概念解释:

功率谱：功率谱是描述信号在不同频率上的能量分布的工具。它反映了信号在各个频率上的功率大小，通常通过傅里叶变换将信号从时域转换到频域来获得。功率谱能够帮助我们了解信号的主要频率成分及其能量贡献，例如在脑电数据中，通过功率谱可以观察到不同脑区在不同频率段（如 δ 波、θ 波、α 波、β 波）的活动强度。功率谱的单位通常是“功率”，例如微伏平方（μV^2）。

功率谱密度：功率谱密度（Power Spectral Density，PSD）是功率谱的归一化形式，它表示单位频率范围内的功率分布。与功率谱相比，功率谱密度能够更准确地描述信号在不同频率上的能量分布，尤其是在频率分辨率较高的情况下。PSD 的单位通常是“功率/频率”，例如微伏平方每赫兹（$\mu V^2/Hz$）。通过计算功率谱密度，可以更好地比较不同信号或不同频率段的能量分布，同时也有助于消除信号长度等因素对结果的影响。

PLV：相位锁定值（PLV）是一种用于衡量两个信号之间相位同步性的指标。它可以帮助我们了解信号在不同时间点上的相位一致性，从而揭示信号之间的耦合关系。PLV 的计算基于信号的相位信息，而不是幅值信息，因此它对噪声和幅值变化具有一定的鲁棒性。在脑电（EEG）研究中，PLV 常用于分析不同脑区之间的同步活动。例如，通过计算两个电极通道之间的 PLV，可以判断它们是否在某个特定频率下表现出相位同步。这种同步性可能与大脑的功能连接、认知过程或神经网络的活动有关。PLV 的值范围在 0 到 1 之间，其中 0 表示完全无相位锁定，1 表示完全相位锁定。

Epoch：在脑电数据处理中，epoch（时间窗）是一个重要的概念，它指的是将连续的脑电数据分割成多个固定长度的时间段，用于后续的分析和处理。具体来说，epoch 的划分是基于特定的时间间隔，例如在本实验中，我们将连续的脑电数据分割为每个长度为 1 秒的时间窗，相邻时间窗之间有 0.5 秒的重叠。这种分割方式使得我们可以对每个 epoch 内的脑电活动进行独立分析，从而更细致地观察和研究脑电特征在不同时间点上的变化规律。此外，epoch 的划分也有助于减少噪声的影响，并提高数据分析的统计可靠性。

annotation（标注） 是指对脑电数据中的特定事件或特征进行标记和注释的过程。这些标注通常用于指示数据中的重要信息，例如实验中的特定刺激时刻、被试的行为反应、或者脑电数据中出现的伪迹（如眼动、肌电干扰等）。

参考：

https://mne.tools/stable/index.html

https://mne.tools/stable/auto_tutorials/preprocessing/40_artifact_correction_ica.html#what-is-ica

https://mne.tools/mne-icalabel/stable/index.html

https://blog.csdn.net/qq_44930039/article/details/127734713