

人工智能数学基础：矩阵分析 + 最优化思维导图

蓝色：矩阵分析

紫色：最优化

黄色：本年度新增/强化

浅蓝：AI应用联系

算法模块：输入—步骤—输出

人工智能数学基础

课程引入

人工智能、机器学习、深度学习

- 任务类型：分类/回归；学习范式：有监督/半监督/无监督
- 典型模型：线性回归（LR）、神经网络（NN/感知机网络）、DNN/CNN
- Transformer/注意力机制：Query、Key、Value 与相似度得分
- 相关概念：训练/验证/测试、损失函数/目标函数、过拟合、正则化、最优化

矩阵分析

机器学习常用量

- 标量、向量、矩阵、张量、范数
- 向量：定义、模、方向角/方向余弦、投影、点乘、外积；外积结果常形成秩1矩阵
 - AI应用：词向量、文档向量、特征向量、支持向量机、余弦相似度
 - 注意力机制：Query · Key 给出相似度；批量形式为 QK^T
- 矩阵：线性方程组；特殊矩阵（方阵、三角矩阵、对角矩阵、数量矩阵、单位矩阵）；同型矩阵、相等矩阵
 - AI应用：全连接层 $Wx + b$ 、线性回归、PCA协方差计算、矩阵化卷积
- 张量：高维数组，图像/视频/深度学习 batch 的统一表示
- 向量范数： $\|x\|_0, \|x\|_1, \|x\|_2, \|x\|_\infty$ ； L_p 单位球几何直觉
 - L_1 倾向稀疏， L_2 抑制过拟合；范数常作为损失、距离和正则化项
- 矩阵范数：Frobenius范数、谱范数、核范数
 - $\|A\|_2 = \sigma_{\max}(A)$ ； $\|A\|_* = \sum_i \sigma_i$ ； $\|A\|_F = (\sum_i \sigma_i^2)^{1/2}$
 - AI应用：推荐系统矩阵分解误差、GAN谱归一化、低秩模型复杂度控制

矩阵运算

- 矩阵加减、数乘、矩阵乘法、矩阵转置、矩阵求逆、伴随矩阵
- 矩阵的迹： $\text{tr}(A) = \sum_i a_{ii}$
- Hadamard积： $A \circ B = (a_{ij}b_{ij})$ ，用于掩码、门控、注意力权重
- Kronecker积： $A \otimes B$ 构造块矩阵，用于张量化模型和结构化特征表示
- 矩阵求逆方法补充：LU、Cholesky、迭代法、Moore—Penrose伪逆

线性相关与线性无关

- 定义、极大线性无关组、向量组的秩、向量组等价、线性表示
- 求秩和极大无关组：按列构矩阵 → 初等行变换 → 读主元列和线性关系；矩阵的秩等于行秩也等于列秩

- 四个基本子空间：列空间 $\mathcal{C}(A)$ 、行空间 $\mathcal{C}(A^T)$ 、零空间 $\mathcal{N}(A)$ 、左零空间 $\mathcal{N}(A^T)$
- 维数定理： $\text{rank}(A) + \text{nullity}(A) = n$
- PCA与线性子空间：寻找协方差矩阵中方差最大的低维子空间

算法模块 | PCA主成分分析

矩阵分析PPT第150页

- | | |
|-----------|--|
| 输入 | • 数据矩阵 $X \in \mathbb{R}^{n \times d}$ ，目标维数 k |
| 步骤 | <ol style="list-style-type: none"> 1. 中心化：$X_c = X - \mathbf{1}\mu^T$; 2. 协方差矩阵：$\Sigma = X_c^T X_c / n$; 3. 特征分解：$\Sigma = Q\Lambda Q^T$，按特征值从大到小排序； 4. 取前 k 个特征向量 Q_k，得到 $X_{\text{low}} = X_c Q_k$; 5. 需要重建时：$X_{\text{recon}} \approx X_{\text{low}} Q_k^T + \mathbf{1}\mu^T$。 |
| 输出 | • 低维表示 X_{low} ；主成分方向 Q_k ；可选重建 X_{recon} |
| 说明 | • 含义：保留主成分方向，丢弃噪声方向； k 是保留维数/有效秩。 |

• 矩阵的秩

- k 阶子式、矩阵秩、满秩矩阵、降秩矩阵、初等变换求秩
- 性质： $R(A) = R(A^T)$ ；初等变换不改变秩； $R(AB) \leq \min\{R(A), R(B)\}$
- 矩阵低秩近似与Eckart–Young定理：截断SVD给出最优低秩近似
- 矩阵填充与推荐系统：根据已知评分预测缺失评分；常假设评分矩阵低秩
- 核范数： $\|A\|_*$ 是秩函数 $\text{rank}(A)$ 的常用凸松弛

• 矩阵的特征值与谱定理

- 向量内积、正交向量组、标准正交基、Schmidt正交化、正交矩阵
- 特征值与特征向量： $Ax = \lambda x$ ；特征方程 $|\lambda E - A| = 0$
- 相似矩阵：特征值相同； A 可对角化当且仅当有 n 个线性无关特征向量
- 实对称矩阵：特征值为实数；不同特征值对应特征向量正交；可正交对角化
- 谱定理：实对称矩阵可写为 $A = Q\Lambda Q^T$
- 谱半径： $\rho(A) = \max_i |\lambda_i|$ ；迭代 $x_{k+1} = Bx_k + c$ 的收敛与 $\rho(B)$ 相关

• 矩阵分解

- LU分解： $A = LU$ ，其中 L 为下三角矩阵， U 为上三角矩阵
- 满秩分解： $A = BC$ ， B 列满秩， C 行满秩；分解不唯一

算法模块 | 满秩分解 (Hermite标准形法)

矩阵分析PPT第223—228页

- 输入**
- 非零矩阵 A , 秩 $r = R(A)$
- 步骤**
1. 对 A 作初等行变换, 得到 Hermite 标准形 H ;
 2. 在 H 中确定 r 个主元列, 对应到原矩阵 A 中取这 r 列组成 B ;
 3. 取 H 的前 r 个非零行组成 C ;
 4. 得到满秩分解 $A = BC$, 其中 B 列满秩、 C 行满秩。
- 输出**
- $A = BC$; B 为列满秩矩阵, C 为行满秩矩阵
- 说明**
- 本模块按课件第228页流程表述; 课堂手算时重点是先求秩和主元列, 再写出分解。

- QR分解: $A = QR$, Q 为正交/酉矩阵, R 为上三角矩阵

算法模块 | QR分解 (Schmidt正交化, 练习常用流程)

矩阵分析PPT第234—242页; 课堂计算流程

- 输入**
- 矩阵 $A = [a_1, a_2, \dots, a_n]$; 手算示例通常从列满秩 A 入手, 若要求 R 对角元为正需统一符号
- 步骤**
1. 按列作Schmidt正交化: $u_1 = a_1, u_i = a_i - \sum_{j=1}^{i-1} (q_j^T a_i) q_j$;
 2. 单位化: $q_i = u_i / \|u_i\|_2$, 组成 $Q = [q_1, q_2, \dots, q_n]$;
 3. 由 $R = Q^T A$ 计算上三角矩阵, 等价于 $r_{ij} = q_i^T a_j$ ($i \leq j$)、 $r_{ij} = 0$ ($i > j$);
 4. 若题目要求 R 对角元为正, 必要时同时改变 Q 的列符号和 R 的对应行符号;
 5. 核对: $Q^T Q = I$, R 为上三角, $A = QR$ 。
- 输出**
- 正交/酉矩阵 Q ; 上三角矩阵 R
- 说明**
- 最小二乘应用中常写为: $\min \|Ax - b\|_2 = \min \|QRx - b\|_2$, 因 Q 正交, 转化为上三角方程 $Rx = Q^T b$ 的回代求解。

- SVD分解: $A = U\Sigma V^T$, 奇异值 $\sigma_i = \sqrt{\lambda_i}$, λ_i 来自 $A^T A$ 或 AA^T

算法模块 | SVD奇异值分解 (练习常用计算流程)

矩阵分析PPT第252页、第255页; 课堂计算流程

- 输入**
- 任意 $m \times n$ 矩阵 A
- 步骤**
1. 共同第一步: 求 AA^T 或 $A^T A$ 的非零特征值 λ_i , 令 $\sigma_i = \sqrt{\lambda_i}$, 排成 Σ ;
 2. 方法一 (课件第252页): 先由 AA^T 的单位正交特征向量确定 $U = [U_1, U_2]$, 再令 $V_1 = A^T U_1 \Delta^{-1}$, 补齐 V_2 , 得 $V = [V_1, V_2]$;
 3. 方法一等价路线: 也可先由 $A^T A$ 得 $V = [V_1, V_2]$, 再令 $U_1 = AV_1 \Delta^{-1}$, 补齐 U_2 ;
 4. 方法二 (课件第255页): 分别求 AA^T 和 $A^T A$ 的单位正交特征向量, 直接组成 U 与 V ;
 5. 最后核对: $A = U\Sigma V^T$ (复数情形写 $A = U\Sigma V^H$)。
- 输出**
- U 、 Σ 、 V ; 或按题目只给出奇异值/最大奇异向量
- 说明**
- 课堂要点: 奇异值来自 $A^T A$ 或 AA^T 特征值的平方根, 奇异值非负; 课堂计算若只需奇异值, 不必完整求出 U, V 。

• 最优化

• 最优化问题概述

- 优化定义: 目标函数 + 约束条件; 实例包括食谱问题、资金使用问题
- 问题分类: 无约束/有约束, 连续/离散, 线性/非线性, 凸/非凸
- AI中的优化: 用目标函数表达训练误差、正则化和约束, 再通过算法寻找参数

• 最优化数学基础

- 方向导数：梯度向量与方向余弦的点乘
- 梯度： $\nabla f(x)$ 由偏导数组成，指向函数局部上升最快方向
- Hessian矩阵： $\nabla^2 f(x)$ 描述局部曲率；深度学习中对应损失曲面弯曲程度

• 凸集、凸函数与凸优化

- 凸集：任意两点连线仍在集合内； $\alpha x_1 + (1 - \alpha)x_2 \in S, \alpha \in [0, 1]$
- 凸函数：函数图像上任意两点连线在曲线弧上方
- 凸函数一阶条件： $f(y) \geq f(x) + \nabla f(x)^T(y - x)$
- 凸函数二阶条件： $\nabla^2 f(x) \succeq 0$
- 凸优化：凸约束集 + 凸目标函数；局部极小点即全局极小点
- AI应用：线性回归、逻辑回归、SVM等可形成凸优化问题或凸优化子问题

• 标准形式和对偶形式

- 线性规划对偶：从资源约束的“原问题”转为资源定价的“对偶问题”

算法模块 | 线性规划对偶构造

最优化PPT第55-79页

输入

- 原问题写成统一 max 形式，例如 $\max c^T x, Ax \leq b, x \geq 0$

步骤

1. 标准 max 型： $\max c^T x, Ax \leq b, x \geq 0$ ；
2. 对应对偶： $\min b^T y, A^T y \geq c, y \geq 0$ ；
3. 若原约束为“ $\geq$ ”，对应对偶变量 $y_i \leq 0$ ；若为“ $=$ ”，对应 y_i 自由；
4. 若原变量 $x_j \geq 0$ ，对应对偶约束“ $\geq$ ”；若 $x_j \leq 0$ ，对应“ $\leq$ ”；若 x_j 自由，对应“ $=$ ”；
5. 用弱对偶检查方向： $\max$ 原问题任一可行值 $\leq \min$ 对偶任一可行值。

输出

- 对偶目标函数、对偶约束、对偶变量符号限制

说明

- 影子价格解释：对偶变量表示资源边际价值；SVM对偶中样本以内积出现，便于核函数化。

- 弱对偶：任一对偶可行目标值给出原问题目标值的界
- 强对偶：在线性规划适当条件下，原问题最优值等于对偶问题最优值
- SVM对偶：样本以内积 $x_i^T x_j$ 形式出现，便于引入核函数 $K(x_i, x_j)$

• 连续优化

- 最小二乘法 (LSP)：用二范数衡量预测值与真实值偏差
- 线性回归正规方程： $X^T X w = X^T y$ ；大规模或病态时转向迭代优化
- 一阶优化算法
 - 梯度下降法：沿负梯度方向下降；关键是搜索方向与步长

算法模块 | 最速梯度下降/梯度下降法

最优化PPT第97—108页；课堂计算流程

输入	可微目标函数 $f(x)$，初始点 x_0，停止阈值 ε
步骤	- 计算梯度：$g_k = \nabla f(x_k)$；若 $\ g_k\ \leq \varepsilon$，则停止； - 搜索方向：$d_k = -g_k$； - 若为最速下降，精确线搜索：$\lambda_k = \arg \min_{\lambda \geq 0} f(x_k + \lambda d_k)$；若题目给学习率 η，直接用 $x_{k+1} = x_k - \eta \nabla f(x_k)$； - 更新：$x_{k+1} = x_k + \lambda_k d_k$（精确线搜索）或 $x_{k+1} = x_k - \eta \nabla f(x_k)$（固定学习率题）； - 重复以上步骤，直到满足停止条件。
输出	迭代点 x_{k+1}；若继续迭代，最终得到近似极小点 x^*
说明	课件例题常要求迭代若干步后用一阶/二阶必要条件判别极小性；精确线搜索下 $g_{k+1}^\top g_k = 0$，可能出现锯齿现象。

- SGD：每轮用随机样本或小批量样本近似梯度，加快大数据训练
- Mini-batch：深度学习反向传播常用折中；batch_size决定每批样本数
- 学习率策略：AdaGrad、RMSProp、Adam/AdamW、动量、衰减、warmup、分层学习率
- 共轭梯度法：构造 A 共轭方向，二次正定问题最多 n 步精确求解

算法模块 | FR共轭梯度法（二次函数情形）

最优化PPT第109—128页；课堂计算流程

输入	正定二次函数 $f(x) = \frac{1}{2}x^\top Ax - b^\top x + c$，其中 $A \succ 0$；初始点 x_0
步骤	- 初始化：$g_0 = Ax_0 - b$，$d_0 = -g_0$； - 若 $\ g_k\ \leq \varepsilon$，则停止； - 搜索步长：$\lambda_k = -\frac{d_k^\top g_k}{d_k^\top A d_k}$； - 更新点：$x_{k+1} = x_k + \lambda_k d_k$； - 新梯度：$g_{k+1} = Ax_{k+1} - b$； - FR系数：$\beta_k = \frac{\ g_{k+1}\ _2^2}{\ g_k\ _2^2}$； - 新方向：$d_{k+1} = -g_{k+1} + \beta_k d_k$；继续迭代。
输出	二次正定问题的极小点；理论上精确算术下最多 n 步得到精确解
说明	共轭条件：$d_i^\top A d_j = 0$ ($i \neq j$)。非二次函数中通常配合线搜索与重启策略。

- 二阶优化算法
 - 牛顿法：用二阶Taylor展开构造局部二次模型

算法模块 | 牛顿法

最优化PPT第130—135页；课堂计算流程

输入	• 二阶可微函数 $f(x)$ ，初始点 x_0 ，停止阈值 ε
步骤	1. 计算梯度 $g_k = \nabla f(x_k)$ 与 Hessian $H_k = \nabla^2 f(x_k)$； 2. 若 $\ g_k\ \leq \varepsilon$，则停止； 3. 求解线性方程 $H_k d_k = -g_k$，等价于 $d_k = -H_k^{-1} g_k$（常用等价写法）； 4. 可取 $\alpha_k = 1$，或通过线搜索确定 α_k； 5. 更新：$x_{k+1} = x_k + \alpha_k d_k$。
输出	• 近似极小点 x^*
说明	• 优势：局部收敛快；限制：需计算/存储/求解Hessian，Hessian病态或非正定时方向可能不可靠。

- 拟牛顿法：不用显式二阶导数，用梯度变化近似 Hessian 或其逆

算法模块 | 拟牛顿法：DFP/BFGS/L-BFGS

最优化PPT第136—148页；课堂计算流程

输入	• 可微无约束问题 $\min f(x)$ ，初始点 x^0 ，初始逆Hessian近似 H_0 （常取 I ）
步骤	1. 计算 $g^k = \nabla f(x^k)$，取搜索方向 $d^k = -H_k g^k$； 2. 由一维搜索确定步长 λ_k，更新 $x^{k+1} = x^k + \lambda_k d^k$； 3. 按课件记号令 $p^k = x^{k+1} - x^k$，$q^k = g^{k+1} - g^k$； 4. 拟Newton条件：$H_{k+1} q^k = p^k$，表示新的逆Hessian近似应匹配本步梯度变化； 5. DFP/BFGS用秩二修正更新 H_{k+1}；L-BFGS只保存最近若干组 (p^k, q^k) 以适应大规模问题。
输出	• 近似极小点；逐步改进的逆Hessian近似矩阵 H_k
说明	• DFP逆矩阵修正常写为 $H_{k+1} = H_k + \frac{p^k (p^k)^\top}{(p^k)^\top q^k} - \frac{H_k q^k (q^k)^\top H_k}{(q^k)^\top H_k q^k}$；BFGS是DFP的对偶方法。 • 方法定位：拟牛顿法避免直接计算Hessian，用迭代矩阵近似Hessian或其逆；Hessian非正定时牛顿方向可能不可靠。

• 本图不纳入范围

- 按本次要求，最优化课件中的图论与离散优化部分不归纳在本思维导图内。