

人工智能数学基础

矩阵分析

刘志磊

天津大学
人工智能学院

Email: zhileiliu@tju.edu.cn



人工智能学院
School of Artificial Intelligence

课程背景



参考: <https://paperswithcode.com/methods/category/convolutional-neural-networks>



课程背景

- 人工智能

- 机器学习

- 深度学习

- 数学基础

- **Linear Algebra.**
 - **Vector Calculus.**
 - **Matrix Decomposition.**
 - Probability and Distributions.
 - Analytic Geometry.

“Two of the pillars of machine learning are **matrix algebra** and **optimization**. Matrix algebra involves the matrix-vector representation and modeling of currently available data, and optimization involves the numerical computation of parameters for a system designed to make decisions on yet unseen data.

机器学习的两个支柱是**矩阵代数**和**最优化**。矩阵代数涉及矩阵向量表示和当前可用数据的建模，而最优化旨在对看不见数据做出决策的系统的参数进行计算。” (Zhang, p. 222)

参考: <https://paperswithcode.com/methods/category/convolutional-neural-networks>



矩阵分析

• 1. 基础回顾与扩展

- 机器学习常用量：向量、矩阵、张量、范数
- 矩阵运算：矩阵的加减乘运算、转置、求逆运算及伴随矩阵
- 矩阵的迹 (trace)、Hadamard积、Kronecker积

• 2. 线性空间与子空间

- 极大线性无关组、向量组的秩及其求解方法
- 列空间、行空间、零空间及维数定理

• 3. 矩阵的秩



- 初等变换求矩阵的秩、矩阵秩的性质
- 矩阵近似与低秩逼近
- 矩阵填充的秩条件

• 4. 矩阵的特征值与谱定理

- 向量的内积和正交化、矩阵的特征值与特征向量、相似矩阵、实对称矩阵的对角化
- 谱定理、矩阵的谱半径与收敛性

• 5. 矩阵分解

- LU分解、满秩分解、QR分解、奇异值(SVD)分解等



参考教材：

- [1] 《机器学习数学基础》电子工业出版社，齐伟 [编著]
- [2] 《矩阵分析》(第2版) [美] Roger A. Horn [著] 张明尧 [译]
- [3] <A Matrix Algebra Approach to Artificial Intelligence> Xian-Da Zhang

1. 机器学习常用量

- 1.0 标量 (scalar)

- 1.1 向量 (Vector)

- 1.2 矩阵 (Matrix)

- 1.3 张量 (Tensor)

- 1.4 范数 (Norm)

Scalar Vector Matrix Tensor

1 $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$ $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ $\begin{bmatrix} 1 & 2 \\ 1 & 7 \end{bmatrix} \begin{bmatrix} 3 & 2 \\ 5 & 4 \end{bmatrix}$

$$\left. \begin{aligned} a_{11}x_1 + \cdots + a_{1n}x_n &= b_1 \\ &\vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n &= b_m \end{aligned} \right\} \mathbf{Ax} = \mathbf{b}$$

$$\mathbf{A} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix} \in \mathbb{R}^m$$

参考资料:

[1] [Linear Algebra for Deep Learning](#)



1. 机器学习常用量

• 1.1 向量 (Vector)

- 定义：一个由n个数组组成的元组（通常为实数）
 - n为向量的维度
 - n为正实数，取值范围 $[1, +\infty]$
- 写法：能被写成一行或一列
 - 列是标准写法
 - 写成行的形式一般要加转置符号
 - 粗体小写字母 **a, b, x** （默认列向量，形状 $n \times 1$ ）

$$\mathbf{a} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \quad \mathbf{a}^T = (x_1 \dots x_n) \quad \mathbf{a} \in \mathbb{R}^{n \times 1}$$

MXNET

PYTORCH

TENSORFLOW


```
x = torch.arange(4)
x
```

```
tensor([0, 1, 2, 3])
```



1. 机器学习常用量

• 1.1 向量 (Vector)



There are three different types of vector in science and engineering [18]:

基础内涵

- **Physical vector**: Its elements are physical quantities with magnitude and direction, such as a displacement vector, a velocity vector, an acceleration vector, and so forth.

直观呈现

- **Geometric vector**: A directed line segment or arrow can visualize a physical vector. Such a representation is known as a geometric vector. For example, $\mathbf{v} = \overrightarrow{AB}$ represents the directed line segment with initial point A and terminal point B .

运算载体

- **Algebraic vector**: A geometric vector needs to be represented in algebraic form in order to operate. For a geometric vector $\mathbf{v} = \overrightarrow{AB}$ on a plane, if its initial point is $A = (a_1, a_2)$ and its terminal point is $B = (b_1, b_2)$, then the geometric vector $\mathbf{v} = \overrightarrow{AB}$ can be represented in an algebraic form $\mathbf{v} = \begin{bmatrix} b_1 - a_1 \\ b_2 - a_2 \end{bmatrix}$. Such a geometric vector described in algebraic form is known as an algebraic vector.


三者关系：物理→几何可视化→代数计算，是同一概念的不同侧面



1. 机器学习常用量

• 1.1 向量 (Vector)

- 向量：既有大小又有方向的量（又称为矢量）
- 向量的模：向量的大小
- 自由向量：与起点无关的向量
- 单位向量：模为1 的向量
- 零向量：模为0的向量（无方向or任意方向）





$$\begin{aligned}\vec{e}_1 &= (0, 1) \\ \vec{e}_2 &= (1, 0) \\ \vec{e}_3 &= \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)\end{aligned}$$

1. 机器学习常用量

• 1.1 向量 (Vector)

- 向量还能有如下表示：
 - 可以表示为空间中的一个点
 - 也可以表示成一条有方向和大小的直线



1. 机器学习常用量

• 1.1 向量 (Vector)

- 应用举例：
 - 词向量 (Word Embedding, 自然语言处理- NLP)
 - 词袋 (Bag of Words, BOW)
 - Word2vec、GloVe、FastText等

文件1 (记作 d_1) : John likes to watch movies. Mary likes movies too.

文件2 (记作 d_2) : John also likes to watch football games.



	John	likes	to	watch	movies	also	football	games	Mary	too
d_1	1	2	1	1	2	0	0	0	1	1
d_2	1	1	1	1	0	1	1	1	0	0

1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量加法

- 平行四边形原则
- 三角形原则
- 运算规律



- 交换律 (Commutative law)

$$a + b = b + a$$


- 结合律 (Associative law) $(a + b) + c = a + (b + c) = a + b + c$

1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量加法

例题1:



向量相加其实就是向量中对应的坐标相加

$$s = a_1 + a_2 + a_3 + a_4 + a_5$$


1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量减法

$$b - a = b + (-a)$$

$$a - a = a + (-a) = 0$$



• 三角不等式

$$|a + b| \leq |a| + |b|$$

$$|a - b| \leq |a| + |b|$$

1. 机器学习常用量

• 1.1 向量 (Vector)

• 词向量的加减法

- **加法：**在词向量空间中，词向量的加法代表着语义上的组合或关联。
 - 例如，如果将“国王”的词向量加上“女性”和“父亲”的词向量，可能会得到接近于“王后”的词向量。
- **减法：**词向量的减法则表示着语义上的差异或关系。
 - 例如，用“国王”的词向量减去“男性”的词向量，可能会得到接近于“女王”的词向量。
- 词向量加减法的运用基于词向量在高维空间的分布，这些向量被设计成在空间中**捕捉到词语之间的语义关系**。因此，通过对词向量进行加减法操作，我们可以探索词语之间的语义相似性和关系，这种方法被广泛用于词语类比、关系推理等自然语言处理任务中。
- Word2Vec Demo: <https://remykarem.github.io/word2vec-demo/>




1. 机器学习常用量

• 1.1 向量 (Vector)

• 表征向量的加减法

• 解耦表征学习 (Disentangled Representation Learning)



<https://blog.csdn.net/focky666>

1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量与数的乘法

- λ 是一个数, λ 与 a 的乘积是一个新向量, 记作 λa .

$$|\lambda a| = |\lambda| |a|$$

• 运算律

$$\lambda(\mu a) = \mu(\lambda a) = \lambda\mu a$$

$$(\lambda + \mu)a = \lambda a + \mu a$$

distributive law $\lambda(a + b) = \lambda a + \lambda b$



1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量与数的乘法

• 向量数乘应用

- **特征缩放**: 在机器学习中, 特征缩放是一种常见的预处理步骤, 通过向量数乘可以对特征进行缩放以保证它们在相似的尺度上。例如, 在使用支持向量机 (SVM) 或者神经网络等算法时, 特征缩放可以帮助加速收敛并提高模型的性能。常见的特征缩放方法包括**最小-最大缩放 (Min-Max Scaling)** 和 **标准化 (Standardization)**, 它们都涉及到向量数乘操作。
- **权重更新**: 在神经网络的训练中, 权重更新是非常重要的步骤。通过向量数乘, 可以将**学习率乘以梯度向量**, 然后将结果加到权重向量上, 以更新神经网络的参数。这个过程是优化算法 (如梯度下降) 中的核心步骤, 用于不断调整模型参数以最小化损失函数。 $w \leftarrow w - \eta \cdot \nabla L$



1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量的模

- 1. 设 $r = (x, y, z)$, 作 $OM = r$, 则有:


$$r = OM = OP + OQ + OR$$

➡ $|r| = |OM| = \sqrt{x^2 + y^2 + z^2}$

- 2. 设, $A = (x_1, y_1, z_1)$, $B = (x_2, y_2, z_2)$, 则有:

$$AB = OB - OA = (x_2 - x_1, y_2 - y_1, z_2 - z_1)$$

➡ $|AB| = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2 + (z_2 - z_1)^2}$




1. 机器学习常用量

• 1.1 向量 (Vector)

• 方向角与方向余弦


- 设有两非零向量 a, b 。任取空间一点 O 作 $OA=a, OB=b$, 则称:

$\phi = \angle AOB$ 为向量 ab 的夹角



- 设 $r=(x,y,z) \neq 0$ 。则称 r 与三角坐标轴的夹角 α, β, γ 为其方向角
- 方向角的余弦称为其方向余弦

$$\cos \alpha = \frac{x}{|r|} = \frac{x}{\sqrt{x^2 + y^2 + z^2}}$$



1. 机器学习常用量

• 1.1 向量 (Vector)

• 方向角与方向余弦

- 方向角的余弦称为其方向余弦

$$\cos\alpha = \frac{x}{|r|} = \frac{x}{\sqrt{x^2 + y^2 + z^2}}$$

$$\cos\beta = \frac{y}{|r|} = \frac{y}{\sqrt{x^2 + y^2 + z^2}}$$


$$\cos\gamma = \frac{z}{|r|} = \frac{z}{\sqrt{x^2 + y^2 + z^2}}$$

- 方向余弦的性质

$$\cos^2 \alpha + \cos^2 \beta + \cos^2 \gamma = 1$$

- 向量 e_r 为 r 的单位向量

$$e_r = \frac{r}{|r|} = (\cos\alpha, \cos\beta, \cos\gamma)$$



1. 机器学习常用量

• 1.1 向量 (Vector)

例题2： 已知两点 $M_1(2,2,\sqrt{2})$ 和 $M_2(1,3,0)$, 计算向量 M_1M_2 的模、方向余弦和方向角

解：

$$\begin{aligned} M_1M_2 &= (1-2, 3-2, 0-\sqrt{2}) \\ &= (-1, 1, -\sqrt{2}) \end{aligned}$$

$$|M_1M_2| = \sqrt{1+1+2} = 2$$

$$\cos\alpha = -\frac{1}{2} \quad \cos\beta = \frac{1}{2} \quad \cos\gamma = -\frac{\sqrt{2}}{2}$$

$$\Rightarrow \alpha = \frac{2\pi}{3} \quad \beta = \frac{\pi}{3} \quad \gamma = \frac{3\pi}{4}$$



1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量的模、方向角与方向余弦一应用

- **特征选择和降维：**在特征选择和降维中，可以利用向量的模、方向余弦和方向角等信息来评估特征之间的相关性和重要性。通过计算各个特征向量之间的夹角和相似度，可以选择最具代表性的特征向量，从而提高模型的性能和效率。
- **文本分类：**在文本分类任务中，常常使用词袋模型表示文档，每个文档可以看作一个向量。通过计算文档向量之间的夹角或余弦相似度，可以度量它们之间的相似程度，从而实现文本分类或文档检索的任务。

$$\cos\theta = (a \cdot b) / (|a| |b|)$$

- **神经网络中的梯度下降：**在神经网络的训练中，梯度下降是一种常用的优化算法。梯度可以看作是损失函数关于参数的导数向量，其大小和方向分别代表了损失函数的变化率和下降方向。通过调整参数向量的大小和方向，可以实现损失函数的最小化，从而提高模型的性能。



1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量在轴上的投影

$$a \cdot b = |a| |b| \cos \phi = |b| \cdot (a \text{ 在 } b \text{ 方向的投影})$$

设 a 与 u 轴正向的夹角为 ϕ , 则 a 在轴 u 上的投影为 $a \cos \phi$.


记作: $Prj_u a$ 或者 a_u

$$a_u = |a| \cos \phi$$

投影的性质:

$$(a + b)_u = a_u + b_u$$

$$(\lambda a)_u = \lambda a_u$$



1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量在轴上的投影


例题3: 设立方体的一条对角线为 OM , 一条棱为 OA , 且

$$|OA| = a,$$

求 OA 在 OM 方向上的投影

$$\cos \phi = \frac{|OA|}{|OM|} = \frac{1}{\sqrt{3}}$$

$$\text{Prj}_{OM} OA = |OA| \cos \phi = \frac{a}{\sqrt{3}}$$



1. 机器学习常用量

• 1.1 向量 (Vector)


- 向量的点乘 (内积, inner product/dot product/scalar product)
 - 定义: 对应元素相乘

$$a = \mathbf{x} \cdot \mathbf{y} = \sum_{i=1}^n x_i y_i$$

- 结果为一个标量(scalar)
- 点乘的另一种形式
 - 对每个元素相乘

$$a = \mathbf{x} \cdot \mathbf{y} = \boxed{\|\mathbf{x}\|} \|\mathbf{y}\| \cos(\theta)$$

- 结果还是一个标量



Attention/Transformer机制: Query 是查询, Key 是索引, Query·Key = 相似度得分

1. 机器学习常用量

• 1.1 向量 (Vector)

- 向量的点乘 (内积, inner product/dot product/scalar product)
 - 定义: 对应元素相乘

$$a = \mathbf{x} \cdot \mathbf{y} = \sum_{i=1}^n x_i y_i$$

- 应用
 - 特征工程
 - 加权平均
 - 相似度计算
 - 夹角余弦



1. 机器学习常用量

• 1.1 向量 (Vector)

A vector with unit Euclidean length is known as a normalized (or standardized) vector.

• 向量的长度

- 定义: $\|\alpha\| = \sqrt{(\alpha, \alpha)}$

- 性质: $\|k\alpha\| = |k| \|\alpha\|$

- Cauchy不等式:

$$\forall \alpha, \beta \in [V_n(F); (\alpha, \beta)], |(\alpha, \beta)| \leq \|\alpha\| \|\beta\|$$
$$\|\alpha + \beta\| \leq \|\alpha\| + \|\beta\|$$

- 欧式空间中向量的**夹角**:

- $\alpha \neq 0, \beta \neq 0$, 夹角 θ 定义为:

$$\cos\theta = \frac{(\alpha, \beta)}{\|\alpha\| \|\beta\|}$$

余弦相似度(Cosine Similarity)



1. 机器学习常用量

• 1.1 向量 (Vector)

- 向量的内积 (inner product/dot product)
 - 定义：内积是实数域上的向量空间 V 的一个函数，其中向量 u 与 v 的内积是一个实数，表示为 $\langle u, v \rangle$
 - 内积空间：满足以下性质的向量空间成为内积空间
 - $\langle u, v \rangle = \langle v, u \rangle$
 - $\langle u+v, w \rangle = \langle u, w \rangle + \langle v, w \rangle$
 - $\langle cu, v \rangle = c\langle u, v \rangle$
 - $\langle u, u \rangle \geq 0$ 当且仅当 $u=0$ 时， $\langle u, u \rangle = 0$



1. 机器学习常用量

• 1.1 向量 (Vector)

- 向量的外积 (outer product/cross product)

- 定义: $m \times 1$ real vector $\mathbf{u}$ 与 $n \times 1$ real vector $\mathbf{v}$

$$\mathbf{u} \circ \mathbf{v} = \mathbf{u}\mathbf{v}^T = \begin{bmatrix} u_1 v_1 & \cdots & u_1 v_n \\ \vdots & \ddots & \vdots \\ u_m v_1 & \cdots & u_m v_n \end{bmatrix};$$

- 外积的结果一定是秩1矩阵 (矩阵SVD分解基础)

- 应用:

- 纹理分析: 向量外积可以用来计算纹理特征之间的关系, 从而捕捉不同纹理模式之间的差异, 实现纹理分类和识别任务。
 - 图像合成: 向量外积可以用来生成新的像素值, 从而实现图像的合成和重建, 生成具有新纹理和结构的图像, 用于图像风格迁移或图像增强等应用。
 - 图像变换: 在图像变换任务中, 如图像旋转、缩放和仿射变换等, 向量外积可以用来计算变换矩阵, 从而实现图像像素的重新排列和变换。



1. 机器学习常用量

• 1.1 向量 (Vector)

- 向量运算在机器学习中的应用
 - 数据的特征/标签表示
 - 神经网络 (Neural Network, NN)
 - 支持向量机 (Support Vector Machine, SVM)
 - 线性回归 (Linear Regression, LR)



1. 机器学习常用量

• 1.1 向量 (Vector)

• 向量运算在机器学习中的应用

• 线性回归 (Linear Regression, LR)

• 基于LR的房价预测

No. of Rooms (x0)	Size (Square feet) (x1)	Year Built (x2)	No. of Floors (x3)	Price (y)
2	1434	2010	1	8500
3	1534	2019	2	9600
2	962	1996	3	25880
...	...	...	...	...
...	...	...	...	...

Where,

x_i = features of a house

y = target variable

$$x = \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

&

$$\theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix}$$

$$h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$$



1. 机器学习常用量

• 1.2 矩阵 (Matrix)

- 线性方程组的一般形式为：

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n = b_m \end{cases}$$

$$\text{数表} \quad \left(\begin{array}{cccc} a_{11} & a_{12} & \text{L} & a_{1n} \\ a_{21} & a_{22} & \text{L} & a_{2n} \\ \text{M} & & & \\ a_{m1} & a_{m2} & & a_{mn} \end{array} \right) \quad \left(\begin{array}{ccccc} a_{11} & a_{12} & \text{L} & a_{1n} & b_1 \\ a_{21} & a_{22} & \text{L} & a_{2n} & b_2 \\ \text{M} & \text{M} & \text{M} & \text{M} & \text{M} \\ a_{m1} & a_{m2} & \text{L} & a_{mn} & b_m \end{array} \right)$$

系数矩阵

增广矩阵

1. 机器学习常用量

• 1.2 矩阵 (Matrix)

- 定义:

- 由 $m \times n$ 个数 a_{ij} ($i = 1, 2, \dots, m; j = 1, 2, \dots, n$)排列成的 m 行 n 列的数表称为**m行n列矩阵**，简称为**m×n矩阵**，通常用大写字母A, B, ...表示，其中 a_{ij} 为矩阵中的元素

$$A = \begin{pmatrix} a_{11} & a_{12} & \text{L} & a_{1n} \\ a_{21} & a_{22} & \text{L} & a_{2n} \\ \text{M} & \text{M} & & \text{M} \\ a_{m1} & a_{m2} & \text{L} & a_{mn} \end{pmatrix} \begin{array}{l} \longrightarrow \text{第一行} \\ \longrightarrow \text{第二行} \\ \\ \end{array}$$

第一列 第二列

- 矩阵可以简记为:

$$A = A_{m \times n} = (a_{ij})_{m \times n}, \quad \text{或} \quad A = (a_{ij})$$

```
MXNET  PYTORCH  TENSORFLOW
A = torch.arange(20).reshape(5, 4)
A
tensor([[ 0,  1,  2,  3],
        [ 4,  5,  6,  7],
        [ 8,  9, 10, 11],
        [12, 13, 14, 15],
        [16, 17, 18, 19]])
```

1. 机器学习常用量

• 1.2 矩阵 (Matrix)

• 特殊矩阵:

行矩阵: 只有一行的矩阵也称为行向量

$$(a_1 \quad a_2 \quad \Lambda \quad a_n)$$

列矩阵: 只有一列的矩阵也称为列向量

$$\begin{pmatrix} a_1 \\ a_2 \\ \mathbf{M} \\ a_n \end{pmatrix}$$

零矩阵: 元素全是零的矩阵叫做, 简记为 $O_{m \times n}$



1. 机器学习常用量

• 1.2 矩阵 (Matrix)

- 方阵：行数与列数相等的矩阵
 - 有n行n列的矩阵称为n阶方阵或n阶矩阵

$$A = A_{n \times n} = A_n = \begin{pmatrix} a_{11} & a_{12} & \text{L} & a_{1n} \\ a_{21} & a_{22} & \text{L} & a_{2n} \\ \text{L} & & & \\ a_{n1} & a_{n2} & \text{L} & a_{nn} \end{pmatrix} = (a_{ij})_{n \times n}$$



1. 机器学习常用量

• 1.2 矩阵 (Matrix)

• 三角形矩阵

$$\begin{pmatrix} a_{11} & a_{12} & L & a_{1n} \\ 0 & a_{22} & L & a_{2n} \\ M & M & M & M \\ 0 & 0 & L & a_{nn} \end{pmatrix} \quad \begin{pmatrix} a_{11} & 0 & L & 0 \\ a_{21} & a_{22} & L & 0 \\ M & M & M & M \\ a_{n1} & a_{n2} & L & a_{nn} \end{pmatrix}$$

上三角形矩阵

下三角形矩阵

上/下三角矩阵是LU分解的两个因子

• 对角矩阵与数量矩阵

对角矩阵

数量矩阵

单位矩阵

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & L & 0 \\ 0 & \lambda_2 & L & 0 \\ M & M & M & M \\ 0 & 0 & L & \lambda_n \end{pmatrix}$$

$$\begin{pmatrix} \lambda & 0 & L & 0 \\ 0 & \lambda & L & 0 \\ M & M & M & M \\ 0 & 0 & L & \lambda \end{pmatrix}$$

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, L, \lambda_n)$$

$$\begin{pmatrix} 1 & 0 & L & 0 \\ 0 & 1 & L & 0 \\ M & M & M & M \\ 0 & 0 & L & 1 \end{pmatrix}$$

I_n 或 I

特征值分解: $A=Q\Lambda Q^T$, 其中 Λ 就是对角矩阵, λ_i 是特征值。



1. 机器学习常用量

• 1.2 矩阵 (Matrix)

- **同型矩阵**：行数与列数分别相等的矩阵

如：

$$A = \begin{pmatrix} 1 & 1 & 0 & 1 \\ 0 & 4 & 3 & -7 \end{pmatrix} \quad C = \begin{pmatrix} 0 & 5 & 4 \\ 1 & 2 & 3 \\ 0 & 0 & 0 \end{pmatrix}$$
$$B = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix} \quad D = \begin{pmatrix} 7 & 8 & 9 \\ 1 & 2 & 3 \end{pmatrix}$$

只有矩阵 A 与矩阵 B 同型

- 元素均为实数的矩阵为**实矩阵**；元素均为复数的矩阵为**复矩阵**

例如：

$$\begin{pmatrix} 1 & 0 & 3 & 5 \\ -9 & 6 & 4 & 3 \end{pmatrix} \quad \text{是一个 } 2 \times 4 \text{ 实矩阵；}$$

$$\begin{pmatrix} 13 & 6 & 2i \\ 2 & 2 & 2 \\ 2 & 2 & 2 \end{pmatrix} \quad \text{是一个 } 3 \times 3 \text{ 复矩阵；}$$



1. 机器学习常用量

• 1.2 矩阵 (Matrix)

• 相等矩阵

如果 $A = (a_{ij})$ 与 $B = (b_{ij})$ 是同型矩阵，并且对应位置上的元素相等，即


$$a_{ij} = b_{ij} (i = 1, 2, \Lambda, m; j = 1, 2, \Lambda, n),$$

那么就称矩阵A与矩阵B相等，记作 $A=B$



1. 机器学习常用量


• 1.3 张量 (Tensor)



MXNET	PYTORCH	TENSORFLOW
<pre>X = torch.arange(24).reshape(2, 3, 4) X</pre>		
<pre>tensor([[[0, 1, 2, 3], [4, 5, 6, 7], [8, 9, 10, 11]], [[12, 13, 14, 15], [16, 17, 18, 19], [20, 21, 22, 23]]])</pre>		

- **定义：**几何代数中定义的张量是基于向量和矩阵的推广，通俗一点理解的话，就是给一个二维矩阵增加一个或多个维度使其变成三维矩阵或多维矩阵。一般使用花体大写字母 $\mathcal{A}, \mathcal{B}$ 表示。

- 例如：RGB图像，视频数据等



PYTHON
<pre>import torch x = torch.randn(8, 3, 224, 224) print(x.shape)</pre>
输出:
<pre>torch.Size([8, 3, 224, 224])</pre>

1. 机器学习常用量

• 1.3 张量 (Tensor)

- 深度学习中的张量维度约定

数据类型	张量形状	各维含义	框架表示
单张灰度图	$H \times W$	高度 $\times$ 宽度	2D矩阵
单张彩色图	$H \times W \times C$	高度 $\times$ 宽度 $\times$ 通道(3)	3阶张量
一批彩色图 Eg. CNN输入	$N \times C \times H \times W$	批量 $\times$ 通道 $\times$ 高 $\times$ 宽	4阶张量
序列数据 Eg. RNN输入	$T \times N \times d$	时间步 $\times$ 批量 $\times$ 特征维	3阶张量
Transformer权重	$num_{heads} \times d_k \times d_k$	头数 $\times$ 键维 $\times$ 查询维	3阶张量




1. 机器学习常用量

• 1.3 张量 (Tensor)

• TensorFlow

- TensorFlow是人工智能AI领域的一个重要软件工具，是谷歌于2015年基于DistBelief进行研发的第二代开源人工智能学习系统。
- 人工智能领域分为三个方面，即基础层、技术层和应用层；而TensorFlow就是技术层中的学习框架。
- 主流的深度学习框架之一（其他框架：Keras, MXNet, PyTorch, CNTK, Theano, Caffe等）
- 例：Tensor [BatchSize, height, width, channel size]



1. 机器学习常用量

Many problems in artificial intelligence need to solve **optimization problems** in which vector and/or matrix norms are the **cost function terms** to be optimized.

• 1.4 范数 (Norm)

• 定义：设 V 为 R 上的一个线性空间，如果 V 上的实函数 $\|x\|$ 满足性质：

1. 正定性：对 $\forall x \in V, \|x\| \geq 0$, 且 $\|x\| = 0 \Leftrightarrow x = 0$;

2. 齐次性：对 $\forall x \in V, \alpha \in R, \|\alpha x\| = |\alpha| \|x\|$;

3. 三角不等式：对 $\forall x, y \in V, \|x + y\| \leq \|x\| + \|y\|$,

则称 V 是一个**赋范线性空间**，称 $\|x\|$ 为 V 中 x 的**向量范数**

- 引入“范数”目的是为了得到一种线性空间中的向量“大小”的度量、或两个向量之间的“接近”程度的比较。
- 向量范数是**将向量映射到标量**的函数 f



1. 机器学习常用量

• 1.4 范数 (Norm)

• 向量范数

MXNET

PYTORCH

TENSORFLOW

```
tf.reduce_sum(tf.abs(u))
```

MXNET

PYTORCH

TENSORFLOW

```
u = tf.constant([3.0, -4.0])
tf.norm(u)
```

名称	公式	几何直觉	典型用途
L0 范数	$\ x\ _0 = \text{向量中非零分量个数}$	稀疏度量, 非真正范数	稀疏编码、特征选择
L1 范数 (曼哈顿)	$\ x\ _1 = \sum_{i=1}^n x_i $	各坐标绝对值之和	Lasso 正则化 (促进稀疏)
L2 范数 (欧氏)	$\ x\ _2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{X^T X}$	欧氏距离	Ridge 正则化、梯度裁剪
L^∞ 范数 (切比雪夫)	$\ x\ _\infty = \max_{1 \leq i \leq n} x_i $	最大绝对分量	对抗攻击扰动约束
L_p 范数 (统一形式)	$\ x\ _p = \sqrt[p]{\sum_{i=1}^n x_i ^p}$	$p \rightarrow \infty$ 趋近于 L^∞	广义框架



1. 机器学习常用量

• 1.4 范数 (Norm)

- 向量范数

ℓ_0 -norm

$$\|\mathbf{x}\|_0 \stackrel{\text{def}}{=} \sum_{i=1}^m x_i^0, \quad \text{where } x_i^0 = \begin{cases} 1, & \text{if } x_i \neq 0; \\ 0, & \text{if } x_i = 0. \end{cases}$$

That is,

$\|\mathbf{x}\|_0$ = number of nonzero entries of $\mathbf{x}$.

- In artificial intelligence, L0-norm is usually used as a measure of sparse vectors. However, the it is difficult to be optimized. The L1-norm can be regarded as a relaxed form of the L0-norm.

$$\text{sparse vector } \mathbf{x} = \arg \min_{\mathbf{x}} \|\mathbf{x}\|_0.$$

$$\text{sparse vector } \mathbf{x} = \arg \min_{\mathbf{x}} \|\mathbf{x}\|_1.$$



1. 机器学习常用量

• 1.4 范数 (Norm)

• 向量范数—应用场景

• L1 范数（曼哈顿距离）：

- 特征选择：L1 范数倾向于产生稀疏解，因此在特征选择问题中常用于筛选出最重要的特征。
- 稀疏信号处理：L1 范数最小化能够促使某些信号系数变为零，从而实现信号的稀疏表示。

• L2 范数（欧几里德范数）：

- 正则化：L2 范数常用于机器学习模型的正则化，可以控制模型的复杂度，防止过拟合。
- 最小二乘法：L2 范数在最小二乘法中作为损失函数的一部分，用于衡量预测值与真实值之间的误差。

• L^∞ 范数（最大值范数）：

- 误差分析： L^∞ 范数可以用于衡量向量的最大误差，因此在某些情况下用于评估模型或算法的稳定性和鲁棒性。

• L_p 范数：

- 在不同的问题中，可根据具体需求选择合适的 p 值来度量向量的大小，例如在机器学习中的正则化问题中，通过调整 p 值可以平衡模型的复杂度和拟合能力。




1. 机器学习常用量

• 1.4 范数 (Norm)

• 范数单位球的几何直觉

- 定义: $\|x\|_p \leq 1$ 所围成的区域称为 L_p 单位球。不同 p 值对应不同形状:
 - $p = 1$: 正方形 (菱形) 对角线朝坐标轴, 解倾向于稀疏 (落在顶点)
 - $p = 2$: 标准圆球, 各方向对称, 解无稀疏偏好
 - $p \rightarrow \infty$: 正方形, 各坐标方向等价



- 与L2范数相比, L1范数受异常值的影响较小
- L1 正则化比 L2 更容易产生稀疏解

1. 机器学习常用量

• 1.4 范数 (Norm)

• 向量范数

例题4: 设向量 $X = (-1, 2, -3)$, 求 $\|X\|_1$, $\|X\|_2$, $\|X\|_\infty$

$$\|X\|_1 = |-1| + |2| + |-3| = 6$$

$$\|X\|_2 = \sqrt{(-1)^2 + 2^2 + (-3)^2} = \sqrt{14}$$

$$\|X\|_\infty = \max\{|-1|, |2|, |-3|\} = 3$$



1. 机器学习常用量

注：tr 表示矩阵的迹（对角线元素之和）

• 1.4 范数 (Norm)

- 矩阵范数 ($A \in R^{n \times n}$)

名称	公式	计算方式	典型用途
Frobenius 范数	$\ A\ _F = \sqrt{\sum_{i,j=1}^n a_{ij} ^2}$ $= \sqrt{\text{tr}(A^T A)}$	对所有元素平方求和开根,	矩阵差的度量、权重衰减
谱范数 (2-范数)	$\ A\ _2 = \sqrt{\lambda_{\max}(A^T A)}$ (最大特征值)	需要 SVD 分解	谱归一化 (GAN训练稳定)
核范数 (迹范数)	$\ A\ _* = \sum_{i=1}^{\tilde{n}} \sigma_i(A)$ (奇异值之和)	需要 SVD 分解	矩阵填充、低秩约束
1-范数 (列范数)	$\ A\ _1 = \max_{1 \leq j \leq n} \sum_{i=1}^n a_{ij} $	各列L1范数的最大值	稀疏矩阵近似
∞ -范数 (行范数)	$\ A\ _\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n a_{ij} $	各行L1范数的最大值	稀疏矩阵近似



1. 机器学习常用量

• 1.4 范数 (Norm)

- 矩阵范数 ($A \in R^{n \times n}$)
- 矩阵的迹 (trace)
 - 定义: $\text{tr}(A) = \sum_{i=1}^n A_{ii}$ (方阵 A 对角线元素之和)
 - 性质:

性质1 线性性	$\text{tr}(\alpha A + \beta B) = \alpha \cdot \text{tr}(A) + \beta \cdot \text{tr}(B)$
性质2 转置不变	$\text{tr}(A) = \text{tr}(A^T)$
性质3 循环置换 ★	$\text{tr}(ABC) = \text{tr}(CAB) = \text{tr}(BCA)$ (注意: 顺序不能随意交换, 但可以循环)
性质4 与特征值的关系	$\text{tr}(A) = \sum_i \lambda_i$ (迹等于所有特征值之和)
性质5 与内积的关系	$\text{tr}(A^T B) = \sum_{ij} A_{ij} B_{ij}$ (矩阵内积的标量形式, 即 Frobenius 内积)



1. 机器学习常用量

• 1.4 范数 (Norm)

• 矩阵范数

例题4: 矩阵 $A = \begin{bmatrix} 1 & 5 & -2 \\ -2 & 1 & 0 \\ 3 & -8 & 2 \end{bmatrix}$ 求 $\|A\|_1$, $\|A\|_2$, $\|A\|_\infty$, $\|A\|_F$

$$\|A\|_1 = \max\{1 + 2 + 3, 5 + 1 + 8, 2 + 0 + 2\} = 14$$

$$\|A\|_\infty = \max\{1 + 5 + 2, 2 + 1 + 0, 3 + 8 + 2\} = 13$$

$$\|A\|_F = \sqrt{1 + 25 + 4 + 4 + 1 + 0 + 9 + 64 + 4} = \sqrt{112}$$

$$A^T A = \begin{bmatrix} 14 & -21 & 4 \\ -21 & 90 & 26 \\ 4 & -26 & 8 \end{bmatrix}$$

$A^T A$ 的特征方程为 $\|A^T A - \lambda E\| = 0$

解的最大特征值为 $\lambda \approx 102.66$

$$-\lambda^3 + 112\lambda^2 - 959\lambda + 16 = 0$$

$$\|A\|_2 = \sqrt{\lambda} \approx 10.132$$



1. 机器学习常用量

• 1.4 范数 (Norm)

• 矩阵范数应用示例

- 在矩阵分解任务（如主成分分析 PCA、推荐系统的协同过滤）中，F 范数用于衡量矩阵近似误差或作为正则化项

- 如推荐系统中，用户 - 物品评分矩阵 R 的分解目标为：

$$\min_{U,V} \|R - UV^T\|_F^2 + \lambda(\|U\|_F^2 + \|V\|_F^2)$$

- 其中 U 和 V 是用户和物品的隐向量矩阵，F 范数惩罚项防止过拟合，约束矩阵 U 和 V 的元素大小。
- 对在生成对抗网络（GAN）中，谱范数约束判别器的权重矩阵，确保其满足 Lipschitz 条件，稳定训练过程
 - 判别器 D 的权重矩阵 W 需满足 $\|W\|_2 \leq K$ ，通过正交归一化或梯度惩罚实现，避免梯度消失或爆炸




1. 机器学习常用量

• 1.4 范数 (Norm)

- 过拟合与正则化

- 过拟合问题



- 在机器学习中，**范数 (Norm)** 和**正则化 (Regularization)** 是紧密关联的概念，二者通过对模型参数施加“约束”或“惩罚”，共同作用于防止过拟合问题
 - **正则化**是一种通过修改损失函数（或目标函数）来抑制模型复杂度的技术，核心思想是在原损失函数中加入**正则化项**（惩罚项），迫使模型参数取值更“简单”或更“平滑”，从而降低过拟合风险
 - 正则化项通常由模型参数的范数构成，不同范数对应不同的正则化方法
 - **L1 范数**对应 L1 正则化 (Lasso 正则化)
 - **L2 范数**对应 L2 正则化 (岭回归/Ridge回归)

L1 regularization on least squares:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} \sum_j \left(t(\mathbf{x}_j) - \sum_i w_i h_i(\mathbf{x}_j) \right)^2 + \lambda \sum_{i=1}^k |w_i|$$

L2 regularization on least squares:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} \sum_j \left(t(\mathbf{x}_j) - \sum_i w_i h_i(\mathbf{x}_j) \right)^2 + \lambda \sum_{i=1}^k w_i^2$$

