

3. 线性相关与线性无关

- 3.1 极大线性无关组的概念
- 3.2 向量组的秩
- 3.3 向量组的秩和极大线性无关组求解方法
- 3.4 列空间、行空间、零空间及维数定理
- 3.5 应用：PCA、线性方程组几何解释、特征脸



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **定义：** 对于n 维向量组 $a_1, a_2, \dots, a_s$, 若存在实数 $k_1, k_2, \dots, k_s$ 使得

$$k_1 a_1 + k_2 a_2 + \dots + k_s a_s = b$$

则称向量b为 $a_1, a_2, \dots, a_s$ 的线性组合。

或者称向量b能由向量组 $a_1, a_2, \dots, a_s$ 线性表示(线性表出)。

- **例子：** 向量组 $a_1 = (1, 2, 0, 1), a_2 = (1, 1, -1, 3), a_3 = (1, 3, 1, -1)$, 零向量 $0 = (0, 0, 0, 0)$ 可由它们线性表示

$$0 = 2a_1 - a_2 - a_3$$



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- 对于线性方程组 $Ax=b$, 其中 系数矩阵 A 为 $m \times n$ 阶矩阵, 将 A 列分块为 $A=(a_1, a_2, \dots, a_n)$, 未知数向量为 $x=(x_1, x_2, \dots, x_n)^T$, 则有

$$x_1 a_1 + x_2 a_2 + \dots + x_n a_n = b$$

- {
- ① $Ax=b$ 有解 $\iff$ 向量 b 能由向量组 $a_1, a_2, \dots, a_n$ 线性表示;
 - ② $Ax=b$ 有 唯一解 $\iff$ 向量 b 能由向量组 $a_1, a_2, \dots, a_n$ 线性表示, 且 表示方法唯一。

- 假设:** 矩阵 A 为 $m \times n$ 阶矩阵, 将 A 列分块为 $A=(a_1, a_2, \dots, a_n)$ 。

- ① 齐次线性方程组 $Ax=0$ 有非零解;



- ② 存在 不全为零 的实数 $c_1, c_2, \dots, c_n$ 使得 $c_1 a_1 + c_2 a_2 + \dots + c_n a_n = 0$

3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **向量组的线性相关性：** 对于n维向量组 $a_1, a_2, \dots, a_n$ ，如果**存在**不全为零的实数 $k_1, k_2, \dots, k_n$ 使得

$$k_1 a_1 + k_2 a_2 + \dots + k_n a_n = 0,$$

则称n维向量组 $a_1, a_2, \dots, a_n$ **线性相关**，否则称该向量组**线性无关**。

- **线性无关：**

假设 $a_1, a_2, \dots, a_n$ 线性无关，即如果 $k_1 a_1 + k_2 a_2 + \dots + k_n a_n = 0$ ，则
 $k_1 = k_2 = \dots = k_n = 0$



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **例1:** 证明 n 维向量组 $e_1 = (1, 0, \dots, 0)^T, e_2 = (0, 1, \dots, 0)^T, \dots, e_n = (0, 0, \dots, 1)^T$ 线性无关。

证: 设 $k_1 e_1 + k_2 e_2 + \dots + k_n e_n = 0$,

则 $(k_1, k_2, \dots, k_n)^T = (0, 0, \dots, 0)^T$,

→ $k_1 = k_2 = \dots = k_n = 0$,

→ 向量组 $e_1, e_2, \dots, e_n$ 线性无关.



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **定理1:** 当 $n \geq 2$ 时, 向量组 $a_1, a_2, \dots, a_n$ 线性相关 的充要条件是:
其中至少有一个向量能由其余向量线性表出。

证明: 必要性 $\Rightarrow$

设 $a_1, a_2, \dots, a_n$ 线性相关, 则存在不全为0的实数 $k_1, k_2, \dots, k_n$ 使得

$$k_1 a_1 + k_2 a_2 + \dots + k_n a_n = 0,$$

不妨设 $k_n \neq 0$, 则 $a_n = \frac{-k_1}{k_n} a_1 + \dots + \frac{-k_{n-1}}{k_n} a_{n-1}$

即 a_n 可以由 $a_1, a_2, \dots, a_{n-1}$ 线性表示。

充分性 $\Leftarrow$

若某个向量可被其余向量线性表出, 不妨设 a_1 可由其余向量表示, 即存在实数 $k_2, \dots, k_n$, 使得 $a_1 = k_2 a_2 + \dots + k_n a_n$, 即:

$$a_1 + (-k_2) a_2 + \dots + (-k_n) a_n = 0,$$

其系数不全为0, 因此 $a_1, a_2, \dots, a_n$ 线性相关。



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **推论1:** 当 $n \geq 2$ 时, 向量组 $a_1, a_2, \dots, a_n$ 线性无关的充要条件是:
其中任意一个向量都不能由其余向量线性表出。
- **推论2:**
 - 矩阵A 的列向量组线性相关(无关)的充要条件是 $Ax=0$ 有非零解(只有零解).
 - **方阵**A 的列向量组线性相关(无关)的充要条件是 $\det(A)=0$ ($\det(A) \neq 0$) .



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **定理2:** 如果向量组 $a_1, a_2, \dots, a_n$ 中有部分向量线性相关, 则这 n 个向量也线性相关.

证明: 不妨设前 r ($r < n$) 个向量 $a_1, a_2, \dots, a_r$ 线性相关, 即存在不全为零的实数 $k_1, k_2, \dots, k_r$ 使得

$$k_1 a_1 + k_2 a_2 + \dots + k_r a_r = 0;$$

令 $k_{r+1} = k_{r+2} = \dots = k_n = 0$, 则有

$$k_1 a_1 + k_2 a_2 + \dots + k_r a_r + k_{r+1} a_{r+1} + \dots + k_n a_n = 0;$$

由于系数 $k_1, k_2, \dots, k_n$ 不全为零, 因此 $a_1, a_2, \dots, a_n$ 线性相关.

- **推论3:** 如果向量组 $a_1, a_2, \dots, a_n$ 线性无关, 则其中部分向量也线性无关
 - 部分组相关, 则全体组也相关
 - 全体组无关, 则部分组也无关



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **定理3:** 设 m 元向量组 $A: a_1, a_2, \dots, a_s$, n 元向量组 $B: b_1, b_2, \dots, b_s$, $m+n$ 元向量组 $C: c_1, c_2, \dots, c_s$, 且

$$c_i = \begin{pmatrix} a_i \\ b_i \end{pmatrix}, i = 1, \dots, s$$

则 A, B 中任何一个向量组线性无关, 则 C 也线性无关。

证明: 不妨设向量组 A 线性无关。设实数 $k_1, k_2, \dots, k_s$ 使得

$$k_1 c_1 + k_2 c_2 + \dots + k_s c_s = 0,$$

$$\text{即 } k_1 \begin{pmatrix} a_1 \\ b_1 \end{pmatrix} + k_2 \begin{pmatrix} a_2 \\ b_2 \end{pmatrix} + \dots + k_s \begin{pmatrix} a_s \\ b_s \end{pmatrix} = 0 \Rightarrow k_1 a_1 + k_2 a_2 + \dots + k_s a_s = 0$$

由于向量组 A 线性无关, 因此 $k_1, k_2, \dots, k_s$ 必全为零,

→ $c_1, c_2, \dots, c_s$ 线性无关



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **定理4:** 向量组A: $a_1, a_2, \dots, a_r$ 线性无关, 向量组B: $a_1, a_2, \dots, a_r, b$ 线性相关, 则b可由向量组A线性表示, 且表示唯一。

证明: 由已知, 存在不全为零的实数 $k_1, \dots, k_{r+1}$ 满足:

$$k_1 a_1 + \dots + k_r a_r + k_{r+1} b = 0.$$

若 $k_{r+1} = 0$, 则存在不全为零的实数 $k_1, \dots, k_r$ 满足

$$k_1 a_1 + \dots + k_r a_r = 0.$$

这与向量组A线性无关矛盾, 因此 k_{r+1} 必不为零, 从而

$$b = \left(-\frac{k_1}{k_{r+1}} \right) a_1 + \dots + \left(-\frac{k_r}{k_{r+1}} \right) a_r$$



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **定理4:** 向量组A: $a_1, a_2, \dots, a_r$ **线性无关**, 向量组B: $a_1, a_2, \dots, a_r, b$ **线性相关**, 则b可由向量组A**线性表示**, 且**表示唯一**。

下证唯一性。

设b可以被向量组A线性表示为:

$$b = \alpha_1 a_1 + \Lambda + \alpha_r a_r,$$

$$b = \beta_1 a_1 + \Lambda + \beta_r a_r.$$

两式相减可得

$$(\alpha_1 - \beta_1) a_1 + \Lambda + (\alpha_r - \beta_r) a_r = \mathbf{0},$$

由于向量组A线性无关, 从而上式系数全为零, 即

$$\alpha_1 = \beta_1, \Lambda, \alpha_r = \beta_r$$

唯一性得证。



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **推论4:** 向量组 $a_1, a_2, \dots, a_r$ 线性无关, 向量 b 不能由 $a_1, a_2, \dots, a_r$ 线性表示, 则向量组 $a_1, a_2, \dots, a_r, b$ 线性无关。
- **推论5:** 向量 b 能由 $a_1, a_2, \dots, a_r$ 线性表示, 且表达式唯一
↔ 则向量组 $a_1, a_2, \dots, a_r$ 线性无关。



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

$k_1\mathbf{a}_1 + k_2\mathbf{a}_2 + \dots + k_s\mathbf{a}_s = \mathbf{0}$ 有非零解 $\rightarrow$ 线性相关

线性相关

存在不全为零的 k_i
使线性组合=0
 $\Leftrightarrow$ 有向量是其余的
线性组合 (冗余)

线性无关

只有全零的 k_i
才能使线性组合=0
 $\Leftrightarrow$ 任何向量都不能
由其余向量表示

关键等价关系

线性相关
 $\Leftrightarrow A\mathbf{x}=\mathbf{0}$ 有非零解
 $\Leftrightarrow \text{rank}(A) < n$
 $\Leftrightarrow |A|=0$ (方阵情形)



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **例2:** 试讨论下列向量组的线性相关性

$$\alpha_1 = (1, 0, -1)^T, \alpha_2 = (1, -1, 0)^T, \alpha_3 = (0, 1, 1)^T$$

解 设有一组数 k_1, k_2, k_3 , 使得

$$k_1 \alpha_1 + k_2 \alpha_2 + k_3 \alpha_3 = 0$$

即

$$k_1 \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} + k_2 \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} + k_3 \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 0 \Rightarrow \begin{cases} k_1 + k_2 = 0 \\ -k_2 + k_3 = 0 \\ -k_1 + k_3 = 0 \end{cases}$$



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

• **例2:** 试讨论下列向量组的线性相关性

➤ 可见向量组的相关性等价于这个齐次方程组有否非零解。

➤ 而它的系数行列式

$$\begin{vmatrix} 1 & 1 & 0 \\ 0 & -1 & 1 \\ -1 & 0 & 1 \end{vmatrix} = -2 \neq 0$$

由克莱姆法则，只有唯一零解，即 $k_1 = k_2 = k_3 = 0$ 。

于是向量组 a_1, a_2, a_3 是线性无关的。



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **例3:** 设向量 $\alpha_1, \alpha_2, \alpha_3$ 线性无关, 试证明 $\alpha_1, \alpha_1 + \alpha_2, \alpha_1 + \alpha_2 + \alpha_3$ 也线性无关。

证 设有一组数 k_1, k_2, k_3 , 使得

$$k_1 \alpha_1 + k_2 (\alpha_1 + \alpha_2) + k_3 (\alpha_1 + \alpha_2 + \alpha_3) = 0$$

即

$$(k_1 + k_2 + k_3)\alpha_1 + (k_2 + k_3)\alpha_2 + k_3\alpha_3 = 0$$

因为向量 $\alpha_1, \alpha_2, \alpha_3$ 线性无关

$$\begin{cases} k_1 + k_2 + k_3 = 0 \\ k_2 + k_3 = 0 \\ k_3 = 0 \end{cases} \xrightarrow{\text{系数行列式}} \begin{vmatrix} \mathbf{1} & \mathbf{1} & \mathbf{1} \\ & \mathbf{1} & \mathbf{1} \\ & & \mathbf{1} \end{vmatrix} = \mathbf{1} \neq \mathbf{0}$$

所以由克莱姆法则 方程组只有零解, 即 $k_1 = k_2 = k_3 = 0$ 。



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

• 定义：

- 向量组 V 中，如果含有 r 个向量的子向量组线性无关，并且 V 中任何含 $r+1$ 个向量的子向量组都线性相关，则将 r 称为向量组 V 的秩。
- 如果向量组 V 的秩为 r ，则 V 中含有 r 个线性无关向量组成的子向量组称为 V 的一个极大(线性)无关组。
- 一个向量组线性无关当且仅当它的极大无关组就是它自身。



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

设 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是向量组 T 的一部分向量, 如果满足:

(1) $\alpha_1, \alpha_2, \dots, \alpha_r$ 线性无关

(2) $\forall \alpha \in T$ α 可由 $\alpha_1, \alpha_2, \dots, \alpha_r$ 线性表示

→ 则称 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是向量组 T 的极大无关组



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

• 注：

- 只有零向量构成的向量组没有极大无关组
- 上页的(2)表示这个线性无关组具有极大性

• 推论：设 T 是由 n 维向量所组成的向量组，则

- T 的每个极大线性无关组与 T 等价
- T 的任意两个极大线性无关组所含向量的个数是相同的。



极大线性无关组不唯一(r 小于向量组向量个数时)



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

• **例4:** $a_1 = (1, 2, -1)$, $a_2 = (2, -3, 1)$, $a_3 = (4, 1, -1)$

➡ a_1, a_2, a_3 线性相关;
 a_1, a_2 为 T 的极大线性无关组;
 a_2, a_3 ; a_1, a_3 也是 T 的极大线性无关组

➡ 极大线性无关组不唯一



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

• 向量组之间的线性表示

- **定义：** 设有两个向量组(I) $\alpha_1, \alpha_2, \dots, \alpha_m$; (II) $\beta_1, \beta_2, \dots, \beta_s$;
若向量组(II)中的每个向量都能由向量组(I)线性表示,
则称向量组(II)能由向量组(I)线性表示。

此时, 对于每个向量 β_j , 存在系数 $c_{1j}, c_{2j}, \dots, c_{mj}$, 使得

$$\beta_j = c_{1j}\alpha_1 + c_{2j}\alpha_2 + \dots + c_{mj}\alpha_m = (\alpha_1, \alpha_2, \dots, \alpha_m) \begin{pmatrix} c_{1j} \\ c_{2j} \\ \vdots \\ c_{mj} \end{pmatrix}$$



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

$$\text{即有, } (\beta_1, \beta_2, \Lambda, \beta_s) = (\alpha_1, \alpha_2, \Lambda, \alpha_m) \begin{pmatrix} c_{11} & c_{12} & \Lambda & c_{1s} \\ c_{21} & c_{22} & \Lambda & c_{2s} \\ M & M & O & M \\ c_{m1} & c_{m2} & \Lambda & c_{ms} \end{pmatrix}$$

若记 $A_{n \times m} = (\alpha_1, \alpha_2, \Lambda, \alpha_m)$, $B_{n \times s} = (\beta_1, \beta_2, \Lambda, \beta_s)$,
则所谓的向量组(II)能由向量组(I)线性表示意味着
存在矩阵 $C_{m \times s}$, 使得

$$B_{n \times s} = A_{n \times m} \cdot C_{m \times s},$$

其中n为向量的维数。



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **例：** 设向量组 $\beta_1, \beta_2, \beta_3, \beta_4$ 能由 $\alpha_1, \alpha_2, \alpha_3, \alpha_4$ 线性表示， 其中

$$\begin{aligned}\beta_1 &= \alpha_1 + \alpha_2, & \beta_2 &= \alpha_2 + \alpha_3, \\ \beta_3 &= \alpha_3 + \alpha_4, & \beta_4 &= -\alpha_1 + \alpha_4,\end{aligned}$$

则有

$$(\beta_1, \beta_2, \beta_3, \beta_4) = (\alpha_1, \alpha_2, \alpha_3, \alpha_4) \begin{pmatrix} 1 & 0 & 0 & -1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{pmatrix}$$



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- **定理：** 设向量组 $\alpha_1, \alpha_2, \dots, \alpha_r$ 能由 $\beta_1, \beta_2, \dots, \beta_s$ 线性表示，若 $r > s$ ，则向量组 $\alpha_1, \alpha_2, \dots, \alpha_r$ 线性相关。

即：若向量组 $\alpha_1, \alpha_2, \dots, \alpha_r$ 线性无关，则 $r \leq s$ 。

- **推论：** $n + 1$ 个 n 维向量一定线性相关。

因为任何 n 维向量都可由 **n 维基本向量** $e_1, e_2, \dots, e_n$ 线性表示



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

• 向量组之间的等价

- **定义：** 若向量组 $\alpha_1, \alpha_2, \dots, \alpha_r$ 与向量组 $\beta_1, \beta_2, \dots, \beta_s$ 能相互线性表示，此时，若记：

$$A_{n \times m} = (\alpha_1, \alpha_2, \dots, \alpha_m), \quad B_{n \times s} = (\beta_1, \beta_2, \dots, \beta_s),$$

则存在矩阵 $C_{m \times s}$ 和 $D_{s \times m}$ ，使得

$$B_{n \times s} = A_{n \times m} \cdot C_{m \times s}, \quad A_{n \times m} = B_{n \times s} \cdot D_{s \times m},$$

其中 n 为向量的维数。

- 例如：任何一个向量组与它的极大线性无关组是等价的。




3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

• 向量组之间的等价

• **定理：** 两个等价的向量组中各自的极大线性无关组所含的向量个数相等。



即向量组 $\alpha_{i_1}, \alpha_{i_2}, \dots, \alpha_{i_r}$ 能由 $\beta_{i_1}, \beta_{i_2}, \dots, \beta_{i_s}$ 线性表示,
且 $\alpha_{i_1}, \alpha_{i_2}, \dots, \alpha_{i_r}$ 线性无关,
同理 $r \geq s$, 即得 $r = s$ 。

3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

- 向量组之间的等价

- **定理：** 两个等价的向量组中各自的极大线性无关组所含的向量个数相等。

- **推论：**

- 若两个线性无关的向量组等价，则它们所含的向量个数相等；
- 在一个给定的向量组中，各个极大线性无关组所含的向量个数相等，且向量个数是惟一的。



3. 线性相关与线性无关

• 3.1 极大线性无关组的概念

定理	内容	直觉	联系
充要条件	向量组线性相关 $\Leftrightarrow$ 至少一个向量可由其余表示	存在冗余 = 可被合成	数据冗余特征
子集扩展	部分线性相关 $\Rightarrow$ 整体线性相关	有冗余的集合加向量 还是有冗余	冗余特征无法 通过加特征消除
维数限制	m 维向量组若含 $n > m$ 个向量 必线性相关	鸽巢原理：向量个数 $>$ 维度，必有冗余	特征数 $>$ 样本数时 设计矩阵必有线性相关列

3. 线性相关与线性无关

• 3.2 向量组的秩

- **定义：** 一个向量组中的极大线性无关组所含的向量个数称为向量组的秩。
- **结论：** 等价的向量组秩相等。



3. 线性相关与线性无关

• 3.2 向量组的秩

• 向量组的秩与矩阵秩的关系

• **定理：** 设 $A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$ $\begin{matrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_m \end{matrix}$

$\beta_1 \quad \beta_2 \quad \cdots \quad \beta_n$

则 $r(A) = \underbrace{\alpha_1, \alpha_2, \dots, \alpha_m}_{\text{行秩}}$ 的秩 $= \underbrace{\beta_1, \beta_2, \dots, \beta_n}_{\text{列秩}}$ 的秩

通常说，**矩阵的秩等于行秩等于列秩**

3. 线性相关与线性无关

• 3.2 向量组的秩

• 向量组的秩与矩阵秩的关系

• **推论：** 设 A 为 $m \times n$ 阶矩阵，且 $r(A)=r$ ，则有

➤ 当 $r=m$ 时， A 的行向量线性无关，
当 $r < m$ 时， A 的行向量线性相关；

➤ 当 $r=n$ 时， A 的列向量线性无关，
当 $r < n$ 时， A 的列向量线性相关；

➤ 特别地，**方阵** A 的行(列)向量线性无关的充要条件是 $|A| \neq 0$ 。



3. 线性相关与线性无关

• 3.3 向量组的秩和极大线性无关组求解方法

- 无论所给向量组是行向量还是列向量，都按列向量排列，并构成矩阵A；
- 对矩阵A 进行初等行变换得到行标准形矩阵B；
- 根据矩阵B 的秩及其列向量的线性组合关系，直接得出原向量组的秩、极大线性无关组以及线性组合关系。

1	2	3	4	5
构造矩阵	初等行变换	读秩	读极大无关组	读线性关系
向量按列排列 $\rightarrow A$ $= [\alpha_1 \alpha_2 \dots \alpha_n]$	对A做初等行变换 $\rightarrow$ 行阶梯形B	非零行数 = rank(A) = 向量组的秩	主元所在列对应的 原始向量 = 极大无 关组	从行最简形读出其 余向量的表示系数

3. 线性相关与线性无关

• 3.3 向量组的秩和极大线性无关组求解方法

- **例：** 求向量组 $\alpha_1 = (1, 0, 1, 0)^T, \alpha_2 = (0, 1, 0, 1)^T, \alpha_3 = (2, 1, 2, 1)^T, \alpha_4 = (2, 2, 1, 3)^T, \alpha_5 = (1, 5, 3, 3)^T$

的极大无关组，并用极大无关组表示该向量组的其他向量。

- 解：** (1) 做矩阵 $A = (\alpha_1, \alpha_2, \alpha_3, \alpha_4, \alpha_5)$
(2) 然后对A进行初等行变换，化成行阶梯简化形

$$A = \begin{pmatrix} 1 & 0 & 2 & 2 & 1 \\ 0 & 1 & 1 & 2 & 5 \\ 1 & 0 & 2 & 1 & 3 \\ 0 & 1 & 1 & 3 & 3 \end{pmatrix} \rightarrow \begin{pmatrix} \textcircled{1} & 0 & 2 & 0 & 5 \\ 0 & \textcircled{1} & 1 & 0 & 9 \\ 0 & 0 & 0 & \textcircled{1} & -2 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix} = (\beta_1, \beta_2, \beta_3, \beta_4, \beta_5) = B$$

- (3) 因此 $\beta_1, \beta_2, \beta_4$ 是矩阵B的列向量组的极大线性无关组。

3. 线性相关与线性无关

• 3.3 向量组的秩和极大线性无关组求解方法

- **例：** 求向量组 $\alpha_1 = (1, 0, 1, 0)^T, \alpha_2 = (0, 1, 0, 1)^T, \alpha_3 = (2, 1, 2, 1)^T,$
 $\alpha_4 = (2, 2, 1, 3)^T, \alpha_5 = (1, 5, 3, 3)^T$

的极大无关组，并用极大无关组表示该向量组的其他向量。

解： (3) 因此 $\alpha_1, \alpha_2, \alpha_4$ 是矩阵A的列向量组的极大线性无关组。

$$A = \begin{pmatrix} 1 & 0 & 2 & 2 & 1 \\ 0 & 1 & 1 & 2 & 5 \\ 1 & 0 & 2 & 1 & 3 \\ 0 & 1 & 1 & 3 & 3 \end{pmatrix} \longrightarrow \begin{pmatrix} \textcircled{1} & 0 & 2 & 0 & 5 \\ 0 & \textcircled{1} & 1 & 0 & 9 \\ 0 & 0 & 0 & \textcircled{1} & -2 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix} = (\beta_1, \beta_2, \beta_3, \beta_4, \beta_5) = B$$

又因为

$$\begin{pmatrix} 2 \\ 1 \\ 0 \\ 0 \end{pmatrix} = 2 \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} + 1 \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix}; \quad \begin{pmatrix} 5 \\ 9 \\ -2 \\ 0 \end{pmatrix} = 5 \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} + 9 \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix} + (-2) \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix} \longrightarrow \begin{matrix} \beta_3 = 2\beta_1 + 1\beta_2; \\ \beta_5 = 5\beta_1 + 9\beta_2 - 2\beta_4 \end{matrix} \longrightarrow \begin{matrix} \alpha_3 = 2\alpha_1 + 1\alpha_2; \\ \alpha_5 = 5\alpha_1 + 9\alpha_2 - 2\alpha_4 \end{matrix}$$



3. 线性相关与线性无关

• 3.3 向量组的秩和极大线性无关组求解方法

- 例：设 $\alpha_1 = (1, 1, 2, 2)$, $\alpha_2 = (1, 2, 3, 4)$,
 $\alpha_3 = (2, 3, 5, 6)$, $\alpha_4 = (3, 4, 7, 8)$,

求：(1) 向量组的秩；(2) 向量组的极大线性无关组；
(3) 将其余向量表示为极大线性无关组的线性组合。

解：

$$\begin{array}{cccc} \alpha_1 & \alpha_2 & \alpha_3 & \alpha_4 \\ \left(\begin{array}{cccc} 1 & 1 & 2 & 3 \\ 1 & 2 & 3 & 4 \\ 2 & 3 & 5 & 7 \\ 2 & 4 & 6 & 8 \end{array} \right) & \xrightarrow{\text{行变换}} & \left(\begin{array}{cccc} 1 & 1 & 2 & 3 \\ 0 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 \\ 0 & 2 & 2 & 2 \end{array} \right) & \xrightarrow{\text{行变换}} & \left(\begin{array}{cccc} 1 & 0 & 1 & 2 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{array} \right) \end{array}$$

(1) 向量组的秩为 2;

(2) 极大线性无关组为 α_1, α_2 ;

(3) 线性组合关系为 $\alpha_3 = \alpha_1 + \alpha_2$, $\alpha_4 = 2\alpha_1 + \alpha_2$.

由于极大线性无关组是不惟一的，因此可以根据要求选择不同的极大线性无关组，此时只需按要求对矩阵继续进行行变换。



3. 线性相关与线性无关

• 3.3 向量组的秩和极大线性无关组求解方法

- **例：** 设 $\alpha_1 = (1, 1, 2, 2), \alpha_2 = (1, 2, 3, 4),$
 $\alpha_3 = (2, 3, 5, 6), \alpha_4 = (3, 4, 7, 8),$

求：(1) 向量组的秩；(2) 向量组的极大线性无关组；
(3) 将其余向量表示为极大线性无关组的线性组合。

解：

由于极大线性无关组是不惟一的，因此可以根据要求选择不同的极大线性无关组，此时只需按要求对矩阵继续进行行变换。

第一种选择

$$\begin{pmatrix} 1 & 0 & 1 & 2 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \xrightarrow[r_1 + (-2)r_2]{\text{行变换}} \begin{pmatrix} 1 & -2 & -1 & 0 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

极大线性无关组为 $\alpha_1, \alpha_4;$

线性组合关系为 $\alpha_2 = (-2)\alpha_1 + \alpha_4,$

$\alpha_3 = (-1)\alpha_1 + \alpha_4.$

第二种选择

$$\begin{pmatrix} 1 & 0 & 1 & 2 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \xrightarrow[r_2 + (-1)r_1]{\text{行变换}} \begin{pmatrix} 1 & 0 & 1 & 2 \\ -1 & 1 & 0 & -1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

极大线性无关组为 $\alpha_2, \alpha_3;$

线性组合关系为 $\alpha_1 = (-1)\alpha_2 + \alpha_3,$

$\alpha_4 = (-1)\alpha_2 + 2\alpha_3.$



3. 线性相关与线性无关

• 3.3 向量组的秩和极大线性无关组求解方法

• **推论1:** 若向量组 $\{\beta_1, \beta_2, \dots, \beta_n\}$ 可由 $\{\alpha_1, \alpha_2, \dots, \alpha_m\}$ 线性表示, 则
$$R\{\beta_1, \beta_2, \dots, \beta_n\} \leq R\{\alpha_1, \alpha_2, \dots, \alpha_m\}$$

• **推论2:** 矩阵相加秩的性质
$$r(A+B) \leq r(A) + r(B)$$

• **推论3:** 矩阵相乘秩的性质
$$r(A_{m \times s} B_{s \times n}) \leq \min(r(A_{m \times s}), r(B_{s \times n}))$$

工程视角

- 在 PyTorch / NumPy 中直接调用 `torch.linalg.matrix_rank(A)` 即可
- 工程上极少手动求极大无关组, 重点掌握其几何含义即可

3. 线性相关与线性无关

• 3.4 列空间、行空间、零空间及维数定理

- 矩阵的四个基本子空间
 - 由 [Gilbert Strang \(MIT\)](#) 提出

列空间 Column Space $C(A)$

定义：A的列向量的所有线性组合

$$C(A) = \{ Ax : x \in \mathbb{R}^n \}$$

所在空间： $\mathbb{R}^m$ （输出）

维数： $r = \text{rank}(A)$

行空间 Row Space $C(A^T)$

定义：A的行向量的所有线性组合

等价于 $C(A^T) = \{ A^T y \}$

所在空间： $\mathbb{R}^n$ （输入）

维数： $r = \text{rank}(A)$

零空间 Null Space / Kernel $N(A)$

定义： $Ax = 0$ 的所有解

$$N(A) = \{ x : Ax = 0 \}$$

所在空间： $\mathbb{R}^n$ （输入）

维数： $n - r$ （零化度）

左零空间 Left Null Space $N(A^T)$

定义： $A^T y = 0$ 的所有解

等价于 $y^T A = 0$

所在空间： $\mathbb{R}^m$ （输出）

维数： $m - r$

正交关系： $C(A^T) \perp N(A)$ （在 $\mathbb{R}^n$ 中）； $C(A) \perp N(A^T)$ （在 $\mathbb{R}^m$ 中）




3. 线性相关与线性无关

• 3.4 列空间、行空间、零空间及维数定理

- 矩阵的四个基本子空间

- 几何图示



- A 把行空间向量"可逆地"映射到列空间 (可逆映射, 维度相同都= r)
- 把零空间向量"压缩"为零

3. 线性相关与线性无关

- **3.4 列空间、行空间、零空间及维数定理**
 - 矩阵的四个基本子空间

子空间	计算方法	维数	注意
列空间 $C(A)$	初等行变换找主元列 $\rightarrow$ 取原A中对应列	r	必须用原矩阵的列，不能用变换后的
行空间 $C(A^T)$	行变换 $\rightarrow$ 行阶梯形 $\rightarrow$ 直接取非零行	r	与列空间相反，取变换后的行即可
零空间 $N(A)$	解齐次方程组 $Ax=0 \rightarrow$ 写出通解（自由变量参数化）	$n-r$	维数 = 自由变量个数
左零空间 $N(A^T)$	对 A^T 做行变换，解 $A^Ty=0$	$m-r$	维数定理： $r+(m-r)=m$

例： $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$

$\text{rank}=2 \rightarrow C(A)$ 由第1、2列张成;
 $N(A)$ 基为 $(1, -2, 1)^T$;
 $\dim(N(A^T))=3-2=1$



3. 线性相关与线性无关

- **3.4 列空间、行空间、零空间及维数定理**
 - 维数定理 (Rank-Nullity Theorem)

$$\text{rank}(A) + \text{nullity}(A) = n$$

n = 矩阵列数 (输入空间维数) | rank = 列秩 | nullity = 零空间维数 (零化度)

满秩方阵 $\text{rank}=n=m$

$\text{nullity}=0$
 $Ax=b$ 唯一解
→ A 可逆, 一一对应

列满秩 $\text{rank}=n<m$

$\text{nullity}=0$
最多一个解
→ 用最小二乘法

行满秩 $\text{rank}=m<n$

$\text{nullity}=n-m>0$
无穷多解
→ 选最小范数解

一般情形 $\text{rank}=r$

$\text{nullity}=n-r>0$
有解则无穷多
→ 低秩映射/降维

完整解 = 特解 x_p + 零空间中任意向量 x_n →

$$x = x_p + c_1 v_1 + c_2 v_2 + \dots + c_{\{n-r\}} v_{\{n-r\}}$$




3. 线性相关与线性无关

• 3.5 AI应用：PCA与线性子空间

➤ 主成分分析（Principal Component Analysis, PCA）

➤ 本质：找协方差矩阵列空间中方差最大的低维子空间



子空间含义：PCA保留协方差矩阵的行空间（主成分方向）；丢弃零空间（噪声方向）；主成分个数 k = 保留维数 = 有效秩

参考资料：


- [1] [主成分分析（PCA）原理详解](#)
- [2] [Principal Component Analysis](#)
- [3] [Eigenfaces for Face recognition](#)
- [4] [EigenFaces and A Simple Face Detector with PCA/SVD in Python](#)
- [5] [Linear Regression vs Logistic Regression](#)



3. 线性相关与线性无关


• 3.5 AI应用：PCA与线性子空间

- 主成分分析 (Principal Component Analysis, PCA)
- 特征脸 (EigenFaces)



- 线性回归
- 逻辑回归

<u>Linear Regression</u>	→	<u>Logistic Regression</u>
$f_{w,b}(x) = \sum_i w_i x_i + b$	→	$f_{w,b}(x) = \sigma\left(\sum_i w_i x_i + b\right)$
Output: any value	→	Output: between 0 and 1



参考资料:

- [1] [主成分分析 \(PCA\) 原理详解](#)
- [2] [Principal Component Analysis](#)
- [3] [Eigenfaces for Face recognition](#)
- [4] [EigenFaces and A Simple Face Detector with PCA/SVD in Python](#)
- [5] [Linear Regression vs Logistic Regression](#)

4. 矩阵的秩

- 4.1 矩阵秩的概念
- 4.2 初等变换求矩阵的秩
- 4.3 矩阵秩的性质
- 4.4 矩阵低秩近似与Eckart-Young定理
- 4.5 矩阵填充与推荐系统
- 4.6 核范数：秩的凸松弛



4. 矩阵的秩

• 4.1 矩阵秩的概念

- **定义1:** 在 $m \times n$ 矩阵 A 中任取 k 行和 k 列($k \leq m, k \leq n$), 由交点上的 k^2 个元素按照原顺序排成的 k 阶行列式, 称为矩阵 A 的 k 阶子行列式(简称 k 阶子式).

- $m \times n$ 矩阵 A 的 k 阶子式共有 $C_m^k C_n^k$ 个.
- 当一个 k 阶子式等于零时, 称为 k 阶零子式. (否则称为非零子式)

• 余子式与代数余子式

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}$$

a_{12} 元素的余子式

$$M_{12} = \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix}$$

a_{12} 元素的代数余子式

$$A_{12} = (-1)^{1+2} M_{12} = - \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix}$$



4. 矩阵的秩

• 4.1 矩阵秩的概念

- **定义1:** 在 $m \times n$ 矩阵 A 中任取 k 行和 k 列($k \leq m, k \leq n$), 由交点上的 k^2 个元素按照原顺序排成的 k 阶行列式, 称为矩阵 A 的 k 阶子行列式(简称 k 阶子式).

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \end{pmatrix}$$

一个二阶子式

$$\begin{vmatrix} a_{12} & a_{13} \\ a_{22} & a_{23} \end{vmatrix}$$

一个二阶子块

$$\begin{pmatrix} a_{12} & a_{13} \\ a_{22} & a_{23} \end{pmatrix}$$

4. 矩阵的秩

• 4.1 矩阵秩的概念

- **定义2:** 设矩阵A 中有一个不等于零的 r 阶子式D, 且所有 $r+1$ 阶子式 (如果存在的话) 全等于零, 那么D 称为矩阵A的最高阶非零子式, 数 r 称为矩阵A的秩, 记作 $R(A)$.

- 规定: 零矩阵的秩等于零

- 注:

- 矩阵A的秩就是A中非零子式的最高阶数 .
- 若A 为 $m \times n$ 矩阵, 则 $0 \leq R(A) \leq \min(m, n)$.

- 因为行列式与其转置行列式相等, 从而A和 A^T 中的子式对应相等:

$$R(A) = R(A^T)$$

- 对于矩阵的行阶梯形、行最简形、标准形, 矩阵的秩等于非零行的行数.



4. 矩阵的秩

• 4.1 矩阵秩的概念

- **例7:** 求矩阵A、B的秩 .

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 3 & -5 \\ 4 & 7 & 1 \end{pmatrix}$$

解:

在A中, 2阶子式 $\begin{vmatrix} 1 & 2 \\ 2 & 3 \end{vmatrix} \neq 0$.

A只有一个3阶子式, $|A| = 0$

→ $R(A) = 2$

$$B = \begin{pmatrix} 2 & 1 & 0 & 3 & -2 \\ 0 & 3 & 1 & 2 & 5 \\ 0 & 0 & 0 & 4 & 3 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

解:

B有3个非零行, 因此4阶子式全为0

$$\begin{vmatrix} 2 & -1 & 3 \\ 0 & 3 & -2 \\ 0 & 0 & 4 \end{vmatrix} = 24 \neq 0,$$

→ $R(B) = 3$



4. 矩阵的秩

• 4.1 矩阵秩的概念

- 设A 为n 阶方阵(其n 阶子式只有一个 $|A|$)

➤ 若 $|A| \neq 0$ (即A可逆)

↔ A有n 阶非零子式(最高阶的子式)

↔ $R(A) = n$

可逆矩阵又称为满秩矩阵。

➤ 若 $|A| = 0$ (即A不可逆)

↔ A非零子式的最高阶数 $< n$

↔ $R(A) < n$

不可逆矩阵又称为降秩矩阵。



4. 矩阵的秩

• 4.1 矩阵秩的概念

列空间视角

$\text{rank}(A)$
= 列向量张成空间的维数
= 列空间 $C(A)$ 的维数

行空间视角

$\text{rank}(A)$
= 行向量张成空间的维数
= 行空间 $C(A^T)$ 的维数

映射视角

$\text{rank}(A)$
= 线性映射 $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$
的像空间维数

信息视角

$\text{rank}(A)$
= 去掉冗余后
独立方向的个数

秩 = 矩阵表达的独立信息维数 (有效维度)

$\text{rank}(A)=0$	$\text{rank}(A)=1$	$\text{rank}(A)=2$	$\text{rank}(A)=n$ (满秩)
零矩阵 映射到原点	秩1矩阵 映射到一条线	映射到 一个平面	满秩映射 可逆, 无信息损失



4. 矩阵的秩

• 4.2 初等变换求矩阵秩

- 设 A 为任意一个 $m \times n$ 矩阵

$A \xrightarrow{\text{有限次初等行变换}} \text{行阶梯形矩阵}$

- **定理：** 初等行、列变换不改变矩阵的秩，
即：若 $A \sim B$ ，则 $R(A)=R(B)$

- **总结：**

- 利用定义：寻找矩阵中非零子式的最高阶数；
- 初等变换法：秩(A) = 行(列)阶梯形矩阵中非零行(列)的行(列)数

$A \xrightarrow{\text{初等变换}} \text{行(列)阶梯形矩阵}$



4. 矩阵的秩

• 4.2 初等变换求矩阵秩

• 例8:
$$A = \begin{pmatrix} 3 & 2 & 0 & 5 & 0 \\ 3 & -2 & 3 & 6 & -1 \\ 2 & 0 & 1 & 5 & -3 \\ 1 & 6 & -4 & -1 & 4 \end{pmatrix}$$

注意：行阶梯形矩阵的形式不是唯一的，与具体的变换步骤有关，但非零行的行数是唯一确定的。

求矩阵A的秩，并求出一个最高阶非零子式。

• 解：对A作初等行变换，将其化为行阶梯形。

$$A = \begin{pmatrix} 3 & 2 & 0 & 5 & 0 \\ 3 & -2 & 3 & 6 & -1 \\ 2 & 0 & 1 & 5 & -3 \\ 1 & 6 & -4 & -1 & 4 \end{pmatrix} \xrightarrow{r} \begin{pmatrix} 1 & 6 & -4 & -1 & 4 \\ 0 & -4 & 3 & 1 & -1 \\ 0 & 0 & 0 & 4 & -8 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix} = B$$

A的非零子式的最高阶数是3.

下面求一个3阶非零子式：在行阶梯形矩阵B中，三个非零行的首个非零元所在列分别为：第1、2、4列. 在A和B中分别取第1、2、4列，构成矩阵A1和B1



4. 矩阵的秩

• 4.2 初等变换求矩阵秩

• 例8:

$$A = \begin{pmatrix} 3 & 2 & 0 & 5 & 0 \\ 3 & -2 & 3 & 6 & -1 \\ 2 & 0 & 1 & 5 & -3 \\ 1 & 6 & -4 & -1 & 4 \end{pmatrix}$$

注意：行阶梯形矩阵的形式不是唯一的，与具体的变换步骤有关，但非零行的行数是唯一确定的。

求矩阵A的秩，并求出一个最高阶非零子式。

• 解：

$$A = \begin{pmatrix} 3 & 2 & 0 & 5 & 0 \\ 3 & -2 & 3 & 6 & -1 \\ 2 & 0 & 1 & 5 & -3 \\ 1 & 6 & -4 & -1 & 4 \end{pmatrix} \xrightarrow{r} \begin{pmatrix} 1 & 6 & -4 & -1 & 4 \\ 0 & -4 & 3 & 1 & -1 \\ 0 & 0 & 0 & 4 & -8 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix} = B$$
$$A_1 = \begin{pmatrix} 3 & 2 & 5 \\ 3 & -2 & 6 \\ 2 & 0 & 5 \\ 1 & 6 & -1 \end{pmatrix}$$
$$B_1 = \begin{pmatrix} 1 & 6 & -1 \\ 0 & -4 & 1 \\ 0 & 0 & 4 \\ 0 & 0 & 0 \end{pmatrix}$$

• (1) A的秩 $R(A)=3$

• (2) 计算 A_1 的前3行构成子式，

这个子式便是 A_1 的一个3阶非零子式，
同时也是A的一个3阶非零子式。

$$\begin{vmatrix} 3 & 2 & 5 \\ 3 & -2 & 6 \\ 2 & 0 & 5 \end{vmatrix} = -16 \neq 0.$$



4. 矩阵的秩

• 4.3 矩阵秩的性质

性质	公式	AI/工程含义
有界性	$0 \leq \text{rank}(A) \leq \min\{m, n\}$	数据维度的天然上界
等价不变	$A \sim B \Rightarrow \text{rank}(A) = \text{rank}(B)$	高斯消元求秩的理论基础
转置不变	$\text{rank}(A) = \text{rank}(A^T)$	$A^T A$ 和 $A A^T$ 有相同非零特征值 (SVD基础)
★可逆乘积不变	$P, Q \text{ 可逆} \rightarrow \text{rank}(PAQ) = \text{rank}(A)$	满秩分解与SVD的理论基础
增广	$\text{rank}(A) \leq \text{rank}([A, B]) \leq \text{rank}(A) + \text{rank}(B)$	特征增广的维数上界
★乘法不增秩	$\text{rank}(AB) \leq \min\{\text{rank}(A), \text{rank}(B)\}$	LoRA设计依据： $\text{rank}(AB^T) \leq r$ (低秩约束)
加法	$\text{rank}(A+B) \leq \text{rank}(A) + \text{rank}(B)$	特征融合时的维数上界
零乘积	$AB=0 \rightarrow \text{rank}(A) + \text{rank}(B) \leq n$	SVD正交性： $U^T U = I$ 的数学保证



4. 矩阵的秩

• 4.3 矩阵秩的性质

- **例9:** 设 A 为 n 阶方阵 ($n \geq 2$), 证明

$$R(A^*) = \begin{cases} n & \text{若 } R(A) = n \\ 1 & \text{若 } R(A) = n - 1 \\ 0 & \text{若 } R(A) < n - 1 \end{cases}$$

- **证明:**

- 若 $R(A) = n$, 则 A 可逆 $\rightarrow A^*$ 可逆 (伴随矩阵性质) $\rightarrow R(A^*) = n$
- 若 $R(A) < n - 1$, 则 A 的 $n - 1$ 阶子式全为零 $\rightarrow A^*$ 为零矩阵 $\rightarrow R(A^*) = 0$
- 若 $R(A) = n - 1$, 即 $R(A) < n \rightarrow |A| = 0 \rightarrow AA^* = |A|E = O$

$$\rightarrow R(A) + R(A^*) \leq n \rightarrow R(A^*) \leq n - R(A) = 1$$

又因为 $R(A) = n - 1 \rightarrow A$ 至少有一个 $n - 1$ 阶非零子式

$\rightarrow A^*$ 至少有 1 个非零元素

$\rightarrow R(A^*) \geq 1$

结合以上两式, 得 $R(A^*) = 1$.



4. 矩阵的秩

• 4.4 矩阵低秩近似与Eckart-Young定理

• 低秩近似的提出

- 实际数据矩阵（图像/推荐/文本）通常具有低秩结构：形式上是高维矩阵，但有效信息维度远低于矩阵的形式维数

应用场景	原始维度	有效秩 k	意义
图像压缩	$m \times n$ 像素	$k \ll \min(m, n)$	压缩比 n/k
推荐系统	百万 $\times$ 百万	10-100	隐因子模型
NLP	词汇 $\times$ 文档	100-300	潜在语义主题
基因组学	样本 $\times$ 基因	10-50	种群结构分析

• 低秩近似问题

- 给定矩阵 $A \in \mathbb{R}^{m \times n}$ ，找秩不超过 k 的矩阵 $\hat{A}_k$ ，使 $\|A - \hat{A}_k\|$ 最小
- Eckart-Young-Mirsky 定理



4. 矩阵的秩

• 4.4 矩阵低秩近似与Eckart-Young定理

• Eckart-Young定理

SVD分解 : $A = U\Sigma V^T = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_r u_r v_r^T$ ($\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$)

Eckart-Young-Mirsky 定理 (1936)

- 最优秩-k近似 : $\hat{A}_k = \sigma_1 u_1 v_1^T + \dots + \sigma_k u_k v_k^T$ (取前k个奇异值分量)
- 误差 : $\|A - A_k\|_F^2 = \sigma_{k+1}^2 + \dots + \sigma_r^2$ $\|A - \hat{A}_k\|_2 = \sigma_{k+1}$ (对任意rank $\leq k$ 的矩阵B, A_k 最优)

三层含义

- 最优秩-k 近似唯一确定 (由前 k 个奇异值给出)
- Frobenius 范数和谱范数下最优解相同
- 奇异值大小反映信息重要程度: σ_1 最大 $\rightarrow$ 最重要; σ_r 最小 $\rightarrow$ 最不重要

• 矩阵分解部分详细介绍



4. 矩阵的秩

• 4.5 矩阵填充与推荐系统

	电影A	电影B	电影C	电影D
用户1	5	?	3	?
用户2	?	4	?	2
用户3	3	?	?	5

• 问题：已知矩阵 A 的部分元素，恢复完整矩阵

要素	内容
问题背景	推荐系统：用户-物品评分矩阵中大多数评分缺失（约 99% 稀疏）
低秩假设	真实评分矩阵是低秩的：用户偏好由少数 k 个隐因子决定
数学公式	$\min \text{rank}(X) \text{ s.t. } X_{ij} = A_{ij}, (i,j) \in \Omega$ （已观测）
凸松弛	核范数最小化： $\min \ X\ _* \text{ s.t. } X_{ij} = A_{ij}$
工程方法	矩阵分解 ： $X = PQ^T$, $P \in \mathbb{R}^m (m \times k)$, $Q \in \mathbb{R}^n (n \times k)$

📌 Netflix Prize (100 万美元竞赛)

- 2006 年 Netflix 发布：约 1% 观测，预测缺失评分
- 获胜方案：协同过滤 + 矩阵分解（本质就是低秩矩阵填充）
- 可恢复性条件： $O(mn \log n)$ 个随机观测足以精确恢复（Candès-Recht 2009）



4. 矩阵的秩

• 4.5 核范数：秩的凸松弛

• 优美的类比：向量稀疏性 $\leftrightarrow$ 矩阵低秩性

• 直接最小化 $\text{rank}(X)$ 是 NP-hard 问题

对象	理想约束	凸松弛	理论保证
向量稀疏性	L0 范数: $\ x\ _0$ (NP-hard)	L1 范数: $\ x\ _1$ (线性规划)	RIP 条件下 L1 等价 L0 (Candès-Tao)
矩阵低秩性	秩: $\text{rank}(X)$ (NP-hard)	核范数: $\ X\ _*$ (半正定规划)	随机观测下等价于秩 (Candès-Recht)

🔑 三种范数的对比

- 核范数 $\|X\|_* = \sum_i \sigma_i$ (奇异值之和) $\rightarrow$ 促进低秩 (类比 L1)
- Frobenius $\|X\|_F = \sqrt{\sum \sigma_i^2}$ (奇异值的 L2) $\rightarrow$ 平滑收缩 (类比 L2)
- 谱范数 $\|X\|_2 = \sigma_1$ (最大奇异值) $\rightarrow$ 控制 Lipschitz 常数
- 关系: $\|X\|_2 \leq \|X\|_F \leq \|X\|_* \leq \sqrt{\text{rank}(X)} \cdot \|X\|_F$

4. 矩阵的秩

• 4.6 矩阵秩的应用

- 矩阵的秩反映了数据流形空间的维度
 - $R(A)=0$ 点
 - $R(A)=1$ 线
 - $R(A)=2$ 平面
- 应用
 - 数据降维
 - 低秩矩阵分解 ($A=B*C$) $R(A)<\min(R(B),R(C))$
 - SVD分解、QR分解、特征值分解等
 - 交叉验证
 - 矩阵填充($A=B+C$)
 - 图像修复
 - 协同过滤
 - 推荐系统

