

5. 矩阵的特征值与特征向量

- 5.1 向量的内积和正交化
- 5.2 矩阵的特征值与特征向量
- 5.3 相似矩阵
- 5.4 实对称矩阵的对角化
- 5.5 谱定理、矩阵的谱半径与收敛性



5. 矩阵的特征值与特征向量

- 5.1 向量的内积和正交化

- **定义1:** 设有n维向量

$$\alpha = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}, \quad \beta = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix},$$

(α, β)的内积定义为: $(\alpha, \beta) = \alpha^T \beta = a_1 b_1 + a_2 b_2 + \dots + a_n b_n$

说明: $n(n \geq 4)$ 维向量的内积是3维向量数量积的推广, 但是没有3维向量直观的几何意义。



5. 矩阵的特征值与特征向量

- 5.1 向量的内积和正交化

- 内积的运算性质

- $(\alpha, \beta) = (\beta, \alpha)$

- $(k\alpha, \beta) = k(\alpha, \beta);$

- $(\alpha + \beta, \gamma) = (\alpha, \gamma) + (\beta, \gamma);$

- $(\alpha, \alpha) \geq 0, (\alpha, \alpha) = 0$ 当且仅当 $\alpha = 0$.

- $(\alpha + \beta)^2 \leq (\alpha, \alpha) + (\beta, \beta)$ (施瓦兹不等式)

5. 矩阵的特征值与特征向量

- 5.1 向量的内积和正交化

- **定义2:** $(\alpha, \beta) = \arccos \frac{(\alpha, \beta)}{|\alpha||\beta|}$ ($|\alpha||\beta| \neq 0$) 称为向量间的夹角.

- **定义3:** 若 $(\alpha, \beta) = 0$, 则称 α 与 β 正交, 记作 $\alpha \perp \beta$.
注: 零向量与任何向量都正交.

- **定义4:** 若一非零向量组中的向量两两正交, 则称该向量组为正交向量组.

- 思考: 正交与独立同分布的异同?



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

- **定理1:** 若 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是正交向量组, 则该向量组线性无关。

- **证明:** 设 $k_1\alpha_1 + k_2\alpha_2 + \dots + k_r\alpha_r = 0, (k_i \in R, i = 1, 2, \dots, r)$
 $\rightarrow (\alpha_i, k_1\alpha_1 + k_2\alpha_2 + \dots + k_r\alpha_r) = 0, (i = 1, 2, \dots, r)$

$$\rightarrow k_1(\alpha_i, \alpha_1) + k_2(\alpha_i, \alpha_2) + \dots + k_r(\alpha_i, \alpha_r) = 0,$$

由于 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是正交向量组, 故当 $i \neq j$ 时 $(\alpha_i, \alpha_j) = 0$

$$\rightarrow k_i(\alpha_i, \alpha_i) = 0, \text{ 又因为 } \alpha_i \neq 0$$

$$\rightarrow k_i = 0 \ (i = 1, 2, \dots, r)$$



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

- **定义5:** 设 n 维向量 $e_1, e_2, \dots, e_n$ 是向量空间的一组基, 如果 $e_1, e_2, \dots, e_n$ 两两正交, 且都是单位向量, 则称其为**标准正交基**。

- 例 $e_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \\ 0 \end{pmatrix}, e_2 = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \\ 0 \\ 0 \end{pmatrix}, e_3 = \begin{pmatrix} 0 \\ 0 \\ 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, e_4 = \begin{pmatrix} 0 \\ 0 \\ 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}.$

- 同理可知 $\varepsilon_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \varepsilon_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \end{pmatrix}, \varepsilon_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}, \varepsilon_4 = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}.$ 也是一组正交基。

基 $\begin{matrix} \Leftarrow \\ \Rightarrow ? \end{matrix}$ 正交基 $\begin{matrix} \Leftarrow \\ \Rightarrow ? \end{matrix}$ 标准正交基



5. 矩阵的特征值与特征向量

- 5.1 向量的内积和正交化

- 施密特正交化 (Gram-Schmidt Orthogonalization)

- 施密特正交化是线性代数中一种将线性无关向量组转化为正交向量组的方法，核心思想是**通过逐次投影消除向量间的相关性，最终得到一组正交基**。
- 该方法在矩阵分解、特征值计算、机器学习（如主成分分析 PCA）等领域有重要应用。
- 前提与目标：
 - 前提：给定线性无关向量组 $\{\alpha_1, \alpha_2, \dots, \alpha_r\}$ ，构成向量空间A
 - 目标：构造正交向量组 $\{\beta_1, \beta_2, \dots, \beta_r\}$ ，构成正交向量空间B
- 思考：
 - 为什么“线性无关”还不够，很多算法还要追求“正交”？
 - 去掉投影这一步在几何上到底消除了什么？
 - 如果原始特征几乎共线，正交化后对回归会有什么影响？



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

- **施密特正交化过程：** 设 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是线性无关向量组，通过递归方法逐个构造正交向量，每次构造新向量时，减去其在已构造正交向量上的投影，以消除相关性。

➤ **正交化：** 取 $\beta_1 = \alpha_1$

$$\beta_2 = \alpha_2 - \frac{(\beta_1, \alpha_2)}{(\beta_1, \beta_1)} \beta_1,$$

$$\beta_3 = \alpha_3 - \frac{(\beta_1, \alpha_3)}{(\beta_1, \beta_1)} \beta_1 - \frac{(\beta_2, \alpha_3)}{(\beta_2, \beta_2)} \beta_2$$

$$\beta_r = \alpha_r - \frac{(\beta_1, \alpha_r)}{(\beta_1, \beta_1)} \beta_1 - \frac{(\beta_2, \alpha_r)}{(\beta_2, \beta_2)} \beta_2 - \Lambda - \frac{(\beta_{r-1}, \alpha_r)}{(\beta_{r-1}, \beta_{r-1})} \beta_{r-1}$$

➤ **单位化：** 取 $e_1 = \frac{\beta_1}{|\beta_1|}, e_2 = \frac{\beta_2}{|\beta_2|}, \Lambda \Lambda, e_r = \frac{\beta_r}{|\beta_r|},$





5. 矩阵的特征值与特征向量

- 5.1 向量的内积和正交化

- 例10:** 用施密特正交化方法, 将以下向量组**标准**正交化.

$$a_1 = (1, 1, 1, 1)^T, a_2 = (1, -1, 0, 4)^T, a_3 = (3, 5, 1, -1)^T$$

解:



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

• **例11:** 已知 $a_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$, 求一组非零向量 a_2, a_3 , 使得 a_1, a_2, a_3 正交

解: a_2, a_3 应满足方程 $a_1^T x = 0$, 即 $x_1 + x_2 + x_3 = 0$.

基础解系:

$$\xi_1 = \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}, \xi_2 = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix}.$$

把基础解系正交化, 即为所求. 令

$$a_2 = \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}, \quad a_3 = \begin{pmatrix} 0 \\ 1 \\ -1 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} -1 \\ 2 \\ -1 \end{pmatrix}.$$



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

- **定义6:** 若 n 阶实矩阵满足 $AA^T = E$, 则称 A 为正交矩阵

$$A^T A = E \Leftrightarrow \begin{pmatrix} a_{11} & a_{21} & \mathbf{L} & a_{n1} \\ a_{12} & a_{22} & \mathbf{L} & a_{n2} \\ \mathbf{L} & \mathbf{L} & \mathbf{L} & \mathbf{L} \\ a_{1n} & a_{2n} & \mathbf{L} & a_{nn} \end{pmatrix} \begin{pmatrix} a_{11} & a_{12} & \mathbf{L} & a_{1n} \\ a_{21} & a_{22} & \mathbf{L} & a_{2n} \\ \mathbf{L} & \mathbf{L} & \mathbf{L} & \mathbf{L} \\ a_{n1} & a_{n2} & \mathbf{L} & a_{nn} \end{pmatrix} = E$$

- **推论:** 正交矩阵 A 的逆矩阵 $A^{-1} = A^T$
 - 正交矩阵的逆等于其转置 ($A^{-1}=A^T$) , 计算量从 $O(n^3)$ 降到 $O(n^2)$, 这在AI中意义巨大。



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

- **定理2:** A为正交矩阵的**充要条件**是A的列(行) 向量都是单位向量且两两正交 .

- **证明:**

$$\Leftrightarrow \begin{pmatrix} \alpha_1^T \\ \alpha_2^T \\ \mathbf{M} \\ \alpha_n^T \end{pmatrix} (\alpha_1, \alpha_2, \mathbf{L}, \alpha_n) = E \Leftrightarrow \begin{pmatrix} \alpha_1^T \alpha_1 & \alpha_1^T \alpha_2 & \mathbf{L} & \alpha_1^T \alpha_n \\ \alpha_2^T \alpha_1 & \alpha_2^T \alpha_2 & \mathbf{L} & \alpha_2^T \alpha_n \\ \mathbf{M} & \mathbf{M} & \mathbf{M} & \mathbf{M} \\ \alpha_n^T \alpha_1 & \alpha_n^T \alpha_2 & \mathbf{L} & \alpha_n^T \alpha_n \end{pmatrix} = E$$

$$\Leftrightarrow \alpha_i^T \alpha_j = \delta_{ij} = \begin{cases} 1, & \text{当 } i = j; \\ 0, & \text{当 } i \neq j \end{cases} \quad (i, j = 1, 2, \mathbf{L}, n)$$

由此可知A的列向量组构成一个标准正交基，同理行向量组也是。



5. 矩阵的特征值与特征向量

- 5.1 向量的内积和正交化

- **例12:** 判别下列矩阵是否为正交矩阵 .

$$\begin{pmatrix} \frac{1}{9} & -\frac{8}{9} & -\frac{4}{9} \\ -\frac{8}{9} & \frac{1}{9} & -\frac{4}{9} \\ -\frac{4}{9} & -\frac{4}{9} & \frac{7}{9} \end{pmatrix}$$



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

• 定理3: A, B 是 n 阶正交矩阵

性质	公式/结论	证明思路	AI含义
积是正交矩阵	A, B 正交 $\rightarrow AB$ 正交	$(AB)^T(AB) = B^T A^T AB = B^T IB = I$	正交变换复合仍是正交变换 (旋转 $\times$ 旋转=旋转)
行列式为 ± 1	$ A = \pm 1$ $ A =1$ 为旋转, $ A =-1$ 含反射	$ A^T A = I \rightarrow A ^2 = 1$	$ A =1$: 保向旋转; $ A =-1$: 含翻转的等距变换
逆是正交矩阵	A 正交 $\rightarrow A^{-1} = A^T$ 也正交	$(A^T)^T A^T = AA^T = I$	逆变换成本极低 转置 $O(n^2)$ 而非求逆 $O(n^3)$
转置是正交矩阵	A 正交 $\rightarrow A^T$ 也正交	$A^T(A^T)^T = A^T A = I$	在神经网络中正交权重初始化可双向传播梯度



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

• **例13:** A, B 都是 n 阶正交矩阵, 且 $|A|=1$, $|B|=-1$, 求 $|A+B|$.

解: 由于 $AA^T = E$, $BB^T = E$, 可知:

$A^{-1} = A^T$, $B^{-1} = B^T$, 于是

$$\begin{aligned} |A+B| &= |EA + BE| = |BB^{-1}A + BA^{-1}A| \\ &= |B(B^{-1} + A^{-1})A| = |B||B^{-1} + A^{-1}||A| \\ &= -|B^{-1} + A^{-1}| = -|A^T + B^T| \\ &= -|(A+B)^T| = -|A+B| \quad \longrightarrow \quad |A+B| = 0 \end{aligned}$$



5. 矩阵的特征值与特征向量

• 5.1 向量的内积和正交化

• 将矩阵（或向量组）进行正交化的优势

• 简化计算与几何直观

- **内积为零的便利性**：正交向量组中任意两个不同向量的内积为零，这使得在投影、坐标分解等运算中大幅简化计算。
- **几何解释清晰**：正交向量组在几何上对应相互垂直的坐标轴，便于直观理解数据在不同维度上的独立贡献。

• 数值稳定性与矩阵分解

- **避免病态矩阵问题**：非正交的向量组在计算逆矩阵或解线性方程组时容易出现数值不稳定的问题，正交矩阵的逆矩阵等于其转置，计算简单且数值稳定性强。
- **矩阵QR分解的基础**：任意矩阵可分解为正交矩阵 Q 和上三角矩阵 R 的乘积 ($A=QR$)，正交化是 QR 分解的核心步骤。
- **矩阵特征值分解、奇异值分解 (SVD)** 中，正交矩阵是分解的基础组件，用于提取数据的正交基。

• 特征提取与降维

• 优化算法与几何变换



5. 矩阵的特征值与特征向量

- 5.1 向量的内积和正交化

- 正交矩阵在机器学习中的应用：

- **特征提取和降维：**在PCA（主成分分析）中，协方差矩阵 Σ 的特征向量矩阵 Q 是正交矩阵，满足 $Q^T \Sigma Q = \Lambda$ 。正交矩阵可以被用来旋转、反射和平移数据点，将数据点从原始空间映射到一个新空间，使得新空间中的每个特征之间相互独立，从而进行降维并且去除冗余信息。
- **线性回归：**在线性回归中，正交矩阵可以用于求解最小二乘法，从而得到最优解。正交矩阵的特殊性质可以大大简化计算过程，并减少误差的影响。
- **图像处理：**在图像处理中，正交矩阵可以用于旋转、缩放、平移图像，或者进行图像的傅里叶变换。正交矩阵的性质可以确保变换后的图像保持清晰和准确。
- **神经网络正交权重初始化（Orthogonal Initialization）：**初始化权重矩阵为正交矩阵，使得前向传播时各层输出的范数保持稳定（等距映射），避免梯度消失/爆炸，正交变换不改变向量的L2范数，梯度不会被指数放大或压缩。
PyTorch实现： `torch.nn.init.orthogonal_(layer.weight)`
- **矩阵分解：**矩阵的三角分解，将矩阵分解为正交矩阵和上三角矩阵的乘积



5. 矩阵的特征值与特征向量

• 5.2 矩阵的特征值和特征向量

• Q: 当一个矩阵作用在向量上的时候, 会发生什么?

- 给定矩阵 A , 再给一个向量 x 。当做矩阵乘法 Ax 的时候, 得到的新向量 Ax 和原向量 x 之间, 会有什么关系?

- 例: $A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$

- 若 $x = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, 则 $Ax = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 0 \end{pmatrix} = 2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 2x$

- 方向没变, 只是长度变成了 2 倍

- 若 $x = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$, 则 $Ax = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 3 \end{pmatrix} = 3 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = 3x$

- 方向不变, 长度变成了 3 倍

- 若 $x = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$, 则 $Ax = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$

- 方向改变, 原来是 45° 方向, 现在变成了别的角度

对于一个给定的矩阵 A , 到底是哪些'特殊'的向量, 会拥有'方向不变'这种神奇的性质?



5. 矩阵的特征值与特征向量

• 5.2 矩阵的特征值和特征向量

- **定义8:** 设A为n阶方阵, 若存在数 λ 和n 维非零向量x, 使得 $Ax = \lambda x$ 则称 λ 是A的一个**特征值**, x为矩阵A属于特征值 λ 的**特征向量**

$$Ax = \lambda x \rightarrow (\lambda E - A)X = 0$$

- **特征值性质:** 若A的特征值是 λ , x是A的属于 λ 的特征向量, 则
 - (1) kA 的特征值是 $k\lambda$. (k 是任意常数)
 - (2) A^m 的特征值是 λ^m . (m 是任意整数)
 - (3) 若A可逆, 则 A^{-1} 的特征值是 λ^{-1} , 伴随矩阵 A^* 的特征值是 $\frac{|A|}{\lambda}$.
且x 仍然是矩阵 kA , A^m , A^{-1} , A^* 分别对应于 $k\lambda$, λ^m , λ^{-1} , $\frac{|A|}{\lambda}$ 的特征向量。

几何直觉: $Ax = \lambda x$ 意味着"A对向量x的作用仅仅是拉伸 ($\lambda > 0$) 或反向拉伸 ($\lambda < 0$) 或压缩, 方向不变".



5. 矩阵的特征值与特征向量

• 5.2 矩阵的特征值和特征向量

• **证明(3)**：当A可逆时，特征值 λ 不为0. 由 $Ax = \lambda x$ 得

$$1、A^{-1}(Ax) = A^{-1}(\lambda x) = \lambda A^{-1}x$$

$$\Rightarrow A^{-1}x = \lambda^{-1}x$$

$$2、A^*(Ax) = A^*(\lambda x) = \lambda A^*x = |A|x$$

$$\Rightarrow A^*x = \frac{|A|}{\lambda}x$$

- **特征值性质**：若A的特征值是 λ ， x 是A的属于 λ 的特征向量，则
- (4) $f(x)$ 为 x 的多项式，则 $f(A)$ 的特征值为 $f(\lambda)$
 - (5)方阵A的属于不同特征值的特征向量线性无关
 - (6)矩阵A 和 A^T 的特征值相同



5. 矩阵的特征值与特征向量

- 5.2 矩阵的特征值和特征向量

- 求特征值、特征向量的步骤：

- 写出特征方程 $|\lambda E - A| = 0$ ，求其所有的根，即可求出特征值 λ ；
- $Ax = \lambda x \rightarrow (\lambda E - A)x = 0$ ，求该齐次线性方程组的一个基础解系；
- 特征向量=基础解系的所有非零线性组合（注意：不包含零向量）



5. 矩阵的特征值与特征向量

• 5.2 矩阵的特征值和特征向量

• **例13:** 求矩阵A的特征值和特征向量 $A = \begin{pmatrix} 4 & 6 & 0 \\ -3 & -5 & 0 \\ -3 & -6 & 1 \end{pmatrix}$

解:
$$f(\lambda) = |\lambda E - A| = \begin{vmatrix} \lambda - 4 & -6 & 0 \\ 3 & \lambda + 5 & 0 \\ 3 & 6 & \lambda - 1 \end{vmatrix} = (\lambda - 1)^2 (2 + \lambda)$$

所以, A的特征值为 $\lambda_1 = \lambda_2 = 1$, $\lambda_3 = -2$

① $\lambda_1 = \lambda_2 = 1$, 解 $(E - A)x = 0$, 基础解系如下:

$$\xi_1 = \begin{pmatrix} -2 \\ 1 \\ 0 \end{pmatrix}, \xi_2 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \quad k_1 \xi_1 + k_2 \xi_2$$

② $\lambda_3 = -2$, 解 $(-2E - A)x = 0$, 基础解系如下:

$$\xi_3 = \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} \quad k_3 \xi_3 \quad (k_3 \neq 0)$$



5. 矩阵的特征值与特征向量

• 5.2 矩阵的特征值和特征向量

- **例：**求矩阵A的特征值和特征向量 $A = \begin{pmatrix} -1 & 1 & 0 \\ -4 & 3 & 0 \\ 1 & 0 & 2 \end{pmatrix}$

解： Step 1 : $\det(\lambda E - A) = (\lambda - 2)(\lambda - 1)^2 = 0 \rightarrow \lambda_1 = \lambda_2 = 1$ (二重根), $\lambda_3 = 2$

Step 2a : $\lambda_1 = \lambda_2 = 1$, 解 $(E - A)x = 0$

$$E - A = \begin{bmatrix} 2 & -1 & 0 \\ 4 & -2 & 0 \\ -1 & 0 & -1 \end{bmatrix} \rightarrow \text{行化简} \rightarrow \text{rank} = 2$$

基础解系 : $\xi_1 = (1, 2, -1)^T$

Step 2b : $\lambda_3 = 2$, 解 $(2E - A)x = 0$

$$2E - A = \begin{bmatrix} 3 & -1 & 0 \\ 4 & -1 & 0 \\ -1 & 0 & 0 \end{bmatrix} \rightarrow \text{rank} = 3 \dots \rightarrow$$

基础解系 : $\xi_2 = (0, 0, 1)^T$

注意： $\text{rank}(\lambda_i E - A)$ 决定特征向量个数，这是后续矩阵可对角化条件的核心。



5. 矩阵的特征值与特征向量

• 5.2 矩阵的特征值和特征向量

• $Ax = \lambda x$ 特征值和特征向量的物理含义：

- 矩阵的特征值和特征向量本质是揭示线性变换矩阵 A 的“方向”和“尺度”—特征向量 x 表示变换中保持方向不变的轴，特征值 λ 表示该方向上的缩放因子。
- **特征向量 x ：变换的“不变方向”。**特征向量代表了矩阵变换中“不旋转、只缩放”的方向。例如，在图像旋转缩放变换中，特征向量对应于旋转轴方向，特征值对应缩放比例。
- **特征值：方向上的“能量 / 重要性”。**特征值的绝对值越大，对应特征向量方向上的变换强度越大（缩放更剧烈）。在数据分布中（如协方差矩阵），特征值表示数据在特征向量方向上的方差，反映该方向上的信息丰富度。例如，特征值大的方向意味着数据在该维度上分布更分散，携带更多有效信息。

注意：

特征向量的非唯一性：同一特征值 λ 对应的特征向量构成线性子空间（特征子空间），基础解系不唯一，但维数（几何重数）唯一。

代数重数 vs 几何重数： λ 在特征多项式中的重数=代数重数；对应线性无关特征向量个数=几何重数。**几何重数 $\leq$ 代数重数。**

常见错误：**特征向量不能是零向量（定义中明确要求 $x \neq 0$ ）！**

大数计算中 $\det(\lambda E - A)$ 展开极其繁琐，实际用迭代法（幂法、QR算法），手算仅限 3×3 以内。



5. 矩阵的特征值与特征向量

- 5.2 矩阵的特征值和特征向量

- **特征值和特征向量在机器学习中的应用：**

- **主成分分析（PCA）：降维与特征提取**

- 核心原理：

- 计算数据的协方差矩阵 Σ ，其特征向量对应数据的主成分方向，特征值对应各方向的方差。
 - 按特征值从大到小排序，选择前 k 个最大特征值对应的特征向量，构成投影矩阵，将原始数据投影到低维空间。

- 物理含义：

- 特征值越大，对应主成分方向上的数据波动越大（信息越多），降维时优先保留。
 - 例如，人脸数据集的协方差矩阵特征向量（“特征脸”）对应人脸的主要变化模式（如表情、姿态），特征值表示该模式的贡献度。

- **数据表示与结构分析：将数据映射到特征向量张成的正交空间，揭示潜在模式（如谱聚类、LDA）**

- **模型稳定性与优化：分析权重矩阵或 Hessian 矩阵的特征值，指导网络训练和算法设计**



5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

- **定义9:** 设A与B是n阶方阵, 若存在一个可逆矩阵P, 使得:

$$B = P^{-1}AP$$

则称B与A相似, 记作 $A \sim B$ 。

- **矩阵相似的性质:**

性质	结论	证明关键	几何含义
等价关系	反身性 $A \sim A$; 对称性 $A \sim B \Rightarrow B \sim A$; 传递性 $A \sim B, B \sim C \Rightarrow A \sim C$	$P=I$, 互换 P^{-1} , 复合可逆矩阵	"相似"是矩阵之间的等价关系, 同一等价类中的矩阵描述同一线性变换
行列式相同	$\det(A) = \det(B)$	$\det(P^{-1}AP) = \det(P^{-1})\det(A)\det(P) = \det(A)$	行列式是线性变换的体积缩放因子, 与坐标系选取无关
迹相同	$\text{tr}(A) = \text{tr}(B)$	迹=特征值之和, 相似矩阵特征值相同	迹是线性变换的"总缩放率", 基不变量
特征值相同	A,B的特征多项式相同 $\rightarrow$ 特征值相同	$\det(\lambda I - P^{-1}AP) = \det(P^{-1}(\lambda I - A)P) = \det(\lambda I - A)$	特征值是线性变换本身的属性, 不依赖于坐标系
秩相同	$\text{rank}(A) = \text{rank}(B)$	可逆矩阵乘积不改变秩	维数定理: 像空间维数与坐标系无关

- 相似矩阵的几何本质: A和B描述的是同一个线性变换, 只是在不同的基(坐标系)下表示, P是基变换矩阵。
- 相似矩阵共享"体质"(行列式、迹、特征值、秩、特征多项式), 但"外貌"(具体元素)不同。



5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

• **推论1:** 若 n 阶方阵 A 与对角矩阵 $\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ 相似, 则 $\lambda_1, \lambda_2, \dots, \lambda_n$ 即是 A 的特征值.

• **推论2:** 对 n 阶方阵 A , 若存在可逆矩阵 P , 使得 $P^{-1}AP = \Lambda$ 为对角矩阵, 则方阵 A 可对角化.

证明: 若 $P^{-1}AP = \Lambda$ 为对角矩阵, 则 $A^k = P \Lambda^k P^{-1}$, $\phi(A) = P\phi(\Lambda)P^{-1}$

$$\Lambda^k = \begin{pmatrix} \lambda_1^k & & & \\ & \lambda_2^k & & \\ & & \ddots & \\ & & & \lambda_n^k \end{pmatrix}, \quad \phi(\Lambda) = \begin{pmatrix} \phi(\lambda_1) & & & \\ & \phi(\lambda_2) & & \\ & & \ddots & \\ & & & \phi(\lambda_n) \end{pmatrix},$$

利用上述结论可以很方便地计算矩阵 A 的多项式 $\phi(A)$.



5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

- **定理6:** n 阶方阵 A 可对角化的充分必要条件是 A 有 n 个线性无关的特征向量.

证明: 设存在可逆阵 P , 使 $P^{-1}AP = \Lambda$ 为对角阵, 把 P 用其列向量表示为 $P = (p_1, p_2, \dots, p_n)$, 由 $P^{-1}AP = \Lambda$ 得 $AP = P\Lambda$

$$\begin{aligned} A(p_1, p_2, \dots, p_n) &= AP = A(p_1, p_2, \dots, p_n) = (Ap_1, Ap_2, \dots, Ap_n) \\ &= (p_1, p_2, \dots, p_n) \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{pmatrix} = (\lambda_1 p_1, \lambda_2 p_2, \dots, \lambda_n p_n) \\ &= (\lambda_1 p_1, \lambda_2 p_2, \dots, \lambda_n p_n). \end{aligned}$$
$$\begin{aligned} \therefore P^{-1}AP &= \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{pmatrix} \\ &= (p_1, p_2, \dots, p_n) \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{pmatrix} = P \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{pmatrix} \end{aligned}$$

引理: 对于 n 阶方阵 A , 属于其不同特征值的特征向量必线性无关。



5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

• **例：** 设 $A = \begin{pmatrix} 4 & 6 & 0 \\ -3 & -5 & 0 \\ -3 & -6 & 1 \end{pmatrix}$, A能否对角化?

$$\text{解: } f(\lambda) = |\lambda E - A| = \begin{vmatrix} \lambda - 4 & -6 & 0 \\ 3 & \lambda + 5 & 0 \\ 3 & 6 & \lambda - 1 \end{vmatrix} = (\lambda - 1)^2(2 + \lambda)$$

所以, A的特征值为 $\lambda_1 = \lambda_2 = 1, \lambda_3 = -2$

当 $\lambda_1 = \lambda_2 = 1$ 时, 解方程组 $(E - A)x = 0$, 得基础解系 $\xi_1 = \begin{pmatrix} -2 \\ 1 \\ 0 \end{pmatrix}, \xi_2 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$

当 $\lambda = -2$ 时, 解方程 $(-2E - A)x = 0$, 得基础解系 $\xi_3 = \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix}$.

由于 $\begin{vmatrix} -2 & 0 & -1 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{vmatrix} = 1 \neq 0 \Rightarrow \xi_1, \xi_2, \xi_3$ 线性无关 $\Rightarrow A$ 可以对角化.

令 $P = (\xi_1, \xi_2, \xi_3) = \begin{pmatrix} -2 & 0 & -1 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{pmatrix}$, 则有 $P^{-1}AP = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -2 \end{pmatrix}$



5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

• **例：** 设 $A = \begin{pmatrix} 4 & 6 & 0 \\ -3 & -5 & 0 \\ -3 & -6 & 1 \end{pmatrix}$, A 能否对角化?

解: $f(\lambda) = \begin{vmatrix} \lambda - 4 & -6 & 0 \\ 3 & \lambda + 5 & 0 \\ 3 & 6 & \lambda - 1 \end{vmatrix} = (\lambda - 4)(\lambda + 5)(\lambda - 1)$

注意

所以, A 有三个互异的特征值
当 $\lambda_1 = 4$ 时, 解方程 $(A - 4I)\xi = 0$, 得 $\xi_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$

当 $\lambda = -2$ 时

则有 $P^{-1}AP = \begin{pmatrix} -2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$.

由于 $|A - \lambda_1 I| = 0$

即矩阵 P 的列向量和对角矩阵中特征值的位置要相互对应.

令 $P = (\xi_1, \xi_2, \xi_3) = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & -2 \end{pmatrix}$, 则有 $P^{-1}AP = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & -2 \end{pmatrix}$



5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

• **例：** $A = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 1 & x \\ 1 & 0 & 0 \end{pmatrix}$ 问 x 为何值时，矩阵 A 可以对角化？

解： $|\lambda E - A| = \begin{vmatrix} \lambda & 0 & -1 \\ -1 & \lambda - 1 & -x \\ -1 & 0 & \lambda \end{vmatrix} = (\lambda - 1) \begin{vmatrix} \lambda & -1 \\ -1 & \lambda \end{vmatrix} = (\lambda - 1)^2 (\lambda + 1)$

$$\lambda_1 = -1, \lambda_2 = \lambda_3 = 1$$

$\lambda_2 = \lambda_3 = 1$ 有2个线性无关的特征向量时，

$R(E - A) = 1$ $E - A = \begin{pmatrix} 1 & 0 & -1 \\ -1 & 0 & -x \\ -1 & 0 & 1 \end{pmatrix} \sim \begin{pmatrix} 1 & 0 & -1 \\ 0 & 0 & x+1 \\ 0 & 0 & 0 \end{pmatrix} \rightarrow x = -1$

解空间的个数为方阵维数 n 减去其秩 $R(A)$



5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

• **例：** $A = \begin{pmatrix} 1 & -1 & 1 \\ 2 & 4 & -2 \\ -3 & -3 & a \end{pmatrix}$ $B = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & b \end{pmatrix}$ 且A与B相似，求 a, b 的值。

解：因为A与B相似，所以它们有相同的特征值 $2, 2, b$

$$\begin{cases} |A| = 4b \\ 1 + 4 + a = 2 + 2 + b \end{cases} \rightarrow a=5, b=6$$

方阵特征值之和等于其主对角线元素之和（矩阵的迹）

5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

• 由特征值、特征向量求矩阵

已知方阵A 的特征值是 $\lambda_1 = 0, \lambda_2 = 1, \lambda_3 = 3$,

相应的特征向量是 $\eta_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \eta_2 = \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}, \eta_3 = \begin{pmatrix} 1 \\ -2 \\ 1 \end{pmatrix}$, 求A.

分析: 令 $P = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 0 & -2 \\ 1 & -1 & 1 \end{pmatrix}, \Lambda = \begin{pmatrix} 0 & & \\ & 1 & \\ & & 3 \end{pmatrix},$

则 $P^{-1}AP = \Lambda$

$$\therefore A = P\Lambda P^{-1} = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{pmatrix}$$



5. 矩阵的特征值与特征向量

- 5.3 相似矩阵

- 求方阵的幂

- **例：** 设 $A = \begin{pmatrix} 4 & -5 \\ 2 & -3 \end{pmatrix}$, 求 A^{100} .

解： $A^{100} = P\Lambda^{100}P^{-1}$

$$= \begin{pmatrix} 1 & 5 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} (-1)^{100} & 0 \\ 0 & 2^{100} \end{pmatrix} \frac{1}{3} \begin{pmatrix} -2 & 5 \\ 1 & -1 \end{pmatrix}$$



5. 矩阵的特征值与特征向量

• 5.3 相似矩阵

- **矩阵对角化**的本质是存在一组完整的**特征向量基**，使得矩阵在该基下的表示为对角矩阵。
 - **对角化作用**：特征值对应的特征向量构成数据的主要变化方向，低维隐变量通过线性组合生成高维样本，实现数据压缩与重构。
- **矩阵对角化**在机器学习中的本质是利用特征向量的正交基分解复杂变换，将原问题转化为特征值控制的独立维度问题，从而
 - **降维**：剔除冗余信息，保留关键特征（如 PCA、LDA）。
 - **解耦**：将耦合的多维问题分解为独立的一维问题（如优化算法）。
 - **结构揭示**：通过特征值的大小或符号揭示数据的内在结构（如谱聚类、生成模型）。
 - **矩阵变换**：**相似矩阵变换**的本质是对线性变换在不同基下的表现，并且在机器学习中有广泛的应用。比如，在图像处理中，可以对图像矩阵进行相似矩阵变换，实现图像的旋转、缩放等操作。如PCA算法就是通过特征值分解实现矩阵变换，从而进行无监督降维，提取图像特征等任务。



5. 矩阵的特征值与特征向量

• 5.4 实对称矩阵的对角化（特征分解特例）

- **定理7：** 实对称矩阵的特征值为实数.
- **定理8：** 设 λ 是 n 阶实对称矩阵 A 的 k 重特征值，则 A 的属于特征值 λ 的线性无关的特征向量个数恰为 k 。即： $R(\lambda E - A) = n - k$
- **定理9：** 设 λ_1, λ_2 是对称矩阵 A 的两个特征值， p_1, p_2 是对应的特征向量，若 $\lambda_1 \neq \lambda_2$ ，则 p_1 与 p_2 正交。

证明 $\lambda_1 p_1 = A p_1, \quad \lambda_2 p_2 = A p_2, \quad \lambda_1 \neq \lambda_2,$

$\because A$ 对称, $A = A^T,$

$$\therefore \lambda_1 p_1^T = (\lambda_1 p_1)^T = (A p_1)^T = p_1^T A^T = p_1^T A,$$

于是 $\lambda_1 p_1^T p_2 = p_1^T A p_2 = p_1^T (\lambda_2 p_2) = \lambda_2 p_1^T p_2,$

$$\Rightarrow (\lambda_1 - \lambda_2) p_1^T p_2 = 0.$$

$$\because \lambda_1 \neq \lambda_2, \quad \therefore p_1^T p_2 = 0. \quad \text{即 } p_1 \text{ 与 } p_2 \text{ 正交.}$$

- **定理10：** 设 A 为 n 阶对称矩阵, 则必有正交矩阵 P , 使 $P^{-1}AP = \Lambda$.



5. 矩阵的特征值与特征向量

- 5.4 实对称矩阵的对角化（特征分解特例）

- 求正交矩阵 P 使 $P^{-1}AP$ 为对角矩阵的具体步骤如下:

- 求出 A 的所有不同的特征值 $\lambda_1, \lambda_2, \dots, \lambda_s$.
- 求出 A 对应每个特征值 λ_i 的线性无关的特征向量.
- 将对应的特征向量进行单位正交化处理
- 以求出的 n 个两两正交的单位特征向量作为列向量，所得的 n 阶方阵即为所求的正交矩阵 P



5. 矩阵的特征值与特征向量

• 5.4 实对称矩阵的对角化（特征分解特例）

• **例：** 设 $A = \begin{pmatrix} 1 & 2 & 2 \\ 2 & 1 & 2 \\ 2 & 2 & 1 \end{pmatrix}$ ，求正交矩阵 P ，使 $P^{-1}AP$ 为对角矩阵。

解： 显然 $A^T = A$ ，故一定存在正交矩阵 P ，使 $P^{-1}AP$ 为对角矩阵。

$$|\lambda E - A| = \begin{vmatrix} \lambda - 1 & -2 & -2 \\ -2 & \lambda - 1 & -2 \\ -2 & -2 & \lambda - 1 \end{vmatrix} = (\lambda + 1)^2(\lambda - 5) \Rightarrow \lambda_1 = \lambda_2 = -1, \lambda_3 = 5.$$

对于 $\lambda_1 = \lambda_2 = -1$ 解齐次线性方程组 $(-E - A)x = 0$ ，求得唯一解 $\alpha_1 = \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \alpha_2 = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$

正交化，令 $\beta_1 = \alpha_1 = \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \beta_2 = \alpha_2 - \frac{(\beta_1, \alpha_2)}{(\beta_1, \beta_1)}\beta_1 = \begin{pmatrix} -1/2 \\ -1/2 \\ 1 \end{pmatrix}$

再单位化，令 $\gamma_1 = \frac{\beta_1}{|\beta_1|} = \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \end{pmatrix}, \gamma_2 = \frac{\beta_2}{|\beta_2|} = \begin{pmatrix} -\sqrt{6}/6 \\ -\sqrt{6}/6 \\ \sqrt{6}/3 \end{pmatrix}$



5. 矩阵的特征值与特征向量

• 5.4 实对称矩阵的对角化（特征分解特例）

• **例：** 设 $A = \begin{pmatrix} 1 & 2 & 2 \\ 2 & 1 & 2 \\ 2 & 2 & 1 \end{pmatrix}$ ，求正交矩阵 P ，使 $P^{-1}AP$ 为对角矩阵。

解(续)： 对于 $\lambda_3 = 5$ ，解齐次线性方程组 $(5E - A)x = 0$ ，求得一基础解系为 $\alpha_3 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$

只有一个向量，只要单位化，得 $\gamma_3 = \frac{\alpha_3}{|\alpha_3|} = \begin{pmatrix} 1/\sqrt{3} \\ 1/\sqrt{3} \\ 1/\sqrt{3} \end{pmatrix}$

令 $P = \begin{pmatrix} -1/\sqrt{2} & -\sqrt{6}/6 & 1/\sqrt{3} \\ 1/\sqrt{2} & -\sqrt{6}/6 & 1/\sqrt{3} \\ 0 & \sqrt{6}/3 & 1/\sqrt{3} \end{pmatrix}$ ，则有 $P^{-1}AP = \begin{pmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 5 \end{pmatrix}$



5. 矩阵的特征值与特征向量

• 5.4 实对称矩阵的对角化（特征分解特例）

• **例：** 设3阶实对称矩阵 A 的特征值为 $\lambda_1 = 1, \lambda_2 = -1, \lambda_3 = 0$. λ_1, λ_2 对应的特征向量依次为 $p_1 = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}, p_2 = \begin{pmatrix} 2 \\ 1 \\ -2 \end{pmatrix}$, 求 A .

解： p_3 与 p_1, p_2 正交

$$\begin{cases} P_1^T P_3 = 0 \\ P_2^T P_3 = 0 \end{cases} \Rightarrow \begin{cases} x_1 + 2x_2 + 2x_3 = 0 \\ 2x_1 + x_2 - 2x_3 = 0 \end{cases} \Rightarrow p_3 = \begin{pmatrix} 2 \\ -2 \\ 1 \end{pmatrix}$$

p_1, p_2, p_3 单位正交化, 得单位正交矩阵 P , 则

$$A = P \begin{pmatrix} 1 & & \\ & -1 & \\ & & 0 \end{pmatrix} P^{-1} \quad P = \frac{1}{3} \begin{pmatrix} 1 & 2 & 2 \\ 2 & 1 & -2 \\ 2 & -2 & 1 \end{pmatrix}$$



5. 矩阵的特征值与特征向量

• 5.4 实对称矩阵的对角化（特征分解特例）

矩阵特征值分解在多个领域有广泛的应用：

- **主成分分析（PCA）**：在数据降维和特征提取中，PCA使用特征值分解来确定数据的主要变化方向。
- **谱聚类**：在机器学习中，谱聚类利用特征值分解来发现数据的固有结构。
- **线性动态系统**：在控制理论和信号处理中，特征值分解用于分析系统的稳定性和动态行为。
- **图像处理**：在图像处理中，特征值分解可以用于图像压缩和特征提取。
- **文本挖掘**：在文本分析中，特征值分解可以用于主题建模和文档分类。
- **量子力学**：在量子力学中，特征值问题与物理系统的能量水平有关。
- **Google的PageRank算法**：PageRank使用特征值分解来确定网页的重要性。
- **推荐系统**：在推荐系统中，特征值分解可以用于用户和物品的偏好建模。
- **金融市场分析**：在金融领域，特征值分解可以用于风险分析和投资组合优化。
- **结构力学和弹性力学**：在工程学中，特征值分解用于分析结构的振动特性。




5. 矩阵的特征值与特征向量

• 5.4 实对称矩阵的对角化（特征分解特例）

• PCA（主成分分析）

- **数据标准化**：在进行PCA之前，通常需要对数据进行**标准化处理**，以确保每个特征对PCA的贡献是相等的。标准化通常涉及将**每个特征的值减去其平均值然后除以其标准差**。
- **协方差矩阵计算**：计算数据的**协方差矩阵**，或者在数据已经标准化的情况下，计算其相关系数矩阵。协方差矩阵反映了数据特征间的相关性。
- **特征值分解**：对协方差矩阵进行**特征值分解**。这个步骤会得到一组特征值和对应的特征向量。特征值表示了数据在特征向量方向上的方差，而特征向量则指示了数据变化的主要方向。
- **选择主成分**：**根据特征值的大小，选择前几个最大的特征值对应的特征向量**。这些特征向量代表了数据中最主要的变化方向，即主成分。
- **构造投影矩阵**：使用选定的**特征向量构造一个投影矩阵**，这个矩阵将用于将原始数据投影到新的坐标系中，也就是主成分空间。
- **数据转换**：将原始数据通过投影矩阵转换到**主成分空间**中。在这个新空间中，数据的第一主成分具有最大的方差，第二主成分具有第二大的方差，依此类推。
- **解释结果**：解释转换后的数据，通常选择的前几个主成分就能够解释大部分的数据方差，从而实现数据降维和特征提取。



5. 矩阵的特征值与特征向量

• 5.5 谱定理、矩阵的谱半径与收敛性

- 谱定理：实对称矩阵的"完美对角化"
 - 为什么实对称矩阵在人工智能应用中无处不在？

AI 场景	对称矩阵的来源
PCA / 降维	协方差矩阵 $\Sigma = X^T X / n$
SVM / 核方法	Gram 矩阵 $K (K_{ij} = \langle x_i, x_j \rangle)$
图神经网络	邻接矩阵 / 拉普拉斯矩阵 $L = D - A$
优化算法	Hessian 矩阵 H (二阶导数对称)
距离学习	马氏距离的度量矩阵
二次型/能量	$\ Ax\ ^2 = x^T(A^T A)x$

➤ 为什么对称矩阵这么特殊？

- 所有 AI 算法中描述"相似度/相关性"的核心数据结构都是对称矩阵
- 对称矩阵的几何 = "n 个独立方向上的纯缩放", 无旋转混淆
- 这就要求我们必须深入理解它的特征结构 = **谱定理**



5. 矩阵的特征值与特征向量

• 5.5 谱定理、矩阵的谱半径与收敛性

- 谱定理：实对称矩阵的"完美对角化"

谱定理（实对称矩阵版本）

设 A 为 n 阶实对称矩阵，则：

- ① A 的所有特征值都是实数；
- ② 不同特征值对应的特征向量必正交；
- ③ A 必可正交对角化： $\exists$ 正交矩阵 Q , 使得 $Q^T A Q = \Lambda$

$$A = Q \Lambda Q^T = \lambda_1 \mathbf{q}_1 \mathbf{q}_1^T + \lambda_2 \mathbf{q}_2 \mathbf{q}_2^T + \dots + \lambda_n \mathbf{q}_n \mathbf{q}_n^T$$

➤ 谱定理告诉我们什么？

- 任何对称矩阵都可以分解为" n 个正交方向上的独立缩放"之和
- 每一项 $\lambda_i \mathbf{q}_i \mathbf{q}_i^T$ 是一个秩-1 矩阵（外积），代表一个"主成分"
- 特征值的大小 = 该方向的"重要性/能量"



5. 矩阵的特征值与特征向量

• 5.5 谱定理、矩阵的谱半径与收敛性

- 谱定理：实对称矩阵的"完美对角化"
 - 谱定理的几何意义 → "三步走"

① 旋转 Q^T

把数据从原始坐标系
旋转到特征向量
构成的新坐标系

② 缩放 Λ

在新坐标系下
沿每个轴独立缩放
缩放倍数 = 特征值

③ 旋转回 Q

再旋转回原坐标系
(如果是 SVD, 最后一步
可以是不同的旋转)

➤ 总结

- 对称矩阵的几何作用 = 旋转到主轴 → 沿主轴缩放 → 旋转回来
- 特征向量 = 主轴方向; 特征值 = 主轴上的缩放倍数

5. 矩阵的特征值与特征向量

• 5.5 谱定理、矩阵的谱半径与收敛性

- 谱半径与矩阵收敛性
 - 为什么要研究"谱半径"?
 - 现代 AI 中几乎所有算法都涉及"迭代":

算法	迭代形式	收敛条件
梯度下降	$x_{k+1} = x_k - \eta \nabla f(x_k)$	与 Hessian 谱半径相关
幂迭代法	$x_{k+1} = Ax_k / \ Ax_k\ $	要求 $ \lambda_1 > \lambda_2 $
Jacobi/Gauss-Seidel	$x_{k+1} = Bx_k + c$	迭代矩阵谱半径 < 1
PageRank	$x_{k+1} = Mx_k$	M 是随机矩阵, 谱半径=1
马尔可夫链	$\pi_{k+1} = \pi_k P$	转移矩阵谱半径=1

谱半径定义: $\rho(A) = \max\{ |\lambda| : \lambda \text{ 是 } A \text{ 的特征值} \}$



5. 矩阵的特征值与特征向量

• 5.5 谱定理、矩阵的谱半径与收敛性

- 谱半径与矩阵收敛性

核心定理（矩阵幂的收敛性）

$$\lim_{k \rightarrow \infty} A^k = 0 \iff \rho(A) < 1$$

即：矩阵反复相乘是否趋于零，完全由谱半径决定

谱半径范围	A^k 行为	工程含义
$\rho(A) < 1$	$A^k \rightarrow 0$ (指数衰减)	迭代算法收敛 ✓
$\rho(A) = 1$	A^k 有界但不一定收敛	边界情形 (马尔可夫链)
$\rho(A) > 1$	$A^k \rightarrow \infty$ (指数爆炸)	迭代算法发散 ✗

➤ 直观证明（用谱定理）

- 若 A 对称可对角化： $A^k = Q \Lambda^k Q^T$
- $\Lambda^k = \text{diag}(\lambda_1^k, \lambda_2^k, \dots, \lambda_n^k)$
- 所有 $|\lambda_i| < 1$ 时， $\lambda_i^k \rightarrow 0$ ，故 $A^k \rightarrow 0$
- 反之，若某个 $|\lambda_i| \geq 1$ ，对应方向不会消失



5. 矩阵的特征值与特征向量

• 5.5 谱定理、矩阵的谱半径与收敛性

• 谱半径与矩阵收敛性

• 应用案例：梯度下降的学习率 η 应该怎么选？

考虑二次函数 $f(x) = \frac{1}{2} x^T H x$ 的梯度下降

$$x_{\{k+1\}} = x_k - \eta H x_k = (I - \eta H) x_k$$

 收敛 $\Leftrightarrow \rho(I - \eta H) < 1$

- 设 H 的特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0$ (H 正定)
- 则 $I - \eta H$ 的特征值为 $1 - \eta \lambda_i$
- 要求所有 $|1 - \eta \lambda_i| < 1 \rightarrow 0 < \eta < 2/\lambda_{\max}$
- 最优学习率: $\eta^* = 2/(\lambda_{\max} + \lambda_{\min})$
- 收敛速度: $\rho^* = (\kappa - 1)/(\kappa + 1)$, 其中 $\kappa = \lambda_{\max}/\lambda_{\min}$ (条件数)

 为什么深度学习要做“特征归一化”？

- 归一化后 H 的条件数 κ 变小 $\rightarrow$ 收敛更快
- 这就是 BatchNorm / LayerNorm 的数学动机