

6. 矩阵分解

- 6.0 矩阵分解的意义

- 6.1 满秩分解

- $A_{m \times n} = C_{m \times r} R_{r \times n}$, 将矩阵分解为两个低秩矩阵的乘积
- 应用: 数据压缩、数据降维、矩阵近似、图像处理

- 6.2 QR分解

- $A = QR$, 将矩阵分解为正交矩阵Q与上三角矩阵R
- 应用: 求解矩阵特征值、矩阵求逆、求解线性方程组

- 6.3 奇异值分解 (SVD分解)

- $A_{m \times n} = Q_{m \times n} D_{n \times n} T'_{n \times n}$ 将矩阵分解成三个低维矩阵
- 应用: PCA、图像处理、推荐系统、数据压缩



6. 矩阵分解

- 6.0 矩阵分解的目的
 - 复杂矩阵难以被计算机进行精确处理，计算量大
 - 矩阵分解 (Matrix decomposition/matrix factorization)
 - 将矩阵拆分成若干低维度矩阵进行处理
 - 计算机进行线性代数运算的基础，如求逆/求行列式/矩阵运算等
 - 分解方法
 - 满秩分解
 - QR分解 (正三角分解/酉三角分解)
 - 奇异值分解 (SVD分解)
 - 实对称矩阵的特征分解、LU分解、非负矩阵分解 (NMF)



6. 矩阵分解

- 6.0 矩阵分解的目的

- 五种矩阵分解方法

- 满秩分解 $A = CR$ 

Independent columns in C
Row echelon form in R
Leads to column rank = row rank
- LU分解 $A = LU$ 

LU decomposition from
Gaussian elimination
(Lower triangular)(Upper triangular)
- QR分解 $A = QR$ 

QR decomposition as
Gram-Schmidt orthogonalization
Orthogonal Q and triangular R
- 特征分解 $S = Q\Lambda Q^T$ 

Eigenvalue decomposition
of a symmetric matrix S
Eigenvectors in Q , eigenvalues in Λ
- SVD分解 $A = U\Sigma V^T$ 

Singular value decomposition
of all matrices A
Singular values in Σ

6. 矩阵分解

• 6.1 满秩分解

$$A = CR$$



- **满秩分解**：将任意一个非零矩阵（长方形）A分解成一个列满秩矩阵C与一个行满秩矩阵R的乘积问题。

$$A = CR$$

$$\begin{bmatrix} 1 & 2 & 3 \\ 2 & 3 & 5 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

- **主要内容：**

- 矩阵的Hermite标准形
- 利用Hermite标准形进行矩阵的满秩分解

6. 矩阵分解

• 6.1 满秩分解

- **满秩分解定理：** 设 $A \in C_r^{m \times n}$ ($r > 0$), 则存在 $B \in C_r^{m \times r}$, $C \in C_r^{r \times n}$, 使
$$A=BC,$$

上式称为矩阵A的满秩分解.

说明： 当A为满秩矩阵（列满秩或行满秩），A可分解为一个因子为单位矩阵，另一个因子为A本身，称此满秩分解为平凡分解($A=EA=AE$)。

设A的一个极大线性无关行向量组为 $(\alpha_{i1}, \alpha_{i2}, \dots, \alpha_{ir})'$

$$\text{则 } A = \begin{pmatrix} k_{11}\alpha_{i1} + k_{12}\alpha_{i2} + \dots + k_{1r}\alpha_{ir} \\ k_{21}\alpha_{i1} + k_{22}\alpha_{i2} + \dots + k_{2r}\alpha_{ir} \\ \vdots \\ k_{s1}\alpha_{i1} + k_{s2}\alpha_{i2} + \dots + k_{sr}\alpha_{ir} \end{pmatrix} = \begin{pmatrix} k_{11} & k_{12} & \dots & k_{1r} \\ k_{21} & k_{22} & \dots & k_{2r} \\ \vdots & \vdots & & \vdots \\ k_{s1} & k_{s2} & \dots & k_{sr} \end{pmatrix} \begin{pmatrix} \alpha_{i1} \\ \alpha_{i2} \\ \vdots \\ \alpha_{ir} \end{pmatrix}$$

6. 矩阵分解

• 6.1 满秩分解

• 定义矩阵 $A \in \mathbb{C}_r^{m \times n}$ 的 **Hermite 标准形H** 为：

- 前 r 行中，每行至少有一个非0元，且第一个非零元为1，而后 $m-r$ 行全为0；
- 若H中第 i 行的第一个非零元1位于第 k_i ($i = 1, 2, \dots, r$) 列，则有 $k_1 < k_2 < \dots < k_r$ ；
- $k_1, k_2, \dots, k_r$ 列为单位矩阵 I_m 的前 r 列。

$$H = \begin{pmatrix} & & & k_1 & & & k_2 & & & k_r & & & \\ 0 & \Lambda & 0 & 1 & * & \Lambda & * & 0 & * & \Lambda & * & 0 & * & \Lambda & * \\ 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 1 & * & \Lambda & * & 0 & * & \Lambda & * \\ M & M & M & M & M & M & M & M & M & M & M & M & M & \Lambda & M \\ 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & * & \Lambda & 0 & 1 & * & \Lambda & * \\ 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 \\ \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda \\ 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 \end{pmatrix} \begin{matrix} \\ \\ \\ \text{第 } r \text{ 行} \\ \\ \\ \end{matrix}$$

阶梯型矩阵

• **定理：**任何一个非零矩阵都可通过初等行变换化为Hermite 标准形H，且H的前 r 行线性无关。采用矩阵的说法就是，存在 $S \in \mathbb{C}_m^{m \times m}$ ，使得

$$SA=H$$



6. 矩阵分解

• 6.1 满秩分解

- **例：**化矩阵A为Hermite 标准形 $A = \begin{pmatrix} 0 & 2i & i & 0 & 4+2i & 1 \\ 0 & 0 & 0 & -3 & -6 & -3-3i \\ 0 & 2 & 1 & 1 & 4-4i & 1 \end{pmatrix}$, $i^2 = -1$

解：

$$\begin{aligned} A &\xrightarrow{r_1 \times (-\frac{i}{2})} \begin{pmatrix} 0 & 1 & \frac{1}{2} & 0 & 1-2i & -\frac{i}{2} \\ 0 & 0 & 0 & -3 & -6 & -3-3i \\ 0 & 2 & 1 & 1 & 4-4i & 1 \end{pmatrix} \\ &\xrightarrow{r_3 - 2r_1} \begin{pmatrix} 0 & 1 & \frac{1}{2} & 0 & 1-2i & -\frac{i}{2} \\ 0 & 0 & 0 & -3 & -6 & -3-3i \\ 0 & 0 & 0 & 1 & 2 & 1+i \end{pmatrix} \\ &\xrightarrow[r_2 \leftrightarrow r_3]{r_2 + 3r_3} \begin{pmatrix} 0 & 1 & \frac{1}{2} & 0 & 1-2i & -\frac{i}{2} \\ 0 & 0 & 0 & 1 & 2 & 1+i \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} = H \end{aligned}$$



6. 矩阵分解

• 6.1 满秩分解

- **满秩分解定理：** 设 $A \in C_r^{m \times n}$ ($r > 0$), 且A的Hermite 标准形H为

$$H = \begin{pmatrix} & & & k_1 & & & & k_2 & & & & k_r & & & \\ 0 & \Lambda & 0 & 1 & * & \Lambda & * & 0 & * & \Lambda & * & 0 & * & \Lambda & * \\ 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 1 & * & \Lambda & * & 0 & * & \Lambda & * \\ M & M & M & M & M & M & M & M & M & M & M & M & M & \Lambda & M \\ 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & * & \Lambda & 0 & 1 & * & \Lambda & * \\ 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 \\ \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda & \Lambda \\ 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 & 0 & 0 & \Lambda & 0 \end{pmatrix} \begin{matrix} \\ \\ \\ \\ \text{第} r \text{行} \\ \\ \\ \end{matrix}$$

则取A的 $k_1, k_2, \dots, k_r$ 列构成矩阵B, 取H的前r行构成矩阵C, 则 $A=BC$ 即为矩阵A的满秩分解。



6. 矩阵分解

- 6.1 满秩分解

- 满秩分解的步骤:

- 求矩阵A的Hermite 标准形H;
 - 取矩阵B为A的对应于H的r个单位向量的列;
 - 取矩阵C为H的前r个非0行;

则 $A=BC$.



6. 矩阵分解

• 6.1 满秩分解

• **例：**求矩阵 $A = \begin{pmatrix} 2 & 4 & 1 & 1 \\ 1 & 2 & -1 & 2 \\ -1 & -2 & -2 & 1 \end{pmatrix}$ 的满秩分解.

解：首先利用行初等变换求A的Hermite 标准形H:

$$A = \begin{pmatrix} 2 & 4 & 1 & 1 \\ 1 & 2 & -1 & 2 \\ -1 & -2 & -2 & 1 \end{pmatrix} \xrightarrow[r_1 \leftrightarrow r_2]{} \begin{pmatrix} 1 & 2 & -1 & 2 \\ 2 & 4 & 1 & 1 \\ -1 & -2 & -2 & 1 \end{pmatrix} \xrightarrow[r_3 + r_1]{r_2 - 2r_1} \begin{pmatrix} 1 & 2 & -1 & 2 \\ 0 & 0 & 3 & -3 \\ 0 & 0 & -3 & 3 \end{pmatrix} \xrightarrow[r_3 + r_2]{r_2 \times \frac{1}{3}} \begin{pmatrix} 1 & 2 & -1 & 2 \\ 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & 0 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & 0 \end{pmatrix} = H$$

可见 $k_1 = 3, k_2 = 3$, 故A的满秩分解为:

$$A = \begin{pmatrix} 2 & 1 \\ 1 & -1 \\ -1 & -2 \end{pmatrix} \begin{pmatrix} 1 & 2 & 0 & 1 \\ 0 & 0 & 1 & -1 \end{pmatrix}$$



6. 矩阵分解

• 6.1 满秩分解

• **例：**求矩阵 $\mathbf{A}_{4 \times 6} = \begin{bmatrix} 1 & 2 & 0 & 1 & 1 & 10 \\ 3 & 6 & 1 & 4 & 2 & 36 \\ 2 & 4 & 0 & 2 & 2 & 27 \\ 6 & 12 & 1 & 7 & 5 & 73 \end{bmatrix}$ 的满秩分解.

解：首先利用行初等变换求A的Hermite 标准形H:

$$\mathbf{A}_{4 \times 6} \sim \begin{bmatrix} \mathbf{1} & 2 & 0 & 1 & 1 & 0 \\ 0 & 0 & \mathbf{1} & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 & 0 & \mathbf{1} \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} = \mathbf{H}$$

可见 $k_1 = 1, k_2 = 3, k_3 = 6$, 故A的满秩分解为:

$$\mathbf{A}_{4 \times 6} = \mathbf{B}_{4 \times 3} \mathbf{C}_{3 \times 6}$$

$$= \begin{bmatrix} \mathbf{1} & \mathbf{0} & \mathbf{10} \\ \mathbf{3} & \mathbf{1} & \mathbf{36} \\ \mathbf{2} & \mathbf{0} & \mathbf{27} \\ \mathbf{6} & \mathbf{1} & \mathbf{73} \end{bmatrix} \begin{bmatrix} 1 & 2 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$



6. 矩阵分解

- 6.1 满秩分解

- 矩阵A的满秩分解是不唯一的。

设 $A=BC$, $B \in C_r^{m \times r}$, $C \in C_r^{r \times n}$, 则

$$\forall D \in C_r^{r \times r},$$

$$A = (BD)(D^{-1}C) = B_1C_1$$




6. 矩阵分解

• 6.1 满秩分解

• 应用举例：

矩阵低秩分解



- **在图像压缩方面：**满秩分解被用于将图像矩阵分解为两个低秩矩阵相乘，可以保留重要的图像特征并减少图像的存储空间。由于图像矩阵通常是高维且密集的，因此这种方法可以显著减少矩阵的大小，从而减少图像的存储空间。例如，JPEG2000压缩标准的基础就是使用满秩分解算法。
- **在图像重建方面：**满秩分解被应用于图像去噪、图像超分辨率、图像增强等任务中。通过分解图像矩阵为低秩矩阵，可以去除噪声和保留重要的图像特征，从而提高图像质量。例如，可以将噪声图像矩阵分解为两个低秩矩阵，然后根据得到的低秩矩阵重建原始图像。
- **协同过滤：**满秩分解通常用于协同过滤，以生成推荐系统中的用户-商品评分矩阵。通过将该矩阵分解为两个低秩矩阵相乘，可以找到“潜在特征”并补充缺失值，从而改进推荐算法，为用户推荐更好的产品。

- [矩阵低秩与图像去噪去码等应用](#)

- Fan, Huixin, Jie Li, Qiangqiang Yuan, Xinxin Liu, and Michael Ng. "[Hyperspectral image denoising with bilinear low rank matrix factorization](#)." *Signal Processing* 163 (2019): 132-152.



6. 矩阵分解

• 6.2 QR分解

$$A = QR$$



- QR分解也称为正交三角分解.

$$\begin{aligned} |\lambda E - A| = 0 &\rightarrow |\lambda QQ^{-1} - QR| = 0 \\ &\rightarrow |Q||\lambda Q^{-1} - R| = 0 \rightarrow |\lambda Q^T - R| = 0 \end{aligned}$$

- 矩阵QR分解是一种特殊的三角分解，在解决矩阵特征值的计算、最小二乘法等问题中起到重要作用。

- 主要方法：

- Schmidt正交化方法
- Householder变换
- Givens变换

参考资料：[矩阵的QR分解以及在最小二乘法中的应用](#)



6. 矩阵分解

$$U^H U = U U^H = E_n$$

n 个列向量是复数空间的一个标准正交基。
正交矩阵在复数域上的推广。

• 6.2 QR分解

- **定义：** 设 $A \in \mathbb{C}^{m \times r}$ ，如果存在 n 阶酉矩阵 Q 和 n 阶上三角矩阵 R ，使
$$A = QR$$

则称之为 A 的QR分解 或 酉三角分解。

当 $A \in \mathbb{R}^{n \times n}$ 时，则称为 A 的正三角分解。

- 矩阵的 QR 分解 (QR Decomposition) 是一种重要的矩阵分解方法
- 其基本原理是将一个满秩矩阵 (或列满秩矩阵) 分解为一个正交矩阵 (Orthogonal Matrix) Q 和一个上三角矩阵 (Upper Triangular Matrix) R 的乘积，即 $A = QR$



6. 矩阵分解

注：QR分解本身并不要求矩阵必须是列满秩的，但QR分解的结果取决于矩阵的秩。当矩阵 A 是列满秩的时候，即 A 的列向量线性无关，QR分解得到的 R 矩阵的对角线上的元素都是非零的，并且 R 的非零元素会形成一个从左上角到右下角的对角带，这在某些应用中有利。如果矩阵 A 不是列满秩的，那么在QR分解中， R 矩阵的对角线上会出现零元素，这些零元素的位置反映了 A 的列向量之间的线性依赖关系。

• 6.2 QR分解

- **QR分解定理：**任意一个 (列) 满秩实(复) 矩阵 A ，都可唯一地分解 $A = QR$ ，其中 Q 为正交（酉）矩阵， R 是具有正对角元的上三角矩阵。

证明：设 A 是一个列满秩实矩阵， A 的 n 个列向量为 $x_1, x_2, \dots, x_n$ 。由于 $x_1, x_2, \dots, x_n$ 线性无关，将它们用Schmidt正交化方法得标准正交向量 $e_1, e_2, \dots, e_n$

$$\begin{cases} x_1 = b_{11}e_1 \\ x_2 = b_{12}e_1 + b_{22}e_2 \\ \vdots \\ x_n = b_{1n}e_1 + b_{2n}e_2 + \dots + b_{nn}e_n \end{cases} \quad \text{其中 } b_{ii} > 0, i = 1, 2, \dots, n$$

$$\text{令 } Q = (e_1 \ e_2 \ \dots \ e_n), R = \begin{pmatrix} b_{11} & b_{12} & \dots & b_{1n} \\ & b_{22} & \dots & b_{2n} \\ & & \ddots & \vdots \\ & & & b_{nn} \end{pmatrix}$$

则 $Q^T Q = I$



6. 矩阵分解

• 6.2 QR分解

- **QR分解定理**：任意一个 (列) 满秩实(复) 矩阵A，都可唯一地分解 $A = QR$ ，其中Q为正交（酉）矩阵，R是具有正对角元的上三角矩阵。

证明：再证唯一性：

如果 $A = QR = Q_1 R_1$ ，由此可得 $Q = Q_1 R_1 R^{-1} = Q_1 D$

式中 $D = R_1 R^{-1}$ 仍为具有正对角元的上三角矩阵。由于

$$I = Q^T Q = (Q_1 D)^T (Q_1 D) = D^T D$$

即D为正交矩阵，因此D为单位矩阵（正规上三角为对角阵），故

$$Q = Q_1 D = Q_1, R_1 = DR = R$$

说明：

- 若不要求R具有正对角元，则A的不同QR分解仅在正交矩阵的列和上三角矩阵R的对应行相差模为1的因子。
- 若A为满秩复矩阵，则存在酉矩阵Q与复非奇异上三角矩阵R，使 $A = QR$
- 该定理的证明过程给出了利用Schmidt正交化方法求可逆矩阵QR分解的方法。



6. 矩阵分解

• 6.2 QR分解

一个列向量线性无关的, $m \times n$ ($m > n$) 级实矩阵 A , 可分解为 $A = QR$, 其中 Q 的列向量组为正交单位向量组, R 是主对角元全为正数的上三角矩阵。

证明: 记 $A = (\alpha_1, \alpha_2, \dots, \alpha_n)$,

因为其列向量线性无关, 则经过施密特正交变换后,

可得到一个正交向量组: $(\beta_1, \beta_2, \dots, \beta_n)$

其中 $\alpha_i = \sum_{j=1}^{i-1} \frac{(\alpha_i, \beta_j)\beta_j}{(\beta_j, \beta_j)} + \beta_i$ ($i > 1$), $\alpha_1 = \beta_1$.

则有: $A = (\alpha_1, \alpha_2, \dots, \alpha_n) = (\beta_1, \beta_2, \dots, \beta_n) \begin{pmatrix} 1 & b_{12} & \dots & b_{1n} \\ 0 & 1 & \dots & b_{2n} \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix}$

其中 $b_{ji} = \frac{(\alpha_i, \beta_j)}{(\beta_j, \beta_j)}$;

再将 $(\beta_1, \beta_2, \dots, \beta_n)$ 单位化, 得到:

$$A = (\alpha_1, \alpha_2, \dots, \alpha_n) = (\gamma_1, \gamma_2, \dots, \gamma_n) \begin{pmatrix} |\beta_1| & b_{12} & \dots & b_{1n} \\ 0 & |\beta_2| & \dots & b_{2n} \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & |\beta_n| \end{pmatrix}$$

等号右边两个矩阵即为所求的 Q, R ;



6. 矩阵分解

• 6.2 QR分解

• **例：**求矩阵A的QR分解 $A = \begin{pmatrix} 1 & 2 & 2 \\ 1 & 0 & 2 \\ 0 & 1 & 1 \end{pmatrix}$

解：记 $x_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, x_2 = \begin{pmatrix} 2 \\ 0 \\ 1 \end{pmatrix}, x_3 = \begin{pmatrix} 2 \\ 2 \\ 1 \end{pmatrix}$, 则将 x_1, x_2, x_3 正交化

$$\begin{cases} y_1 = x_1 \\ y_2 = x_2 - \frac{(x_2, y_1)}{(y_1, y_1)} y_1 = x_2 - y_1 = (1, -1, 1)^T \\ y_3 = x_3 - \frac{(x_3, y_1)}{(y_1, y_1)} y_1 - \frac{(x_3, y_2)}{(y_2, y_2)} y_2 \\ \quad = x_3 - 2y_1 - \frac{1}{3}y_2 = \frac{1}{3}(-1, 1, 2)^T \end{cases} \xrightarrow{\text{再单位化}} \begin{cases} e_1 = \frac{y_1}{|y_1|} = \frac{\sqrt{2}}{2}(1, 1, 0)^T \\ e_2 = \frac{y_2}{|y_2|} = \frac{\sqrt{3}}{3}(1, -1, 1)^T \\ e_3 = \frac{y_3}{|y_3|} = \frac{\sqrt{6}}{6}(-1, 1, 2)^T \end{cases} \xrightarrow{\text{整理得}} \begin{cases} x_1 = \sqrt{2}e_1 \\ x_2 = \sqrt{2}e_1 + \sqrt{3}e_2 \\ x_3 = 2\sqrt{2}e_1 + \frac{\sqrt{3}}{3}e_2 + \frac{\sqrt{6}}{3}e_3 \end{cases}$$

$$\text{令 } Q = \begin{pmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{3}}{3} & -\frac{\sqrt{6}}{6} \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{3}}{3} & \frac{\sqrt{6}}{6} \\ 0 & \frac{\sqrt{3}}{3} & \frac{\sqrt{6}}{3} \end{pmatrix}, \quad R = \begin{pmatrix} \sqrt{2} & \sqrt{2} & 2\sqrt{2} \\ 0 & \sqrt{3} & \frac{\sqrt{3}}{3} \\ 0 & 0 & \frac{\sqrt{6}}{3} \end{pmatrix} \quad \text{则 } A=QR.$$



6. 矩阵分解

- 6.2 QR分解

- **例：** 利用Schmidt正交化方法求矩阵的QR分解 $A = \begin{pmatrix} 0 & 3 & 1 \\ 0 & 4 & -2 \\ 2 & 1 & 2 \end{pmatrix}$



6. 矩阵分解

- 6.2 QR分解

- QR分解应用

- **线性回归**：QR分解可以用于普通最小二乘法（Ordinary Least Squares, OLS）中的可信度区间和置信区间的计算。OLS的主要目标是通过数据点来拟合一个线性模型，而QR分解可以使得这个拟合过程更加稳定和准确。
- **特征选择**：在特征选择中，我们需要从给定的初始特征集中选择出最具相关性的子集。在选择的过程中，我们往往需要计算协方差矩阵和它的特征向量。QR分解可以用于协方差矩阵的分解，进而进行特征选择。
- **奇异值分解（SVD）**：QR分解常用于奇异值分解（SVD）过程中。SVD是一种将矩阵分解为三个矩阵乘积的方法：将原始矩阵分解为左奇异矩阵、奇异值矩阵和右奇异矩阵的乘积，其中右奇异矩阵被采用QR分解来计算。
- **矩阵求逆**：QR分解可以被用来计算矩阵的逆。QR分解可以得到一个上三角矩阵和一个正交矩阵，因此可以计算矩阵的逆，从而避免了直接计算逆矩阵的计算复杂度高的问题。



6. 矩阵分解

• 6.2 QR分解


```
1 # QR decomposition
2 from numpy import array
3 from numpy.linalg import qr
4 # define a 3x2 matrix
5 A = array([[1, 2], [3, 4], [5, 6]])
6 print(A)
7 # QR decomposition
8 Q, R = qr(A, 'complete')
9 print(Q)
10 print(R)
11 # reconstruct
12 B = Q.dot(R)
13 print(B)
```

• QR分解在最小二乘中的应用

$$\begin{aligned} \text{err}(y_i - \hat{y}) &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y})^2 = \frac{1}{n} \sum_{i=1}^n (y_i - w^T x_i)^2 \\ &= \frac{1}{n} (y - wX)^T (y - wX) \\ &= \frac{1}{n} (y^T y - 2wX^T y + w^T X^T X w) \end{aligned}$$



$$\begin{aligned} \frac{\partial}{\partial w} \text{err} &= \frac{1}{n} (2wX^T X - 2X^T y) = 0 \\ wX^T X &= X^T y \\ w &= (X^T X)^{-1} X^T y \end{aligned}$$



$$\begin{aligned} \hat{w}^* &= (X^T X)^{-1} X^T y \\ X^T X \hat{w}^* &= X^T y \\ R^T Q^T Q R \hat{w}^* &= R^T Q^T y \\ R^T R \hat{w}^* &= R^T Q^T y \quad (Q^T Q = I) \\ R \hat{w}^* &= Q^T y \\ \hat{w}^* &= R^{-1} Q^T y \end{aligned}$$

参考资料: [线性回归, 最小二乘, 矩阵条件数, QR分解](https://towardsdatascience.com/qr-matrix-factorization-15bae43a6b2)


<https://towardsdatascience.com/qr-matrix-factorization-15bae43a6b2>



6. 矩阵分解

- 6.2 QR分解

- QR分解在神经网络反向传播优化中的应用



参考资料: [Backpropagating through QR decomposition](#)

6. 矩阵分解

• 6.3 奇异值分解 (SVD分解) $A = U\Sigma V^T$

- 将一般矩阵 $A_{m \times n}$ 进行分解

- **定义1:** 设 $A = [a_1, a_2, \dots, a_n]$, 其中 a_i 是 A 的列向量, 则

$$G = A^T A = \begin{bmatrix} a_1^T \\ \vdots \\ a_n^T \end{bmatrix} [a_1, \dots, a_n] = \begin{bmatrix} a_1^T a_1 & \cdots & a_1^T a_n \\ \vdots & \ddots & \vdots \\ a_n^T a_1 & \cdots & a_n^T a_n \end{bmatrix}$$

矩阵 G 中每个元素都可以用 A 的列向量求内积获得, 即 $g_{ij} = \langle a_i, a_j \rangle$, 称矩阵 G 为格拉姆矩阵 (Gramian Matrix, 或 Gram Matrix)

- 因为 $(A^T A)^T = A^T (A^T)^T = A^T A$, 所以格拉姆矩阵 G 为对称矩阵

注: 格拉姆矩阵可以看做是一种特殊的协方差矩阵, 或称为偏心协方差矩阵, 即没有减去均值的协方差矩阵。

6. 矩阵分解

• 6.3 奇异值分解 (SVD分解)

- 设 $A \in C_r^{m \times n}$, λ_i 是格拉姆矩阵 $A^H A$ 的特征值, μ_i 是 AA^H 的特征值, 它们都是实数。如果记

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > \lambda_{r+1} = \lambda_{r+2} = \cdots = \lambda_m = 0$$

$$\mu_1 \geq \mu_2 \geq \cdots \geq \mu_r > \mu_{r+1} = \mu_{r+2} = \cdots = \mu_n = 0$$

特征值 λ_i 和 μ_i 之间有如下关系:

- **定理1:** 设 $A \in C_r^{m \times n}$, 那么 $\lambda_i = \mu_i > 0$ ($i = 1, 2, \dots, r$), 即 $A^H A$ 与 AA^H 的非零特征值相等.
- **定义2:** 称 $\delta_i = \sqrt{\lambda_i} = \sqrt{\mu_i} > 0$ ($i = 1, 2, \dots, r$) 为矩阵 A 的正奇异值, 简称奇异值.



6. 矩阵分解

• 6.3 奇异值分解

• **例：**求下列矩阵的奇异值

$$(1) \quad A = \begin{bmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

解：

$$AA^H = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

显然 AA^H 的特征值为 **5, 0, 0**,
所以A的奇异值为 $\sqrt{5}$

$$(2) \quad A = \begin{bmatrix} 0 & -1 & 1 \\ 2 & 0 & 0 \end{bmatrix}$$

$$AA^H = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}$$

显然A 的特征值为2,4, 所以A的奇异
值为 $\sqrt{2}$, 2 。



6. 矩阵分解

• 6.3 奇异值分解

- **定义3:** 设 $A, B \in C^{m \times n}$, 若

$$\exists S \in U^{m \times m}, T \in U^{n \times n}, \text{ s.t. } A = SBT$$

则称A与B酉等价.

- **定理2:** 设 $A, B \in C^{m \times n}$, 且酉等价, 则A与B有相同的正奇异值。

- 等价矩阵是指通过一系列行变换和列变换, 可以将一个矩阵转化为另一个矩阵的矩阵。
- 酉等价矩阵是等价矩阵的一种特殊情况, 它是利用酉矩阵进行矩阵变换得到的等价矩阵。
- 等价矩阵具有以下性质:
 - 等价矩阵具有相同的秩。
 - 等价矩阵具有相同的行列式。
 - 等价矩阵具有相同的特征多项式和特征值。
 - 等价矩阵具有相同的行空间和列空间。
 - 等价矩阵具有相同的对角化和三角化。
 - 等价矩阵具有相同的奇异值分解和QR分解。
 - 等价矩阵具有相同的秩一等于零特征值的个数。



6. 矩阵分解

定义：正规阵（正规矩阵，实数域称之对称矩阵）是指一个 $n \times n$ 复矩阵 A 满足以下条件：

$$A^H A = A A^H$$

其中 A^H 表示为 A 的共轭转置。正规矩阵可以被对角化，即存在一个酉矩阵 U ，使得 $U^H A U = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$

• 6.3 奇异值分解

- 定理3 (奇异值分解定理)：** 设 $A \in \mathbb{C}_r^{m \times n}$, $\alpha_1 \geq \alpha_2 \geq \dots \geq \alpha_r$ 是 A 的 r 个奇异值，那么存在 m 阶酉矩阵 U 和 n 阶酉矩阵 V 使得

$$A = U \begin{pmatrix} \Delta & 0 \\ 0 & 0 \end{pmatrix} V^H$$

其中 $\Delta = \begin{bmatrix} \alpha_1 & & & \\ & \alpha_2 & & \\ & & \ddots & \\ & & & 0 \\ & & & & \ddots & \\ & & & & & \alpha_r \end{bmatrix}$ ，且满足 $\alpha_1 \geq \alpha_2 \geq \dots \geq \alpha_r$.

称表达式 $A = U \begin{pmatrix} \Delta & 0 \\ 0 & 0 \end{pmatrix} V^H$ 为**矩阵 A 的奇异值分解式**。

证： 记 AA^H 的特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > \lambda_{r+1} = \lambda_{r+2} = \dots = \lambda_m = 0$
因为 AA^H 是正规阵，所以 $\exists U \in U^{m \times m}$

$$U^H A A^H U = \text{diag}(\alpha_1^2, \alpha_2^2, \dots, \alpha_r^2, \dots, 0, \dots, 0)$$

$$= \begin{bmatrix} \Delta \Delta^H & 0 \\ 0 & 0 \end{bmatrix}$$



6. 矩阵分解

定义：次酉矩阵 (Subunitary Matrix) 是指一个 $n \times n$ 的复矩阵 A 满足以下条件：

$$A^H A \leq I$$

其中 I 表示为 $n \times n$ 的单位矩阵。

• 6.3 奇异值分解

证 (续)： 记 $U = [U_1, U_2]$ ，其中 U_1 是 $m \times r$ 矩阵， U_2 是 $m \times (m-r)$ 矩阵。

$$\begin{aligned} U^H A A^H U &= \begin{bmatrix} U_1^H \\ U_2^H \end{bmatrix} A A^H [U_1, U_2] \\ &= \begin{bmatrix} U_1^H \\ U_2^H \end{bmatrix} [A A^H U_1, A A^H U_2] \end{aligned}$$

$$= \begin{bmatrix} U_1^H A A^H U_1 & U_1^H A A^H U_2 \\ U_2^H A A^H U_1 & U_2^H A A^H U_2 \end{bmatrix}$$

$$= \begin{bmatrix} \Delta \Delta^H & O \\ O & O \end{bmatrix}$$

比较后得到

$$U_1^H A A^H U_1 = \Delta \Delta^H \dots\dots\dots (1)$$

$$U_1^H A A^H U_2 = O \dots\dots\dots (2)$$

$$U_2^H A A^H U_1 = O \dots\dots\dots (3)$$

$$U_2^H A A^H U_2 = O \dots\dots\dots (4)$$

令 $V_1 = A^H U_1 \Delta^{-H}$ 则 $V_1^H V_1 = \Delta^{-1} U_1^H A A^H U_1 \Delta^{-H}$

由 (1) 知 $V_1^H V_1 = I_r$ ，所以 V_1 是次酉阵

即 $V_1 \in U_r^{n \times r}$ ，所以，存在 $V_2 \in U_{n-r}^{n \times (n-r)}$ 使得：

$$V = [V_1, V_2] \in U^{n \times n} \quad \text{所以}$$



6. 矩阵分解

• 6.3 奇异值分解

$$\begin{aligned} U_1^H A A^H U_1 &= \Delta \Delta^H \dots\dots\dots (1) \\ U_1^H A A^H U_2 &= \mathbf{O} \dots\dots\dots (2) \\ U_2^H A A^H U_1 &= \mathbf{O} \dots\dots\dots (3) \\ U_2^H A A^H U_2 &= \mathbf{O} \dots\dots\dots (4) \end{aligned}$$

证 (续) : $U^H A V = \begin{bmatrix} U_1^H \\ U_2^H \end{bmatrix} A [V_1, V_2] = \begin{bmatrix} U_1^H A V_1 & U_1^H A V_2 \\ U_2^H A V_1 & U_2^H A V_2 \end{bmatrix}$

所以, $U_1^H A V_1 = U_1^H A A^H U_1 \Delta^{-H} = \Delta$

由 (4) $U_2^H A A^H U_2 = (A^H U_2)^H (A^H U_2) = \mathbf{O}$

从而: $A^H U_2 = \mathbf{O} \quad U_2^H A = \mathbf{O}$

所以: $U_2^H A V_1 = \mathbf{O} \quad , U_2^H A V_2 = \mathbf{O}$

又因为 $V_1 = A^H U_1 \Delta^{-H}$

所以, $V_1 \Delta^H = A^H U_1$, 得出 $U_1^H A = \Delta V_1^H$

所以 $U_1^H A V_2 = \mathbf{O} \quad U^H A V = \begin{bmatrix} \Delta & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix} \quad A = U \begin{pmatrix} \Delta & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{pmatrix} V^H$



6. 矩阵分解

$$A = U \times \Sigma \times V^T$$

$m \times n$ $m \times m$ $m \times n$ $n \times n$

• 6.3 奇异值分解 (SVD分解)

• 更一般地理解 $A = U\Sigma V^T$ 可以认为, 对于任意 $m \times n$ 的矩阵 A 可以分解为:

- U 是 $m \times m$ 正交矩阵 ($U^T = U^{-1}$), $U = [u_1 \dots u_m]$, 其中 u_i ($i = 1, \dots, m$) 是列向量;
- V 是 $n \times n$ 正交矩阵 ($V^T = V^{-1}$), $V = [v_1 \dots v_n]$, 其中 v_i ($i = 1, \dots, n$) 是列向量;
- Σ 是 $m \times n$ (类) 对角矩阵, 形式为:

$$\Sigma = \begin{bmatrix} \delta_1 & \dots & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \dots & \delta_r & \dots & 0 \\ 0 & \dots & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \dots & 0 \end{bmatrix}$$

其中, 奇异值 $\delta_i = \sqrt{\lambda_i} = \|Av_i\| > 0$, $\delta_1 \geq \dots \geq \delta_r > 0$

• 由此, SVD分解可表示为:

$$A = U\Sigma V^T = [u_1 \dots u_m] \begin{bmatrix} \delta_1 & \dots & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \dots & \delta_r & \dots & 0 \\ 0 & \dots & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \dots & 0 \end{bmatrix} \begin{bmatrix} v_1^T \\ \vdots \\ v_r^T \\ \vdots \\ v_n^T \end{bmatrix} = [u_1 \dots u_m] \begin{bmatrix} \delta_1 v_1^T \\ \vdots \\ \delta_r v_r^T \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \delta_1 u_1 v_1^T + \dots + \delta_r u_r v_r^T$$



6. 矩阵分解

• 6.3 奇异值分解 (SVD分解)

• SVD分解步骤:

① 求出 AA^H 或 A^HA 的全部特征值 λ_i , 则 $\alpha_i = \sqrt{\lambda_i}$ 为 A 的正奇异值, 求得 Σ

② 求酉矩阵 $U \in U^{m \times m}$, (U的列向量为 AA^H 的单位化正交特征向量), 使得:

$$U^H A A^H U = \text{diag}[\alpha_1^2, \alpha_2^2, \dots, \alpha_r^2, 0, \dots, 0] = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_r, 0, \dots, 0]$$

③ 设 $U = [U_1, U_2]$, $V_1 = A^H U_1 \Delta^{-H}$, 则 V_1 为次酉阵, 于是求 $V_2 = U_{n-r}^{n \times (n-r)}$, 使得 $V = [V_1, V_2]$, $V \in U^{n \times n}$

$$④ \quad A = U \begin{pmatrix} \Delta & 0 \\ 0 & 0 \end{pmatrix} V^H$$

- 上述步骤是通过Gram矩阵 AA^H 的特征值确定奇异值矩阵 Σ , 并通过其特征向量单位正交化后确定酉 (正交) 矩阵 $U = [U_1, U_2]$, 然后通过 $V_1 = A^H U_1 \Delta^{-H}$ 求次酉阵 V_1 , 进而通过 V_1 求与其互补的次酉阵 V_2 确定酉 (正交) 矩阵 $V = [V_1, V_2]$, 则 $A = U \Sigma V^H$ 。
- 也可以先通过 $A^H A$ 求 Σ 和 $V = [V_1, V_2]$, 再通过 $U_1 = A V_1 \Delta^{-1}$ 确定次酉阵 U_1 , 进而通过 U_1 求与其互补的次酉阵 U_2 确定 $U = [U_1, U_2]$, 则 $A = U \Sigma V^H$ 。



6. 矩阵分解

• 6.3 奇异值分解 (SVD分解)

• **例：**求矩阵A的奇异值分解表达式 $A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 1 & 0 \end{pmatrix}$

解： $A^H A = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix}$, $|\lambda E - A^H A| = (\lambda - 1)(\lambda - 3)\lambda$,

所以 $A^H A$ 的特征值为 $\lambda_1 = 3$, $\lambda_2 = 1$, $\lambda_3 = 0$, 则 A 的正奇异值 $\sigma_1 = \sqrt{3}$, $\sigma_2 = 1$,

则 $\Delta = \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \end{bmatrix}$, 又 $A^H A$ 的特征值为 $\lambda_1 = 3$, $\lambda_2 = 1$, $\lambda_3 = 0$ 对应的特征向量分别为

$$\varepsilon_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \varepsilon_2 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \varepsilon_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

6. 矩阵分解

• 6.3 奇异值分解 (SVD分解)

解(续): 将 $\varepsilon_1, \varepsilon_2, \varepsilon_3$ 单位化得正交矩阵

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad \text{取 } V_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & 0 \end{bmatrix}, \quad \text{则}$$

$$U_1 = AV_1\Delta^{-1} = \begin{bmatrix} \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \\ \frac{2}{\sqrt{6}} & 0 \end{bmatrix}, \quad \text{取 } U_2 = \begin{bmatrix} \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{3}} \end{bmatrix}, \quad \text{则 } U = [U_1, U_2] \text{ 为酉矩阵。}$$

矩阵A的奇异值分解结果为:

$$A = U \begin{bmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} V^H$$

6. 矩阵分解

• 6.3 奇异值分解 (SVD分解)

• SVD分解步骤 (方法2) :

① 求出 AA^H 或 A^HA 的全部特征值 λ_i , 则 $\alpha_i = \sqrt{\lambda_i}$ 为 A 的正奇异值, 求得 Σ

② 求酉矩阵 $U \in U^{m \times m}$, U 的列向量为 AA^H 的单位正交特征向量, 使得:
 $UAA^HU^H = \text{diag}[\alpha_1^2, \alpha_2^2, \dots, \alpha_r^2, 0, \dots, 0] = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_r, 0, \dots, 0]_{m \times m}$
其中, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0$

③ 同理, 求酉矩阵 $V \in U^{n \times n}$, V 的列向量为 A^HA 的单位正交特征向量, 使得:
 $VA^HAV^H = \text{diag}[\alpha_1^2, \alpha_2^2, \dots, \alpha_r^2, 0, \dots, 0] = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_r, 0, \dots, 0]_{n \times n}$
其中, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0$

④ $A = U\Sigma V^H$

6. 矩阵分解

- 6.3 奇异值分解 (SVD分解)

- **SVD分解应用**

- **特征提取：**SVD可以用于从高维数据中提取最主要的特征，即特征降维。对于一个拥有很多行和列的高维数据矩阵，SVD可以计算出它的前 k 个最重要的奇异值及对应的左右奇异向量，从而将原始矩阵重新构建成一个低秩矩阵，以达到降维的目的。
- **推荐系统：**SVD可以用于处理用于对用户和商品进行评分的稀疏矩阵，使得可以在更小的维度空间中对这种数据进行操作。这有助于预测用户可能感兴趣的物品，进而优化推荐系统。
- **图像处理：**SVD可以用于图像压缩，使得我们可以保留原始图像的大多数信息，同时减小图像文件的存储空间。此外，SVD还可以用于去除图片中的噪声信息，从而提高图像质量。
- **词语嵌入：**在自然语言处理中，SVD可以用于计算单词之间的关联度，从而生成词向量和文本嵌入向量。这有助于在文本分类、语言模型等任务中提高精度。


6. 矩阵分解

• 6.3 奇异值分解

$$\begin{matrix} \text{orange box} & \approx & \text{cyan box} & \times & \text{orange box} & \times & \text{cyan box} \\ A & \approx & U' & \times & \Sigma' & \times & V'^T \\ m \times n & & m \times r & & r \times r & & r \times n \end{matrix}$$

• SVD分解应用

- 奇异值描述矩阵对应的拉伸变换在各个方向上的比例，是矩阵的重要性质
- 奇异值的分布通常非常不均，在很多的情况下前10%甚至1%的奇异值之和就占了全部奇异值之和的99%以上（贡献率），因此我们可以用前几个大的奇异值来近似的描述矩阵，从而实现数据压缩（降维）。



6. 矩阵分解

- 6.3 奇异值分解

- **QR分解在SVD分解中的应用**

- 计算SVD时，可以利用QR分解来简化计算过程

1. **薄QR分解**：首先对矩阵 A 进行薄QR分解，即：

$$A = QR$$

其中 Q 是一个正交矩阵， R 是一个 $m \times n$ 的上三角矩阵。

2. **R的SVD分解**：接着对上三角矩阵 R 进行SVD分解：

$$R = U_R \Sigma V^T$$

3. **组合结果**：最后，将 Q 、 U_R 、 Σ 和 V 组合起来，得到：

$$A = QU_R \Sigma V^T$$

其中 $U = QU_R$ ， Σ 和 V 保持不变。

- 这个过程中，QR分解帮助我们简化了SVD分解的计算，特别是当**矩阵A很大时 ($m < n$)**，使用QR分解可以减少计算量和提高数值稳定性。



矩阵分析

- 1. 机器学习常用量

- 向量、矩阵、张量、范数

- 2. 矩阵运算

- 矩阵的加减法、数乘、乘法、转置、求逆运算及伴随矩阵

- 3. 线性相关与线性无关

- 极大线性无关组、向量组的秩及其求解方法

- 4. 矩阵的秩

- 初等变换求矩阵的秩、矩阵秩的性质

- 5. 矩阵的特征值与特征向量

- 向量的内积和正交化、矩阵的特征值与特征向量、相似矩阵、**实对称矩阵的对角化**

- 6. 矩阵分解

- 满秩分解、★QR分解、奇异值(SVD)分解

参考教材:

[1] 《矩阵分析》(第2版) [美]Roger A.Horn[著] 张明尧[译]

[2] <A Matrix Algebra Approach to Artificial Intelligence> Xian-Da Zhang

