




第三章 语音识别

语音识别是语音信息处理重要的研究方向

- 基于模板匹配的语音识别技术是20世纪70年代的主流技术。
- 上世纪80年代以来，语音识别算法逐步从模板匹配算法进展到基于统计模型的算法。2010年之前，基于GMM-HMM是语音识别的经典声学模型。2010年前后，DNN-HMM逐步替代了GMM-HMM。2015年前后，端到端模型逐步成为当时主流技术。2023年后，语音大模型成为研究的热点。
- 除了声学模型，本章也会介绍语音识别的另外两个主要组成部分：语言模型和解码算法。

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望

第三章 语音识别

■ 3.1 语音识别概述

- 3.1.1 语音识别的基本概念（基本概念）

- 3.1.2 语音识别方法的回顾（基本概念）

- 3.1.3 语音识别的典型应用（了解）

■ 3.2 声学模型

■ 3.3 语言模型

■ 3.4 语音识别解码算法

■ 3.5 语音识别技术的展望

什么是语音识别（ASR）？

■ 定义：

- 自动语音识别（Automatic Speech Recognition）：机器通过识别把人类的语音信号转变为相应的文本的技术。
- 语音信息处理的最核心方法




■ 语音识别的结果作为

- 最终输出（转写：Dictation）
- 自然语言处理（对话系统、机器翻译）的输入

语音识别的用途


- 语音识别的结果作为
 - 最终输出（转写：Dictation）



语音识别的用途（续）

■ 语音识别的结果作为

- 最终输出（转写：Dictation）
- 自然语言处理（对话系统、机器翻译）的输入



语音识别的分类

■ 按发音方式分

□ 孤立词（isolated words）识别

“打开空调”

□ 连接词（connected words）识别

“现在 我 简单 介绍 语音 识别 的 基本 概念。”
连续数字识别

□ 连续语音（continuous speech）识别

“现在我简单介绍语音识别的基本概念。”

语音识别的分类

■ 按词汇表 (Vocabulary) 的大小分

□ 小词汇表识别系统

包括10~100个词条

□ 中词汇表识别系统

包括100~1000个词条

□ 大词汇表识别系统

包括1000个以上的词条

语音识别的分类

■ 按说话人分

- 特定说话人（speaker-dependent）语音识别
只能识别固定某个人的语音
- 非特定说话人（speaker-independent）语音识别
能识别任意人的语音

语音识别评价指标

■ 单词错误率 (Word Error Rate)

$$\text{Word Error Rate} = \frac{100 (\# \text{Insertions} + \# \text{Substitutions} + \# \text{Deletions})}{\text{Total Word in Correct Transcript}}$$

Insertion: 插入; Substitution: 置换; Deletion: 删除

Alignment example:

REF: portable **** PHONE UPSTAIRS last night so

HYP: portable FORM OF STORES last night so

Eval I S S

$$\text{WER} = 100 (1+2+0)/6 = 50\%$$

单词错误率评价指标的缺点?
有没有其他更合适的评价指标?

第三章 语音识别

- 3.1 语音识别概述
 - 3.1.1 语音识别的基本概念
 - 3.1.2 语音识别方法的回顾
 - 3.1.3 语音识别的典型应用
- 3.2 声学模型
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望

语音识别主流方法的演化


Before mid 70's	Mid 70's – mid 80's	After mid 80's
启发式 (Heuristic)	模板匹配 (Template matching)	统计模型 (Mathematical)
Rule-based and declarative	Deterministic and data-driven	Probabilistic and data-driven

模式识别方法
(Pattern Recognition Approach)

基于规则的语音识别

- 利用规则来指导语音识别：
 - Phonetics（语音学），phonology（音韵学）
 - Syntax（语法）
 - Pragmatics（语用学）
- 缺点
 - 难以表达规则
 - 难以知道如何提升系统的性能


基于数据驱动的语音识别



基于模板匹配的语音识别

- 概念：将输入模板与参考模板比较，查找最相似的模板

输入
模板




Different length



How to compare?

How about linear alignment?

参考
模板1



参考
模板N

基于模板匹配的语音识别（续）

- 如何计算两个矢量序列 X 和 Y 之间的相似度？

$$X = \{x_1, x_2, x_3, \dots, x_I\}$$

$$Y = \{y_1, y_2, y_3, \dots, y_J\}$$

存在问题：

- 长度不同， $I \neq J$
- 对不准

- 经典解决方法：动态时间弯折/归正（DTW）


把时间归正和距离测度计算结合起来的非线性归正技术。

DTW是采用动态规划（Dynamic Programming, DP）技术，将一个复杂的全局问题转化为许多局部最优问题，逐步进行决策。

将表示两个语音段的矢量序列对准了再计算相似度。

动态时间归正的思路

■ 如何对准？




- 每一条从 $(1, 1)$ 到 (I, J) 路径都有一个累计距离称为路径的代价。
- 每一条路径都代表一种对齐情况。
- 代价最小的路径就是所求对准路径。

动态时间归正的思路（续）

- 将对准问题，或者说将求两个语音段的相似度问题，转化成了搜索代价最小的最优路径问题。
- 事实上，在搜索过程中，往往要进行路径的限制

- (1) 起点/终点的限制
- (2) 连续性限制



受一步局部路径约束

- 再此限制条件下，可以将全局最优化问题转化为许多局部最优化问题一步一步地来求解，这就动态规划 (Dynamic Programming, 简称DP) 的思想。

动态时间归正的思路（续）

定义一个代价函数 $g(i, j)$ 表示从起始点 $(1, 1)$ 出发，到达 (i, j) 点最小代价路径的累计距离。

有：

$$g(i, j) = \min_{(i', j') \rightarrow (i, j)} \{g(i', j') + d(\mathbf{x}_i, \mathbf{y}_j)W\}$$

则：

$$g(i, j) = \min \left\{ \begin{array}{l} g(i-1, j) + d(\mathbf{x}_i, \mathbf{y}_j)W(1) \\ g(i-1, j-1) + d(\mathbf{x}_i, \mathbf{y}_j)W(2) \\ g(i, j-1) + d(\mathbf{x}_i, \mathbf{y}_j)W(3) \end{array} \right\}$$

$d(\mathbf{x}_i, \mathbf{y}_j)$: $\mathbf{x}_i$ 与 $\mathbf{y}_j$ 的距离

依次类推， $g(i-1, j)$ 、 $g(i, j-1)$ 、 $g(i-1, j-1)$ 可由更低一层的代价函数计算得到。

动态时间归正的思路（续）

- 这样就可从

$g(1,1)$ 逐步向上搜索。


- 加权系数的取值与局部路径有关

$$W = \begin{cases} 2 & (i-1, j-1) \rightarrow (i, j) \\ 1 & \text{其它} \end{cases}$$

- 定义回溯函数

$$p(i, j)$$

- 平行四边形区域约束




动态时间归正路径搜索算法

(1) 初始化:


$$i = j = 1, \quad g(1, 1) = 2d(x_i, y_j)$$

$$g(i, j) = \begin{cases} 0 & \text{当}(i, j) \in \text{Reg} \\ \text{huge} & \text{当}(i, j) \notin \text{Reg} \end{cases}$$

约束区域Reg: 可以假定是这样
一个平行四边形，它有两个顶
点位于(1, 1)和(1, J)，相邻两
条边的斜率分别为2和1/2。



动态时间归正路径搜索算法（续）



(2) 递推求累计距离，并记录回溯信息：

受一步局部路径约束

$$g(i, j) = \min \left\{ \begin{array}{l} g(i-1, j) + d(\mathbf{x}_i, \mathbf{y}_j)W(1) \\ g(i-1, j-1) + d(\mathbf{x}_i, \mathbf{y}_j)W(2) \\ g(i, j-1) + d(\mathbf{x}_i, \mathbf{y}_j)W(3) \end{array} \right\}$$

$$i = 2, 3, \dots, I; j = 2, 3, \dots, J; (i, j) \in \text{Reg}$$

一般取距离加权值为， $W(1) = W(3) = 1$ ， $W(2) = 2$

并将 (i, j) 点的回溯信息记录在 $p(i, j)$ 中。

动态时间归正路径搜索算法（续）

（3）回溯求出所有的匹配点对：


根据每步的上一步最佳局部路径 $p(i,j)$ ，由匹配点 (I,J) 对向前回溯一直到 $(1,1)$ 。这个回溯过程对于求平均模板或聚类中心来讲是必不可少的，但在识别过程往往不必进行。

- 对所求得的 $g(I,J)$ 还需用 $\sum W$ 作为分母来归正

动态时间归正算法缺点

- 很难区分非常类似的模板（硬匹配）
- 当输入和模板之间的声学条件不同时，语音识别的性能急剧下降（缺少多样性）
- 没有充分利用语音信号的时序动态信息
- 不利于进行大词汇表连续语音识别（LVCSR）
- 需要新的技术来消除以上问题
 - 更易于训练不同的模板
 - 更加鲁棒的匹配技术
 - 更适合于进行LVCSR
- 解决方案：基于统计模型的语音识别

基于统计模型的语音识别框架（重点掌握）



Front-end processing
(前端处理)

Back-end processing
(后端处理)

什么是声学模型？

计算发音相似度的模型

语音识别-噪音通道模型

■ 噪音通道 (Noisy Channel) 模型

- 源句子 (source sentence) 经过噪音通道 (noisy channel) 会生成噪音句子 (noisy sentence)。我们通过对噪音句子的解码得到猜测的句子 (guessed sentence)
- 搜索所有可能的句子
- 找出最优解



语音识别-噪音通道模型（掌握）

■ 噪音通道（Noisy Channel）模型

- 本质是求 $\operatorname{argmax} P(W|X)$ ：
给出声学特征 X ，查找最匹配的单词序列 W 。
- 应用贝叶斯法则（Bayes' rule）：

声学模型 语言模型


$$\operatorname{argmax}_W P(W|X) = \operatorname{argmax}_W \frac{P(X|W)P(W)}{P(X)}$$

因 $P(X)$ 与 W 无关，可以去掉分母 $P(X)$ 。


语音识别-声学模型

从GMM-HMM到端到端模型


1990s-2009: The GMM-HMM hybrid system. (CU-HTK)



2009-2019: The DNN-HMM hybrid system. (JHU-Kaldi, MS-CNTK)




2014: The CTC End-to-End system. (CMU-EESEN, Baidu-WarpCTC)



2016: The Encoder-Decoder End-to-End system.


(Google-LAS/Transformer, facebook-wav2letter, JHU-ESPNet)



2023-Now: Speech Large Language Model

语音识别-声学模型


■ GMM-HMM（高斯混合模型-隐马尔可夫模型）



- L. R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. Proc. IEEE, 77(2):257–286, 1989.

语音识别-声学模型


■ DNN-HMM（深度神经网络-隐马尔可夫模型）



语音识别-声学模型

■ End-to-end Model (端到端模型)

不需要语言模型和词典



语音识别-语言模型

- **语言模型**：根据语言客观事实而进行的语言抽象数学建模，用以计算文字序列的概率
- 分类
 - 基于文法的语言模型
 - 基于统计的语言模型（N-gram语言模型，神经语言模型）
- 主要应用
 - **语音识别**
 - 文本生成
 - 机器翻译
 - 阅读理解
 -

□ 例子：“（福建重口音）我要回福建省福州市，帮我买盒五仁月饼。”，只有声学模型可能会被误识别为“我要回胡建省湖州市，帮我买盒五人月饼。”

语音识别-语言模型

■ N-gram (N元文法) 语言模型

□ 单词序列

$$w_1^n = w_1 \dots w_n$$

□ 概率的链式法则

$$P(w_1^n) = P(w_1)P(w_2 | w_1)P(w_3 | w_1^2) \dots P(w_n | w_1^{n-1}) = \prod_{k=1}^n P(w_k | w_1^{k-1})$$

□ N-gram近似

假设词 w_k 出现的概率只与前 $N-1$ 个单词有关

$$P(w_1^n) = \prod_{k=1}^n P(w_k | w_{k-N+1}^{k-1})$$

语音识别-解码算法

$$P(W|X) = \operatorname{argmax}_{\{w_1^N\}\{t_1^N\}} \left\{ \sum_{n=1}^N \log(P_{acoust}(\mathbf{x}_{t_{n-1}+1}^{t_n} | w_n)) \right. \\ \left. + \lambda \cdot \sum_{n=1}^N \log(P_{lang}(w_n | w_{n-1}) + \delta) \right\}$$


$P_{acoust}(\mathbf{x}_{t_{n-1}+1}^{t_n} | w_n)$: 声学模型的似然

$P_{lang}(w_n | w_{n-1})$: 语言模型的似然

λ : 权重; δ : 插入的惩罚

语音识别-解码算法

■ Viterbi搜索算法



■ WFST（加权有限状态转换器）搜索算法

第三章 语音识别

- 3.1 语音识别概述
 - 3.1.1 语音识别的基本概念
 - 3.1.2 语音识别方法的回顾
 - 3.1.3 语音识别的典型应用
- 3.2 声学模型
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望

语音识别的典型应用

- 语音转写
- 语音对话
- 语音翻译
-

语音识别的典型应用-语音转写

■ 语音转写

- 语音转写系统
- 语音输入法

1 上传音频

2 等待转写

3 下载结果

确认订单信息

中文机器快转
适用于标准普通话

英文机器快转
适用于标准英语

订单名称
HYST20190829064939PM

出稿类型
文字

专业领域
科技

机器快转 请上传文件 (最多可添加10个音频文件)。




将文件拖放到此处上传，或点击上传

支持mp3、mp4、wav、pcm、m4a、amr、wma、3gp、aac等格式。


开始转写

语音识别的典型应用-语音对话



- **语音识别**：完成语音到文本的转换，将用户说话的声音转化为语音。
- **自然语言理解**：完成对文本的语义解析，提取关键信息，进行意图识别与实体识别。
- **对话管理**：负责对话状态维护、数据库查询、上下文管理等。
- **自然语言生成**：生成相应的自然语言文本。
- **语音合成**：将生成的文本转换为语音。

语音识别的典型应用-语音翻译



第三章 语音识别

■ 3.1 语音识别概述

■ 3.2 声学模型

- 3.2.1 隐马尔可夫模型（掌握、部分重点）

- 3.2.2 基于GMM-HMM的语音识别技术（掌握、基本概念、了解）

- 3.2.3 DNN-HMM（基本概念）

■ 3.3 语言模型

■ 3.4 语音识别解码算法

■ 3.5 语音识别技术的展望

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
 - 3.2.1 隐马尔可夫模型
 - 3.2.2 基于GMM-HMM的语音识别技术
 - 3.2.3 DNN-HMM
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望

马尔可夫过程（了解）

- **马尔可夫过程**：状态空间中经过从一个状态到另一个状态的转换的随机过程。该过程要求具备“无记忆”的性质，即下一状态的条件概率分布只能由当前状态决定，在时间序列中它前面的事件均与之无关。
- 马尔可夫过程具有**马尔可夫性质（无后效性）**，当一个随机过程在给定现在状态及所有过去状态情况下，其未来状态的条件概率分布仅依赖于当前状态；换句话说，在给定现在状态时，它与过去状态（即该过程的历史路径）是条件独立的。

马尔可夫链（基本概念）

- **马尔可夫链**：一种离散状态的马尔可夫过程（序列），为状态空间中经过从一个状态到另一个状态的转换的随机过程。具有如下性质：
 - 状态空间是有限的或可列；
 - 是一种离散时间随机过程；
 - 具有马尔可夫性质（无后效性）。即在给定当前知识或信息的情况下，过去（即当期以前的历史状态）对于预测将来（即当期以后的未来状态）是无关的。

马尔可夫链的定义（基本概念）

定义 设随机过程的状态空间为： $q_t \in \{s_j, j = 1, 2, \dots, N\}$,

系统在时间 t 的状态只与其在时间 $t-1$ 的状态相关，满足以下关系

$$\begin{aligned} &P(q_t = s_j | q_{t-1} = s_i, q_{t-2} = s_k \dots) \\ &= P(q_t = s_j | q_{t-1} = s_i), \quad t = 1, 2, \dots, T \end{aligned}$$

则称该随机过程为离散时间、离散状态的一阶马尔可夫过程，或简称为一阶**马尔可夫链**。

齐次马尔可夫链（了解）

定义 设 $\{Q = q_1, q_2, \dots, q_T\}$ 是马尔可夫链，记

$$P(q_t = s_j | q_{t-1} = s_i) = a_{ij}(t), \quad i, j = 1, 2, \dots, N$$


$a_{i,j}(t)$ 表示 t 时刻从状态 i 转移到状态 j 的概率。如果这些转移概率与时间 t 无关，则得到**齐次马尔可夫链**。

状态转移概率 $a_{i,j}$ 必须满足下列条件：

$$a_{ij} \geq 0 \quad \forall i, j;$$

$$\sum_{j=1}^N a_{i,j} = 1 \quad \forall i$$

马尔可夫链的例子（了解）




马尔可夫链的问题与隐马尔可夫模型（HMM）

（基本概念）

- 实际问题比Markov链模型所描述的更为复杂。观察到的事件并不是与状态一一对应，而是通过一组概率分布相联系。
- **HMM的定义**：使用**双重随机过程**来描述模型，一个是Markov链，描述状态的转移（**不可见**）；另一个随机过程描述状态和观察值之间的统计对应关系（**可见**）。由于状态是不可见的，因此称之为“**隐**” **Markov模型（HMM）**。
- HMM创建于20世纪70年代，是美国数学家鲍姆(Leonard E. Baum)等人提出来的。
- 每个状态上有观察值概率分布。

HMM的示意图（基本概念）



用一个观测的概率分布与每一个状态对应，而不是一个确定的观测值或事件，这就在马尔可夫序列的状态中引入了随机性，使其状态并不能被直接观测。


HMM的例子 --- 天气（了解）

状态不可见
观察值可见


观察值：干燥（Dry）、干枯（Dryish）、潮湿（Damp）、湿透（Soggy）四种湿度

观测值概率矩阵：


	Dry	Dryish	Damp	Soggy
Sunny	0.60	0.20	0.15	0.05
Cloudy	0.25	0.25	0.25	0.25
Rainy	0.05	0.10	0.35	0.50



HMM的例子 —— 掷骰子（了解）




HMM的例子—— 掷骰子（续）



$P(\text{Blue} \cdot \text{White} | \lambda) ?$

HMM的例子 —— 模型概率计算（了解）



$P(\text{Blue} \cdot \text{White} | \lambda)$?

状态转移概率

Transition Probability

$$P(S_0 S_1) = 0.5$$

$$P(S_0 S_2) = 0.33$$

$$P(S_0 S_3) = 0.17$$

$$P(S_1 S_1) = 0.5$$

$$P(S_1 S_2) = 0.33$$

$$P(S_1 S_3) = 0.17$$

$$P(S_2 S_1) = 0.33$$

$$P(S_2 S_2) = 0.5$$

$$P(S_2 S_3) = 0.17$$

观察值概率

Observation Probability


$$P(\text{Blue} | S_1) = 0.7$$

$$P(\text{White} | S_1) = 0.3$$

$$P(\text{Blue} | S_2) = 0.2$$

$$P(\text{White} | S_2) = 0.8$$

HMM的例子 —— 模型概率计算（续）（了解）



$P(\text{Blue} \cdot \text{White} | \lambda)$?

状态转移概率

Transition Probability

$$P(S_0 S_1) = 0.5$$

$$P(S_0 S_2) = 0.33$$

$$P(S_0 S_3) = 0.17$$

$$P(S_1 S_1) = 0.5$$

$$P(S_1 S_2) = 0.33$$

$$P(S_1 S_3) = 0.17$$

$$P(S_2 S_1) = 0.33$$

$$P(S_2 S_2) = 0.5$$

$$P(S_2 S_3) = 0.17$$

观察值概率

Observation Probability

$$P(\text{Blue} | S_1) = 0.7$$


$$P(\text{White} | S_1) = 0.3$$

$$P(\text{Blue} | S_2) = 0.2$$

$$P(\text{White} | S_2) = 0.8$$

HMM的例子 —— 模型概率计算（续） （了解）

$P(\text{Blue} \cdot \text{White} | \lambda)$?



$P(\text{Blue} \mid S_1) = 0.7$
 $P(\text{White} \mid S_1) = 0.3$

$P(\text{Blue} \mid S_2) = 0.2$
 $P(\text{White} \mid S_2) = 0.8$

$S_0 \rightarrow S_1 \rightarrow S_1 \rightarrow S_3$
 $\downarrow \quad \downarrow$
 Blue White

$S_0 \rightarrow S_1 \rightarrow S_2 \rightarrow S_3$
 $\downarrow \quad \downarrow$
 Blue White

$S_0 \rightarrow S_2 \rightarrow S_1 \rightarrow S_3$
 $\downarrow \quad \downarrow$
 Blue White

$S_0 \rightarrow S_2 \rightarrow S_2 \rightarrow S_3$
 $\downarrow \quad \downarrow$
 Blue White

隐马尔可夫模型(HMM)介绍（了解）

- HMM是一个经典的机器学习模型，被广泛用于语音识别，语音合成，模式识别等领域。
- HMM的重要性随着深度学习算法的流行而下降。但是作为一个经典模型，学习并理解HMM建模对提高我们的问题解决能力，扩展算法思路，了解语音识别、语音合成技术的本质是十分有帮助的。

HMM的模型描述和参数（基本概念）

HMM可以用下列参数来描述，包括状态集合、观察值序列和3个概率矩阵：

1) **状态集合**： $S = \{s_j, j = 1, 2, \dots, N\}$

N: 可能的状态数目。这些状态之间满足马尔可夫性质，是马尔可夫模型中实际所隐含的状态。这些状态不可被直接观测而得到。

2) **可观测值集合**： $V = \{v_1, v_2, \dots, v_K\}$

K: 每个状态对应的可能的观察值数目。在模型中与隐含状态相关联，可通过直接观测而得到。时刻 t 观察到的观察值为 $\mathbf{o}_t$ ， $\mathbf{o}_t \in \{v_1, v_2, \dots, v_K\}$ 。

HMM的模型描述和参数（续）（基本概念）

3) 初始状态概率矩阵: $\pi = [\pi_1 \ \pi_2 \ \dots \ \pi_N]$

表示隐含状态在初始时刻 $t=1$ 的概率矩阵。其中

$\pi_i = P(q_1 = i)$ 。

4) 状态转移矩阵: $\mathbf{A} = [a_{i,j}]$, $1 \leq i, j \leq N$

描述了HMM中各个状态之间的转移概率, $a_{i,j}$ 表示在 $t-1$ 时刻状态为 s_i (即 i), 且在 t 时刻状态为 s_j (即 j) 的概率。

5) 观测值概率矩阵: $\mathbf{B} = [b_j(k)]$, $1 \leq j \leq N, 1 \leq k \leq K$

表示在 t 时刻、隐含状态是 s_j 的条件下, 观察值为 v_k 的概率。

$b_j(\mathbf{o}_t) = P(\mathbf{o}_t = v_k | q_t = j)$, $k = 1, 2, \dots, K; j = 1, 2, \dots, N$

一个HMM的参数组为: $\lambda = (\mathbf{S}, \mathbf{V}, \pi, \mathbf{A}, \mathbf{B})$; 简写为: $\lambda = (\pi, \mathbf{A}, \mathbf{B})$

HMM的三个基本问题（掌握）

问题1：模型概率计算问题

已知一个HMM参数组 $\lambda = (\pi, A, B)$ ，和给定一个观察值序列 $\mathbf{O} = o_1 o_2 \dots o_T$ 的条件下，如何计算在给定模型 λ 的条件下观察值序列 $\mathbf{O}$ 的概率 $P(\mathbf{O}|\lambda)$ 。

问题2：模型解码问题

给定模型 λ 和观察值序列 $\mathbf{O}$ ，如何确定一个最佳状态序列 $Q^* = \{q_1^*, q_2^*, \dots, q_T^*\}$ 。

问题3：模型参数估计问题

给定观察值序列集合 $\mathbf{O}$ ，如何调整参数 λ ，使得 $P(\mathbf{O}|\lambda)$ 达到最大值。

模型概率计算 —— 直接算法（了解）

先计算 $P(\mathbf{O}, \mathbf{Q}|\lambda)$ ，其中 $\mathbf{Q}$ 为一给定的状态序列 $\mathbf{Q} = q_1 q_2, \dots, q_T$

有
$$P(\mathbf{O}, \mathbf{Q}|\lambda) = P(\mathbf{O}|\mathbf{Q}, \lambda)P(\mathbf{Q}|\lambda)$$

而
$$P(\mathbf{O}|\mathbf{Q}, \lambda) = \prod_{t=1}^T P(\mathbf{o}_t|q_t, \lambda) = b_{q_1}(\mathbf{o}_1)b_{q_2}(\mathbf{o}_2) \cdots b_{q_T}(\mathbf{o}_T)$$

$$P(\mathbf{Q}|\lambda) = \pi_{q_1} a_{q_1 q_2} \cdots a_{q_{T-1} q_T}$$

所以
$$\begin{aligned} &P(\mathbf{O}, \mathbf{Q}|\lambda) \\ &= \pi_{q_1} b_{q_1}(\mathbf{o}_1) a_{q_1 q_2} b_{q_2}(\mathbf{o}_2) \cdots a_{q_{T-1} q_T} b_{q_T}(\mathbf{o}_T) \end{aligned}$$

模型概率计算 —— 直接算法（续）（了解）

$$\begin{aligned} P(\mathbf{o}|\lambda) &= \sum_{\forall \mathbf{Q}} P(\mathbf{o}, \mathbf{Q}|\lambda) \\ &= \sum_{\forall \mathbf{Q}} \pi_{q_1} b_{q_1}(\mathbf{o}_1) a_{q_1 q_2} b_{q_2}(\mathbf{o}_2) \cdots a_{q_{T-1} q_T} b_{q_T}(\mathbf{o}_T) \end{aligned}$$

计算量? $2TN^T$

当 $N = 5$, $T = 100$ 时, 计算量达 10^{72}

解决思路：前向、后向算法


(forward algorithm, backward algorithm)

模型概率计算 —— 前向算法(forward algorithm)

(掌握)

前向变量: $\alpha_t(i) = P(\mathbf{o}_1 \mathbf{o}_2 \cdots \mathbf{o}_t, q_t = i | \lambda)$

定义: 到时刻 t 为止部分观测序列为 $\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_t$, 且状态为 s_i (为方便表示, 在后面的算法中状态 s_i 简记为 i) 的概率。



前向概率计算示意图

模型概率计算 —— 前向算法（续） （掌握）


前向变量有如下性质：

(1) 初值易求 $\alpha_1(i) = P(\mathbf{o}_1, q_1 = i) = \pi_i b_i(\mathbf{o}_1)$

(2) 可以计算 $P(\mathbf{O}|\lambda) = \sum_{i=1}^N \alpha_T(i)$

(3) 有递推关系 $\alpha_t(j) = \left[\sum_{i=1}^N \alpha_{t-1}(i) a_{ij} \right] b_j(\mathbf{o}_t)$

因此可以利用递推关系，逐层递推，计算出全部 $\alpha_t(j)$ 。
最后再由 $\alpha_T(j)$ 计算得到 $P(\mathbf{O}|\lambda)$ 。



前向概率计算示意图

模型概率计算 —— 前向算法 (续)

(掌握)

前向算法:


(1) 初始化: 对 $1 \leq i \leq N$, 有

$$\alpha_1(i) = \pi_i b_i(\mathbf{o}_1)$$

(2) 递推: 对 $2 \leq t \leq T, 1 \leq j \leq N$, 有

$$\alpha_t(j) = \left[\sum_{i=1}^N \alpha_{t-1}(i) a_{ij} \right] b_j(\mathbf{o}_t)$$

(3) 终止: $P(\mathbf{o}|\lambda) = \sum_{i=1}^N \alpha_T(i)$



前向概率计算示意图


计算量为 N^2T ,
当 $N=5, T=100$ 时,
只需 2500 次乘法运算

模型概率计算——后向算法 (backward algorithm)

(掌握)

后向变量: $\beta_t(i) = P(\mathbf{o}_{t+1} \mathbf{o}_{t+2} \cdots \mathbf{o}_T | q_t = i, \lambda)$

定义: 从时刻 $t+1$ 开始到 T 为止部分观测序列为 $\mathbf{o}_{t+1}, \mathbf{o}_{t+2}, \dots, \mathbf{o}_T$, 且状态为 i 的概率。



后向概率计算示意图

模型概率计算 —— 后向算法 (续)

(掌握)

后向算法:


(1) 初始化: 对 $1 \leq i \leq N$, 有

$$\beta_T(i) = 1$$

(2) 递推: 对 $t = T - 1, T - 2, \dots, 1, 1 \leq i \leq N$, 有

$$\beta_t(i) = \left[\sum_{j=1}^N \beta_{t+1}(j) a_{ij} b_j(\mathbf{o}_{t+1}) \right]$$

(3) 终止: $P(\mathbf{O}|\lambda) = \sum_{i=1}^N \pi_i b_i(\mathbf{o}_1) \beta_1(i)$



后向概率计算示意图

计算量为 $N^2 T$ 数量级

模型解码问题的描述（掌握）

■ 最佳状态序列的确定

确定一个最佳状态序列 $\mathbf{Q}^* = q_1^*, q_2^*, \dots, q_T^*$, 使 $P(\mathbf{O}, \mathbf{Q}^* | \lambda)$ 为最大。

$$\mathbf{Q}^* = \underset{\mathbf{Q}}{\operatorname{argmax}} P(\mathbf{O}, \mathbf{Q} | \lambda)$$

定义 $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1 q_2 \dots q_{t-1}, q_t = i, \mathbf{o}_1 \mathbf{o}_2 \dots \mathbf{o}_t | \lambda)$ 为时刻 t 时沿着一条路径 $q_1 q_2 \dots q_{t-1}$, 且 $q_t = i$, 产生 $\mathbf{o}_1 \mathbf{o}_2 \dots \mathbf{o}_t$ 的最大概率。

如何求解最佳状态序列 $\mathbf{Q}$?

解决思路: Viterbi 算法

Viterbi算法（掌握）

求取最佳状态序列 Q^* 的过程为


(1) 初始化: 对 $1 \leq i \leq N$, 有

$$\begin{aligned}\delta_1(i) &= \pi_i b_i(\mathbf{o}_1) \\ \varphi_1(i) &= 0\end{aligned}$$

(2) 递推: 对 $2 \leq t \leq T, 1 \leq j \leq N$, 有

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(\mathbf{o}_t)$$

$$\varphi_t(j) = \operatorname{argmax}_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}]$$




Viterbi算法（续）（掌握）

求取最佳状态序列 Q^* 的过程为

(3) 终止:

$$P^* = \max_{1 \leq i \leq N} [\delta_T(i)]$$

$$q_T^* = \operatorname{argmax}_{1 \leq i \leq N} [\delta_T(i)]$$



(4) 路径回溯, 确定最佳状态序列:

$$q_t^* = \varphi_{t+1}(q_{t+1}^*), t = T - 1, T - 2, \dots, 1$$

最终得到最佳状态序列 Q^* 以及所对应的概率 P^*

模型参数估计的思路（基本概念）

给定一个观察值序列 $O = o_1 o_2 \dots o_T$ 确定一个 $\lambda = (\pi, A, B)$ 使得 $P(O|\lambda)$ 最大。实际上，不存在一种方法直接估计最佳的 λ 。

思路：

根据观察值序列选取初始模型 $\lambda = (\pi, A, B)$ ，然后依据某种方法求得一组新参数 $\hat{\lambda} = (\hat{\pi}, \hat{A}, \hat{B})$ ，保证有 $P(O|\hat{\lambda}) > P(O|\lambda)$ 。利用递归的思路重复这个过程，逐步改进模型参数，直到 $P(O|\hat{\lambda})$ 收敛。

■ 经典的方法：Baum-Welch算法

Baum-We lch算法（基本概念）

- Baum-We lch算法是用来解决当观测序列和隐状态序列未知时的HMM参数的算法，该算法是期望最大化（EM）算法的一个特例。
- 设辅助函数 $L(\lambda, \hat{\lambda}) = \sum_Q P(Q|\mathbf{O}, \hat{\lambda}) \log P(\mathbf{O}, Q|\lambda)$ 。
 - 在步骤E（期望）求给定参数集 λ 上的 $L(\lambda, \hat{\lambda})$ ；
 - 在步骤M（最大化）更新模型参数 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 。

$$\hat{\lambda} = \arg \max_{\lambda} \sum_Q P(Q|\mathbf{O}, \hat{\lambda}) \log P(\mathbf{O}, Q|\lambda)$$

- Baum-We lch算法未必能求得全局最大值、而有可能得到一局部极值点。

Baum-We lch算法（续）（了解）

- 给定训练序列 $\mathbf{O}$ 和模型 λ 时，
定义 $\xi_t(i, j)$ 为 t 时刻处于状态 i ， $t+1$ 时刻处于状态 j 的概率；
定义 $\gamma_t(i)$ 为 t 时刻位于状态 i 的概率。
- 使用初始化参数 $\pi_i, a_{ij}, b_i(k)$ 和前向概 $\alpha_t(j)$, 后向概率 $\beta_t(j)$ ，
在步骤E时计算期待值 $\xi_t(i, j)$ 和 $\gamma_t(i)$ 。

$$\xi_t(i, j) = P(q_t = i, q_{t+1} = j | \mathbf{O}, \lambda) = \frac{\alpha_t(i) a_{ij} b_j(\mathbf{o}_{t+1}) \beta_t(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(\mathbf{o}_{t+1}) \beta_t(j)};$$

$$\gamma_t(i) = P(q_t = i | \mathbf{O}, \lambda) = \sum_{j=1}^N \xi_t(i, j) = \frac{\alpha_t(i) \beta_t(i)}{\sum_{j=1}^N \alpha_t(j) \beta_t(j)}$$

$\xi_t(i, j)$: 在 t 时刻处于状态 i 且在 $t+1$ 时刻处于状态 j 的概率。

$\gamma_t(i)$: t 时刻处于状态 i 的概率，即为状态占用概率。

Baum-We lch算法（续）（了解）

- 在步骤M时重新估计HMM的参数如下：

$$\hat{a}_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)} ;$$


$$\hat{b}_j = \frac{\sum_{t=1, o_t=v_k}^{T-1} \gamma_t(j)}{\sum_{t=1}^{T-1} \gamma_t(i)} ;$$

$$\hat{\pi}_i = \gamma_1(i)$$

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
 - 3.2.1 隐马尔可夫模型
 - 3.2.2 基于GMM-HMM的语音识别技术
 - 3.2.3 DNN-HMM
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望


语音识别领域离散HMM的典型结构（基本概念）



从左向右HMM
(Left-to-right HMM)

如何计算连续随机变量的概率？（了解）

- 语音的特征向量为连续数值！
- 如何计算连续数值的特征值所对应的概率？
 - 矢量量化（Vector Quantization）：把特征向量聚类到有限（离散）的类



- 用概率密度函数
 - 经典模型：混合高斯模型（GMM）用来计算观测值概率

单高斯模型 —— 单元高斯模型（了解）

- 高斯分布即正态分布，是最常见概率分布模型，它经常被用来刻画一些随机量的变化情况。当样本数据 x 是一维数据时，高斯分布（称为单元高斯模型）遵从下方概率密度函数：

$$P(x|\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$$

则称 x 服从均值(期望)为 μ ，方差为 σ^2 的正态分布，记为 $x \sim N(\mu, \sigma^2)$ 。

单高斯模型 —— 多元高斯模型（了解）

- 当样本数据 $\mathbf{x} = (x_1, x_2, \dots, x_D)^T$ 为多维数据时，遵从下方概率密度函数，称为多元高斯模型：

$$P(\mathbf{x}|\theta) = \frac{1}{(2\pi)^{D/2}(\boldsymbol{\Sigma})^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$


其中， $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_D)^T = E(\mathbf{x})$ ，
 $\boldsymbol{\Sigma} = E[(\mathbf{x} - \bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}})^T]$ 分别为 $\mathbf{x}$ 的均值和协方差矩阵。

在语音识别中，多元高斯模型的输入为 t 时刻观测值的向量 $\mathbf{o}_t$ （比如：实际系统中可为某一帧的特征向量 MFCC 等）。

高斯混合模型 (Gaussian Mixture Models)

(基本概念)

- **高斯混合模型**是用高斯概率密度函数精确地量化事物，将一个事物分解为若干的基于高斯概率密度函数（正态分布曲线）形成的模型。它可以看作是由M个单高斯模型组合而成的模型来描述复杂的数据（比如语音数据）分布。



使用高斯混合模型是因为高斯分布具备很好的数学性质以及良好的计算性能。

高斯混合模型（续）（掌握）

- 对于M个高斯模型的混合模型， c_m 是观测数据属于第m个子模型的先验概率（混合权重），则高斯混合模型的概率分布为：

$$P(\mathbf{x}|\theta) = \sum_{m=1}^M c_m N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m)$$

$$N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m) = \frac{1}{(2\pi)^{D/2}(\boldsymbol{\Sigma}_m)^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_m)^T \boldsymbol{\Sigma}_m^{-1}(\mathbf{x} - \boldsymbol{\mu}_m)\right\}$$

其中， $\sum_{m=1}^M c_m = 1$ ， $N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m)$ 是第m个子模型的高斯分布密度函数。

高斯混合模型（续）（掌握）


- 在语音处理中，我们通常用连续的概率密度函数来描述连续的观察值向量（ $\mathbf{o}_t$ ）的概率分布。混合高斯模型是其中应用最成功的、最广泛的概率密度函数，若用混合高斯模型（GMM）来表示 $\mathbf{o}_t$ 的概率分布

$$b_i(\mathbf{o}_t) = \sum_{m=1}^M \frac{c_{i,m}}{(2\pi)^{D/2} |\boldsymbol{\Sigma}_{i,m}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{o}_t - \boldsymbol{\mu}_{i,m})^T \boldsymbol{\Sigma}_{i,m}^{-1} (\mathbf{o}_t - \boldsymbol{\mu}_{i,m}) \right\}$$

其中， $c_{i,m}$ 是状态*i*时第*m*个高斯子模型的权重， $\boldsymbol{\mu}_{i,m}$ 和 $\boldsymbol{\Sigma}_{i,m}$ 为状态*i*时第*m*个高斯分布的均值向量和协方差矩阵。

基于GMM-HMM的语音识别框架（基本概念）


■ GMM-HMM（高斯混合模型-隐马尔可夫模型）



- L. R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. Proc. IEEE, 77(2):257–286, 1989.

基于HMM的孤立词识别技术（基本概念）


■ 孤立词识别原理图



建模单元：孤立词或者子词（音素等）

基于HMM的连接词识别技术（了解）

- 基于HMM的连接词识别
 - 典型例子：数字串识别
- 0-9共10个数字，采用从左至右无跨越HMM
- 形成一个新的HMM
- 通过Viterbi算法解码



基于HMM的连续语音识别技术（基本概念）

- 连续语音识别（特别是大词表连续语音识别：LVCSR）是语音识别研究中意义最重大、应用成果最丰富，同时最具有挑战性的研究课题。
- 特有的问题：
 - 词（模式）的数量太多，语料不够；
 - 发音相近的内容多，误识严重；
 - 句子中的单词数不确定；
 - 单词边界（起始和结束时间）难以确定；
 - 发音变化（受协同发音的影响严重）。


基于HMM的LVCSR系统的统一框架

（基本概念）

- 将整个识别系统分为三层：声学—语音层、词层和句法层
 - 声学—语音层是识别系统的底层，它接受输入语音，并以一种“子词（Subword）”单位作为其识别输出，每个子词单位对应一套HMM结构和参数。
 - 词层规定词汇表中每个词是由什么音素—音子串接而成的。
 - 句法层中规定词按照什么规则组合成句子。


基于HMM的LVCSR系统的统一框架（续）

（了解）



基于HMM的LVCSR系统的统一框架（续）


（了解）



在句法层，每个句子由若干词条组成，每一个词条都选自词汇表。句中的一个要选择的词条以一定的概率出现，而第二个词条选择的概率与前一个词条有关（[语言模型](#)），依此类推，直到句子的结束。

在词层，每一个词条由若干音子串接而成，为此需要一部[字典](#)来描述这种串接关系。


基于HMM的LVCSR系统的统一框架（续） （了解）



在语音层，每一个音子用一个HMM模型及一套参数来表示。


基于HMM的LVCSR系统的统一框架（续）

（基本概念）



基于子词单元的连续语音识别系统总体框图

基于统计模型的语音识别框架（重点掌握）



Front-end processing
(前端处理)

Back-end processing
(后端处理)

连续语音识别系统需要解决的几个主要问题 (了解)

- | | |
|------------------|------|
| 1. 声学建模单元（子词）的选择 | 声学模型 |
| 2. 如何由子词构成词？ | 字典 |
| 3. 如何训练子词模型？ | 声学模型 |
| 4. 如何有效利用语言学知识？ | 语言模型 |
| 5. 如何识别得到最优单词序列？ | 解码算法 |


建模单元的选择 —— 原则（基本概念）

- 以词作为基本单元建立模型不合理，造成大量不必要的冗余存储和计算。因此一般采用比词小的子词识别基元，如音节、半音节、音素等。
- 声学单元越小，其数量也就越少，训练模型的工作量也就越小；
- 但是，单元越小，对上下文的敏感性越大，更容易受到前后相邻的影响而产生变异，因此其类型设计和训练样本的采集更困难。

建模单元的选择 —— 三音素HMM（基本概念）


- 单音素建模没有考虑协同发音效应。协同发音 (coarticulation) 是指在语流中，音段并非是静止的、分离的声音，音段会对相邻的音段产生影响。
- 协同发音的一个解决方法是用三音素建模，考虑音素的上下文，表示为“l-c+r”，其中，c表示中心单元，l为左相关信息，r为右相关信息。
- 假设共有N个音素，那么就需要 N^3 个三音素，当N增大时，参数量也是非常大的。因此，在语音建模中，使用决策树来进行三音素建模。这一过程依赖于单音素建模后的对齐。

建模单元的选择 —— 决策树（了解）



如何由子词构成词？（了解）

- 在声学—语音学层与句法层之间有一个词层，在词层中应有一部字典来规定词表中每一个词是用哪些子词单元以何种方式构筑而成的。最简单实用的方案是每个词用若干子词单元串接而成。
- 每个词的发音可能有多种变化方式，在子词串接时，必须有所体现。
 - 替换：即词中的某个音子可能被用其它相似而略有差异的子词单元所替换。
 - 插入和删除：词中有时增加了一个不是本词成分的子词单元，有时又将本词成分中的某个子词删除。



如何训练子词模型？（了解）


分段 K 均值算法

- 初始化：将每个训练语句线性分割成子词单元，将每个子词单元线性分割成状态，即假定在一个语句中，子词单元及其内部的状态驻留时间是均匀的；
- 聚类：对每个给定子词单元的每一个状态，其在所有训练语句段中特征矢量用 K 均值算法聚类；
- 参数估计：根据聚类的结果计算均值、各维方差和混合权值系数；
- 分段：根据上一步得到的新的子词单元模型，通过Viterbi算法对所有训练语句再分成子词单元和状态，重新迭代聚类和参数估计，直到收敛。

从单音素到三音素GMM

(基本概念)

- 始于单音素，进行EM训练
- 将高斯分布 (Gaussians) 复制到三音素中
- 创建决策树并对高斯分布进行聚类
- 复制并混合训练 (GMMs)




第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
 - 3.2.1 隐马尔可夫模型
 - 3.2.2 基于GMM-HMM的语音识别技术
 - 3.2.3 DNN-HMM
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望


语音识别-声学模型

从GMM-HMM到端到端模型


1990s-2009: The GMM-HMM hybrid system. (CU-HTK)



2009-2019: The DNN-HMM hybrid system. (JHU-Kaldi, MS-CNTK)




2014: The CTC End-to-End system. (CMU-EESEN, Baidu-WarpCTC)



2016: The Encoder-Decoder End-to-End system.

(Google-LAS/Transformer, facebook-wav2letter, JHU-ESPNet)




2023-Now: Speech Large Language Model

HMM的观测值概率分布

- 离散分布 (Discrete Distribution) HMM
 - 矢量量化 (Vector Quantization: VQ)
- 连续分布 (Continues Distribution) HMM (CD-HMM)
 - 高斯混合模型 (Gaussian Mixture Model: GMM)
 - 深度神经网络 (Deep Neural Network: DNN)

VQ和GMM的问题（了解）



GMM的问题:

- 实际的数据并不严格服从高斯分布
- 一般利用上下文无关的特征

- 二维特征
- 单高斯模型

基于DNN的语音识别算法

- 20世纪80年代就开始进行结合ANN的尝试
 - 用ANN替换GMM
 - 用BP算法进行训练
- 但由于当时机器运算能力的限制及多层网络训练的复杂性，其效果并不理想（过拟合）。
- 2010年，深度学习开始对语音识别领域产生重要的影响，其识别错误率显著下降。
- 基于DNN的语音识别技术也是深度学习方法在工业界的第一个成功应用，具有里程碑式的意义。

基于DNN的语音识别算法（续）（了解）

- 深度学习是机器学习的子领域，它是对多层表示和抽象的学习，通过多层表示来对数据之间的复杂关系进行建模。
- 通过多层非线性表示来对数据间的复杂关系进行建模。
- 引入深度学习的语音识别技术：
 - 基于DNN-HMM的语音识别方法（本课程的内容）
 - 基于RNN-HMM的语音识别方法
 - 端到端语音识别方法（展望）

深度神经网络（DNN）的介绍

- 深度神经网络（Deep Neural Network, DNN）可以简单的定义为在输入层和输出层之间有多层隐含层（超过一层）的人工神经网络。
- 经典的做法是先基于深度信念网络（Deep Belief Networks, DBN）做预训练，之后用反向传播（Backpropagation, BP）算法微调。

深度神经网络(DNN)的介绍 (续)


每一个神经元把经过乘法线性变换的上一层的输出求和得到 $\mathbf{a}^l$ ，然后通过非线性激活函数输出给下一层。对于包含 L 个隐层的DNN，假设其输入为 $\mathbf{h}^0 = \mathbf{o}_t$ ，第 l 层隐层的输出 $\mathbf{h}^l$ 可以由如下公式表示：

$$\mathbf{a}^l = \mathbf{W}^l \mathbf{h}^{l-1} + \mathbf{b}^l \quad 1 \leq l \leq L + 1$$

$$\mathbf{h}^l = f(\mathbf{a}^l) \quad 1 \leq l \leq L$$

$$f(a) = \frac{1}{1 + e^{-a}}$$

其中 $f(\cdot)$ 是非线性激活函数， $\mathbf{W}^l$ 和 $\mathbf{b}^l$ 是第 l 层隐层的权重和偏置向量。



深度神经网络(DNN)的介绍（续）

分类任务（比如：语音识别）的损失函数多采用最小交叉熵（cross-entropy, CE）准则，可以表示如下：


$$J_{CE} = -\sum_{i=1}^C y_i \log h_i^{L+1}$$

其中 y_i 是观测值 $\mathbf{o}_t$ 属于第 i 类的经验概率分布（从训练数据的标注中来）， h_i^{L+1} 是采用DNN估计的观测值 $\mathbf{o}_t$ 属于第 i 类的概率，表示为：

$$h_i^{L+1} = P(i|\mathbf{o}_t) = \frac{e^{-a_i^{L+1}}}{\sum_j e^{-a_j^{L+1}}}$$

利用反向传播（BP）算法最小化 J_{CE} 得到更新网络的参数。


GMM-HMM（高斯混合模型-隐马尔可夫模型）回顾



- L. R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. Proc. IEEE, 77(2):257–286, 1989.

DNN-HMM语音识别算法框架

- 用DNN替换GMM
- 用DNN计算观察值概率
- 用GMM-HMM算法分割语音内容
- 在分割好的语音内容上训练DNN
- 识别性能大幅度改善



DNN-HMM的建模能力

- DNN不需要对声学特征所服从的分布进行假设；
- DNN的输入可以采用连续的拼接帧，更好的利用了上下文信息；
- DNN的训练过程可以采用随机优化算法来实现，因此当训练数据规模较大时也能进行非常高效的训练；
- 在发音模式分类上，DNN这种鉴别式模型也要比GMM这种生成式模型更加适合；
- 无监督预训练。

DNN的输入

- 更底层的滤波器组（Filter Bank, FBK）声学特征。它利用Mel滤波器组在功率谱上进行滤波并计算对数能量，然后采用其规整值作为特征表示；
- 目前，**FBK特征**比MFCC有效；验证了原始语音频谱对基于DNN的语音识别技术的重要性；
- 不同于传统的GMM采用单帧特征作为输入，DNN会进行拼接帧的操作。会将**相邻的若干帧**进行**拼接**得到一个包含更多信息的**输入向量**，例如每7帧构成一个输入。

DNN的输出

- DNN输出向量的维度对应HMM中状态的个数，通常每一维输出对应一个绑定的triphone状态。
- 训练时，为了得到每一帧语音在DNN上的目标输出值（标注值），需要通过事先训练好的GMM-HMM识别系统在训练语料上进行强制对齐（Force alignment）。
- 基于GMM-HMM通过基于Viterbi算法的强制对齐方法，给每个语音帧打上HMM状态标签，然后依据此状态标签，基于DNN训练算法训练一个DNN模型。
- 用DNN替换GMM

DNN的训练

- 用BP算法直接进行训练往往效果不佳，这也是早期基于ANN的混合声学模型未能成功应用的主要原因
- 多层神经网络参数优化是个高维非凸优化问题，常收敛较差的局部解。
- 梯度消失问题：BP算法计算出的误差会从输出层开始向下呈指数衰减，这样计算出各层的梯度也会随着深度的变化而显著下降，导致靠近输出层的隐层训练的比较好，而靠近输入层的隐层几乎不能得到有效训练。
- 解决方法：通过预训练找一个合适的初值。

DNN的训练(续)

- 分为无监督的预训练(Pre-training)和有监督的鉴别性微调(Fine-tuning)。

- Pre-training

用受限波尔兹曼机(Restricted Boltzmann Machines, **RBM**)算法逐层训练构建深层置信网络(Deep Belief Networks, **DBN**)。

- Fine-tuning

将DBN 作为 DNN 的初始化参数, , 采用标准误差反向传播(Standard Error Back Propagation, BP)算法对DNN进行调整。

DNN的训练(续)

- 使用海量训练数据进行训练能有效避免过拟合问题；
- Dropout等随机优化算法的提出也极大提高了DNN模型的泛化能力；
- 一些措施的采用也成功地减小了梯度消失问题的影响
 - 整流线性单元 (Rectified Linear Units, ReLU) 作为激活函数
 - 采用卷积神经网络 (Convolutional Neural Networks, CNN) 这种深度网络结构。

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
- 3.3 语言模型
 - 3.3.1 语言模型的基本概念（基本概念）
 - 3.3.2 N-gram语言模型（基本概念）
 - 3.3.3 神经语言模型（了解）
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望

语言模型的定义

■ 语言模型：用来计算一个句子概率的模型

- 从词表中任意选择若干同音词所构成的序列不一定能构成自然语言中的合乎句法的句子。
- 人类在识别和理解语句时充分利用了这种约束。

■ 在语音识别中的应用

- 在大词汇量的语音识别系统中，统计语言模型被广泛应用来实现句子的约束。将这些知识与声学模型匹配相结合进行结果判决，以减小由于声学模型不够合理而产生的误识。
- 例子：“（福建重口音）我要回福建省福州市，帮我买盒五仁月饼。”，只有声学模型可能会被误识别为“我要回胡建省湖州市，帮我买盒五人月饼。”

语言模型的分类

- 基于文法的语言模型
 - 总结语法规则及语音规则
- 基于统计的语言模型
 - 统计各个词的出现概率及其相互关联的条件概率
 - 经典模型：N-gram语言模型
- 基于深度学习的语言模型（神经语言模型）
 - 通过训练网络来学习词表征和单词序列的概率化表示

语言模型的评价指标 (Perplexity)

- 衡量一个模型的拟合测试数据程度。
- 使用模型分配给测试集的概率。
- 估计测试语料库中的句子概率并取倒数，对句子长度进行归一化。

$$PP(W) = \sqrt[N]{\frac{1}{P(w_1 w_2 \dots w_N)}}$$

$$P(w_1^N) = P(w_1)P(w_2|w_1)P(w_3|w_1^2)\dots P(w_N|w_1^{N-1}) = \prod_{n=1}^N P(w_n | w_1^{n-1}) \quad W = w_1^N$$

- 测量预测下一个词时的加权平均分支因子(越低越好)

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
- 3.3 语言模型
 - 3.3.1 语言模型的基本概念
 - 3.3.2 N-gram语言模型
 - 3.3.3 神经语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望

N-gram语言模型（掌握）

- 单词序列

$$w_1^n = w_1 \dots w_n$$

- 概率的链式法则

$$P(w_1^n) = P(w_1)P(w_2 | w_1)P(w_3 | w_1^2) \dots P(w_n | w_1^{n-1}) = \prod_{k=1}^n P(w_k | w_1^{k-1})$$

- N-gram近似

$$P(w_1^n) = \prod_{k=1}^n P(w_k | w_{k-N+1}^{k-1})$$

假设词 w_k 出现的概率只与前 $N-1$ 个单词有关：N-1阶马尔可夫模型

N-gram语言模型（续）

- 根据之前的上下文估计每个单词的概率
 - $P(\text{phone} \mid \text{Please turn off your cell})$
- 所需的参数数量随着先前上下文的单词数量呈指数增长
- 一个N-gram 模型只需要N-1 个先前上下文的单词
 - Unigram: $P(\text{phone})$
 - Bigram: $P(\text{phone} \mid \text{cell})$
 - Trigram: $P(\text{phone} \mid \text{your cell})$

N-gram语言模型的复杂度（困惑度）

- 模型训练了来自《华尔街日报》(WSJ)的3800万个单词（可重复），词汇表的大小为19979个单词（互相不重复的单词）
- 用《华尔街日报》150万单词进行评估

	Unigram	Bigram	Trigram
Perplexity	962	170	109

没有使用语言模型（0-gram）时的perplexity为多少？

N-gram语言模型的概率估计

- 基于单词序列的相对频率，可以从原始文本中估计出N-gram条件概率。

$$\text{Bigram:} \quad P(w_n | w_{n-1}) = \frac{C(w_{n-1}w_n)}{C(w_{n-1})}$$

$$\text{N-gram:} \quad P(w_n | w_{n-N+1}^{n-1}) = \frac{C(w_{n-N+1}^{n-1}w_n)}{C(w_{n-N+1}^{n-1})}$$

- 要有一个一致的概率模型，在每个句子中附加一个唯一的开始<s>和结束</s>符号，并将它们视为附加单词。

语言模型的平滑技术

- 由于存在可能的单词序列的组合数，许多罕见（但并非不可能）的组合在训练中从未出现，因此最大似然估计（MLE）错误地将许多参数（也就是稀疏数据）赋值为零。
- 如果在测试过程中出现了新的组合，则给出该组合的概率为零，整个序列的概率为零。
- 在实际处理中，参数被平滑（又称正则化），以重新分配一些概率值给未知的事件。
- 为未知的事件添加概率值需要将其从看到的事件中移除(折现)，以保持和为1的联合分布。

加法平滑技术（了解）

- 对所有事件的频率值加上固定值避免零概率事件，add- δ 平滑在每个事件的出现次数加上一个数 δ ，即

$$P_{\text{add}}(w_{i-N+1}^{i-1}) = \frac{c(w_{i-N+1}w_{i-N+2}\dots w_i) + \delta}{\sum_{w_i} c(w_{i-N+1}w_{i-N+2}\dots w_{i-1}) + \delta|V|}$$

- 其中 $0 < \delta \leq 1$ ， $|V|$ 是Unigram的词表个数。当 $\delta=1$ 时，称为“加1法”。
- 性能较差。

线性插值平滑技术（了解）

- 利用低阶模型对高阶N-gram模型进行线性插值，平滑公式为：

$$P_{\text{interp}}(w_i | w_{i-N+1}^{i-1}) \\ = \lambda_{w_{i-N+1}^{i-1}} P_{\text{ML}}(w_i | w_{i-N+1}^{i-1}) + (1 - \lambda_{w_{i-N+1}^{i-1}}) P_{\text{interp}}(w_i | w_{i-N+2}^{i-1})$$

其中 $\lambda_{w_{i-N+1}^{i-1}}$ 为插值系数

- N元文法语言模型可以递归地定义为由最大似然估计原则得到的N元文法语言模型和（N-1）元文法语言模型的线性插值。

N-gram语言模型的问题：长距离依赖（了解）

- 很多时候，本地上下文并不提供最有用的预测线索，而是由远程依赖提供的
 - 语法的依赖性
 - “The **man** next to the large oak tree near the grocery store on the corner **is** tall.”
 - “The **men** next to the large oak tree near the grocery store on the corner **are** tall.”
 - 语义依赖性
 - “The **bird** next to the large oak tree near the grocery store on the corner **flies** rapidly.”
 - “The **man** next to the large oak tree near the grocery store on the corner **talks** rapidly.”
- 需要更复杂的语言模型来处理这种依赖关系

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
- 3.3 语言模型
 - 3.3.1 语言模型的基本概念
 - 3.3.2 N-gram语言模型
 - 3.3.3 神经语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望

神经语言模型


- 神经语言模型（Neural Language Model, NLM）可以用来对文本的长距离依赖建模。
- 不同于基于类的N-gram模型，神经语言模型在能够识别两个相似的词，并且不丧失将每个词编码为彼此不同的能力。
- 神经语言模型共享一个词（及其上下文）和其他类似词。

神经语言模型历史

- 2003年Bengio等人提出了前向神经网络（Feed-forward Neural Network, FNN）语言模型
- 2010年Mikolov等人将循环神经网络（RNN）用于语言模型
- 2013年Graves等人提出基于长短期记忆（Long Short Term Memory, LSTM）循环神经网络的语言模型
- 2014年Bahdanau等人[46]首次将注意力机制用于NLP任务
- 2016年Tran等人和Mei等人证明了注意力机制可以提升RNNLM的性能

RNN（循环神经网络）语言模型简介

- RNN是一类用于处理序列数据的神经网络，在语言模型中对应单词的前后顺序
- 构建历史长度不受限定，具有更强的记忆能力的网络



RNN的基本结构

RNN（循环神经网络）语言模型简介（续）

■ 例子

输出层



Output Layer

隐藏层

Hidden Layer


输入层

Input Layer



RNN（循环神经网络）语言模型简介（续）

■ 长上下文建模解释




第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
- 3.3 语言模型
- 3.4 语音识别解码算法（了解）
- 3.5 语音识别技术的展望

孤立词识别及解码技术（基本概念）

■ 孤立词识别原理图



连续语音识别的解码算法

$$P(W | Y) = \arg \max_{\{w_1^N\} \{t_1^N\}} \left\{ \sum_{n=1}^N \log(P_{acoust}(y_{t_{n-1}+1}^{t_n} | w_n)) \right. \\ \left. + \lambda \cdot \sum_{n=1}^N \log(P_{lang}(w_n | w_{n-1}) + \delta) \right\}$$

$P_{acoust}(y_{t_{n-1}+1}^{t_n} | w_n)$: 声学模型的似然

$P_{lang}(w_n | w_{n-1})$: 语言模型的似然

λ : 权重

δ : 插入的惩罚

连续语音识别的解码算法

- 对大词汇量连续语音识别，最终目的是从各种可能的子词序列形成的一个网络中，找出一个或多个最优的子词序列。这在本质上属于搜索算法或解码算法的范畴。
- 在搜索过程中，路径数随着搜索的进行急剧增加。全搜索几乎是不可能的。因此常采用基于一定裁剪路径的算法。
- 解码算法
 - 基于Viterbi的解码算法
 - 基于加权有限状态自动机（WFST）

Viterbi beam 搜索解码算法

Viterbi beam搜索算法是一个广度优先的帧同步算法，在每一时刻有效地剪裁低得分路径。


- 初始化
 初始化活动路径（最高层）
- 递推
 For 帧 $t=1$ 到 T
 For 每一层次（指各个层次的语言和声学模型）
 For HMM的每个活动状态
 把每个活动路径向后扩展一帧至所有可以到达的状态
 执行Viterbi计算
 裁剪路径
 End {活动状态}
 End {每一层次}
 End {观察矢量序列}
- 终止：选择最可能的路径

基于Viterbi的解码算法的问题：

- 由于LVCSR实际任务中N-gram，词典和三音素建模导致无法只简单的使用Viterbi算法，需要进行一些工程优化
 - 剪枝(Pruning)
 - 多阶段解码(Multi-stage decoding)
 - 语言模型超前使用(Language model Look-ahead)

加权有限状态转换机(WFST)

- WFST由状态节点和边组成，且边上有对应的输入、输出符号及权重，形式为 $x : y/w$ ，表示该边的输入符号为 x 、输出符号为 y 、权重为 w ，权重可以定义为概率（越大越好）、惩罚（越小越好）等，从起始到结束状态上的所有权重通常累加起来，记为该条路径的分数，一条完整的路径必须从起始状态到结束状态。



语言模型WFST示例

连续语音识别中的WFST

- 连续语音识别利用几个知识来源（词典、语法、音素、声学模型）寻找最有可能的单词序列。

$$HCLG = H \circ C \circ L \circ G$$

G : 语法或语言模型接收器的概率

L : 词典（音素或或字或词）

C : 上下文相关转换机（将上下文相关的音素转化成上下文无关的音素）

H : HMM转换机

WFST解码

$$W' = \operatorname{argmax}_W P(X|W)P(W)$$

- 求解以上问题可以转换成：
 - 四种WFST组成一个大的解码图 $H \circ C \circ L \circ G$ ，然后在这个解码图上进行搜索，将HMM状态转换成最终的句子。
 - 将特征向量 X 用HCLG对齐来解码，

$$W' = \operatorname{argmax}_W X \circ (H \circ C \circ L \circ G)$$

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望
 - 3.5.1 端到端语音识别（基本概念）
 - 3.5.2 主要挑战（了解）
 - 3.5.3 基于大模型的语音识别（了解）

基于CTC的语音识别算法

■ 什么是CTC？


- Connectionist temporal classification, 基于神经网络的时序信号分类。

■ 语音识别为什么需要CTC？

- 传统的语音识别的声学模型训练，对于每一帧的数据，需要知道对应的标签(三音素)。
- 必须预先训练一个GMM-HMM声学模型。
- 采用GMM-HMM系统进行自动对齐标注。
- 对齐的准确性严重依赖GMM-HMM声学模型的可靠性。
- 不论是GMM-HMM声学模型训练，还是语音对齐过程，都需要进行反复多次的迭代，非常耗时。
- 分阶段训练不合理。

基于CTC的语音识别算法（了解）

■ 引入'blank' 符号



■ 对于一段语音，CTC最后的输出仅是spike（尖峰）的序列

“--a-bb” → “ab”

■ 每个CTC输出序列的概率实际上是多个填充了blank符号后输出序列的概率的总和


基于Attention的语音识别算法

- 另一个目前常用的序列到序列的模型是编码器-解码器模型（Encoder-Decoder Model）
- 该模型由编码器和解码器两部分组成，其中编码器将输入序列映射到一个指定长度的向量，解码器将指定长度的向量解码为真实的标签。
- 2014年[1]提出将Attention机制加入到目前的编码器-解码器模型（Encoder-Decoder）中，并成功应用到了机器翻译中，同时取得了当时最好的效果。

基于Attention的语音识别算法

■ 端到端语音识别的优点

- 直接将声学特征映射到更大的单元序列中，而不是音素或初始序列-最终序列



- 字级输出对于下游自然语言处理（NLP）任务来说很容易

■ Encoder-decoder 框架存在如下问题

- 长序列对编码器网络造成巨大的压力
- 解码器网络需要从固定长度的编码向量中寻找与当前时刻相关的序列内容，如果编码向量中压缩太多信息，会导致解码器网络很难准确找到与当前输出对应的序列信息

基于Attention的语音识别算法

■ Attention模型的优点

- 与传统的混合模型相比，Attention的模型实现了端到端训练，能够将整个系统训练到最优。
- 与CTC相比，Attention不需要每帧独立的假设。

■ Attention模型的缺点

- 在噪声环境下很难训练到很好的效果，通常要比CTC的方法差
- 目前的解决方案：CTC和attention联合训练，采用CTC损失函数针对下层Encoder做强制对齐。

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望
 - 3.5.1 端到端语音识别
 - 3.5.2 主要挑战
 - 3.5.3 基于大模型的语音识别

复杂声学场景下的语音识别（基本概念）

- 当语音识别系统处于复杂声学场景下，由于训练声学模型的声学场景与真实复杂声学场景差异过大，导致语音识别系统性能大大降低。
- 而现实生活中，声学场景千变万化，训练集不能完全覆盖所有声学场景
- 例如
 - 训练时噪声、混响等环境可穷举、可模拟，现实中无法穷举，导致训练集和测试集不匹配

复杂声学场景下的语音识别（基本概念）

■ 主要挑战

- 真实世界传感器需要获取声音，但是周围声音是各种各样的，需要获取有效的人声
- 获取人声也不一定是目标任务的人声，可能是用户和别人交谈的声音
- 在远场场景下获取的声音面临着回声干扰、室内混响、多信号源干扰以及非平稳噪声的干扰等等

■ 现状

- 研究新的声学信号处理技术或新的声学信号处理与语音识别的联合优化方案

低数据资源语音识别

- 低数据资源是指音频或者有转录文本的音频较少，导致语音识别性能下降
- 全世界共使用5651种语言，其中，汉、英、印度、俄、西班牙、德、日、法、印度尼西亚、葡萄牙、孟加拉、意大利和阿拉伯语是使用人数较多的语言
- 其他一些少数人使用的语言在语音资源上就显得匮乏（可能只能获得几十小时的音频）

低数据资源语音识别

■ 主要挑战

- 端到端语音识别系统需要大量训练数据，有些特定领域的语音很难获取，包括但不限于以下人群：
 - 非母语学习者
 - 构音障碍患者（由于疾病导致发音的错误，产生的语音可能扭曲、错误）
 - 少数民族人群

■ 现状

- 研究基于迁移学习、模型自适应等算法

多语言和跨语言语音识别（基本概念）

- 目前大多数语音识别系统都是针对一种语言的
- 对于每种语言都训练一个语音识别系统，所需要的成本太高，且需要大量的数据
- 多语言语音识别和跨语言语音识别的区别在于
 - 多语言语音识别只能识别训练集中出现过的语言
 - 跨语言语音识别能识别出从未见过的语言。
- 例子
 - 多语言语音识别：一个用英语、德语训练出来的模型，可以同时英语、德语进行语音识别
 - 跨语言语音识别：一个用英语、德语训练出来的模型，可以同时英语、德语、法语进行语音识别

多语言和跨语言语音识别

■ 主要挑战

- 如何选择建模单元。像字符、子词等单元很难扩展到词汇量大的语言
- 词汇量大导致标签稀疏问题
- 构建发音字典需要每个语言专家的知识，要耗费很大的人力
- 有些语言很难获取

■ 现状

- 需要新技术、新的解决方案

语种混杂语音识别

- 在我们日常交流中，经常会有中文语境下英文单词夹杂的现象，在学术上称为语种混杂（Code-switch）
- 例子
一般语音识别对于句子“这里有Wi-Fi吗”，可能会识别为“这里有外海吗”

语种混杂语音识别

■ 主要挑战

- 由于嵌入语（英文）受主体语（中文）影响形成的非母语口音现象严重
- 不同语言音素构成之间的差异给混合声学建模带来巨大困难
- 带标注的混合语音训练数据极其稀缺

■ 现状

- 最近，端到端的语音识别算法与技术逐步被应用到语种混杂语音识别任务上

多口音语音识别

- 在日常生活中，一个地区的人在说另一个地区的语言时，容易保持自己习惯的发音方式
- 以汉语为例，由于不少普通话使用者把普通话作为第二语言来掌握
- 发音不可避免地受到其方言母语发音的强烈影响，出现发音不准确、发音错误等现象，导致语音识别性能下降

多口音语音识别

■ 主要挑战

- 受母语影响不同方言背景的说话人的发音具有差异性
- 可用于训练语音识别系统的多口音的数据极其稀缺

■ 现状

- 对于第一个问题，虽然不同方言口音之间存在着差异，但也存在着相似性，因此，研究如何改进声学模型以适应更多变化的口音是一种研究趋势
- 第二个问题也是现在语音识别的难点之一

第三章 语音识别

- 3.1 语音识别概述
- 3.2 声学模型
- 3.3 语言模型
- 3.4 语音识别解码算法
- 3.5 语音识别技术的展望
 - 3.5.1 端到端语音识别
 - 3.5.2 主要挑战
 - 3.5.3 基于大模型的语音识别

语音感知大模型

Multitask training data (680k hours)

English transcription

🗣️ "Ask not what your country can do for ..."

📄 Ask not what your country can do for ...

Any-to-English speech translation

🗣️ "El rápido zorro marrón salta sobre ..."

📄 The quick brown fox jumps over ...

Non-English transcription

🗣️ "언덕 위에 올라 내려다보면 너무나 넓고 넓은 ..."


📄 언덕 위에 올라 내려다보면 너무나 넓고 넓은 ...

No speech

🔊 (background music playing)

📄 ∅


Sequence-to-sequence learning




OpenAI: Whisper

语音感知大模型

SenseVoice Small



SenseVoice Large



Tasks Tags

Languages

<zh> <en> <ja>
<ru> <ko> <fr>
<ge> ...

Emotions


<happy> <disgusted>
<angry> <fearful>
<sad> <surprised>
...

Events

<breeze> <laughter>
<sing> <noise>
<bgm> <applause>
<cough> ...


阿里：SenseVoice

语音感知大模型



字节：Seed-ASR

声学模型与语言大模型的联合建模



- Encoder: 如何兼顾声学信息和语义信息的提取; 如何充分利用海量的无标注数据;
- Decoder: 如何更好地融合声学特征和文本特征; 如何从声学特征中分解出语言信息、非语言信息和副语言信息。

上机实验课

内容：语音识别系统实现及验证

时间：10月24日（47教第8机房）

10月28日（47教第8机房）

10月31日（47教第8机房）