




第四章 语音合成

语音合成是语音交互中重要的一环

- 基于波形拼接的语音合成技术是20世纪90年代的主流技术。
- 本世纪初，语音合成算法逐步从基于波形拼接算法进展到基于统计模型的算法。2013年之前，基于HMM是语音合成的经典声学模型。2013年前后，深度学习算法在语音合成领域取得巨大成功，DNN逐步替代了HMM。2016年前后，端到端模型受到越来越多的关注。2023前后，基于大模型的语音合成成为研究热点。
- 重点掌握基于隐马尔可夫模型与深度学习算法的统计参数合成算法。

第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

第四章 语音合成

■ 4.1 语音合成概述

- 4.1.1 语音合成的基本概念（基本概念）

- 4.1.2 语音合成的方法回顾（了解）

- 4.1.3 语音合成的典型应用（了解）

■ 4.2 语音合成的原理

■ 4.3 语音合成的主流技术

■ 4.4 语音合成的技术展望

什么是语音合成？


■ 定义：

- 语音合成（Speech Synthesis）：通过机械的、电子的方法产生人造语音的技术。
- Text-to-Speech (TTS)：自动将文本转换为声音。

■ 目标

还有哪些目标？

- Intelligibility（可懂度）
 - ✓ 可懂度是指语音中有意义的语言单元（如单词、单句等）内容的可识别（可被理解）的程度。（可以通过人工或ASR系统来测评）
- Naturalness（自然度）
 - ✓ 自然度描述合成语音与人类语音听起来的接近程度。（尚未有唯一的客观指标来评价）



广义的语音合成

■ 广义的语音合成研究内容包括：

□ 语音转换(Voice Transformation/Conversion)

说话人转换

语音到歌唱转换(Speech to Singing)

情感转换

口音转换

□ 歌唱合成(Singing Synthesis)


文本到歌唱转换(Text/Lyric to Singing)

□ 可视语音合成(Visual Speech Synthesis)



日本虚拟歌姬
使用了Yamaha的VOCALOID 2语音合成引擎

TTS流程与人的朗读过程的对比



可以看出TTS包括了人的朗读过程的主要要素，但没有考虑两个最重要的要素：上下文理解和意图表达（speech skill）

语音合成例子（了解）

GPT-SoVITS

开源的声音克隆语音合成，实现个性化的文本到语音合成。

开源地址：<https://github.com/RVC-Boss/GPT-SoVITS>




歌声合成例子（了解）

SoVITS

歌声转换：输入原歌声、参考人声，实现歌声转换

开源地址：<https://github.com/svc-develop-team/so-vits-svc>



https://www.bilibili.com/video/BV1yv4y1H7wz/?spm_id_from=333.337.search-card.all.click&vd_source=630a7ec7a92daa52500967b1607859b2



https://www.bilibili.com/video/BV1ea4y1G7gx/?spm_id_from=333.337.search-card.all.click

语音合成的评价指标

■ 主观指标

- 绝对值：MOS (Mean Opinion Score, 1 - 5 or 0 - 100)
- 相对值：CMOS (Comparative MOS, -3 -- 3)
 - ✓ (CMOS) 测试中，测试人员每次都会收听两个音频（两组需要对比的音频，具有相同的文本），并使用 $[-3, 3]$ 中的分数评估后者与前者相比的感觉，间隔为 1，3 代表远优于，-3 代表远差于，0 代表二者无差别。
- 相对值：ABX Test
 - ✓ 与 CMOS 类似，AB 两组音频进行对比，选取 AB 两种音频中音质较好的音频 (A/B)，或认为两组音频无差别(X)。

■ 实验流程注意事项

- 足够的、合理的测听人员与人数
- 测听设备：不同测听设备的主观感觉不同
- 测听安排：是否做测听人员培训？
- 每个测听 session 的时间安排
- 统计有效性：Significant test

语音合成的评价指标（续）

■ 主观指标

▣ 绝对值：MOS (Mean Opinion Score, 1-5 or 0-100)

一种由CCITT推荐的主观评价方法：

MOS分值	等级	语音质量
5	优	流畅自然，无瑕疵
4	良	失真不明显，不注意听感觉不到
3	一般	明显失真，但自然度和清晰度尚可忍受，听起来没有疲劳感
2	差	严重的失真、不自然，听起来有疲劳感
1	劣	语音质量极差，听觉无法忍受

MOS指标的不足点？

语音合成的评价指标（续）

■ 客观指标

- 和真实音频 (Ground Truth) 之间的距离度量

- 根据信号的特性，常用指标有：

1. 梅尔倒谱失真：Mel-Cepstral Distortion (MCD)

$$\text{MCD}_K = \frac{1}{T} \sum_{t=0}^{T-1} \sqrt{\sum_{k=1}^K \left(c_{t,k} - c'_{t,k} \right)^2}$$

2. F0均方根误差：Root Mean Square Error (RMSE) of F0

3. 时长均方根误差：RMSE of Duration

4. ...


语音识别与语音合成客观指标的异同点？

语音合成客观指标的不足点？

第四章 语音合成

- 4.1 语音合成概述
 - 4.1.1 语音合成的基本概念
 - 4.1.2 语音合成的方法回顾
 - 4.1.3 语音合成的典型应用
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

语音合成的发展历史




机械语音合成

Von Kempelen (1791)制作的
语音机的复制品



第一台复制人的发声器官及其作用
，并可以发出“语音”的机器

详解



再现了“**声源-滤波器**”的机理，
从原理上实现了不同类型的声源
，特别对不同类型的辅音声源

机械语音合成（续）

- Homer Dudley's Voder (1939)
 - 通过复杂的键盘手动操作
 - 操作训练难



参数语音合成-线性预测方法


- **参数语音合成**：通过分析计算提取出语音的各种参数，以压缩存储量，然后由人工控制这些参数用于语音合成。
- 线性预测合成是一种应用比较广泛和实用的语音合成方法。它是基于全极点声道模型的假定，采用线性预测分析的原理来合成语音信号。
- 是一种“源—滤波器模型”，其激励参数由增益常数、浊/清音开关信息和基音频率组成。声道参数用LPC参数来控制。

$$x(n) = \hat{x}(n) + Gu(n) = \sum_{i=1}^p a_i x(n-i) + Gu(n)$$

$Gu(n)$ 是观测值 $x(n)$ 和预测值 $\hat{x}(n)$ 的残差， a_i ($i = 1, 2, \dots, p$) 是加权系数。

基于波形拼接的语音合成 --- 整体框架（基本概念）

波形拼接语音合成：先从自然语音中的词或句子抽取语音基元并按一定规律组成语料库，合成语音时根据合成文本的要求，从语料库中查找出合适的基元，通过拼接、韵律修饰，最终得到合成的语音。



波形拼接合成的框架图

基于波形拼接的语音合成 --- 问题

- 需要大规模的精心设计的语音数据库
- 语音数据库中沒有类似音素样例时合成质量差
- 不易控制韵律
- 可扩展性差、不易于维护



如何解决波形拼接合成的问题？

统计参数语音合成（基本概念）


统计参数语音合成（Statistical Parametric Speech Synthesis, SPSS）：对输入的语音进行参数化表征，然后基于统计模型进行声学参数建模，并以训练得到的模型为基础构建语音合成系统。

优点：

- 无需大规模的精心设计的语音数据库
- 合成语音的质量稳定
- 可以控制韵律
- 可扩展性好易于维护

统计参数语音合成（续）（基本概念）

■ 基于HMM的语音合成





■ 基于DNN的语音合成

第四章 语音合成

- 4.1 语音合成概述
 - 4.1.1 语音合成的基本概念
 - 4.1.2 语音合成的方法回顾
 - **4.1.3 语音合成的典型应用**
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

语音合成的典型应用

- 语音交互（家居、出行、客服、旅游等场景）
- 特殊人群（发音障碍、视力障碍）服务
- 虚拟主播
- 有声读物



语音合成的典型应用

- 语音交互（家居、出行、客服、旅游等场景）
- 特殊人群（发音障碍、视力障碍）服务
- 虚拟主播
- 有声读物



语音合成的典型应用

- 语音交互（家居、出行、客服、旅游等场景）
- 特殊人群（发音障碍、视力障碍）服务
- 虚拟主播
- 有声读物



语音合成的典型应用

- 语音交互（家居、出行、客服、旅游等场景）
- 特殊人群（发音障碍、视力障碍）服务
- 虚拟主播
- 有声读物



《我师兄实在太稳健了》有声小说 完结（微软语音自制合成）



有声读物的合成语音哪些不足点？

第四章 语音合成


- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
 - 4.2.1 语音合成的整体框架（重点掌握）
 - 4.2.2 语音合成的文本分析（了解）
 - 4.2.3 语音合成的韵律分析（基本概念、了解）
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望


语音合成的主要流程

- 语音是一种通过语言调制由人类发声器官产生的声学信号。
- 文本转换语音合成的目标是将输入文本转换为自然语音。因此，**语音合成的原理是实现将语言信息调制到声学信号上。**
- 语言处理过程包括：句词切分，文本归一化等。
- 声音处理方面包括：韵律参数预测和声音波形生成。



一些研究把**文本分析**和**韵律预测 (分析)**阶段合并在一起称为**语言分析**

统计参数语音合成的主要流程



语音合成的框架图

- 前端处理：从原始文本提取多种可以被声学模型所识别的语言学特征，亦即在音标和韵律信息方面提供了文本的符号语言表征。
- 后端处理：将语言学特征转换成声学特征，进一步转换成语音波形。

语音合成与语音识别主要流程的异同点有哪些？


第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
 - 4.2.1 语音合成的整体框架
 - **4.2.2 语音合成的文本分析**
 - 4.2.3 语音合成的韵律分析
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

前端处理基本框架（基本概念）


韵律分析

文本分析



分词与词性标注（基本概念）

- 目的：标注词语边界、词语词性。
 - **分词**就是将句子（中文：连续的汉字序列）按照一定的规范重新组合成词序列的过程。
 - 通过分词明确标注词语边界，以便进一步确认词性、韵律边界、发音等。不正确的分词结果还会影响合成语音的自然度。
 - **词性标注**为分词结果中的每个单词标注一个正确的词性的程序，也即确定每个词是名词、动词、形容词或其他词性的过程，词性可以用于预测韵律边界和多音字消歧。




分词与词性标注（续）

- 基于最大前向匹配的分词方法
 - 顾名思义，就是从待分词句子的左边向右边搜索，寻找词的最大匹配。我们需要规定一个词的最大长度，每次扫描的时候寻找当前开始的这个长度的词来和字典中的词匹配，如果没有找到，就缩短长度继续寻找，直到找到字典中的词或者成为单字。
- 基于统计模型（例如：条件随机场（Conditional Random Field, CRF））的分词方法
 - CRF：给定一组输入序列条件下另一组输出序列的条件概率分布模型；
 - 四个标注（B, E, M, S），B表示词的开始（begin），E表示词的结束（end），M表示词的中间，S表示单个词（single）。
- 词性标注：查字典和基于统计模型的方法（和分词类似）

分词与词性标注 --- CRF

- 可用于NLP中序列标注，包括分词、词性等标注
- 算法概述考虑输出序列的上下文关系，比如S后面不能接M和E等
- 输入有n帧，标签k种可能，路径条数： k^n 方
- 根据每个状态的输出概率/状态之间的转移概率，获取最佳路径（维特比算法）
- 今天/天气/不/错（对应的输出序列：BEBESS）
- 推导算法（前向后向、维特比、模型更新）



分词方法比较

■ 基于规则和统计模型的分词方法对比

	基于规则（字典）	统计模型（CRF等）
优点	• 查询效率高 • 可扩展性强 • 可以维护不同的用户字典，不同的域 • 快速修改错误	• 基于统计学习模型，依赖上下文语境、较强泛化能力 • 对于歧义词和未登陆词，具备较强的识别能力
缺点	• 过于依赖字典 • 对于未出现的词，分词能力较低	• 增加模型训练时间 • 不能快速修改错误

■ 解决方法：结合基于规则和统计模型的分词方法

文本归一化（基本概念）

- 文本中除了正常的单词，还会经常出现简略词、日期、公式、号码等文本信息，需要通过文本规范化（**文本归一化**），对这些文本块进行处理，否则合成出的语音就会出现语法错误、语义不完整等情况，从而导致语音合成效果的降低。
- 目的：**转换非标准词为发音明确的口语单词**
 - 前方120M ： 前方一百二十米
 - 拨打120 ： 拨打幺二零
- 方法：
 - 基于规则转换
 - 规则转换与深度学习结合

常见的文本归一化类型

类型	原始文本	正则后文本
专有名词的读音和具有特殊读音的姓氏字	曾国藩 曾经	曾（zēng）国藩 曾（céng）经
单位	这块黄金重达324. 75克	这块黄金重达三百二十四点七五克
日期	她出生于86年8月18日， 她弟弟出生于1995年3月1日	她出生于八六年八月十八日， 她弟弟出生于一九九五年三月一日
数字	电影中梁朝伟扮演的陈永仁的编号27149	电影中梁朝伟扮演的陈永仁的编号二七一四九
分数	现场有7/12的观众投出了赞成票	现场有十二分之七的观众投出了赞成票
钱	随便来几个价格12块5， 34. 5元，20. 1万	随便来几个价格十二块五 三十四点五元 二十点一万
百分数	明天有62%的概率降雨	明天有百分之六十二的概率降雨


常见的文本归一化类型（续）

类型	原始文本	正则后文本
电话	这是固话0421-33441122 这是手机+8618544139121	这是固话零四二一三三四四一一二二 这是手机八六一八五四四一三九一二一
以西文字母开头的词语	α 粒子 B超	(alfa lìzǐ) (B chāo)


字音转换（基本概念）

- 字音转换（标音）：给出每一个字符（比如中文）对应的发音，在此基础上进一步给出协同发音，多音字消岐，儿化音标注，变调等任务。
 - 古都{du1}，都{dou1}有
 - 理解{li2 jie3}
- 方法
 - 基于字典
 - HMM
 - 基于神经网络

多音字消歧



基于词典的多音字消歧方法



基于神经网络的多音字消歧


句法分析

- 词法分析的功能是对输入句子中的词进行切分，而句法分析的功能是分析一个句子中的词与词之间的关系。
- 弄清词之间的关系对于在随后语音合成中的韵律参数的生成至关重要。
- 句法分析的输入是词的序列（可能包含词的属性，例如词性等），而输出时句子的句法结构。

第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
 - 4.2.1 语音合成的整体框架
 - 4.2.2 语音合成的文本分析
 - **4.2.3 语音合成的韵律分析**
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

韵律分析基本框架（基本概念）



韵律结构通常被分为了三个层级：韵律词、中间短语（韵律短语）、语调短语。

语调 (intonation)，即说话的腔调，就是一句话里快慢轻重的配置和变化，体现说话人的态度或口气。

声调 (tone) 又叫字调，是指语言的音调的变化。普通话有四个声调：阴平，阳平，上声，去声。

重音也叫重读。在口语表达中，它有强调重点、突出主要情感的作用。

韵律的特征（基本概念）

- 从语音信号的角度来看，韵律是超音段的声音物理属性信息，例如音高，音长，和强度。
- 从语用功能的角度来看，韵律编码了多种类型的语音意图。韵律表达了信息的焦点，对话的连贯性，言语行为的类型，以及说话人的态度和情感状态。
- 韵律是句法和发音的接口，其受例如多种要素的影响，例如语气的类型，词汇的语义或句法的关联，组合的节奏，以及篇章的连贯性。
- 在语音感知中，韵律反映了节奏，强调，语音速率等。
- 在语音生成中，通过音高（F0），持续时间，能量等的变化实现。

韵律结构及标注 —— 中文（了解）

■ 九零后#1为中华人民#1共和国#2成立七十周年#3准备了大礼#4

■ 韵律等级结构：

音素（LP）->音节（L0）->韵律词（#1）->韵律短语（#2）
->语调短语（#3）->子句子（#4）->主句子->段落->篇章

■ 标注韵律等级

	停顿时长	前后音高特征
韵律词边界	不停顿或从听感上察觉不到停顿	无
韵律短语边界	可以感知停顿，但无明显的静音段	音高不下倾或稍下倾，韵末不可做句末
语调短语边界	有较长停顿	音高下倾比较完全，韵末可以作为句末


韵律结构边界的预测（了解）

- 基于规则的方法：使用语言学的经验知识实现韵律结构预测。这种方法简单而且更直观，但是有很多局限性。
- 基于机器学习方法：将韵律预测转变为分类问题，主要基于词汇等信息。其中代表性的方法包括决策树，隐马尔科夫模型，最大熵模型，条件随机场等等。
- 基于深度神经网络预测韵律短语：比如，基于RNN网络可以预测韵律短语，但没有考虑语义特征。
- 词向量 (word2vec) 作为语义特征被加入基于RNN的韵律层级预测模型。结果显示这种方法相对传统机器学习方法有了一定的提高。
- 如果深度学习和传统模型被结合起来，可以更好地描述韵律层级的多样性。

韵律结构边界的预测—基于神经网络的方法 (了解)

- BLSTM+CRF (韵律边界预测)
- 输入: one-hot特征/词对应的word embedding
- 输出: 三个类别, B/NB/O, 分别代表边界、非边界、others
- 网络结构
 - FFNN+BLSTM
 - CRF(考虑输出之间的联系)


不仅仅是韵律边界预测, TTS前端文本分析模块中的分词、词性标注、多音字消歧, 更是依赖更长的上下文, 所以神经网络(LSTM/GRU)对TTS前端文本分析整个性能都有很大的提升。



(2015.Ding Et.al. AUTOMATIC PROSODY PREDICTION FOR SPEECH SYNTHESIS USING BLSTM-RNN AND EMBEDDING FEATUCHINESERES)

语调分解与控制（了解）

- 语调包括三个要素：声调、连续语音声调相互影响形成的中性语调，以及表达说话人情感或态度的情感语调。
- Fujisaki模型基本上反映了这一属性。在模型中，句子的F0曲线分解为短语成分和声调成分，分别由短语命令和声调命令来控制。



- Fujisaki (2004) 通过引入负的声调命令将其扩展到声调语言的韵律表征。

基频、时长、能量的生成（基本概念）


- 语调调型被隐含于基频模型，句子的基频曲线根据当前音节的拼音、声调与上下文环境，由语料库中的基频统计模型得到，其语调可以认为是语料库中语调的平均。
- 时长与能量也是重要的韵律信息。
- 基频、时长、能量的生成方法
 - 基于规则
 - 基于数据（传统统计模型、深度神经网络等）

第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
 - 4.3.1 基于HMM的语音合成（基本概念）
 - 4.3.2 基于神经网络的语音合成（了解）
 - 4.3.3 声码器（了解）
- 4.4 语音合成的技术展望

为什么是HMM?

状态转移概率矩阵A
观察值概率矩阵B
状态集合S



基于HMM的语音识别声学模型 20世纪80年代中期~

受HMM在语音识别领域成功的启发:
HMM适合于为时序信号建模

声学特征 $\xrightarrow{\text{HMM}}$ 文本
识别、生成

为什么是HMM? (续)


受HMM在语音识别领域成功的启发：
HMM适合于为时序信号建模




- 语音的产生可以理解为一个双重随机过程，一个是气流的经由过程，是无法观测的；而另一个发出的语音，是直接听到也就是说可观测的。
- 相应的，HMM与该发音过程一样，同样是双重随机过程，一个是隐马尔可夫链的输出状态序列（无法观测）；另一个是随机过程输出观察序列（可观测）。

基于HMM的语音识别与语音合成（掌握）

语音识别



语音合成



训练阶段

$$\hat{\Lambda} = \arg \max_{\Lambda} P(L|O, \Lambda)$$


$$\hat{\Lambda} = \arg \max_{\Lambda} P(O|L, \Lambda)$$

O: 声学特征; L: 文本信息


HMM的模型训练（Baum-Welch算法: 最大期望算法的快速实现）：
参考4.2节（语音识别-HMM声学模型）

基于HMM的语音识别与语音合成（续）（掌握）

语音识别



语音合成



解码阶段


$$\hat{L} = \arg \max_L P(O = o | L, \Lambda)$$

$$\hat{O} = \arg \max_O P(O | L = l, \Lambda)$$

HMM的解码算法（基于动态规划算法的Viterbi算法）：

参考（语音识别-HMM声学模型）

基于HMM语音合成系统框架（掌握）



■ 训练流程

1. 数据处理，提取文本特征与声学参数
2. 模型训练
训练数据：
<文本特征，声学参数>
训练过程：
 - a) 单音素训练
 - b) 上下文相关HMM训练
 - c) 决策树聚类
 - d) 聚类后模型训练

■ 合成部分

1. 文本处理，得到输入文本特征
2. 基于似然最大化准则通过HMM生成声学参数
3. 利用声码器将声学参数转换为最终语音

文本特征提取

文本经过前端处理，生成文本特征，进而处理得到语言学特征，才能被声学模型所利用。

文本特征包括诸多因素：

- **音素**：音素包含了发音信息。
- **时长信息**：包含了当前音素发音时长。
- **声调信息**：记录韵母的声调。
- **音节信息**：记录当前音节在词语、短语、语句中的位置信息，数目信息等。
- **词性、韵律词、韵律短语信息**：主要记录韵律相关信息。
- **上下文信息**：除了记录当前音素的上述特征之外，还需要记录当前音素临近音素的对应特征。上下文特征包含了音素系统发音、变调、韵律结构等丰富的信息，是语言学特征中及其重要的部分。

文本特征提取（续）

除此之外，对于特定的语音合成系统，语音合成前端还需要负责生成对应的特殊文本特征：

- 对于情感合成，需要标注整句文本的情感以及句中各短语对应的情感特征。
- 对于风格合成，需要标注文本对应的重读，倾向等等。

上下文特征（了解）

例句：卡尔谱陪外孙玩滑梯。



汉字转拼音带声调（音节为基本单元）

[('k', 'a3'), ('er3'), ('p', 'u3'), ('p', 'ei2'), ('w', 'ai4'), ('s', 'un1'), ('w', 'an2'), ('h', 'ua2'), ('t', 'i1')]



转换为上下文特征（通过上下文语境的问题集）；以 'a3' 这个音节为例

4062911 5165142 sil^k-a3+er3=p@a@/A:xx-3^3@/B:0+8@1^3^1+9#1-9-
/C:xx_n^v#xx+3+1&/D:xx=9!xx@1-1&/E:xx|9-xx@xx#1&xx!1-1#/F:xx^9=5_1-1!

内容	含义	具体信息
4062911 5165142	发音时长	
sil^k-a3+er3=p@a@	基元信息	p1: 前前基元 p2: 前一基元 p3: 当前基元 p4: 后一基元 p5: 后后基元 p6: 当前音节的元音
/A:xx-3^3@	声调信息	a1 前一音节/字的声调 a2 当前音节/字的声调 a3 后一音节/字的声调
/B:0+8@1^3^1+9#1-9-	音节位置信息	b1 当前音节/字到语句开始字的距离 b2 当前音节/字到语句结束字的距离 b3 当前音节/字在词中的位置（正序） b4 当前音节/字在词中的位置（倒序） b5 当前音节/字在韵律词中的位置（正序） b6 当前音节/字在韵律词中的位置（倒序） b7 当前音节/字在韵律短语中的位置（正序） b8 当前音节/字在韵律短语中的位置（倒序）

上下文特征（续）（了解）

例句：卡尔谱陪外孙玩滑梯。



汉字转拼音带声调（音节为基本单元）

[('k', 'a3'), ('er3'), ('p', 'u3'), ('p', 'ei2'), ('w', 'ai4'), ('s', 'un1'), ('w', 'an2'), ('h', 'ua2'), ('t', 'i1')]




转换为上下文特征（通过上下文语境的问题集）；以 'a3' 这个音节为例

4062911 5165142 sil^k-a3+er3=p@a@/A:xx-3^3@/B:0+8@1^3^1+9#1-9-
/C:xx_n^v#xx+3+1&/D:xx=9!xx@1-1&/E:xx|9-xx@xx#1&xx!1-1#/F:xx^9=5_1-1!

内容	含义	具体信息
/C:xx_n^v#xx+3+1&	词性和音节数目	c1 前一个词的词性 c2 当前词的词性 c3 后一个词的词性 c4 前一个词的音节数目 c5 当前词中的音节数目 c6 后一个词的音节数目
/D:xx=9!xx@1-1&	韵律词信息	d1 前一个韵律词的音节数目 d2 当前韵律词的音节数目 d3 后一个韵律词的音节数目 d4 当前韵律词在韵律短语的位置（正序） d5 当前韵律词在韵律短语的位置（倒序）
/E:xx 9-xx@xx#1&xx!1-1#	韵律短语信息	e1 前一韵律短语的音节数目 e2 当前韵律短语的音节数目 e3 后一韵律短语的音节数目 e4 前一韵律短语的韵律词个数 e5 当前韵律短语的韵律词个数 e6 后一韵律短语的韵律词个数 e7 当前韵律短语在语句中的位置（正序） e8 当前韵律短语在语句中的位置（倒序）
/F:xx^9=5_1-1!	语句信息	f1 语句的语调类型 f2 语句的音节数目 f3 语句的词数目 f4 语句的韵律词数目 f5 语句的韵律短语数目

声学特征（谱、基频参数特征）



HMM语音合成的训练阶段

简单模型
(数据充足)




复杂模型
(数据不足)




聚类复杂模型
(解决过拟合)

HMM的训练算法一致





方差下限估计（了解）

- 由于上下文属性可能的组合远大于训练数据的数目，模型方差接近零。
- 为了避免方差过于接近零，需要预先设定一个方差的下限。
- 对于不同的参数需要设定不同的方差下限。




单音素模型训练

- 对所有的单音素HMM进行初始化和训练。
- 得到的模型用于进行上下文相关模型的扩展和初始化。



单音素模型训练（续）

- 模型训练方法：Baum-Welch算法。
- Baum-Welch算法的理论基础是EM算法。
- 与语音识别相同。




定义辅助函数

$$Q(\bar{\lambda}, \lambda) = \sum_Q P(Q, O | \lambda) \log P(Q, O | \bar{\lambda}).$$

上下文相关HMM训练



- 考虑不同的上下文对语音合成的影响。
- 上下文环境：
 - 前后音素
 - 韵律边界（词、短语、句子）



上下文相关HMM训练（续）


■ 考虑前后音素的上下文

/l-c+r/表示：
左边音素-中间音素+右边音素





基于决策树的HMM聚类

- 模型的参数在训练后产生过拟合现象。
- 为了消除样本过少的问题，使得HMM的鲁棒性与数据量达到一个均衡状态。




基于决策树的HMM聚类



聚类后HMM训练

- 与单音素HMM、上下文相关HMM训练相同。
- 基于Baum-Welch算法。



语音合成的参数生成（了解）

基于EM的参数生成算法解决如何使初始子状态序列尽可能接近最优子状态序列等问题(Tokuda et al. 2013)。给定一组HMM和要合成的文本，确定最可能的语音参数矢量序列：

$$\begin{aligned}\mathbf{o}_{max} &= \arg \max_{\mathbf{o}} p(\mathbf{o}|\lambda_{max}, \mathbf{w}) \\ &= \arg \max_{\mathbf{o}} \sum_{\forall \mathbf{q}} p(\mathbf{o}, \mathbf{q}|\lambda_{max}, \mathbf{w}) \\ &\approx \arg \max_{\mathbf{o}, \mathbf{q}} p(\mathbf{o}, \mathbf{q}|\lambda_{max}, \mathbf{w}) \\ &= \arg \max_{\mathbf{o}, \mathbf{q}} p(\mathbf{o}|\mathbf{q}, \lambda_{max})p(\mathbf{q}|\lambda_{max}, \mathbf{w})\end{aligned}$$

定义

$$\mathbf{q}_{max} = \arg \max_{\mathbf{q}} p(\mathbf{q}|\lambda_{max}, \mathbf{w}) \quad (\text{a})$$

则，我们可以获得一个近似

$$\begin{aligned}\mathbf{o}_{max} &\approx \arg \max_{\mathbf{o}} p(\mathbf{o}|\mathbf{q}_{max}, \lambda_{max}) \\ &= \arg \max_{\mathbf{o}} \prod_{t=1}^{T'} \mathcal{N}(o_t; \mu_{\mathbf{q}_{max}, t}, \Sigma_{\mathbf{q}_{max}, t})\end{aligned} \quad (\text{b})$$

(a)的最大化问题可以由状态时长概率分布解决。(b)的最大化问题在给出预先确定的状态序列 $\mathbf{q}_{max}$ 的情况下对 $\mathbf{o}$ 求 $p(\mathbf{o}|\mathbf{q}, \lambda)$ 最大化。

HMM的缺陷

- HMM合成的过平滑问题导致合成效果平淡，音质不好
 - HMM基于建模，假设各状态之间独立，状态参数分布是统计平均的结果；
 - 决策树作为浅层线性模型无法建模复杂的映射关系，对输入特征和数据空间的线性分割会降低模型泛化能力。

第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
 - 4.3.1 基于HMM的语音合成
 - **4.3.2 基于神经网络的语音合成**
 - 4.3.3 声码器
- 4.4 语音合成的技术展望

基于神经网络的语音合成


■ 时长模型

- 输入：经过文本分析从HMM系统中的抄本，转换出的one-hot特征+数值特征
- 输出：音素时长+其状态时长

■ 声学模型

- 输入：时长模型的输入根据时长转换得到的帧级别信息+跟状态以及帧数相关的位置信息
- 输出：谱参数、基频、清浊音(u/v)

■ 经过声码器，得到语音



基于神经网络的语音合成

■ 输入特征表示

- 将数字表示的特征进行保留，如“当前音节所包含的音素数目=5”，则在神经网络的输入的对应维度写上5；
- 将类别的特征使用one hot 表示法，即用和类别数目一样维度的向量表示该特征，比如当前音素为b，b在音素列表中是第2个， 总共音素66个，我们就在第2维填上1，其他65维填上0；
- 增加状态信息，如“当前帧处于第5 个状态”，总共用7 状态建模，则将状态信息表示为“0 0 0 0 1 0 0”。

- 对于时长模型：输入是音素对应的特征表示，输出是其时长+对应状态时长。一句话有多少音素就对应有多少输入。
- 对于参数生成模型：输入是帧级别信息，根据音素时长，展开为帧级别输入，并且增加状态信息。所以一句话有多少帧就有多少输入，和输出语音特征对应。


基于DNN的语音合成（基本概念）

右图显示了基于DNN的语音合成的基本框架和过程。

文本被转换为输入特征序列 $\{x_n^t\}$ ， x_n^t 代表对应语音第 t 帧的第 n 个输入特征。输入特征包括上下文特征和音节持续时间等参数。它们与传统统计参数相同。

经由DNN前向传播，输入特征被映射到输出特征 $\{y_m^t\}$ ， y_m^t 是语音第 t 帧的第 m 维特征。这些输出特征包括语谱参数和激励参数。


DNN的训练使用训练数据中抽取的上下文特征和语音特征的数据对，随后模型的参数可以被连续地更新。



基于RNN的语音合成

循环神经网络(RNN)使用时间上连续的结构模拟人的发音过程对上下文特征和语音特征建模。

- 如果输入一个完整的句子，从句子的开头到结尾和从句子的结尾到开头的两个方向处理上下文信息。
- 基于RNN的TTS使用深度双向LSTM(DBLSTM) (如图所示 Figure)。其中，网络的输入和输出与基于DNN的语音合成相同。
- 输入和输出特征通过HMM模型强制对齐。如果数据并没有强制地对齐，网络仍然可以通过结合诸如连接时序分类(CTC)的方法对输入和输出建模。
- 模型的训练过程与基于DNN的语音合成相同。



This is a pipe line model

(Fan et al., 2015)

基于HMM/NN的语音合成对比


HMM语音合成	
优点	缺点
训练速度快	音质不好，有机械感
模型小	模型平均，没有准确预测参数
合成速度非常快	依赖源滤波器vocoder

NN语音合成	
优点	缺点
神经网络更好的拟合参数	仅仅预测语音参数的均值，没有多样性
能够拟合语音长依赖的特性	时长模型和声学模型分开建模
合成速度快	依然使用源滤波器声码器

第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
 - 4.3.1 基于HMM的语音合成
 - 4.3.2 基于神经网络的语音合成
 - 4.3.3 声码器
- 4.4 语音合成的技术展望

源-滤波器模型(Source-filter model)



源-滤波器模型认为：声音是由激励(excitation)和相应的滤波器(vocal tract)组成

- 声道模型(vocal tract)
- 将声道看做一个谐振腔，“共振峰模型”

源-滤波器模型(Source-filter model) (续)

声带激励分为两类，可以产生清音或者浊音。

- 浊音 (voiced)

气流通过紧绷的声带，对声带进行冲击而产生振动，使声门处形成准周期性的脉冲串，激励信号简化为周期性的脉冲激励。

- 清音 (unvoiced)

声带处于松弛状态，不发生振动，气流通过声门直接进入声道，激励信号简化为随机白噪声。

- 上面的二元激励模型将复杂的产生激励过程简单的划为两部分，大大简化了声门激励的特征，但是合成语音的自然度较低。

- 参数对应关系

- F_0 /pitch对应于激励部分的 $e(n)$ 的周期脉冲序列和白噪声的叠加
- spectral envelope对应于声道谐振部分的 $h(n)$
- aperiodicity对应于激励部分的 $e(n)$ 中的非周期序列

第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望
 - 4.4.1 端到端的语音合成（了解）
 - 4.4.2 语音合成前沿任务（了解）

端到端语音合成（基本概念）

- 端到端 (E2E) 的TTS拥有直接读取文本作为输入并且不使用任何中间表示，直接输出语音波形。他的优化目标是整个系统而不是一个个子系统，从而减少了由人工假设和多阶段建模导致的性能损失。
- 端到端语音合成模型有两种类型：前端和后端的端到端模型。
- 前端的端到端模型：将韵律预测模型，持续时长模型和语音特征模型統合到一个模型里，从而直接读取上下文无关的符号预测语音特征(因此得名端到端语音模型)。
- 后端的端到端模型：读取语音特征作为输入，直接产生声音波形。因此，也被称为神经声码器。
- Tacotron 2 (Shen, et al, 2018) 是经典的端到端语音合成方法，其把前端的端到端模型(Tacotron)和后端的端到端模型(WaveNet)结合在一起。
- 这里，我们将以Tacotron2及其相关工作为例解释端到端语音模型部分和声码器部分，并解释目前研究的难点和热点。

端到端声学模型Tacotron2

Tacotron2系统 (Shen et al, 2018) 包括两个组成部分:

- (1) 结合注意力机制的**循环序列到序列特征预测网络**, 用于从输入字符串预测梅尔谱参数帧序列。
- (2) **WaveNet**的改良版, 基于预测的梅尔谱参数帧产生语音的时域波形。

- **编码器**将输入字符序列 $X = [x_1, x_2, \dots, x_T]$ 转换为隐式特征 $H = [h_1, h_2, \dots, h_T]$, 主要经由


嵌入层 $\bar{E}(x)$,
3层的卷积网络层,
双向LSTM层。

- **编码器的计算过程**可以表示如下

$$f_e = \text{ReLU}\left(F_3 * \text{ReLU}\left(F_2 * \text{ReLU}\left(F_1 * \bar{E}(x)\right)\right)\right)$$

其中 F_1, F_2, F_3 是三个卷积核, ReLU 是非线性激活函数。

$H = \text{EncoderRecurrrency}(f_e)$
 $\text{EncoderRecurrrency}(\cdot)$ 表示双向LSTM。



Tacotron 2系统架构框图


端到端声学模型FastSpeech

结合注意力机制的自回归的声学模型如Tacotron2等存在以下问题：

- (1) **生成速度慢。**
- (2) **鲁棒性差。**经常出现跳词或者重复。
- (3) **可控性差。**难以直接控制速度和韵律。

FastSpeech (Ren Yi, et al, 2019) 将文本（音素）序列作为输入，非自回归地生成梅尔频谱图，考虑文本和语音之间的单调对齐以加快梅尔频谱生成。

- 采用Transformer和1D卷积的前馈网络，**并行生成梅尔谱。**
- **时长预测器 Duration Predictor**，直接预测时长不需要注意力机制来学习对齐，避免跳词或者重复。
- **长度调节器Length Regulator**，解决序列长度不匹配的问题，并**控制语速和部分韵律。**



FastSpeech系统架构框图


端到端声码器模型

- 解码器将梅尔谱系数传递到声码器WaveNet。WaveNet可以不需任何假设直接生成声音波形，生成的声音质量优于传统声码器。
- 对于给定的外部输入 y ，WaveNet建模条件概率分布

$$P(z | y) = \prod_{t=1}^T p(z_t | z_1, \dots, z_{t-1}, y)$$

其中条件序列 y 可以使文本信息，说话人信息等等。 z_t 是当前时刻的波形采样点，每一个因子项都是以以前的历史信息作为输入预测当前采样点的概率分布。

- WaveNet使用扩张因果卷积处理语音序列的长时关联，因此可以获得更大的时间接受野。



扩张系数为1、2、4、8的扩张因果卷积层(接受野为16)

LPCNet结合知识与神经网络

- WaveRNN (Kalchbrenner, et al. 2018) 使用RNN建模从而进一步提高效率。但是，它的复杂度比传统数字信号处理方法高两个量级，原因是RNN声码器需要同时建模声源和滤波器模型。

- 语音生成系统是声源-滤波器模型。LPC使用过去若干采样，如 $s(n-i)$, $\{1, 2, \dots, p\}$ 的线性组合预测到来信号 $s(n)$ ，其残差为


$$\varepsilon(n) = s(n) - \sum_{i=1}^p a_i s(n-i)$$

a_i ($i = 1, 2, \dots, p$) 表示声道滤波器属性，残差误差 $\varepsilon(n)$ 与声源相关。

- LPCNet (Preger et al, 2019) 把语音生成分为两个部分。

- 基于LPC线性预测的线性部分
- 神经网络建模的非线性部分，这一部分改动相对较小。


这一策略简化了任务，提高了效率，并且只需要少量的神经元就可以完成。



LPCNet结合知识与神经网络（续）

LPCNet把信号处理的知识与神经网络结合

- 特征提取是以帧为单位进行（10ms, 160pt），语音生成是以采样的单位进行。
- LPCNet网络可以被分为两个子网络：帧率网络和采样率网络，外加LPC计算模块。核心部分是采样率网络部分。
- 帧率网络主要提供条件矢量输入给采样率网络。该条件矢量一帧计算一次，且在帧内保持不变。
- LPC计算模块从输入特征计算线性预测系数。该LPC同样一帧计算一次而且在帧内保持不变。



$$s(t) = e(t) + \sum_{i=1}^p a_i s(t-i)$$

完全端到端语音合成模型-VITS

与传统的模型相比，端到端语音合成模型虽然在音质上取得了极大进步，但是目前的端到端模型仍然需要**两个阶段**声学模型和声码器，合成的音质依然十分依赖中间声学特征的预测的准确度。VITS (Kim Jaehyeon, et al, 2021) 模型实现了声学模型和解码器部分**统一建模**，避免两段式框架中声学模型与声码器共用的梅尔谱中间表征引入的**误差**问题。

先验编码器


通过先验编码器获取文本**先验分布**的表征 (均值 μ_θ 与方差 σ_θ)

后验编码器

为了给后验编码器提供更高分辨率的信息，使用线性谱而非梅尔频谱作为后验编码器

Flow 标准化流

在先验编码器产生的简单分布和复杂分布间进行可逆变换



VITS训练过程

基于预训练模型的语音生成方法-(VALL-E)（基本概念）

同样得益于预训练模型的离散编码表示，微软提出了VALL-E（Wang, et al, 2023），将语音合成看作为条件语言模型建模任务，而不是连续信号的回归预测任务，利用60k小时的数据进行训练，VALL-E具有了一定的上下文学习能力，对于训练集中未见过的说话人，只需3秒的音频的提示就可以合成出具有高相似度和高音质的音频。


■ 条件语言模型

给定文本序列 X 和语音提示序列 $\tilde{c}_{:,1}$ ，最终离散编码 c 的预测可以用以下语言模型表示 $p(c|X, \tilde{c}; \theta) = p(c_{:,1}|\tilde{c}_{:,1}, X; \theta_{AR}) \prod_{j=2}^8 p(c_{:,j}|c_{:,<j}, X, \tilde{c}; \theta_{NAR})$

■ 自回归和非自回归

1) 预训练模型EnCodec的语音编码的码本是层次化的，因此预测每一个码本都用自回归（AR）会比较慢。

2) 第一个码本的离散编码采用AR预测，剩余的码本采用非自回归（NAR）预测。



VALL-E模型框架图


第四章 语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望
 - 4.4.1 端到端的语音合成
 - 4.4.2 语音合成前沿任务

序列到序列的个性化语音生成


- 在Tacotron等序列到序列语音合成模型被提出后，序列到序列的个性化语音生成技术，包括语音克隆和语音转换等，也逐渐受到研究关注。
- 语音克隆（Voice Cloning）指的是利用少量目标人语音数据，构建具有目标发音人音色特征的语音合成系统；
- 语音转换（Voice Conversion）不同于语音合成，旨在对输入的源说话人语音进行转换，将其音色转换成目标发言人的音色，而保留源语音的文本内容不变。
- 这两个任务的共同点在于都是要利用目标发音人的少量语音进行具有目标发音人音色特点的语音生成模型的训练。

语音克隆和语音转换技术示意图
(Ling et al, 2020)




个性化序列到序列语音合成-基于Tacotron2的研究

- Jia et al. (2018) 基于说话人辨识提出了一个个性化语音合成方法。他们在一个大规模说话人辨认数据库上使用了迁移学习技术，并且为说话人ID任务训练了说话人编码器，而后结合说话人嵌入和Tacotron获得优质的声音克隆。
- 语音合成框架由三个模块组成（如下图所示）：
 - 1) 说话人编码器，被用来抽取说话人嵌入矢量；
 - 2) 合成器，基于Tacotron2生成声学特征；
 - 3) 声码器，使用WaveNet重构语音波形。
- 在说话人ID任务中的损失函数最小化说话人嵌入矢量和同一说话人之间的余弦距离，同时最大化不同说话人嵌入之间的距离。




多风格语音合成

- Wang et al. (2018) 提出了基于Tacotron框架的全局风格标记 (GST) 模型控制多风格语音合成。GST模型将韵律嵌入矢量分为固定数量的风格符号集合。
- 在训练阶段，参考嵌入 (RE) 传入风格标志层并被作为注意力模块的询问矢量使用。这里，注意力模块被用于学习RE和随机初始化嵌入的集合中的每个标注之间的相似度。这个GST集合共享于所有训练序列。
- 在推理阶段，风格嵌入可以从两种途径获得：
 - 1) 使用参考声音序列，该序列可以是不同于期望风格的语音信号。它被描述为“参考语音序列”。
 - 2) 直接设置文本编码器为某些标记，像“B标志”展示的一样。这允许风格控制和操作不依赖于参考信号。





端到端情感语音合成方法

- Lee et al. (2017)基于结合情感标注的Tacotron模型提出了端到端情感语音合成方法，用来合成特定的情感。
- 他们考虑了六种情感，包括平静，生气，害怕，高兴，悲伤，和惊讶。情感标注经过pre-net结构被编码，而后被引入解码网络。在合成语音时，只需要给定文本和情感标注就可以合成带有对应情感的语音。



抗噪语音合成

当在诸如火车站等环境嘈杂的地方广播声音时，声音会变得不容易听清。为了在噪音环境中流畅地交流，人们在噪音环境和安静环境中采用不同的发音策略。说话人改变F0和F1，并且提高相关共振峰的能量避免被噪音掩蔽。即朗伯德效应(Lambert effect)，或朗伯德语音。



左图：男女说话人在安静环境（quiet）和鸡尾酒会（CKTL）的频谱；右图：不同元音在安静环境和鸡尾酒会的频谱变化。其结果，能量在3kHz处增强，它涉及与歌声共振峰相关的最大，属于耳朵敏感度区域。同样，语音频谱的修改会对清晰度在各个方面(听觉，音素识别，话语解析)产生多种影响。

语音感知与语音生成大模型例子

FunAudioLLM: Voice Understanding and Generation Foundation Models for Natural Interaction Between Humans and LLMs

FunAudioLLM: 人类与LLMs之间自然交互的语音理解和生成基础模型

[Paper] [Code] [Modelscope: SenseVoice CosyVoice] [HuggingFace: SenseVoice CosyVoice]

[论文] [代码] [Modelscope: SenseVoice CosyVoice] [HuggingFace: SenseVoice CosyVoice]

Tongyi SpeechTeam 通义演讲团队

Alibaba Group 阿里巴巴集团

Abstract: This report introduces **FunAudioLLM**, a framework designed to enhance natural voice interactions between humans and large language models (LLMs). At its core are two innovative models: **SenseVoice** for high-precision multilingual speech recognition, emotion recognition, and audio event detection; and **CosyVoice** for natural speech generation with multi-language, timbre, and emotion control.

摘要: 本报告介绍了 FunAudioLLM, 这是一个旨在增强人类与大型语言模型 (LLMs) 之间的自然语音交互的框架。其核心是两个创新模型: SenseVoice, 用于高精度多语言语音识别、情感识别和音频事件检测; CosyVoice 用于自然语音生成, 具有多语言、音色和情感控制。

SenseVoice delivers exceptionally low latency and supports over 50 languages, while CosyVoice excels in multi-lingual voice generation, zero-shot voice generation, cross-lingual voice cloning, and instruction-following capabilities.

SenseVoice 提供极低的延迟并支持 50 多种语言, 而 CosyVoice 则在多语言语音生成、零样本语音生成、跨语言语音克隆和指令跟随功能方面表现出色。

The models related to SenseVoice and CosyVoice have been open-sourced on Modelscope and Huggingface, along with the corresponding training, inference, and fine-tuning codes released on GitHub.

SenseVoice 和 CosyVoice 相关模型已在 Modelscope 和 Huggingface 上开源, 相应的训练、推理和微调代码也在 GitHub 上发布。

By integrating these models with LLMs, FunAudioLLM enables applications such as speech translation, emotional voice chat, interactive podcasts, and expressive audiobook narration, thereby pushing the boundaries of voice interaction technology.

通过将模型与 LLMs 集成, FunAudioLLM 支持语音翻译、情感语音聊天、交互式播客和富有表现力的有声读物旁白等应用, 从而突破了语音交互技术的界限。

语音交互大模型

