




第五章 语音增强

第五章 语音增强

■ 5.1 语音增强的概述

- 5.1.1 语音增强的基本概念（基本概念）


- 5.1.2 语音增强方法的回顾（了解）

■ 5.2 单通道语音增强

■ 5.3 多通道语音增强

■ 5.4 语音增强技术的展望

多说话人的现实复杂场景（鸡尾酒会问题）




语音分离与语音增强

为什么需要语音分离？

■ 定义：

- 语音分离（Speech separation）：语音分离是将目标语音从背景干扰中分离出来的任务。
- 语音信息处理的核心算法之一。



语音应用中多说话人语音分离/增强的流程图

■ 根据背景干扰的类型，语音分离通常分为三类：

- 语音去噪（Noise reduction）：语音 & 非语音分离（狭义的语音增强）
- 语音去混响（Dereverberation）：语音混响分离
- 说话人分离（Speaker separation）：多说话人分离（狭义的语音分离）


广义的语音增强
(Speech enhancement)
本章的重点

语音分离与语音增强例子（了解）



单说话人的现实复杂场景

- 本章主要聚焦单说话人场景下的语音增强



混响

障碍物反射引起的声音持续传播

$v(n)$

背景噪声

受损语音(Distorted speech): $y(n) = x(n) * h(n) + v(n)$

$h(n)$: 物体反射所形成的房间脉冲响应 (Room Impulse Response: RIR)

什么是语音增强?

■ 定义:

- 语音增强 (Speech enhancement) : 语音增强是将受损语音中的背景噪声和混响去除得到目标干净语音的任务。
- 主要目标: 提升受损语音的质量以及可懂度。可懂度也称为语言清晰度 (speech intelligibility), 听者能听懂通过一定传声系统传递的语音信号的百分率。不少语音增强技术在减少环境噪声的同时, 也会引入语音的失真, 进而损伤了语音的可懂度。

$$y(n) = x(n) * h(n) + v(n)$$

从被观测的受损语音 $y(n)$ 中恢复干净语音 $x(n)$


狭义语音增强

移除加性噪声


移除混响 (乘性噪声)

广义语音增强


增强前后的语谱图（了解）



受损语音




增强语音




干净语音

背景噪声和混响

背景噪声



干净语音




含噪语音





背景噪声与干净语音有相关性更低

混响



干净语音



混响语音




混响语音与干净语音的相关性更高

混响

■ 定义：


- **混响（Reverberation）**：混响是一种室内声学现象，声音从声源发出后，在空气中传播，在传播过程中，在房间界面上产生反射、吸收、扩散、透射、干涉、衍射等波动效应，形成复杂的室内声场，使人产生**混响感**。当室内声场稳定时，声源停止发声，声音由于多次反射或散射而继续发出，这称为混响。




语音增强的目的

能否同时做好人类感知与机器感知？

语音增强



受损语音



增强语音



■ 目的

- 提高语音可懂度，使人听起来更清晰
- 提高语音识别（包括自动语音识别、说话人识别等）的性能

语音增强的类型

- 通道数
 - 单通道语音增强
 - 多通道语音增强
- 方法类型
 - 基于信号处理的语音增强
 - 基于神经网络的语音增强
- 处理域
 - 时域语音增强
 - 频域语音增强

语音增强的类型（续）

■ 噪声类型

- 语音去噪（加性噪声）
- 语音去混响（乘性噪声）
- 语音去噪 & 语音去混响

■ 目的

- 用于机器感知
 - 语音识别（ASR）、说话人识别（Speaker recognition）等
- 用于人类感知
 - 助听器、会议系统等

语音增强度量指标（了解）


■ 几种常用的度量指标

- 感知语音质量评估（Perceptual Evaluation of Speech Quality: PESQ）
- 短时客观可懂度（Short Time Objective Intelligibility: STOI）
- 分段信噪比（Segmental Signal-to-Noise Ratio (SNR)）
- 对数似然比（Log-likelihood ratio）
- 倒谱距离（Cepstral distance）
- 信号失真比（Signal-to-Distortion Ratio (SDR)）
- 信号干扰比（Signal-to-Interference Ratio (SIR)）
- 语音混响调制能量比（Speech-to-Reverberation Modulation energy Ratio (SRMR)）
- 单词错误率（Word Error Rate (WER)）

语音增强度量指标（续）（了解）

■ 感知语音质量评估 (PESQ)：

- PESQ算法需要带噪的衰减信号和一个原始的参考信号。开始时将两个待比较的语音信号经过电平调整、输入滤波器滤波、时间对准和补偿、听觉变换之后，分别提取两路信号的参数，综合其时频特性，得到PESQ分数，最终将这个分数映射到主观平均意见分(MOS)。
- PESQ得分范围在-0.5 - 4.5之间。得分越高表示语音质量越好。



语音增强度量指标（续）

■ 信噪比（SNR）：

- 含噪语音中语音和噪声的比值取对数

$$SNR = 10 \log_{10} \left(\frac{P_S}{P_N} \right)$$

P_S : 信号功率, P_N : 噪声功率

■ 分段信噪比（Segmental SNR）：

- 由于语音信号是一个缓慢变化的短期稳定信号，不同时间段的信噪比应该不同。为了改善上述问题，可以使用分段信噪比。

语音增强度量指标（续）（了解）

■ 倒谱距离

- 计算倒谱之间的距离并取对数

$$CD = 10/\log_{10} \sqrt{2 \sum_{i=1}^p \{C_x(i) - C_y(i)\}^2}$$

其中， $C_x(i)$ 和 $C_y(i)$ 是干净语音和失真语音的倒谱系数（LPCC或MFCC）， p 是系数的维数。

语音增强度量指标（续）（了解）

■ 信号失真比（SDR）：

目前语音增强度量指标的不足？

- 语音分离中常用的评价指标
- 可以一定程度的反应信号的失真度

$$SDR = 10 \log_{10} \frac{\|s_{target}\|^2}{\|e_{interf} + e_{noise} + e_{artif}\|^2}$$

其中， e_{interf} ， e_{noise} 以及 e_{artif} 分别是干扰、噪声和伪影误差（musical noise）项。

■ 信号干扰比（SIR）：

- 反应了语音增强后干扰程度

$$SIR = 10 \log_{10} \frac{\|s_{target}\|^2}{\|e_{interf}\|^2}$$

第五章 语音增强

- 5.1 语音增强的概述
 - 5.1.1 语音增强的基本概念
 - 5.1.2 语音增强方法的回顾
- 5.2 单通道语音增强
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望

语音增强的历史（了解）

基于信号处理

谱减法，维纳滤波器...

高泛化能力

1976

统计与信号处理+

非负矩阵分解（NMF），
支持向量机，掩蔽... ..

较高性能

2012

基于深度学习的时域分析

进一步提高语音质量但计算成本更高

2017

1988

2013

基于统计的语音增强


（HMM、GMM、NN.....）

性能较高但低泛化

基于深度学习的频域分析

高性能但低泛化和高计算成本

基于传统信号处理的语音增强算法流程（掌握）




- 基于传统信号处理的语音增强系统的目标就是抑制增益，而抑制增益依赖于两个核心步骤：静音检测（VAD）和噪声估计模块。只有准确估计噪声谱才有可能准确估计抑制增益，通常会利用VAD来进行噪声估计。

基于统计模型的语音增强（了解）

- 基于统计模型的方法使用各种统计模型和优化准则，重点研究幅度谱的非线性估计器，这些非线性估计器将噪声和语音频谱系数的概率密度函数显式地考虑在内，并且在某些情况下使用非高斯先验分布。
- 这些估计器通常与考虑语音存在概率的软判决增益修改相结合。其代表性的方法包括最大似然 (ML) 估计器和贝叶斯估计器 (例如，MMSE 和最大后验估计)。这些估计器的主要不同之处在于对感兴趣的参数 (例如，确定性的但未知的、随机的) 和所使用的优化标准的形式所作的假设。
- 另外还有一些基于NMF、SVM以及基于神经网络（浅层）的方法也语音增强带来了较大的性能提升。


基于深度学习的语音增强算法流程（基本概念）




- 需要分为训练阶段和增强阶段。
- 训练：利用大规模数据训练深度学习模型的参数。
- 增强：利用深度学习模型进行语音增强。
- 性能佳，但是计算量大，容易过拟合。

基于深度学习的语音增强/分离的例子（了解）


- 语音分离方法SpEx++在公开数据集WHAMR的分离效果




Noise 




Reverb 




Noise + Reverb 



Estimated 



Estimated 



Estimated 

Meng Ge, Chenglin Xu, Longbiao Wang, Eng Siong Chng, Jianwu Dang and Haizhou Li. “Muti-Stage Speaker Extraction with Utterance and Frame-level Reference Signals”, ICASSP 21.

第五章 语音增强

- 5.1 语音增强的概述
- 5.2 单通道语音增强
 - 5.2.1 基于传统信号处理的语音增强（基本概念）
 - 5.2.2 基于深度学习的语音增强
（掌握、基本概念、了解）
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望

单通道语音增强的主要方法

■ 基于传统信号处理的语音增强

- 基于信号处理的方法（最重要的是噪声估计）。
- 该方法计算量小，通用性强。
- 典型算法：谱减法、维纳滤波器等。

■ 基于神经网络的语音增强

- 深度神经网络具有很强的回归能力。
- 该方法具有较高的性能，但计算量大，泛化能力差。
- 典型方法：DNN、LSTM等

谱减法的定义

■ 定义：

- **谱减法：**用带噪信号的频谱减去噪声信号的频谱得到干净信号频谱的估计。
- **噪声估计**
 - 当语音信号不存在时，可以估计和更新噪声谱。一般都假设输入的一段语音中前 n 帧作为静音时间。
 - 假设噪声是平稳的或缓慢变化的过程，并且噪声谱在更新周期之间没有显著变化。
- **增强信号**是通过计算估计信号频谱的离散傅里叶逆变换得到的。

受损语音信号的时频表示

■ 受损语音 $y(n)$ 的时域表示:

$$y(n) = x(n) * h(n) + v(n)$$

$x(n)$ 是干净语音信号, $h(n)$ 与 $v(n)$ 分别为房间脉冲响应与加性噪声。
本章节只考虑加性噪声, 因此将语音信号用以下数学模型表示:

$$y(n) = x(n) + v(n)$$

■ 受损语音的频域表示:

$$Y(\omega) = X(\omega) + V(\omega) = |Y(\omega)|e^{j\theta_y(\omega)}$$

$Y(\omega)$: 受损 (带噪) 语音的频谱; $X(\omega)$: 干净语音的频谱;

$V(\omega)$: 噪声的频谱; $\theta_y(\omega)$: 含噪语音的相位。

谱减法的思路

- 假设干净语音 $x(n)$ 和噪声 $v(n)$ 是不相关的,

$$|Y(\omega)|^2 = |X(\omega)|^2 + |V(\omega)|^2$$


- 带噪语音的功率谱减去噪声的功率谱得到干净语音功率谱的估计值, 从而得到语音振幅谱的估计 $|\hat{X}(\omega)|$ 以及干净语音的估计值 $\hat{X}(\omega)$,

$$|\hat{X}(\omega)| = (|Y(\omega)|^2 - |\hat{V}(\omega)|^2)^{1/2}$$

$$\hat{X}(\omega) = |\hat{X}(\omega)| e^{j\theta_y(\omega)}$$

干净语音估计值的相位谱可以用带噪语音的相位谱 $\theta_y(\omega)$ 来进行粗略表示, 这是由于在一定程度上, 相位不会严重影响语音质量。

谱减法流程图



广义谱减法

- 从含噪语音的功率谱减去噪声语音的功率谱估计值可能产生负的功率谱值。为了避免这一现象，以及对功率谱或者振幅谱进行一般化操作，广义谱减法的公式如下所示：


$$|\hat{X}(\omega)|^{2n} = \max(|Y(\omega)|^{2n} - \alpha \cdot |\hat{V}(\omega)|^{2n}, \beta \cdot |Y(\omega)|^{2n})$$

- α : 噪声超估计因子
- β : 频谱下限系数，用于防止产生负的频谱结果
- n : 任意指数参数
($n=1$: power SS; $n=0.5$: magnitude SS)



谱减法示例（了解）

如何估计噪声频谱的幅度 $|\hat{V}(\omega)|$?

$$|\hat{X}(\omega)|^{2n} = \max(|Y(\omega)|^{2n} - \alpha \cdot |\hat{V}(\omega)|^{2n}, \beta \cdot |Y(\omega)|^{2n})$$



噪声的振幅谱
的估计值



从含噪的语音频谱中减去估计的噪声频谱

谱减法的优缺点

■ 优点：

- 简单，只需要正反傅立叶变换，且实时实现较容易。

■ 缺点：

- 适用的信噪比范围较窄，在信噪比较低时对语音的可懂度损伤较大。所以实际应用时除了要降低噪声外，还要兼顾语音的可懂度和自然度。
- 由于频谱直接相减会使增强后的语音产生“音乐噪声”，它具有一定的节奏性，听上去类似音乐声。


维纳滤波器的基本原理

■ 滤波器的定义：

- 从连续的(或离散的)输入数据中滤除噪声和干扰以提取有用信息的过程称为**滤波**，而相应的装置称为**滤波器**。

■ 基本原理：

- **维纳滤波**语音增强的目标就是寻找系数为实数的线性滤波器，使得滤波偶信号与原干净语音信号之间的均方误差最小（直接估计干净语音信号），也称**最小二乘滤波器**或**最小平方滤波器**。



传统的维纳滤波器是基于VAD（静音检测）等算法进行噪声估计进而对滤波器进行设计

维纳滤波的简单实现

- 含噪语音信号经线性滤波后提高其信噪比，以得到降噪信号的方法。主要依据维纳滤波器来降噪，维纳滤波器的传输函数为，

$$H(\omega) = \frac{\hat{X}(\omega)}{Y(\omega)} = \frac{P_x(\omega)}{P_x(\omega) + P_v(\omega)}$$

- 在短时平稳的假设下， $X(\omega)$ 与 $V(\omega)$ 的功率谱密度分别为：

$$P_x(\omega) = E[|X(\omega)|^2] \quad P_v(\omega) = E[|V(\omega)|^2]$$

$X(\omega)$ 、 $Y(\omega)$ 与 $V(\omega)$ 分别为干净语音、噪声及带噪语音的频谱；

$\hat{X}(\omega)$ 为干净语谱的估计值；


$E[\cdot]$ 指对 $[\cdot]$ 内的频谱求统计平均。

- 对于平稳噪声而言，一般假设每帧信号的噪声功率已知，即由该帧前面的“静”时段可以估计出噪声功率谱。


维纳滤波的简单实现（续）（了解）

- $E[|X(\omega)|^2]$ 估计的经典方法：
 1. 将数帧平滑的 $|Y(\omega)|^2$ 作为 $E[|Y(\omega)|^2]$ 的初估值；
 2. 将 $E[|Y(\omega)|^2]$ 减去 $E[|V(\omega)|^2]$ 作为 $E[|X(\omega)|^2]$ 的估值。
- 按上述得知 $H(\omega)$ 后，每帧语音信号的频谱即可按 $\hat{X}(\omega)=H(\omega)Y(\omega)$ 得到。
- 时间域的语音信号可由傅里叶逆变换得到，相位部分设为 $Y(\omega)$ 的相位。


基于维纳滤波器的语音增强例子（了解）



含噪语音



增强语音



干净语音



- 维纳滤波后噪声明显感觉减弱
- 但是依然会有噪声残留

传统的语音增强方法的总结

- 常见的传统语音增强算法有谱减法和维纳滤波等。
- 谱减法虽然实现简单，运算量小，但效果比较差，容易出现刺耳的“音乐噪声”。
- 维纳滤波虽然原理较复杂，运算量也相对较大，比谱减法有更好的性能，极大消减“音乐噪声”。
- 但是，基于传统信号处理的语音增强算法的效果与干净语音还有较大差距。

频谱减法和维纳滤波器的主要问题

- 不擅长处理非线性噪声（混响等乘性、卷积噪声）
- 不擅长处理非平稳噪声（时变噪声） 为什么？
- 引入“音乐噪音”
- 性能不佳，噪声消除不干净



如何进一步提升语音增强的性能？

第五章 语音增强

- 5.1 语音增强的概述
- 5.2 单通道语音增强
 - 5.2.1 基于传统信号处理的语音增强
 - 5.2.2 基于深度学习的语音增强
- 5.3 多通道语音增强
- 5.4 语音增强的前景与展望


为什么需要基于深度学习的语音增强？

（基本概念）

■ 深度学习的优势

- 非线性变换能力
- 强大的回归能力
- 擅长处理非平稳噪声
- 增强后的语音更自然，没有音乐噪声


基于深度学习的语音增强的分类（了解）



频域语音增强的流程（掌握）


■ 频域语音增强常用的流程：

- **特征提取**：将时域信号转换为频域特征
- **特征增强**：利用神经网络增强频谱图的振幅
- **波形重构**：将增强的频谱图振幅和噪声相位信息转换（重构）为时域波形信号




基于DNN的语音增强（掌握）

- 基于映射（mapping）的框架（Xu et al., 2015）
 - 将语音增强视为多变量回归问题，其中非线性回归函数由DNN参数化。



基于映射的框架

- 基于掩蔽（mask）的框架（Wang et al., 2017）
 - 受听觉掩蔽现象和听觉场景分析的启发，该框架以掩蔽为主要目标。




基于掩蔽的框架

基于映射的语音增强的框架（掌握）


■ 基于映射的语音增强

- 相对传统的谱减法、维纳滤波器等方法效果有了极大的提升
- 对非平稳噪声有很好的抑制作用




基于映射的语音增强系统示意图

基于映射的语音增强的主要步骤（掌握）



- **训练：** 利用STFT将含噪音频和干净音频提取语谱图特征，前者为训练的输入后者为训练的目标。利用深度学习进行含噪语谱图到干净语谱图的非线性映射，训练非线性函数并保存模型。
- **增强：** 将含噪音频的语谱图输入到训练好的模型，可以得到干净音频特征。将干净的语谱图和原始的相位进行ISTFT变换得到重建后的去噪后的音频。

基于映射的语音增强的训练（了解）



干净语音特征

输出语音特征

输入语音特征

映射模型示意图

基于映射的语音增强的训练（续）（基本概念）

- 基于映射的语音增强的训练损失函数

语音识别的训练损失函数是什么？

- 均方误差（MSE）准则：

$$J_{\text{MSE}}(\mathbf{W}, \mathbf{b}; \mathbb{S}) = \frac{1}{M} \sum_{m=1}^M J_{\text{MSE}}(\mathbf{W}, \mathbf{b}; \mathbf{o}^m, \mathbf{y}^m)$$

$$J_{\text{MSE}}(\mathbf{W}, \mathbf{b}; \mathbf{o}, \mathbf{y}) = \frac{1}{2} \|\mathbf{v}^L - \mathbf{y}\|^2 = \frac{1}{2} (\mathbf{v}^L - \mathbf{y})^T (\mathbf{v}^L - \mathbf{y}).$$

$\{\mathbf{W}, \mathbf{b}\}$ 是模型参数， $\mathbf{o}$ 是观察向量， $\mathbf{y}$ 是相应的输出向量。

- 通过最小化损失函数进行训练

- 学习方法：误差反向传播（BP）算法

听觉掩蔽现象（了解）

- 当一个声音的感知受到另一个声音的影响时，就会发生听觉掩蔽。
- 听觉感知中的一种基本现象。
- 粗略地说，在临界频带内，强音掩盖了弱音。



基于掩蔽的语音增强概念（了解）



4	5	3
6	7	4
2	5	3

含噪语音

0	0.3	0.2
0.2	0.8	0.6
0.4	0.2	1.0

掩蔽


0	1.5	0.6
1.2	5.6	2.4
0.8	1.0	3

增强语音

基于掩蔽的语音增强的框架（掌握）

■ 基于掩蔽的语音增强

- 相对传统的维纳滤波器等方法效果有了极大的提升
- 对非平稳噪声有很好的抑制作用
- 广泛应用于语音降噪、多说话人分离等任务



基于掩蔽的语音增强系统示意图


基于掩蔽的语音增强的主要步骤（掌握）

■ 训练：

- **特征提取：**利用STFT提取含噪音频和干净音频的语谱图特征。
- **计算掩蔽值：**计算从含噪音频到干净语音的掩蔽值（label）。
- **模型参数更新：**利用深度学习进行含噪语谱图到掩蔽值的非线性映射，训练非线性函数并保存模型。

■ 增强：

- **特征提取：**利用STFT提取含噪音频和干净音频的语谱图特征。
- **计算掩蔽值：**将含噪音频的语谱图输入到模型，可以得到掩蔽值。
- **将含噪语音的语谱图和掩蔽值相乘，得到干净语音的语谱图的估值值。**
- **信号重构：**将干净语谱图的估计值和原始的带噪语音的相位进行ISTFT变换得到重建后的增强语音。



基于掩蔽的语音增强的训练损失函数（基本概念）

理想二进制掩码 (IBM)

- 该定义基于噪声信号的二维时频表示：





$$IBM = \begin{cases} 1, & \text{if } SNR(t, f) > threshold \\ 0, & \text{otherwise} \end{cases}$$

- IBM将每个T-F bin标记为目标主导型或干扰主导型。
- IBM评估中常用的损失函数是交叉熵（CE）。

为什么用交叉熵损失函数？

基于掩蔽的语音增强的训练损失函数（续）（了解）

IBM示例



IBM的缺点是什么？该如何改进？

基于掩蔽的语音增强的训练损失函数（续）

（基本概念）

理想比率掩码 (IRM)

- 理想的比率掩码可以看作是IBM的**软版本**：

$$IRM = \left(\frac{|X(t, f)|^2}{|X(t, f)|^2 + |V(t, f)|^2} \right)^\beta$$

- $X(t, f)^2$ 和 $V(t, f)^2$ 分别表示T-F bin的信号和噪声能量
- β 是一个可调参数，一般选取0.5
- 适用于附加噪声，但不适用于混响 **为什么？**
- **MSE**通常用作IRM估计中的损失函数

基于掩蔽的语音增强的训练损失函数（续）（了解）

相位敏感掩模（PSM）

- 增加了相位信息（相位信息对音质有一定的影响）：

$$PSM(t, f) = \frac{|X(t, f)|}{|Y(t, f)|} \cos \theta$$

- θ 表示T-F bin中干净语音和带噪语音之间的相位差
- 比不加相位性能有一定提升

基于掩蔽的语音增强的训练损失函数（续）（了解）

复数理想比例掩蔽（cIRM）

- cIRM掩蔽是**复数域中的理想掩蔽**。它可以直接从含噪语音中重建干净的语音：

$$cIRM = \frac{Y_r X_r + Y_i X_i}{Y_r^2 + Y_i^2} + i \frac{Y_r X_i - Y_i X_r}{Y_r^2 + Y_i^2}$$

$$\hat{X} = cIRM * Y$$

X 和 Y 分别表示干净语音和带噪语音的STFT表示。 $*$ 表示复数乘法。


- cIRM有一个**实部**和一个**虚部**，可以分别估计。

基于掩蔽的语音增强的训练损失函数（续）（了解）

复数理想比例掩膜（cIRM）

■ 利用DNN进行cIRM的学习：

- 输入为含噪的频域特征
- 输出目标为理想比例掩蔽
- 输出为实部和虚部
- 利用ISTFT对实部和虚部进行重建



cIRM的DNN结构


基于映射以及掩蔽的语音增强方法
在不同任务上有何主要差异？

第五章 语音增强


- 5.1 语音增强的概述
- 5.2 单通道语音增强
- 5.3 多通道语音增强
 - 5.3.1 固定波束形成（基本概念）
 - 5.3.2 自适应波束形成（了解）
- 5.4 语音增强技术的展望

多通道语音增强

- 多通道语音增强是一种处理多通道语音（使用麦克风阵列录制的音频）的增强方法。
- 优点：多通道语音增强考虑了音频通道与声源位置信息之间的信息差，因此具有更好的抑制方向性噪声的能力。




线性阵列和圆形阵列



均匀线性阵列

L: 阵列长度
d: 相邻麦克风间距




均匀圆形阵列

R: 圆形麦克风阵列的半径
d: 实际的相邻麦克风直线间距

- 波束形成(Beamforming)技术是主要的阵列处理技术之一。波束形成技术成熟较早，在早期该技术主要应用于雷达等定位系统。

波束形成的基本思路（掌握）

- 对各个麦克风单元接收到的语音信号进行加权求和，该加权系数决定了语音增强的效果。
- 通过调整加权系数，达到对目标声源方向的增强以及对其他干扰方向的抑制的效果，使得整个麦克风阵列对目标方向形成聚焦。



固定波束形成与自适应波束形成

- 根据加权系数是否能够随着接收信号的统计特性进行自我调整，可以将波束形成方法划分为**固定波束形成(Fixed Beamforming)**和**自适应波束形成(Adaptive Beamforming)**。
- **固定波束形成**：一旦设计好滤波器后，加权系数就不再改变。
 - 优点：计算简单，容易实现；
 - 缺点：环境适应性差，对噪声不具有自适应性；
 - 经典算法：
 - **延迟求和波束形成 (DSB: Delay-and-Sum Beamforming)**
 - **滤波求和波束形成 (FSB: Filter-and-Sum Beamforming)**

本章重点


固定波束形成与自适应波束形成（续）（了解）

- 自适应波束形成：加权系数具有自我调节的能力。
 - 优点：性能好，环境适应性好，对噪声具有自适应性；
 - 缺点：算法实现复杂，计算量大；
 - 经典算法
 - 最小方差无畸变响应（MVDR: Minimum Variance Distortionless Response）
 - 线性约束最小方差（LCVM: Linear Constrained Minimum Variance）
 - 广义旁瓣抵消法（GSC: Generalized Sidelobe Canceller）

固定波束形成与自适应波束形成（续）（了解）




固定波束形成



自适应波束形成


延迟求和波束形成基本思路（掌握）

- 延迟求和波束形成是一种经典和简单的固定波束形成方法，主要包含延迟补偿与加权求和处理。



- 延迟补偿使得每个麦克风信号在时间上对齐。
- 经过加权求和，得到增强后的输出信号。

麦克风语音信号（掌握）



$$\xi = d \sin \theta_s$$

$$x_2(t) = x_1(t - \tau_s)$$

$$\tau_s = \xi / c = (d \sin \theta_s) / c$$

c : 声速


d : 麦克风间隔

τ_s : 到达时间差 (TDOA)


θ_s : 到达方向 (DOA)

线性阵列的语音信号（了解）

$$x_i(t) = x_1(t - (i - 1)\tau_s)$$




延迟求和波束形成示意图（了解）



- 增强来自到达方向的声音信号
- 抑制来自其他方向的声音信号

延迟求和波束形成公式（了解）



$$D_i = D_0 - (i - 1)\hat{\tau}_s$$

$$i = 1, 2, \dots, M$$

$$\hat{\tau}_s = (d \sin \hat{\theta}_s) / c$$


$$x_{si}(t) = x_{s1}(t - (i - 1)\tau_s)$$

$$y(t) = \sum_{i=1}^M w_i x_{si}(t - D_i)$$


■ w_i 为第 i 个麦克风的权重，
等权重情况下取 $\frac{1}{M}$

$$x_{si}(t - D_i) = x_{s1}(t - (i - 1)\tau_s - D_i) \approx x_{s1}(t - D_0)$$

基于延迟求和波束形成的语音增强例子（了解）



增强之前



增强之后



TDOA的计算（掌握）

- 如何计算到达时间差（TDOA） τ_s ?
 - 利用两个信号之间的互相关与自相关特性

$$\begin{aligned}\phi_{12}(\tau) &= E[x_1(t) \cdot x_2(t + \tau)] \\ &= E[x_1(t) \cdot x_1(t + \tau - \tau_s)] \\ &= \phi_{11}(\tau - \tau_s)\end{aligned}$$

$\phi_{12}(\tau)$: $x_1(t)$ 和 $x_2(t)$ 的互相关函数


$\phi_{11}(\tau)$: $x_1(t)$ 的自相关函数

TDOA的计算（续）（掌握）

$$\begin{aligned}\phi_{12}(\tau) &= E[x_1(t) \cdot x_2(t + \tau)] \\ &= E[x_1(t) \cdot x_1(t + \tau - \tau_s)] \\ &= \phi_{11}(\tau - \tau_s)\end{aligned}$$

- 延迟为零（ $\tau - \tau_s = 0$ ）时，自相关函数 $\phi_{11}(\tau - \tau_s)$ 的值最大。

$$\hat{\tau}_s = \underset{\tau}{\operatorname{argmax}} \phi_{12}(\tau) = \underset{\tau}{\operatorname{argmax}} \phi_{11}(\tau - \tau_s)$$



到达方向（DOA）： $\hat{\theta}_s = \sin^{-1}(c\hat{\tau}_s/d)$

增强从方向 $\hat{\theta}_s$ 上到来的语音信号。

延迟求和波束成形特点

- 一旦设计了滤波器，加权系数就不会改变。
- 优点：计算简单，易于实现。
- 缺点：环境适应性差，对噪音没有适应性。
- 希望找到一种能够自动适应不同环境的波束形成方法。

第五章 语音增强

- 5.1 语音增强的概述
- 5.2 单通道语音增强
- 5.3 多通道语音增强
 - 5.3.1 固定波束形成
 - 5.3.2 自适应波束形成
- 5.4 语音增强技术的展望


自适应波束形成简介

- **自适应波束形成：** 加权系数具有自我调节的能力。
 - 优点：性能好，环境适应性好，对噪声具有自适应性；
 - 缺点：算法实现复杂，计算量大；
 - 经典算法
 - 最小方差无畸变响应（MVDR: Minimum Variance Distortionless Response）
 - 线性约束最小方差（LCVM: Linear Constrained Minimum Variance）
 - 广义旁瓣抵消法（GSC: Generalized Sidelobe Canceller）
- 目前，自适应波束成形已广泛应用于麦克风阵列语音增强。


MVDR简介

- MVDR 波束成形是一种基于最大信干噪比（SINR）准则的自适应波束成形算法。
- 该算法可以自适应地将麦克风阵列输出在所需方向的功率最小化，并最大化信干噪比以抑制噪声。
- MVDR在军事领域有着比较广泛的应用，例如常被用于水声无线通信技术，可以实现水面舰艇和潜艇之间的通信等等。
- MVDR算法采用了自适应波束形成中常用的采样矩阵求逆算法，该算法在信干噪比下具有较快的收敛速度。

基于MVDR波束形成的语音增强例子



增强之前




增强之后




MVDR与后置滤波简介

- 波束形成后依然会有残留，为了进一步抑制噪声干扰大多数波束形成后都会加一个后置滤波。
- 波束形成可以抑制波束指向之外的噪声、干扰，对于和波束指向同方向的噪声则使用后置滤波的方法进行消除。
- 后置滤波主要通过估计语音、噪声以及干扰的功率谱密度来对波束的结果进一步处理，以降低噪声和干扰。
- 估计出这些功率谱密度后，然后对波束形成（DSB，FSB，MVDR，LCMV等）后的结果按功率谱情况再加一次增益处理，这个处理主要是用于抑制同方向的噪声、干扰。

MVDR与后置滤波例子



增强之前



MVDR+后置滤波器




后置滤波器：维纳滤波器、基于NN的语音增强方法

第五章 语音增强

- 5.1 语音增强的概述
- 5.2 单通道语音增强
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望
 - 5.4.1 语音增强的前沿深度学习模型（了解）
 - 5.4.2 说话人分离（了解）

基于LSTM的语音增强


- LSTM可以利用上下文信息来进行增强
- 相对DNN，LSTM通常会有更好的性能



基于LSTM的SE流程图


基于对抗神经网络的语音增强

- 利用生成模型进行语音增强
- 利用判别器判断生成语音的质量



基于集成学习的语音增强


- 联合不同的网络进行语音增强：
 - CNN可以同时学习上下文及其频域的信息
 - LSTM善于学习上下文的信息
 - DNN适合做非线性映射



基于集成学习的语音增强流程图

语音增强的技巧：多目标训练（掌握）


- 很难断定那种方法(基于映射或基于掩蔽)更好，尤其在噪音脚本不可见的情况下。
- 在不同的SNR水平下，映射和掩蔽框架之间有很强的互补性。



多目标训练结构示意图

基于多任务学习的语音增强（掌握）


- 语音的其他任务可以作为增强任务的互补信息，为其提供丰富的语义或者说话人信息。
- 多任务学习能够利用不同任务的信息进行语音增强。
- 增强的语音对语音识别、说话人识别（ASV: Automatic Speaker Verification）或者其他任务的性能提升也有帮助。



多任务学习示意图

时域语音增强

- 在频域，语音增强往往受到相位信息的限制，难以进一步提高性能。
- 在时域，语音增强模型可以使用深度神经网络，而无需提取特征（端到端）。




Wave-U-Net示意图

- Wave-U-Net 是一种卷积神经网络，适用于音频源分离任务，它直接作用于原始音频波形。
- 它是 U-Net 架构对一维时域信号的一种变形，实现端到端音频源分离。通过一系列下采样和上采样块（包括 1D 卷积和下/上采样过程），在多个尺度/抽象级别和时间分辨率上计算特征。

第五章 语音增强

- 5.1 语音增强的概述
- 5.2 单通道语音增强
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望
 - 5.4.1 语音增强的前沿深度学习模型
 - 5.4.2 说话人分离



多说话人的现实复杂场景（回顾）



$$y(n) = \sum_i^M (x_i(n) * h_i(n)) + v(n) \quad M: \text{说话人数量}$$

复杂听觉场景下的耳和脑机制（基本概念）


- 人的听觉系统具有惊人的能力来解析复杂听觉场景。人类依靠耳蜗的活动机制对声音频谱进行最初的分析，并通过大脑自下而上刺激驱动和自上而下任务驱动的组合来对特定听觉物体进行选择。
- **自下而上刺激驱动：**被动接收听觉刺激，通过声源间的差异进行分离。
- **自上而下任务驱动：**主动选择性倾听特定声音，聚焦注意特定声源。



听觉场景下的耳与脑机制的示意图

复杂听觉场景下的耳和脑机制（续）（基本概念）


- 人的听觉系统具有惊人的能力来解析复杂听觉场景。人类依靠耳蜗的活动机制对声音频谱进行最初的分析，并通过大脑自下而上刺激驱动和自上而下任务驱动的组合来对特定听觉物体进行选择。
- **自下而上刺激驱动：**被动接收听觉刺激，通过声源间的差异进行分离。
- **自上而下任务驱动：**主动选择性倾听特定声音，聚焦注意特定声源。



机器模仿人脑机制的示意图

自下而上刺激驱动：盲源分离方案

- 基于深度学习的盲源分离方案通常是利用数据驱动直接构建混合信号与各源信号之间的非线性映射关系。
- 面向复杂声学场景，引入环境信息估计或系统融合能提升模型的鲁棒性。
- 面向多说话人交互场景，DPCL、PIT和TasNet等算法较为有效。




自下而上刺激驱动的通用框架

自下而上刺激驱动：置换不变性训练（PIT）

■ 基于PIT的语音分离方法

- 直接用语音增强的方法来进行语音分离通常会有置换问题
- PIT 直接汇集混合源的所有可能排列，并使用具有最低误差的排列来更新网络




自下而上的PIT分离框架


自下而上刺激驱动：时域音频分离网络(TasNet)

- 基于频域的增强网络通常会有以下问题
 - STFT并不一定是最优的语音分离信号变换
 - STFT将信号转换为复数域，但不能很好的处理相位谱
 - 频谱有效分率需要高频率高分辨率，否则会产生时延
- Tasnet提出一种时域上端对端方法，分为编码器、分离和解码器三步，直接对时域上的语音进行分离


A. TasNet block diagram



B. System flowchart




C. Dilated convolutions



自下而上的TasNet分离框架

自上而下任务驱动：目标说话人提取方案

- 基于深度学习的说话人提取方案是通过给予的目标说话人信息（现实应用中用户注册），提取目标说话人特征，关注目标说话人的声源，抑制其他干扰声源。



自上而下任务驱动的通用框架


自上而下任务驱动：SpEx+与SpEx++框架

■ SpEx+框架


- 移除相位估计的问题，时域分离方案替代频域分离方案
- 减缓特征空间的不匹配情况，将目标说话人特征和混合信号特征映射到同一个空间

■ SpEx++框架

- 参考语音较短时，可引入多阶段目标说话人提取策略




SpEx+框架




SpEx++框架

基于深度学习的语音增强/分离的例子


- 语音分离方法SpEx++在公开数据集WHAMR的分离效果




Noise 




Reverb 




Noise + Reverb 



Estimated 



Estimated 




Estimated 

Meng Ge, Chenglin Xu, Longbiao Wang, Eng Siong Chng, Jianwu Dang and Haizhou Li. “Muti-Stage Speaker Extraction with Utterance and Frame-level Reference Signals”, ICASSP 21.

视听一致性：多模态语音分离


- 视觉信息的增加能够改善仅基于听觉信息的掩蔽语音感知。视觉语音提供关于时间和听觉语音振幅包络的信息，同时还携带可在某种发音水平和听觉信号整合在一起的发音信息，将会影响听觉分流。
- 视听觉多模态方案常用视觉信息导向注意来做目标源分离。



视听多模态分离的通用框架

空间模型：麦克风阵列分离方案

- 声源的空间位置是促进听觉场景分析的重要线索。人类依靠耳间声音振幅水平、相位或时间差异的双耳线索，促进来自不同位置声音成分的分离。
- 常用麦克风阵列分离方案除空间特征外，可额外引入目标源方向、脸部或嘴部特征、以及目标说话人特征，结合自适应波束形成做到目标源分离。



麦克风阵列分离的通用框架