语音识别

- 语音识别解码算法
  - 孤立词识别及解码技术
    - 见声学模型小节内容
- 语音识别技术的展望
  - 端到端语音识别
    - 什么是CTC?
      - 基于神经网络的时序信号分类
    - 基于Attention的语音识别算法
      - 编码器-解码器模型（Encoder-Decoder Model）
        - 该模型由编码器和解码器两部分组成，其中编码器将输入序列映射到一个指定长度的向量，解码器将指定长度的向量解码为真实的标签。
      - Attention模型的优点
        - 直接将声学特征映射到更大的单元序列中，而不是音素或初始序列-最终序列
        - 实现了端到端训练，能够将整个系统训练到最优
        - 与CTC相比，Attention不需要每帧独立的假设。
      - Attention模型的缺点
        - 长序列对编码器网络造成巨大的压力
        - 在噪声环境下很难训练到很好的效果，通常要比CTC的方法差
        - 目前的解决方案：CTC和attention联合训练，采用CTC损失函数针对下层Encoder做强制对齐。
  - 复杂声学场景下的语音识别
    - 现实生活中，声学场景千变万化，训练集不能完全覆盖所有声学场景
    - 主要挑战
      - 真实世界传感器需要获取声音，但是周围声音是各种各样的，需要获取有效的人声
      - 获取人声也不一定是目标任务的人声，可能是用户和别人交谈的声音
      - 在远场场景下获取的声音面临着回声干扰、室内混响、多信号源干扰以及非平稳噪声的干扰等等
- 声学模型
  - 隐马尔可夫模型
    - 马尔可夫链
      - 离散状态的马尔可夫过程
      - 从一个状态到另一个状态的转换的随机过程
      - 定义
        - 系统在时间t的状态只与其在时间t-1的状态相关，满足以下关系 $P(q_t = s_j|q_{t-1} = s_i, q_{t-2} = s_k \ldots) = P(q_t = s_j|q_{t-1} = s_i), \quad t = 1,2,\ldots T$
        - 则称该随机过程为离散时间、离散状态的一阶马尔可夫过程，或简称为一阶马尔可夫链。
    - 马尔可夫链的问题与隐马尔可夫模型（HMM）
      - HMM的定义
        - 使用双重随机过程来描述模型，一个是Markov链，描述状态的转移（不可见）；另一个随机过程描述状态和观察值之间的统计对应关系（可见）。由于状态是不可见的，因此称之为"隐"Markov模型（HMM）。

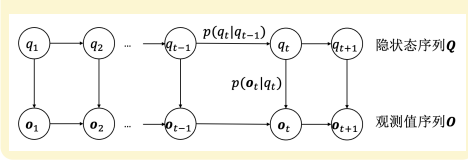

q_1 q_2 … q_{t-1} q_t q_{t+1}
$p(q_t|q_{t-1})$
$p(o_t|q_t)$
隐状态序列Q
o_1 o_2 … o_{t-1} o_t o_{t+1}
观测值序列O

      - HMM的模型描述和参数
        - 状态集合

```
状态 = {
    概率分布参数, // GMM或DNN的参数
    状态转移概率, // 到其他状态的转移概率
    持续时间统计   // 在该状态停留的时间分布
}
```

        - 可观测值集合

```
观测值 = [
    MFCC_1, MFCC_2, ..., MFCC_N,  // 通常13个MFCC系数
    Energy,                    // 帧能量
    Delta_1, Delta_2, ...,        // 一阶差分
    DeltaDelta_1, DeltaDelta_2,... // 二阶差分
]
```

        - 初始状态概率矩阵
        - 状态转移矩阵
        - 观测值概率矩阵
          - 表示在 t时刻、隐含状态是s_j的条件下，观察值为v_k的概率。
      - HMM的三个基本问题
        - 问题1：模型概率计算问题
        - 问题2：模型解码问题
        - 问题3：模型参数估计问题
      - 前向算法(forward algorithm)
        - 定义
          - 到时刻t为止部分观测序列为O1,O2,...,Ot，且状态为S(为方便表示，在后面的算法中状态s_i简记为i)的概率。
        - （1）初始化：对$1 \le i \le N$，有 $\alpha_1(i) = \pi_i b_i(\boldsymbol{o}_1)$
        - （2）递推：对$2 \le t \le T, 1 \le j \le N$，有 $\alpha_t(j) = \left[\sum_{i=1}^{N} \alpha_{t-1}(i) a_{ij}\right] b_j(\boldsymbol{o}_t)$
        - （3）终止： $P(\boldsymbol{O}|\lambda) = \sum_{i=1}^{N} \alpha_T(i)$
      - 后向算法(backward algorithm)
        - 当前时刻t
          ↓
          [O_1, O_2, ..., O_t] [O_t+1, O_t+2, ..., O_T]
          └──── β_t(i) ────┘
          β_t(i)关注的是从t+1时刻到结束时刻的这段序列，考虑了所有可能的状态转移路径。
        - （1）初始化：对$1 \le i \le N$，有 $\beta_T(i) = 1$
        - （2）递推：对$t = T-1, T-2, \ldots, 1, 1 \le i \le N$，有 $\beta_t(i) = \left[\sum_{j=1}^{N} \beta_{t+1}(j) a_{ij}\right] b_j(\boldsymbol{o}_{t+1})$
        - （3）终止： $P(\boldsymbol{O}|\lambda) = \sum_{i=1}^{N} \pi_i b_i(\boldsymbol{o}_1)\beta_1(i)$
      - 模型解码问题的描述
        - 最佳状态序列的确定
          - 确定一个最佳状态序列$\boldsymbol{Q}^* = q_1^*, q_2^*, \cdots, q_T^*$，使$P(\boldsymbol{O},\boldsymbol{Q}^*|\lambda)$为最大。 $\boldsymbol{Q}^* = \arg\max_{\boldsymbol{Q}} P(\boldsymbol{O},\boldsymbol{Q}|\lambda)$
          - 定义$\delta_t(i) = \max_{q_1,q_2,\cdots,q_{t-1}} P(q_1 q_2 \cdots q_{t-1}, q_t = i, \boldsymbol{o}_1\boldsymbol{o}_2\cdots\boldsymbol{o}_t|\lambda)$为时刻t时沿着一条路径$q_1 q_2 \cdots q_{t-1}$，且$q_t = i$，产生$\boldsymbol{o}_1\boldsymbol{o}_2\cdots\boldsymbol{o}_t$的最大概率。
          - 求解最佳状态序列Q?
            - Viterbi算法
              - （1）初始化：对$1 \le i \le N$，有 $\delta_1(i) = \pi_i b_i(\boldsymbol{o}_1)$ $\psi_1(i) = 0$
              - （2）递推：对$2 \le t \le T, 1 \le j \le N$，有 $\delta_t(j) = \max_{1 \le i \le N}[\delta_{t-1}(i)a_{ij}]b_j(\boldsymbol{o}_t)$ $\psi_t(j) = \arg\max_{1 \le i \le N}[\delta_{t-1}(i)a_{ij}]$

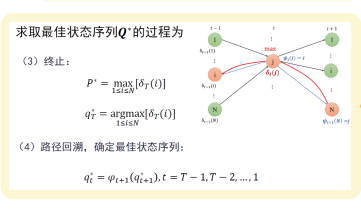

求取最佳状态序列Q^*的过程为

（3）终止：

$P^* = \max_{1 \le i \le N}[\delta_T(i)]$

$q_T^* = \arg\max_{1 \le i \le N}[\delta_T(i)]$

（4）路径回溯，确定最佳状态序列：

$q_t^* = \psi_{t+1}(q_{t+1}^*), t = T-1, T-2, \ldots, 1$

      - 模型参数估计的思路
        - 实际上，不存在一种方法直接估计最佳的模型参数
        - 思路：选取初始模型，计算更新参数，逐步改进。
        - Baum-Welch算法
          - 用来解决当观测序列和隐状态序列未知时的HMM参数的算法，该算法是期望最大化（EM）算法的一个特例。
          - 设辅助函数$L(\lambda,\hat{\lambda}) = \sum_{\boldsymbol{Q}} P(\boldsymbol{Q}|\boldsymbol{O},\lambda)\log P(\boldsymbol{O},\boldsymbol{Q}|\lambda)$。
            - ◻ 在步骤E（期望）求给定参数集λ上的$L(\lambda,\hat{\lambda})$；
            - ◻ 在步骤M（最大化）更新模型参数 $\lambda = (\boldsymbol{A},\boldsymbol{B},\pi)$。
            - $\hat{\lambda} = \arg\max_{\hat{\lambda}} \sum_{\boldsymbol{Q}} P(\boldsymbol{Q}|\boldsymbol{O},\hat{\lambda})\log P(\boldsymbol{O},\boldsymbol{Q}|\lambda)$
          - Baum-Welch算法未必能求得全局最大值、而有可能得到一局部极值点。
  - 语音识别领域离散HMM的典型结构

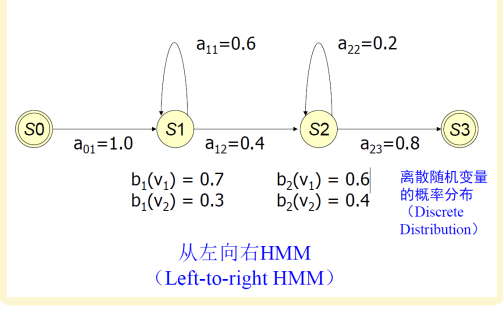

  - 高斯混合模型（Gaussian Mixture Models）
    - 由M个单高斯模型组合而成的模型来描述复杂的数据（比如语音数据）分布。

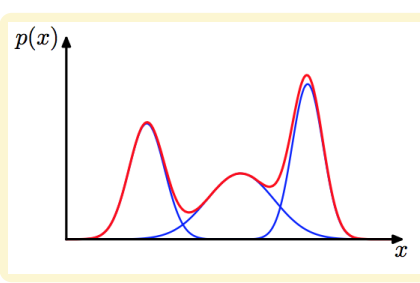

    - 高斯混合模型的概率分布
      - 对于M个高斯模型的混合模型，c_m是观测数据属于第m个子模型的先验概率（混合权重），则高斯混合模型的概率分布为：
        $P(x|\theta) = \sum_{m=1}^{M} c_m N(x|\mu_m,\Sigma_m)$
        $N(x|\mu_m,\Sigma_m) = \frac{1}{(2\pi)^{D/2}|\Sigma_m|^{1/2}}\exp\left\{-\frac{1}{2}(x-\mu_m)^T\Sigma_m^{-1}(x-\mu_m)\right\}$
        其中，$\sum_{m=1}^{M} c_m = 1$，$N(x|\mu_m,\Sigma_m)$是第m个子模型的高斯分布密度函数。
    - 用连续的概率密度函数来描述连续的观察值向量（ot）的概率分布
      - 混合高斯模型（GMM）来表示ot的概率分布
        $b_j(\boldsymbol{o}_t) = \sum_{m=1}^{M} \frac{c_{j,m}}{(2\pi)^{D/2}|\boldsymbol{\Sigma}_{j,m}|^{1/2}}\exp\left\{-\frac{1}{2}(\boldsymbol{o}_t-\boldsymbol{\mu}_{j,m})^T\boldsymbol{\Sigma}_{j,m}^{-1}(\boldsymbol{o}_t-\boldsymbol{\mu}_{j,m})\right\}$
  - 基于GMM-HMM的语音识别技术
    - 基于GMM-HMM的语音识别框架

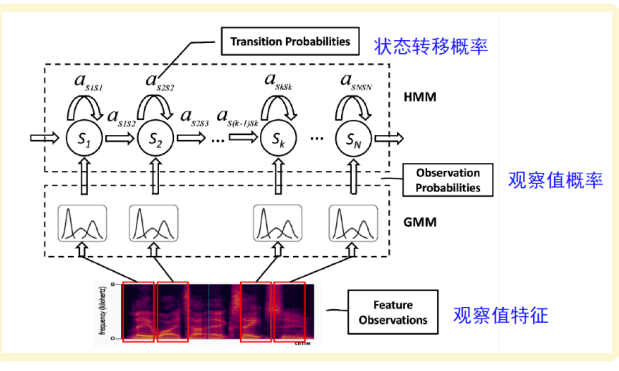

    - 基于HMM的孤立词识别技术

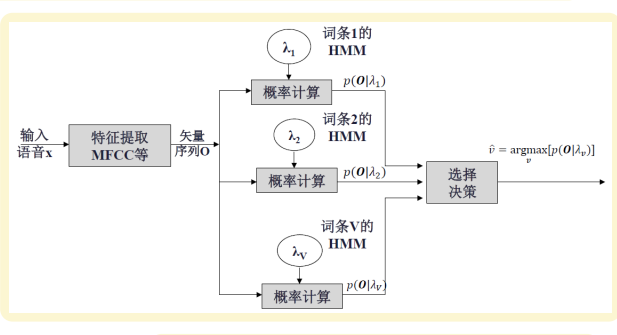

    - 基于HMM的连续语音识别技术
      - 连续语音识别（特别是大词汇量连续语音识别：LVCSR）
      - 基于HMM的LVCSR系统的统一框架
        - 将整个识别系统分为三层：声学—语音层、词层和句法层
          - 声学—语音层是识别系统的底层，它接受输入语音，并以一种"子词（Subword）"单位作为其识别输出，每个子词单位对应一套HMM结构和参数。
          - 词层规定词汇表中每个词是由什么音素—音子串接而成的。
          - 句法层中规定词按照什么规则组合成句子。

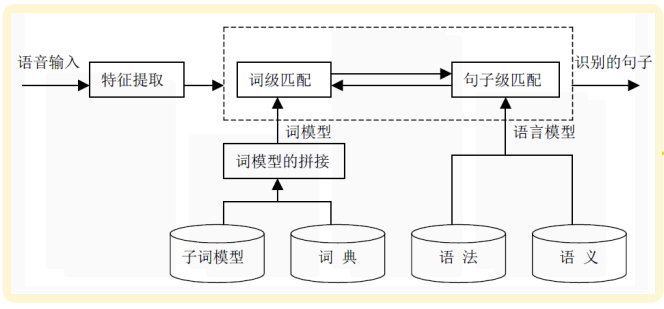

  - 基于统计模型的语音识别框架
    - 框架图
    - 建模单元的选择（基本概念）
      - 原则
        - 以词作为基本单元建立模型不合理，造成大量不必要的冗余存储和计算。因此一般采用比词小的子词识别基元，如音节、半音节、音素等。
        - 声学单元越小，其数量也就越少，训练模型的工作量也就越小；
        - 但是，单元越小，对上下文的敏感性越大，越容易受到前后相邻的影响而产生变异，因此其类型设计和训练样本的采集更困难。
      - 三音素HMM
        - 单音素建模没有考虑协同发音效应。协同发音(coarticulation)是指在语流中，音段并非是静止的、分离的声音，音段会对相邻的音段产生影响。
        - 协同发音的一个解决方法是用三音素建模，考虑音素的上下文，表示为"l-c+r"，其中，c表示中心单元，l为左相关信息，r为右相关信息。
        - 假设共有N个音素，那么就需要N^3个三音素，当N增大时，参数量也是非常大的。因此，在语音建模中，使用决策树来进行三音素建模。这一过程依赖于单音素建模后的对齐。
    - 从单音素到三音素GMM
      - 始于单音素, 进行EM训练
      - 将高斯分布（Gaussians）复制到三音素中
      - 创建决策树并对高斯分布进行聚类
      - 复制并混合训练(GMMs)
      - 流程图

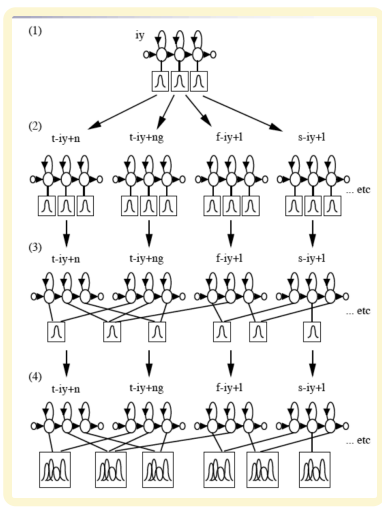

  - DNN-HMM
    - HMM的观测值概率分布
      - 离散分布（Discrete Distribution）HMM
        - 矢量量化（Vector Quantization：VQ）
      - 连续分布（Continues Distribution）HMM (CD-HMM)
        - 高斯混合模型（Gaussian Mixture Model：GMM）
        - 深度神经网络（Deep Neural Network：DNN）
    - 基于DNN的语音识别算法
      - 深度神经网络（Deep Neural Network，DNN）可以简单的定义为在输入层和输出层之间有多层隐含层（超过一层）的人工神经网络。
      - 经典的做法是先基于深度信念网络（Deep Belief Networks，DBN）做预训练，之后用反向传播（Backpropagation，BP）算法微调。
      - 每一个神经元把经过乘法线性变换的上一层的输出求和得到al，然后通过非线性激活函数输出给下一层。
        - $\mathbf{a}^l = \mathbf{W}^l\mathbf{h}^{l-1} + \mathbf{b}^l \quad 1 \le l \le L+1$
        - $\mathbf{h}^l = f(\mathbf{a}^l) \quad 1 \le l \le L$
        - $f(a) = \frac{1}{1+e^{-a}}$
        - 其中 $f(\cdot)$ 是非线性激活函数，$\mathbf{W}^l$和$\boldsymbol{b}^l$是第l层隐层的权重和偏置向量。
      - 分类任务（比如：语音识别）的损失函数多采用最小交叉熵（cross-entropy，CE）准则
        - 分类任务（比如：语音识别）的损失函数多采用最小交叉熵（cross-entropy，CE）准则，可以表示如下：
          $J_{CE} = -\sum_{i=1}^{C} y_i \log h_i^{L+1}$
          其中y_i是观测值$\boldsymbol{o}_t$属于第i类的经验概率分布（从训练数据的标注中来），h_i^{L+1}是采用DNN估计的观测值$\boldsymbol{o}_t$属于第i类的概率，表示为：
          $h_i^{L+1} = P(i|\mathbf{o}_t) = \frac{e^{-a_i^{L+1}}}{\sum_j e^{-a_j^{L+1}}}$
          利用反向传播（BP）算法最小化J_{CE}得到更新网络的参数。
      - DNN-HMM语音识别算法框架

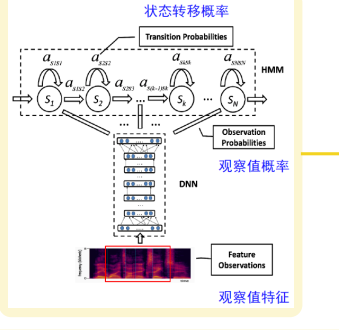

        - 用DNN替换GMM，用DNN计算观察值概率
        - 用GMM-HMM算法分割语音内容
        - 在分割好的语音内容上训练DNN
      - DNN-HMM的建模能力
        - DNN不需要对声学特征所服从的分布进行假设；
        - DNN的输入可以采用连续的拼接帧，更好的利用了上下文信息；
        - DNN的训练过程可以采用随机优化算法来实现，因此当训练数据规模较大时也能进行非常高效的训练；
        - 在发音模式分类上，DNN这种鉴别式模型也要比GMM这种生成式模型更加适合；
        - 无监督预训练。
      - DNN的输入
        - 更底层的滤波器组（Filter Bank，FBK）声学特征。它利用Mel滤波器组在功率谱上进行滤波并计算对数能量，然后采用其规整值作为特征表示；
        - 目前，FBK特征比MFCC有效；证明了原始语音频谱对基于DNN的语音识别技术的重要性；
        - 不同于传统的GMM采用单帧特征作为输入，DNN会进行拼接帧的操作。会将相邻的若干帧进行拼接得到一个包含更多信息的输入向量，例如每7帧构成一个输入
      - DNN的输出
        - DNN输出向量的维度对应HMM中状态的个数，通常每一维输出对应一个绑定的triphone状态。
        - 训练时，为了得到每一帧语音在DNN上的目标输出值（标注值），需要通过事先训练好的GMM-HMM识别系统在训练语料上进行强制对齐（Force alignment）。
        - 基于GMM-HMM通过基于Viterbi算法的强制对齐方法，给每个语音帧打上一个HMM状态标签，然后依据此状态标签，基于DNN训练算法训练一个DNN模型。
      - DNN的训练
        - 用BP算法直接进行训练往往效果不佳，这也是早期基于ANN的混合声学模型未能成功应用的主要原因
        - 多层神经网络参数优化是个高维非凸优化问题，常收敛较差的局部解。
        - 梯度消失问题：BP算法计算出的误差会从输出层开始向下呈指数衰减，这样计算出各层的梯度也会随着深度的变化而显著下降，导致靠近输出层的隐层训练的比较好，而靠近输入层的隐层几乎不能得到有效训练。
        - 解决方法：通过预训练找一个合适的初值。
          - 分为无监督的预训练(Pre-training)和有监督的鉴别性微调(Fine-tuning)。
          - Pre-training：用受限波尔兹曼机(Restricted Boltzmann Machines，RBM)算法逐层训练构建深层置信网络(Deep Belief Networks，DBN)。
          - Fine-tuning：将DBN 作为DNN 的初始化参数，采用标准误差反向传播(Standard Error Back Propagation，BP)算法对DNN进行调整。
          - 使用海量训练数据进行训练能有效避免过拟合问题；
          - Dropout等随机优化算法的提出也极大提高了DNN模型的泛化能力；
          - 一些措施的采用也成功地减小了梯度消失问题的影响
            - 整流线性单元（Rectified Linear Units, ReLU）作为激活函数
            - 采用卷积神经网（Convolutional Neural Networks, CNN）这种深度网络结构。
- 语音识别概述
  - 语音识别的基本概念
    - 什么是语音识别（ASR）
      - 自动语音识别（Automatic Speech Recognition）：机器通过识别把人类的语音信号转变为相应的文本的技术

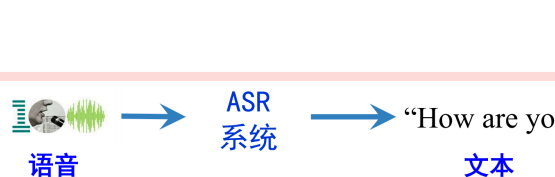

    - 语音识别的分类
      - 按发音方式分
        - 孤立词（isolated words）识别
        - 连接词（connected words）识别
        - 连续语音（continuous speech）识别
      - 按词汇表（Vocabulary）的大小分
        - 小词汇表识别系统
        - 中词汇表识别系统
        - 大词汇表识别系统
      - 按说话人分
        - 特定说话人（speaker-dependent）语音识别
        - 非特定说话人（speaker-independent）语音识别
    - 语音识别评价指标
      - 单词错误率（Word Error Rate）
        - $\text{Word Error Rate} = \frac{100\,(\#\text{Insertions} + \#\text{Substitutions} + \#\text{Deletions})}{\text{Total Word in Correct Transcript}}$
        - Insertion：插入；Substitution：置换；Deletion：删除
  - 语音识别方法的回顾
    - 基于规则的语音识别
      - Phonetics（语音学），phonology（音韵学）
      - Syntax（语法）
      - Pragmatics（语用学）
      - 缺点
        - 难以表达规则
        - 难以知道如何提升系统的性能
    - 基于数据驱动的语音识别

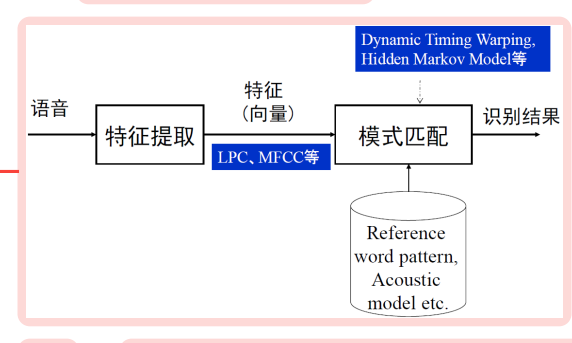

语音
特征提取
特征（向量）
LPC, MFCC等
Dynamic Timing Warping, Hidden Markov Model等
模式匹配
识别结果
Reference word pattern, Acoustic model etc.

    - 基于模板匹配的语音识别
      - 概念
        - 将输入模板与参考模板比较，查找最相似的模板
      - 如何计算两个矢量序列X和Y之间的相似度?
        - 动态时间弯折/归正（DTW）

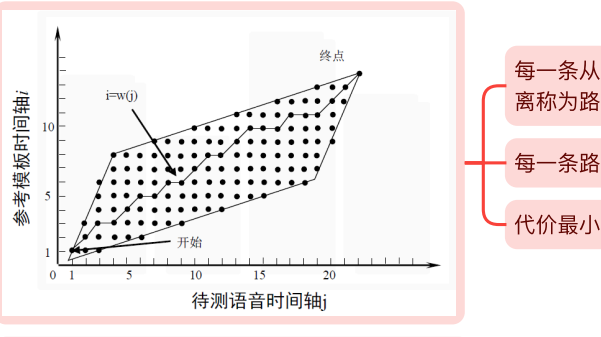

          - 每一条从（1，1）到（I, J）路径都有一个累计距离称为路径的代价。
          - 每一条路径都代表一种对齐情况。
          - 代价最小的路径就是所求对准路径。
          - DTW是采用动态规划（Dynamic Programming, DP）技术，将一个复杂的全局问题转化为许多局部最优问题，逐步进行决策。
          - 将表示两个语音段的矢量序列对准了再计算相似度
          - 缺点改进->基于统计模型的语音识别
    - 基于统计模型的语音识别框架
      - 基于统计模型的语音识别框架

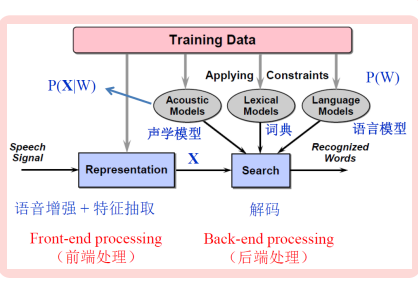

      - 噪音通道模型
        - 源句子（source sentence）经过噪音通道（noisy channel）会生成噪音句子（noisy sentence）。我们通过对噪音句子的解码得到猜测的句子（guessed sentence）
        - 本质是求argmax P(W|X)
          - 给出声学特征X，查找最匹配的单词序列W。
          - 应用贝叶斯法则
            - 声学模型 语言模型 $\arg\max_W P(W|\boldsymbol{X}) = \arg\max_W \frac{P(X|W)P(W)}{P(X)}$
              - 因P(X)与W无关，可以去掉分母P(X)。
      - 声学模型
        - GMM-HMM（高斯混合模型-隐马尔可夫模型）
          - 观察值特征-(GMM)->观察值概率-(HMM)->状态转移概率
        - DNN-HMM（深度神经网络-隐马尔可夫模型）
          - 观察值特征-(DNN)->观察值概率-(HMM)->状态转移概率
        - End-to-end Model（端到端模型）
          - 语音特征->Encoder->Attention->Decoder->输出
      - 语言模型
        - 根据语言客观事实而进行的语言抽象数学建模，用以计算文字序列的概率
        - 分类
          - 基于文法的语言模型
          - 基于统计的语言模型（N-gram语言模型, 神经语言模型）
            - N-gram（N元文法）语言模型
              - ◻ 单词序列 $w_1^n = w_1 \ldots w_n$
              - ◻ 概率的链式法则 $P(w_1^n) = P(w_1)P(w_2|w_1)P(w_3|w_1^2)\ldots P(w_n|w_1^{n-1}) = \prod_{k=1}^{n} P(w_k|w_1^{k-1})$
              - ◻ N-gram近似 $P(w_1^n) = \prod_{k=1}^{n} P(w_k|w_{k-N+1}^{k-1})$ 假设词w_k出现的概率只与前N-1个单词有关
      - 解码算法
        - Viterbi搜索算法
- 语言模型
  - 语言模型的基本概念
    - 语言模型的定义
      - 语言模型：用来计算一个句子概率的模型
      - 在语音识别中的应用：统计语言模型被广泛应用来实现句子的约束。减小由于声学模型不够合理而产生的误识。
        - 例子："（福建重口音）我要回福建省福州市，帮我买盒五仁月饼。"，只有声学模型可能会被误识别为"我要回胡建省湖州市，帮我买盒五人月饼。"
    - 语言模型的分类
      - 基于文法的语言模型
        - 总结语法规则及语音规则
      - 基于统计的语言模型
        - 统计各个词的出现概率及其相互关联的条件概率
      - 基于深度学习的语言模型（神经语言模型）
        - 通过训练网络来学习词表征和单词序列的概率化表示
    - 语言模型的评价指标
      - 估计测试语料库中的句子概率并取倒数，对句子长度进行归一化。
        - $PP(W) = \sqrt[N]{\frac{1}{P(w_1 w_2 \ldots w_N)}}$
          $P(w_1^n) = P(w_1)P(w_2|w_1)P(w_3|w_1^2)\ldots P(w_n|w_1^{n-1}) = \prod_{k=1}^{n} P(w_k|w_1^{k-1}) \qquad W = w_1^N$
          - 测量预测下一个词时的加权平均分支因子(越低越好)
            - （困惑度，模型预测下一个词时，平均需要从多少个候选词中选一个才合理。比如困惑度是 20，意味着模型平均要从 20 个候选词里猜下一个词；困惑度是 5，就只需从 5 个里猜 —— 显然 5 的模型更 "聪明"，对语言的规律把握得更好。）
  - N-gram语言模型
    - N-gram语言模型
      - 单词序列 $w_1^n = w_1 \ldots w_n$
      - 概率的链式法则 $P(w_1^n) = P(w_1)P(w_2|w_1)P(w_3|w_1^2)\ldots P(w_n|w_1^{n-1}) = \prod_{k=1}^{n} P(w_k|w_1^{k-1})$
      - N-gram近似 $P(w_1^n) = \prod_{k=1}^{n} P(w_k|w_{k-N+1}^{k-1})$
      - 假设词w_k出现的概率只与前N-1个单词有关；N-1阶马尔可夫模型
    - 根据之前的上下文估计每个单词的概率
      - P(phone|Pleaseturnoffyourcell) ——所需的参数数量随着先前上下文的单词数量呈指数增长
      - 一个N-gram模型只需要N-1个先前上下文的单词
    - N-gram语言模型的复杂度（困惑度）
    - N-gram语言模型的概率估计
      - 基于单词序列的相对频率，可以从原始文本中估计出N-gram条件概率。
        - Bigram: $P(w_n|w_{n-1}) = \frac{C(w_{n-1}w_n)}{C(w_{n-1})}$
        - N-gram: $P(w_n|w_{n-N+1}^{n-1}) = \frac{C(w_{n-N+1}^{n-1}w_n)}{C(w_{n-N+1}^{n-1})}$
    - 语言模型的平滑技术
      - 由于存在可能的单词序列的组合数，许多罕见（但并非不可能）的组合在训练中从未出现，因此最大似然估计（MLE）错误地将许多参数（也就是稀疏数据）赋值为零。如果在测试过程中出现了新的组合，则给出该组合的概率为零，整个序列的概率为零。
      - 参数被平滑（又称正则化），以重新分配一些概率值给未知的事件。
      - 为未知的事件添加概率值需要将其从看到的事件中移除(折现)，以保持和为1的联合分布。

Presented with xmind