


梅尔频率倒谱系数(MFCC) ——

(倒谱分析可参考MFCC的提取流程)




- ① 语音信号经过预加重、加窗、分帧的预处理过程，得到帧序列语音信号。
- ② 对帧序列语音信号进行离散傅里叶变换（DFT），取模的平方得到离散能量谱 $|X(k)|^2, 1 \leq k \leq \frac{N}{2} - 1$ 。令 $S(k) = |X(k)|^2$ 。

模型概率计算 —— 前向算法(forward algorithm) (掌握)

前向变量: $\alpha_t(i) = P(\mathbf{o}_1 \mathbf{o}_2 \cdots \mathbf{o}_t, q_t = i | \lambda)$

定义: 到时刻 t 为止部分观测序列为 $\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_t$, 且状态为 s_i (为方便表示, 在后面的算法中状态 s_i 简记为 i) 的概率。



前向概率计算示意图

模型概率计算 —— 前向算法 (续)

(掌握)


前向变量有如下性质：

(1) 初值易求 $\alpha_1(i) = P(\mathbf{o}_1, q_1 = i) = \pi_i b_i(\mathbf{o}_1)$

(2) 可以计算 $P(\mathbf{O}|\lambda) = \sum_{i=1}^N \alpha_T(i)$

(3) 有递推关系 $\alpha_t(j) = \left[\sum_{i=1}^N \alpha_{t-1}(i) a_{ij} \right] b_j(\mathbf{o}_t)$

因此可以利用递推关系，逐层递推，计算出全部 $\alpha_t(j)$ 。
最后再由 $\alpha_T(j)$ 计算得到 $P(\mathbf{O}|\lambda)$ 。



前向概率计算示意图

模型概率计算 —— 前向算法 (续)

(掌握)

前向算法:


(1) 初始化: 对 $1 \leq i \leq N$, 有

$$\alpha_1(i) = \pi_i b_i(\mathbf{o}_1)$$

(2) 递推: 对 $2 \leq t \leq T, 1 \leq j \leq N$, 有

$$\alpha_t(j) = \left[\sum_{i=1}^N \alpha_{t-1}(i) a_{ij} \right] b_j(\mathbf{o}_t)$$

(3) 终止: $P(\mathbf{o}|\lambda) = \sum_{i=1}^N \alpha_T(i)$



前向概率计算示意图


计算量为 N^2T ,
当 $N=5, T=100$ 时,
只需 2500 次乘法运算

模型概率计算——后向算法 (backward algorithm)

(掌握)

后向变量: $\beta_t(i) = P(\mathbf{o}_{t+1}\mathbf{o}_{t+2} \cdots \mathbf{o}_T | q_t = i, \lambda)$

定义: 从时刻 $t+1$ 开始到 T 为止部分观测序列为 $\mathbf{o}_{t+1}, \mathbf{o}_{t+2}, \dots, \mathbf{o}_T$, 且状态为 i 的概率。



后向概率计算示意图

模型概率计算 —— 后向算法 (续)

(掌握)

后向算法:


(1) 初始化: 对 $1 \leq i \leq N$, 有

$$\beta_T(i) = 1$$

(2) 递推: 对 $t = T - 1, T - 2, \dots, 1, 1 \leq i \leq N$, 有

$$\beta_t(i) = \left[\sum_{j=1}^N \beta_{t+1}(j) a_{ij} b_j(\mathbf{o}_{t+1}) \right]$$

(3) 终止: $P(\mathbf{O}|\lambda) = \sum_{i=1}^N \pi_i b_i(\mathbf{o}_1) \beta_1(i)$



后向概率计算示意图

计算量为 $N^2 T$ 数量级

模型解码问题的描述（基本概念）

■ 最佳状态序列的确定

确定一个最佳状态序列 $\mathbf{Q}^* = q_1^*, q_2^*, \dots, q_T^*$, 使 $P(\mathbf{O}, \mathbf{Q}^* | \lambda)$ 为最大。

$$\mathbf{Q}^* = \underset{\mathbf{Q}}{\operatorname{argmax}} P(\mathbf{O}, \mathbf{Q} | \lambda)$$

定义 $\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1 q_2 \dots q_{t-1}, q_t = i, \mathbf{o}_1 \mathbf{o}_2 \dots \mathbf{o}_t | \lambda)$ 为时刻 t 时沿着一条路径 $q_1 q_2 \dots q_{t-1}$, 且 $q_t = i$, 产生 $\mathbf{o}_1 \mathbf{o}_2 \dots \mathbf{o}_t$ 的最大概率。

如何求解最佳状态序列 $\mathbf{Q}$?

解决思路: Viterbi 算法

Viterbi算法（基本概念）

求取最佳状态序列 Q^* 的过程为


(1) 初始化: 对 $1 \leq i \leq N$, 有

$$\begin{aligned}\delta_1(i) &= \pi_i b_i(\mathbf{o}_1) \\ \varphi_1(i) &= 0\end{aligned}$$

(2) 递推: 对 $2 \leq t \leq T, 1 \leq j \leq N$, 有

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(\mathbf{o}_t)$$

$$\varphi_t(j) = \operatorname{argmax}_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}]$$




Viterbi算法（续）（基本概念）

求取最佳状态序列 Q^* 的过程为

(3) 终止:

$$P^* = \max_{1 \leq i \leq N} [\delta_T(i)]$$

$$q_T^* = \operatorname{argmax}_{1 \leq i \leq N} [\delta_T(i)]$$



(4) 路径回溯, 确定最佳状态序列:

$$q_t^* = \varphi_{t+1}(q_{t+1}^*), t = T - 1, T - 2, \dots, 1$$

最终得到最佳状态序列 Q^* 以及所对应的概率 P^*

高斯混合模型（续）（基本概念）

- 对于M个高斯模型的混合模型， c_m 是观测数据属于第m个子模型的先验概率（混合权重），则高斯混合模型的概率分布为：

$$P(\mathbf{x}|\theta) = \sum_{m=1}^M c_m N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m)$$

$$N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m) = \frac{1}{(2\pi)^{D/2}(\boldsymbol{\Sigma}_m)^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_m)^T \boldsymbol{\Sigma}_m^{-1}(\mathbf{x} - \boldsymbol{\mu}_m)\right\}$$

其中， $\sum_{m=1}^M c_m = 1$ ， $N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m)$ 是第m个子模型的高斯分布密度函数。

高斯混合模型（续）（基本概念）

- 在语音处理中，我们通常用连续的概率密度函数来描述连续的观察值向量（ $\mathbf{o}_t$ ）的概率分布。混合高斯模型是其中应用最成功的、最广泛的概率密度函数，若用混合高斯模型（GMM）来表示 $\mathbf{o}_t$ 的概率分布

$$b_i(\mathbf{o}_t) = \sum_{m=1}^M \frac{c_{i,m}}{(2\pi)^{D/2} |\boldsymbol{\Sigma}_{i,m}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{o}_t - \boldsymbol{\mu}_{i,m})^T \boldsymbol{\Sigma}_{i,m}^{-1} (\mathbf{o}_t - \boldsymbol{\mu}_{i,m}) \right\}$$

其中， $c_{i,m}$ 是状态*i*时第*m*个高斯子模型的权重， $\boldsymbol{\mu}_{i,m}$ 和 $\boldsymbol{\Sigma}_{i,m}$ 为状态*i*时第*m*个高斯分布的均值向量和协方差矩阵。

N-gram语言模型（基本概念）

- 单词序列

$$w_1^n = w_1 \dots w_n$$

- 概率的链式法则

$$P(w_1^n) = P(w_1)P(w_2 | w_1)P(w_3 | w_1^2) \dots P(w_n | w_1^{n-1}) = \prod_{k=1}^n P(w_k | w_1^{k-1})$$


- N-gram近似

$$P(w_1^n) = \prod_{k=1}^n P(w_k | w_{k-N+1}^{k-1})$$


假设词 w_k 出现的概率只与前 $N-1$ 个单词有关：N-1阶马尔可夫模型

基于HMM的语音识别与语音合成（基本概念）

语音识别



语音合成



训练阶段

$$\hat{\Lambda} = \arg \max_{\Lambda} P(L|O, \Lambda)$$


$$\hat{\Lambda} = \arg \max_{\Lambda} P(O|L, \Lambda)$$

O: 声学特征; L: 文本信息


HMM的模型训练（Baum-Welch算法: 最大期望算法的快速实现）：
参考4.2节（语音识别-HMM声学模型）

基于HMM的语音识别与语音合成（续）（基本概念）

语音识别



语音合成



解码阶段


$$\hat{L} = \arg \max_L P(O = o | L, \Lambda)$$

$$\hat{O} = \arg \max_O P(O | L = l, \Lambda)$$

HMM的解码算法（基于动态规划算法的Viterbi算法）：

参考（语音识别-HMM声学模型）

基于HMM语音合成系统框架（基本概念）



■ 训练流程

1. 数据处理，提取文本特征与声学参数
2. 模型训练
训练数据：
<文本特征, 声学参数>
训练过程：
 - a) 单音素训练
 - b) 上下文相关HMM训练
 - c) 决策树聚类
 - d) 聚类后模型训练

■ 合成部分

1. 文本处理，得到输入文本特征
2. 基于似然最大化准则通过HMM生成声学参数
3. 利用声码器将声学参数转换为最终语音

HMM语音合成的训练阶段（了解）

简单模型
(数据充足)




复杂模型
(数据不足)




聚类复杂模型
(解决过拟合)

HMM的训练算法一致





方差下限估计（了解）

- 由于上下文属性可能的组合远大于训练数据的数目，模型方差接近零。
- 为了避免方差过于接近零，需要预先设定一个方差的下限。
- 对于不同的参数需要设定不同的方差下限。




单音素模型训练（了解）

- 对所有的单音素HMM进行初始化和训练。
- 得到的模型用于进行上下文相关模型的扩展和初始化。



单音素模型训练（续）（了解）

- 模型训练方法：Baum-Welch算法。
- Baum-Welch算法的理论基础是EM算法。
- 与语音识别相同。




定义辅助函数

$$Q(\bar{\lambda}, \lambda) = \sum_Q P(Q, O | \lambda) \log P(Q, O | \bar{\lambda}).$$

上下文相关HMM训练（了解）



- 考虑不同的上下文对语音合成的影响。
- 上下文环境：
 - 前后音素
 - 韵律边界（词、短语、句子）



上下文相关HMM训练（续）（了解）


■ 考虑前后音素的上下文

/l-c+r/表示：
左边音素-中间音素+右边音素





基于决策树的HMM聚类（了解）

- 模型的参数在训练后产生过拟合现象。
- 为了消除样本过少的问题，使得HMM的鲁棒性与数据量达到一个均衡状态。




基于决策树的HMM聚类（了解）




聚类后HMM训练（了解）

- 与单音素HMM、上下文相关HMM训练相同。
- 基于Baum-Welch算法。



基于传统信号处理的语音增强算法流程（基本概念）




- 基于传统信号处理的语音增强系统的目标就是抑制增益，而抑制增益依赖于两个核心步骤：静音检测（VAD）和噪声估计模块。只有准确估计噪声谱才有可能准确估计抑制增益，通常会利用VAD来进行噪声估计。

基于映射的语音增强的框架（掌握）


■ 基于映射的语音增强

- 相对传统的谱减法、维纳滤波器等方法效果有了极大的提升
- 对非平稳噪声有很好的抑制作用



基于映射的语音增强系统示意图

基于映射的语音增强的主要步骤（掌握）



- **训练：** 利用STFT将含噪音频和干净音频提取语谱图特征，前者为训练的输入后者为训练的目标。利用深度学习进行含噪语谱图到干净语谱图的非线性映射，训练非线性函数并保存模型。
- **增强：** 将含噪音频的语谱图输入到训练好的模型，可以得到干净音频特征。将干净的语谱图和原始的相位进行ISTFT变换得到重建后的去噪后的音频。

基于映射的语音增强的主要步骤（掌握）

■ 训练：


- **特征提取**：利用STFT将含噪音频和干净音频提取语谱图特征，前者为训练的输入后者为训练的目标。
- **模型训练**：利用深度学习进行含噪语谱图到干净语谱图的非线性映射，训练非线性函数并保存模型。

■ 增强：

- **特征提取**：利用STFT提取含噪音频的语谱图特征。
- **特征增强**：将含噪音频的语谱图输入到训练好的语音增强模型，估计干净音频特征。
- **信号重构**：将干净语音语谱图的估计值和原始的相位进行ISTFT变换得到重建后的增强语音。


波束形成的基本思路（基本概念）

- 对各个麦克风单元接收到的语音信号进行加权求和，该加权系数决定了语音增强的效果。
- 通过调整加权系数，达到对目标声源方向的增强以及对其他干扰方向的抑制的效果，使得整个麦克风阵列对目标方向形成聚焦。



语音增强的技巧：多目标训练（基本概念）


- 很难断定那种方法(基于映射或基于掩蔽)更好，尤其在噪音脚本不可见的情况下。
- 在不同的SNR水平下，映射和掩蔽框架之间有很强的互补性。



多目标训练结构示意图

基于多任务学习的语音增强（基本概念）

- 语音的其他任务可以作为增强任务的互补信息，为其提供丰富的语义或者说话人信息。
- 多任务学习能够利用不同任务的信息进行语音增强。
- 增强的语音对语音识别、说话人识别（ASV: Automatic Speaker Verification）或者其他任务的性能提升也有帮助。




多任务学习示意图

GMM-UBM识别（基本概念）

- 说话人验证（Verification）任务可以被转换为以下两项的似然比测试：
 - 零假设， H_0 ：测试段 Y 来自假设说话人；
 - 备择假设， H_1 ：测试段 Y 不是来自假设说话人。

$$\Lambda(Y) = \log \frac{p(Y|H_0)}{p(Y|H_1)} \approx \log \frac{p(Y|\theta_{\text{spk}})}{p(Y|\theta_{\text{UBM}})} = s(Y|\theta_{\text{spk}}) - s(Y|\theta_{\text{UBM}})$$



[Source: Reynolds et al, 2000]

GMM-UBM识别（续）（基本概念）

- 给定测试段和说话人模型 θ 的对数似然相似度：

$$s(Y|\theta) = \frac{1}{T} \sum_{t=1}^T \log p(\mathbf{y}_t|\theta) = \frac{1}{T} \sum_{t=1}^T \log \underbrace{\sum_{k=1}^K w_k \mathbf{N}(\mathbf{y}_t|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}_{\text{Speaker GMM or UBM}}$$