




语音信息处理综合实践

天津大学 人工智能学院

王 龙标

王 晓宝

课程信息

- 课程名称：语音信息处理综合实践
- 实践周数：累计1.5周（集中+分组实践；8学时/天）
- 主要先修课程：语音信息处理、自然语言处理
- 成绩考评
 - 平时成绩（平时汇报、出席）：20%
 - 实验与课程设计（最终汇报、实践报告）：80%

建议参考书

- 《语音信号处理理论与实践》高等教育出版社（2024年出版）王龙标主编；党建武、于强编



- 《听觉信息处理前沿研究》上海交通大学出版社（2021年出版）党建武、俞凯编



- 《语音信号处理（第3版）》清华大学出版（2019年出版）韩纪庆、张磊、郑铁然 编著

其它资料

- 《语音信息处理综合实践》整体说明
 - 《语音信息处理综合实践》技术文档
 - 《语音信息处理综合实践》课件
-
- 《语音信息处理》实验教学方案
 - 《语音信息处理》实验环境准备和操作指南
 - 《语音信息处理》课件

本实践课程的主题与目的

■ 主题

- 综合利用语音识别、合成与对话方法，实现基于树莓派的语音交互系统。

■ 目的

- 实践内容将贯通《语音信息处理》课程的主要内容，包括语音识别、语音合成、自然语言对话、副语言信息感知。基于树莓派实现一个软硬件结合的语音交互系统，将本课程所学的理论知识以及实践操作结合，并融会贯通到实际应用中。

本实践的基本内容

■ 语音识别

- 掌握语音唤醒、单词识别、连续语音识别的基本算法并基于开源框架实现基础系统，进而针对不同场景进行模型优化。

■ 语音合成

- 掌握面向语音合成的前端处理、声学模型及声码器的基本算法，基于开源框架实现基础系统并进行模型优化。

本实践的基本内容（续）

■ 语音副语言信息感知

- 掌握广义语音副语言信息感知（如语音情感识别、情绪识别，以及说话人身份、属性等非语言信息识别）的基本算法并基于开源框架实现基础系统，进而结合语音识别结果实现语音理解。

■ 自然语言对话

- 掌握自然语言对话的基本算法并实现基础对话系统，并结合语音识别、副语言信息感知、语音理解与语音合成模块搭建语音对话系统。

实验设备



笔记本电脑



RaspBerry 4 Pi



ReSpeaker 6-Mic



麦克风(USB口)



喇叭(USB口)

- 笔记本电脑：用于连接树莓派，并远程登陆树莓派实现对树莓派系统的操控；
- RaspBerry 4 Pi：树莓派，用于安装Linux系统（资源有限）并在系统上实现语音交互；
- ReSpeaker 6-Mic：麦克风阵列，树莓派本身没有输入系统，需要用到声卡；
- 麦克风(USB口)：用于音频录入；
- 喇叭(USB口)：用于音频输出。

基于树莓派的语音交互

1. 烧系统：给树莓派安装一个Linux系统；
2. 配置环境：在安装好的系统上安装语音交互所需的环境，主要包括python环境、pytorch深度学习框架、python依赖包等；
3. 跑通各个模块的解码测试，初步实现语音到文本（语音识别）、语音到情感（副语言信息感知）、自然语言处理（对话/系统）、文本到语音（语音合成）的转换功能；
4. 进一步优化各个模块的测试准确率，提升语音交互的性能。

实践模式

■ 分组开展课程设计

- 完成基本功能的基础上独立选题，独立设计，撰写设计方案，绘出系统设计方案图，分组汇报及答辩。

■ 分组

- 5-6人（包含1名组长）/组。
- 每名同学有独立的实践内容，可以涉及单个或者多个模块。

要求

- 在树莓派上实现语音识别、副语言信息感知、自然语言对话、语音合成的各功能模块。
- 在树莓派上实现语音对话整体系统。
- 可以在个人笔记本电脑上的虚拟平台训练、微调模型。
- 最后一天分组做整体实践汇报（包括系统设计图等）。在规定的时间内每位同学提交一份实践报告，并附加文件（可执行程序及所有的源代码、演示的demo的视频）。

能力培养和考察

- 能够应用专业知识，研究、分析现有语音信息处理算法中存在的问题。
- 能够根据实际要求，提出相应的语音信息处理解决方案，包括特征分析、算法选择、性能评价及结果解释。
- 能够根据经典算法中存在的问题，设计新的算法，提升逻辑思维能力和想象力。
- 能够根据系统设计与研究，撰写设计方案、能够清晰的进行陈述发言表达自己的设计思想。
- 具有团队合作意识，能够在团队中承担个体、团队成员的角色，可以与他人进行沟通和交流。

本实践的集中实践日历

- 12月3日 5-8节（介绍实践内容、发放硬件及软硬件调试）
- 各组自主协调时间（初步方案讨论）
- 12月13日 5-8节（汇报初步方案及进展情况）
- 各组自主协调时间（初步完成各功能模块）
- 各组自主协调时间（完善各功能模块及优化）
- 12月20日 5-8节（汇报最终方案及进展情况）
- 各组自主协调时间（系统联调及优化）
- 各组自主协调时间（系统联调及优化、最终结果汇报准备）
- 12月26日 5-8节（最终结果汇报（包括系统演示））

12月3日：47楼第三机房

12月13日、20日：47楼第八机房

12月26日：47楼第二机房

最终汇报

■ 汇报时间及地点

- 25年12月26日 13: 30-17: 30
- 47教学楼第二机房

■ 汇报方式

- PPT汇报，12月25日24: 00前通过e-mail提交含演示视频的PPT。
- 每个小组：8分钟汇报时间（包含2分钟左右的演示视频）+4分钟提问。
- 原则上所有同学都需要现场汇报自己的实践内容，因生病等特殊原因无法到场的需要提前请假并录制视频介绍本人的实践内容。

实践报告

■ 提交内容

- 每个小组提交一份小组整体实践报告，含附加文件（可执行程序及所有的源代码、演示的demo的视频等）
- 每位同学提交一份个人实践报告
- 参考整体实践报告模板以及个人实践报告模板

■ 提交时间及方式

- 时间：26年1月4日24：00前
- 方式：电子邮件

- 
- **人机交互概念**
 - **语音交互系统基本概念**
 - **语音交互系统的典型框架**

人机交互

- 人机交互是关于设计、评价和实现供人们使用的交互式计算机系统，且围绕这些方面的主要现象进行研究的科学。

（ACM SIGCHI, 1992, 第6页）



Automated teller machine

- 人机交互是一门研究系统与用户之间的交互关系的学问。系统可以是各种各样的机器，也可以是计算机化的系统和软件。人机交互界面通常是指用户可见的部分。用户通过人机交互界面与系统交流，并进行操作。（维基百科）

多模态人机交互系统

- Turing OS机器人操作系统将机器人与人的交互模式定义为“多模态交互”，即通过文字、语音、视觉、动作、环境等多种方式进行人机交互，充分模拟人与人之间的交互方式。。




声学交互



手势控制




触摸感知



动作交互


车载人机交互示例

- “Nio NOMI”是一款具有情感的人工智能伴侣，同时布置于车辆的前排及后排，它不仅自主处理车辆本身的使用需求，还可持续学习用车人的习惯与兴趣，根据驾驶和生活场景来满足每个人的需求。



- 
- 人机交互概念
 - 语音交互系统基本概念
 - 语音交互系统的典型框架


语音交互系统



自然语言处理：任务型对话/开放域闲聊对话（人机交互）
检索式问答/生成式问答（人机交互）
机器翻译（人人交互）

言语链与人机语音交互（回顾）

*任务型对话系统



ASR: 语音识别（对应人的语音感知）


TTS: 语音合成（对应人的语音生成）

Speaker Recognition: 说话人识别/声纹识别


语音识别-声学模型

从GMM-HMM到端到端模型


1990s-2009: The GMM-HMM hybrid system. (CU-HTK)



2009-2019: The DNN-HMM hybrid system. (JHU-Kaldi, MS-CNTK)




2014: The CTC End-to-End system. (CMU-EESEN, Baidu-WarpCTC)




2016: The Encoder-Decoder End-to-End system.

(Google-LAS/Transformer, facebook-wav2letter, JHU-ESPNet)




2023-Now: Speech Large Language Model

语音识别系统



Conformer



Wenet

其他ASR系统：Paraformer、Zipformer、FunASR等

开放域闲聊对话系统

检索式方法

- 从候选回复中选择恰当的一项；



- 流畅且有信息量的回复
- 容易实施
- 依赖于给定的候选回复

生成式方法

- 利用自然语言生成技术得到回复；



- 灵活的
- 安全回复问题
- 需要更多的数据资源

对话历史



Where do you **live** and what is something you are **doing** today?


I live in **Mongolia** and I will be **making some good sandwiches** today.

端到端对话框架（生成式）

语音合成-端到端声学模型Tacotron2

Tacotron2系统 (Shen et al, 2018) 包括两个组成部分:

- (1) 结合注意力机制的循环序列到序列特征预测网络, 用于从输入字符串预测梅尔谱参数帧序列。
- (2) WaveNet的改良版, 基于预测的梅尔谱参数帧产生语音的时域波形。



Tacotron 2系统架构框图

其他TTS系统: FastSpeech2、GPT-SoVITS等

- 
- 人机交互概念
 - 语音交互系统基本概念
 - 语音交互系统的典型框架

企业典型交互系统：阿里小蜜

无线端多领域私人助理，依托于客户真实的需求，通过智能+人工的方式提供客户良好的购物体验服务。主要提供：

- 助手服务(assistance service)
- 用户服务(customer service)
- 聊天服务(chatting service)




(a) Assistance Service



(b) Customer Service



企业典型交互系统：阿里小蜜



阿里云智能对话平台文档中的智能语音交互系统架构图

企业典型交互系统：阿里小蜜


- 通过对话管理系统的控制，面向不同的领域场景采用不同的领域技术
- QA Bot：通过知识图谱、传统IR以及DeepMatch的方法完成知识问答的匹配
- Task Bot：面向多领域技术完成任务型对话构建与问答
- Chat Bot：完成闲聊机器人的问答
- Rec Bot：完成推荐机器人的问答体系构建
- MC Bot：在文档无法结构化的场景下（例如淘宝或者商家的活动场景），通过Machine Reading的方法来完成问答

企业典型交互系统：微软小冰




- 设计理念：让机器人具备 IQ + EQ + Personality 的能力
- IQ是智商，指能做很多事，有很多技能。
- EQ是情商，主要指对话答复要考虑到对方的情绪和兴趣，也即常说的“会聊天”。用户难过就要安慰鼓励他，高兴就要陪着高兴。
- Personality是指小冰的答复要符合小冰的人设。小冰的人设是可靠、有同情心、有爱心、有幽默感的18岁少女。所以她说的话不能偏离这个人设。

企业典型交互系统：微软小冰



微软小冰系统结构


企业典型交互系统：微软小冰



微软小冰人机交互架构

企业典型交互系统：微软小冰

- 小冰的能力包含两大块：
核心闲聊（Core Chat） 和 **各类技能（Skills）**。
核心闲聊就是一般的闲聊（开域聊天）。而技能是小冰在某些方面的能力，如天气咨询、讲笑话、看图作诗等等。




微软小冰人机交互架构

- DM是对话管理模块，而IQ则是小冰的各种技能库。DM决定当前query交给IQ中的哪个技能处理，对应的技能产生答复返回给用户。

语音交互：从小模型到大模型

语音包含语言、韵律、情感和说话人等信息

- 传统语音交互：多个小模型
- 语音交互大模型：统一处理语音感知、认知与生成的多个任务



语音大模型概述

能听:


将语音信号
转换成文本

会言:

基于输入信息
生成语音反馈


善理解:

结合输入生成相
应的反馈内容




Whisper

语音感知大模型



Encodec+VALL-E

语音生成大模型



QwenLM

语音交互大模型

语音预训练大模型概述

能听:


将语音信号
转换成文本

会言:

基于输入信息
生成语音反馈


善理解:

结合输入生成相
应的反馈内容




从海量无标注的语音数据中学习语音的通用表征
希望被应用到感知、生成和交互任务

语音自监督预训练大模型发展趋势





- 相比于监督/弱监督预训练，自监督预训练能更充分地利用网络上海量的无标注数据。
- 自监督预训练模型的表征通常是更加通用的。

语音感知大模型




语音生成大模型



Encodec+VALL-E

合成/克隆语音的表现力远超传统的基于深度学习的语音合成的效果。

语音交互大模型



语音感知与生成大模型例子 (FunAudioLLM)

FunAudioLLM: Voice Understanding and Generation Foundation Models for Natural Interaction Between Humans and LLMs

FunAudioLLM: 人类与LLMs之间自然交互的语音理解和生成基础模型

[\[Paper\]](#) [\[Code\]](#) [\[Modelscope: SenseVoice CosyVoice\]](#) [\[HuggingFace: SenseVoice CosyVoice\]](#)

[\[论文\]](#) [\[代码\]](#) [\[Modelscope: SenseVoice CosyVoice\]](#) [\[HuggingFace: SenseVoice CosyVoice\]](#)

Tongyi Speech Team 通义演讲团队

Alibaba Group 阿里巴巴集团

Abstract: This report introduces **FunAudioLLM**, a framework designed to enhance natural voice interactions between humans and large language models (LLMs). At its core are two innovative models: **SenseVoice** for high-precision multilingual speech recognition, emotion recognition, and audio event detection; and **CosyVoice** for natural speech generation with multi-language, timbre, and emotion control.

摘要: 本报告介绍了 FunAudioLLM, 这是一个旨在增强人类与大型语言模型 (LLMs) 之间的自然语音交互的框架。其核心是两个创新模型: SenseVoice, 用于高精度多语言语音识别、情感识别和音频事件检测; CosyVoice 用于自然语音生成, 具有多语言、音色和情感控制。

SenseVoice delivers exceptionally low latency and supports over 50 languages, while CosyVoice excels in multi-lingual voice generation, zero-shot voice generation, cross-lingual voice cloning, and instruction-following capabilities.

SenseVoice 提供极低的延迟并支持 50 多种语言, 而 CosyVoice 则在多语言语音生成、零样本语音生成、跨语言语音克隆和指令跟随功能方面表现出色。

The models related to SenseVoice and CosyVoice have been open-sourced on Modelscope and Huggingface, along with the corresponding training, inference, and fine-tuning codes released on GitHub.

SenseVoice 和 CosyVoice 相关模型已在 Modelscope 和 Huggingface 上开源。相应的训练、推理和微调代码也在 GitHub 上发布。

By integrating these models with LLMs, FunAudioLLM enables applications such as speech translation, emotional voice chat, interactive podcasts, and expressive audiobook narration, thereby pushing the boundaries of voice interaction technology.

通过将这两个模型与 LLMs 集成, FunAudioLLM 支持语音翻译、情感语音聊天、交互式播客和富有表现力的有声读物旁白等应用, 从而突破了语音交互技术的界限。

语音感知大模型: SenseVoice
语音生成大模型: CosyVoice/CosyVoice2

语音交互大模型例子 (GPT-4o)



语音交互大模型例子 (Qwen3-Omni)

