注意力机制在图像识别中的应用研究

摘要

随着人工智能的快速发展，人工智能算法被广泛应用在生活中各个方面，其中在计算机视觉领域的算法发展尤为迅速。图像分类问题是计算机视觉中最为常见的问题之一，计算机视觉研究大多围绕这类问题展开。本报告主要研究了不同的主流的注意力机制在图像分类问题中的应用，并比较这些注意力机制的性能，并在此基础上，对这些现有的注意力机制进行改进，以提高性能。

本报告的主要内容为：首先，实现了 SENet、Transformer（ViT）等注意力模型，在CIFAR-10/100和TinyImageNet 数据集上进行测试，通过参数调优，优化模型，通过控制变量实验，分析了参数量、计算开销及分类精度等指标。随后，基于这些现有的模型，对此提出改进，在不显著增加计算量的基础上，提高性能。

关键词— 计算机视觉,图像分类,注意力机制

1. 引言

随着科学技术的不断发展，互联网和通信技术得到广泛应用，极大加快了信息传递的速度和效率。在信息交流过程中，各种图片或视频信息的积累，给信息的存储和处理造成巨大的压力，虽然现有技术发展能够支撑计算机视觉的应用，但是，如果信息大到一定程度，所需的成本是非常高的，会耗费大量财力和时间，这显然是难以接受的。因此，就要从处理数据的算法出发，通过优化算法来达到节约资源，提高效率的目的。

在计算机视觉任务中，处理一张图片时，目的是找到图片中的关键信息，其余信息所起作用很小或者是干扰信息。如果每张图片中的所有信息都受到同等对待进行处理，一旦待处理数据量非常大，所需的资源和时间代价是巨大的。因此，如何定位所给数据中的关键信息就尤为重要。注意力机制就是这样一种算法，注意力机制的作用就是使资源集中在关键有用的区域。

注意力机制原本是指人类视觉系统对信号的一种处理方式。在平时我们用眼睛看东西时，在眼睛视野范围内，首先对全局图像信息进行扫描，找到我们所需的目标，选择性的关注该目标信息而抑制其他我们不感兴趣的图像信息。这种机制的存在，使得在海量信息中，一些重要的有价值的信息能够被人类能够快速锁定，这大大节省资源，提高了提取信息的效率。计算机视觉中的注意力机制借鉴了人类视觉系统对视觉信息的选择性，通过基于注意力机制的深度学习神经网络来选择性的提取输入信息的特征。

当前的注意力模型中，大致可分为通道域注意力，空间域注意力，通道空间混合注意力以及基于Transformer 的自注意力机制。

1.1 空间域

空间注意力机制[3]主要解决图片空间信息不平衡问题。图片中每个区域的像素都表示其特定的特征，但这些不同区域的特征对所要解决问题的重要程度并不相同，那些对解决问题有用的特征才是我们想要的，其他特征可以忽略不计。空间注意力机制就是使网络提取有用的信息，抑制无用信息。空间注意力机制的基本原理是将原始图片做了一个变换，获得权重矩阵，然后对图片中原有空间信息和权重矩阵进行一定的运算，这样使原图片中的关键信息获得大的权重被保留下来，无关信息获得小的权重被抑制。在注意力机制被提出之前，卷积神经网络中的池化层被用来对图片信息进行压缩，提取关键特征，这样可以减少计算量并使准确性得到增加。但是由于池化方法过于暴力，这样会致使某些有用的关键特征信息丢失。于是，注意力机制这种方法被提出来。

1.2 通道域

通道注意力机制[3]是通过建立特征图各通道间的相互依赖性关系来提升网络的有效性。通过卷积层提取得到的特征图，根据卷积核个数会有多个通道，这些通道间所包含的特征信息共同组成了特征图的整体特征。但是，这些单个通道内的特征信息各自代表不同意义，他们对整体特征的贡献是不同的，因此就会导致这些不同通道的特征对解决任务的重要程度是不一样的。基于通道的注意力机制目的就是给这些不同通道的特征信息分配不同的权重，充分利用关键通道的信息，抑制无用通道的信息。

1.3 空间和通道的混合注意力机制

混合注意力机制，同时使用两种不同的注意力机制，就是既使用了基于空间域的注意力机制也使用了基于通道域的注意力机制。 计算机视觉任务主要是使用深度学习的方法来构造出一个好的模型来解决问题，模型主要是通过 CNN 来提取特征。CNN 虽然能够自动提取输入图像的不同级别的特征，但是，最后只是将特征进行简单机械的融合在一起，而忽略了特征内在的联系。比如，不同层次特征之间的联系，同一层次不同通道特

征之间的联系，同一通道不同空间位置特征之间的联系。基于空间的注意力机制和基于通道的注意力机制可以在一定程度上解决上面某个单一问题，但是，无法同时兼顾几个问题。于是，同时使用基于空间和通道的注意力机制的方法就被提出来解决这些问题。

1.4 自注意力

Transformer 机制[4]彻底突破了传统卷积与局部注意力的设计范式，它基于自注意力对全局注意力建模。与传统注意力通过分支学习权重不同，Transformer 将输入特征视为 token 序列，在图片中就是将图像分割成多个图像块，每个块看作一个 Token，通过查询向量（Query）、键向量（Key）、值向量（Value）的交互，生成每个位置的权重分配，每个 Query 向量会与所有 Token 的 Key 向量计算缩放点积相似度。然后通过 Softmax 将这些相似度转换为概率分布。之后使用得到的注意力权重去加权聚合所有 Token 对应的 Value 向量，生成当前 Query Token 的新表示。

在视觉 Transformer 中[1]，每个图像块 Token 的向量表示同时编码了该局部区域的空间位置信息，从这种意义上看，自注意力机制是一种空间域的注意力机制。

虽然当前论文中已经较多的研究了各种注意力机制以及他们在不同任务和数据集的表现，但是较少的文章进行这些机制的实现方式与有效性进行系统性横向对比，因此本技术报告的主要贡献总结如下：

1) 基于 ResNet18 实现了不同的注意力模型，并对比不同注意力机制的实现方法。

2) 在 CIFAR-10, CIFAR-100, TinyImageNet 数据集上进行对比分析性能。

3) 根据对比分析，提出了一种改进的模型，提交收敛性能。

2. 研究方法

为了评估不同注意力模块的性能增益，并确立一个比较基准，选择恰当的基准模型至关重要，在本报告中，选择 ResNet18，作为基准模型，该模型在深度卷积网络中是较为轻量的网络，在计算效率与性能间取得较好的平衡，便于嵌入注意力模块进行对比实验。

在本节中，将基于 ResNet18 对各个不同的注意力机制进行具体的实现，并在 2.8 节提出一种改进的网络，以加快收敛。

2.1 基准模型实现

残差网络[5]通过残差连接，引入残差学习，将网络层的学习目标从直接映射改为学习残差，可以有效缓解梯度消失的问题。

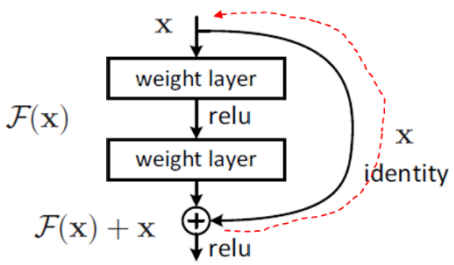

图 2-1 残差块

由图 2-1 所示，残差学习通过跳跃连接，提供一条无参数、无非线性变换的路径，梯度可直接反向传播至浅层，避免因多次连乘导致梯度消失。

此时学习的目标就从拟合直接映射$\mathcal{F}(x)$变为了拟合出残差映射$\mathcal{F}(x)-x$。残差映射往往更容易优化，这也是选择该模型作为基准模型的原因。

残差网络的一个经典案例是 ResNet18，它的一个残差块的构造如下图 2-2，当输入和输出的维度不匹配时，采用 1x1 卷积来调整维度。

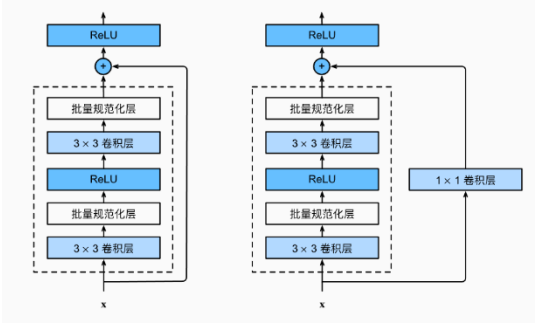

图 2-2 残差块示意图[6]

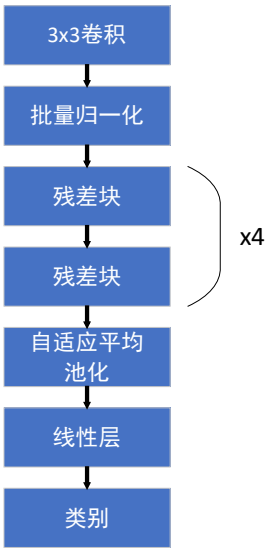

图 2-3 ResNet18 网络结构

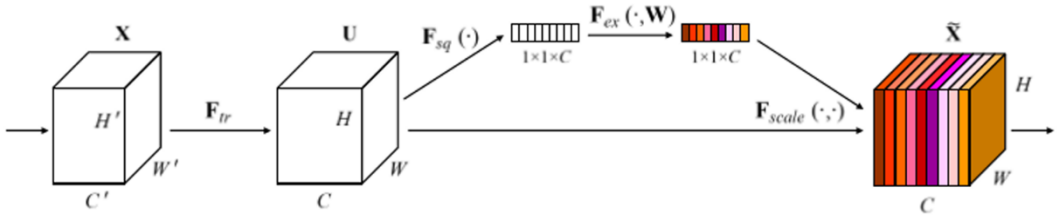

图 2-4 SE 模块结构图

根据 2-2 中的残差快，构造的 ResNet18 基准模型的结构如图 2-3 所示。

2.2 SENet 实现

Hu 等人[7]提出了 SENET，这是一种基于通道域的注意力模型，其结构如图 2-4 所示，其主要思想是通过网络学习特征通道间的权重，使关键特征所在通道得到大的权重，无用特征所在通道得到小的权重，以此来使整个网络模型提取到关键有用的特征，达到更好的效果。

SE Block 的工作流程主要包含三个步骤，即 Squeeze，Excitation 和 Scale，对应图 3-4 中的$\mathcal{F}_{sq}(\cdot)$，$\mathcal{F}_{ex}(\cdot,\mathcal{W})$，$\mathcal{F}_{scale}(\cdot,\cdot)$，其中，Squeeze 操作将输入特征图空间特征进行压缩，将一个通道在整个特征图上的空间信息（HxW）压缩成一个单一的全局描述符，使用全局平均池化。

对于输入特征图 U (形状为 H x W x C，即长，宽和通道数分别为 H，W 和 C)，通过全局平均池化得到一个长度为 C 的向量 Z。其中第 c 个元素 Zc 的计算公式为：

$$\begin{aligned} \mathcal{Z}_c &= \mathcal{F}_{sq}(\mathcal{u}_c) \\ &= \frac{1}{\mathcal{W}\times\mathcal{H}}\sum_{i=1}^{\mathcal{W}}\sum_{j=1}^{\mathcal{H}}\mathcal{u}_c(i,j) \end{aligned} \qquad (2.1)$$

之后是 Excitation 操作，学习通道间的依赖关系并生成权重。基于 Squeeze 步骤得到的全局信息向量 z，学习一个函数，输出一组权重，用来表示每个通道的重要性。这一步使用两个全连接层来实现，具体来说，第一个全连接层将 z（长度为 C）映射到一个更短的维度（长度 C/r）。r 是一个预设的压缩比，用于减小计算量和参数数量。第二个全连接层再将 C/r 的向量映射回原始的通道维度 C。使用 Sigmoid 激活函数将每个输出值限制在 [0, 1] 范围内。最终得到的就是权重向量 S。

最后将权重作用于原输入特征图即可达到最终输出，过程定义为公式（2.2）所示，把权重和原输入特征图像素相乘。

$$\widetilde{X_c} = F_{scale}(u_c, s_c) = s_c \cdot u_c \qquad (2.2)$$

在实际使用过程中 SE 模块可以嵌入到网络中任意合适的位置，例如图 2-5 所示，为 ResNet 中嵌入 SE 模块的方案。其它类似注意力模块也同样可以这样嵌入网络中使用。

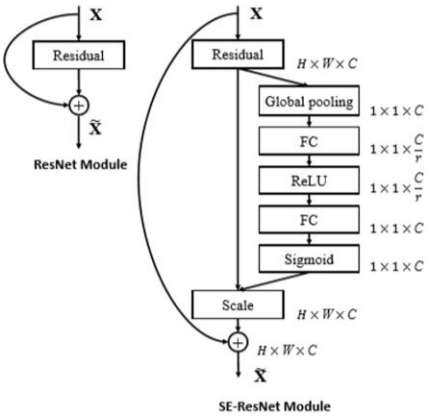

图 2-5 ResNet 中嵌入 SE 模块

然后将基准模型 ResNet18 中的残差块改成嵌入 SE 模块的残差块，就得到了 SEnet，其结构如图 2-6 所示。

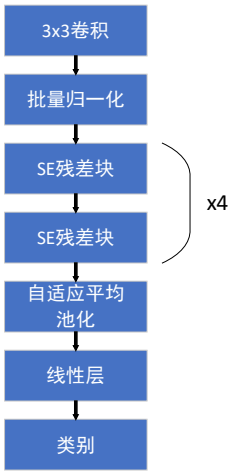

图 2-6 引入 SENet 的 ResNet18

2.3 ECANet 实现

SENet 在 Excitation 阶段使用一个全连接层进行降维，然后再通过另一个全连接层升维。降维操作可能会

破坏通道与其权重之间的直接对应关系，不利于学习有效的通道注意力，并且尽管 SENet 通过参数 r 减少了参数，但在 SE 模块中引入的两个全连接层仍然增加了相当的模型复杂度和参数量，基于此，提出了 ECANet [8]，用一个 1 维卷积代替了两个全连接层，更高效、更轻量，同时提高模型性能。

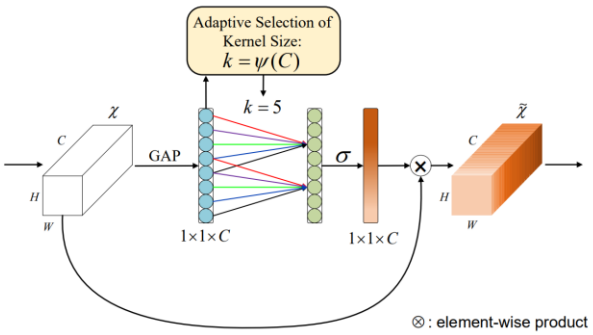

图 2-8 ECANet 模块示意图

在 ResNet18 中引入 ECANet 模块，最后的模型架构和 2.2 节的完全一致，只是将两个全连接改成 1x1 的卷积。

2.4 坐标注意力(CoorAttention)实现

坐标注意力[9]是一种轻量的注意力机制，它通过捕获通道间关系以及长距离的位置信息来增强特征表示。思想是将空间信息分解为两个方向的特征编码。

高度方向，使用自适应平均池化压缩宽度维度，通过 1×1 卷积降维，然后再次使用 1×1 卷积恢复原始通道数并生成注意力图，最后应用 Sigmoid 激活得到高度注意力权重 h_att。

宽度方向，使用自适应平均池化压缩高度维度，并与高度分支共享降维的卷积层，然后恢复原通道的卷积层是独立的，最后生成宽度注意力权重 w_att

最后将原始特征与两个注意力图相乘，即 $identity \times w_{att} \times h_{att}$。

图 2-7 描述了坐标注意力的整个流程，然后将这个模块加入到 ResNet18 中的残差块的后面，得到的网络即为加入该模块的残差网络，如图 2-9 所示。

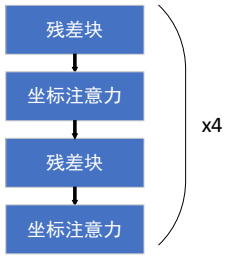

图 2-9 在 ResNet18 中引入坐标注意力

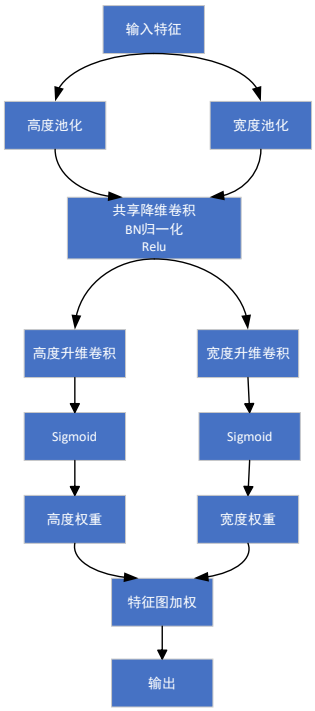

图 2-7 坐标注意力模块

2.6 CBAM 实现

这个模型是一种通道和空间双注意力机制的模块[10]，与前面的 scSE 不同，它采用串行结构依次处理通道和空间维度。在通道注意力方面，与前面的通道 SE 方法相同，而经过通道加权之后，沿通道维度取最大值，沿通道维度取平均值，之后将这两个特征图进行拼接，得到两个通道，对这两个通道应用卷积，输出 1 通道的空间权重，进行加权，由图 2-12 所示。

2.7 ViT 实现

基于自注意力的 Transformer 模型最初是为解决自然语言处理（NLP）领域的问题而提出的，目标为通过自注意力机制建模序列元素间的长距离依赖关系。将这种思想迁移到图像分类领域，一个关键的问题在于如何将二维的图像数据有效地转化为适合 Transformer 处理的序列形式，并合理定义其查询（Query）、键（Key）和值（Value）向量。Vision Transformer (ViT) 模型[11]是这一思想在图像分类任务上最著名的实践之一。

ViT 的策略是将输入图像分割成固定大小的、不重叠的图像块（patches），并将每个图像块线性投影为一个向量，称为 patch embedding 或 token。这些 patch token 按照空间顺序排列，并添加位置编码以保留空间信息。每个 patch token 自身作为序列中的一个元素，通过不同的全连接层独立地生成其对应的 Query、Key 和 Value。 这样，Transformer 的自注意力机制就能在整个图像的所有 patch token 之间建立全局的依赖关系，从而实现图像分类。

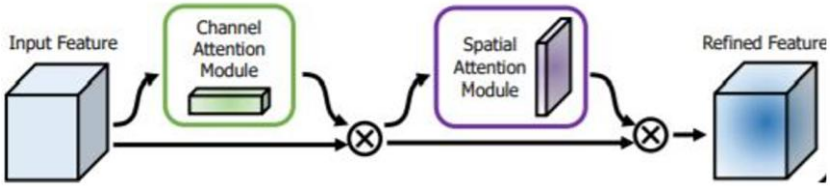

图 2-12 CBAM 模块

具体来说，由图 2-13 所示，首先将图片分割成固定大小的 patch，对于 32x32 大小的图片，patch 的大小为 4x4，对于 64x64 大小的图片，patch 的大小为 8x8，这是一种适中的策略，可以保证不会让 patch 的序列过长，也可以保证对于 32 大小和 64 大小的图片，得到的 patch 序列长度相同，都为 8x8=64，可以在不同大小的输入上保持尽量一致的性能。然后引入一个特殊的 [CLS] token 作为整个序列的分类表示，接下来，通过可学习的参数来表示位置编码，因为图像中的位置关系更复杂。在模型训练时，[CLS] 会与所有 patch 的嵌入一起输入到 Transformer 中，并通过自注意力机制与其他 patch 交互，从而捕获全局信息。最终，将分类 token 的输出使用一个全连接层，得到最后的类别。

在中间的自注意力机制中，使用了深度(n)为 6 的 8 头自注意力，这样设置可以让 ViT 的参数量与 ResNet 相比差别不会过于悬殊。

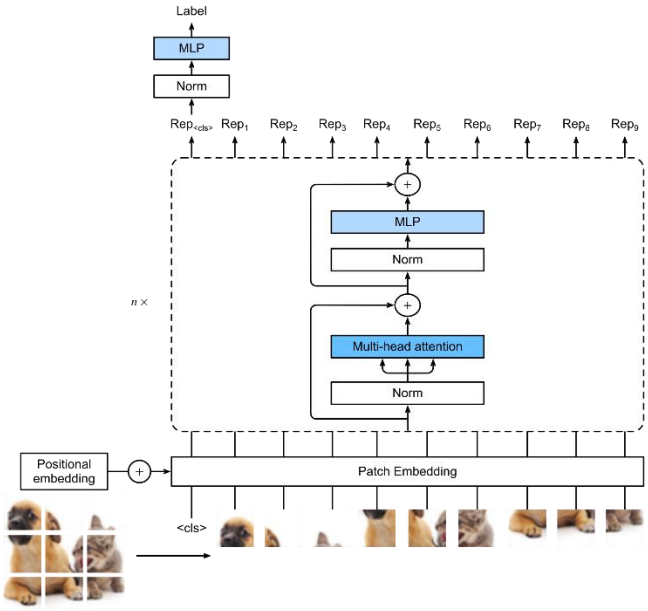

图 2-13 ViT 示意图[6]

2.8 网络的改进

根据第三章中的对比分析，我们发现，因为 CIFAR 数据集图片较小，并且 CIFAR100 数据集的类别更多，从而，对于这个数据集，空间信息更加重要，导致通道注意力效果不佳，我们可以在此基础上，对通道注意力进行改进。

在 CBAM 模块中，作者将通道注意力的思想迁移到了空间上，通过压缩通道上的特征，得到空间注意力权重，我们将采用这种方法，生成空间注意力权重，同时，我们还并行的使用通道注意力，最后将这两个权重同时加权。也就是说，同时使用通道 SE 与空间 SE，两者互补，共同增强特征表示。

在通道 SE 中，使用两次 1x1 卷积来实现，其中第一个卷积减少通道，第二个卷积增加通道；在空间 SE 中，用 1×1 卷积将通道数压缩为 1，变成一个 2 维矩阵，就表示各空间位置的权重，然后这两个分别各自乘以原特征图，并输出。

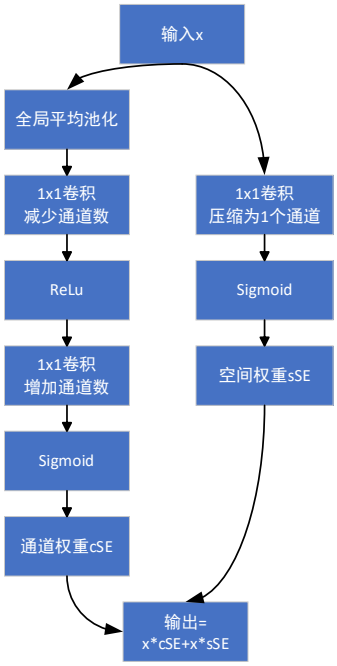

图 2-10 scSE 模块

然后在 ResNet18 中引入该模块，即在每个层后面加入该模块。

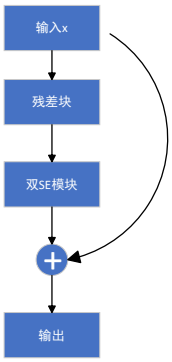

图 2-11 残差-scSE 模块

这样得到的网络既包含了通道注意力，又是对通道注意力的改进，第三章的实验证明，我们的改进是有效的。

3. 实验与结果分析

使用的数据集为 cifar10、cifar100 以及 TinyImagenet。其中，CIFAR-10 包含 10 个 通用物体类别（飞机、汽车、鸟、猫、鹿、狗、青蛙、马、船、卡车），60,000 张微小的 32x32 像素彩色图像，其中 50k 个作为训练；CIFAR-100 与之相比，数据数量相同，但类别变为了 100；Tiny ImageNet 包含 200 个类别，约 120,000 张 64x64 像素彩色图像（每类约 500 张训练 + 50 张验证 + 50 张测试），相比于 CIFAR，要求更高。

由于设备的限制，在本文中，只使用上述的 3 个小型的数据集进行验证，使用这三个数据集，也可以达到本文的目的，即对比不同注意力机制的性能，并验证改进的模型有效性。CIFAR-10/100 是最经典、使用最广泛的小型基准数据集之一，无数的论文都报告了它们在这两个数据集上的结果。Tiny ImageNet 是用来桥接 CIFAR 和标准 ImageNet 难度的数据集，分辨率更高，类别更多，可以更好的评估模型在稍大规模任务上表现。

本实验的平台基于 featurize.cn 上的云算力，具体配置为 GPU，1 块 RTX 4090，共 25.2 GB 显存，CPU，16 核 AMD EPYC 9354，内存 60.1GB。

本实验的内容是，首先在不同数据集上，验证不同初始学习率下的准确率等指标，选出最优指标的准确率，和其他模型进行横向对比，分析性能。

其中，ViT 模型使用 AdamW 优化器，余弦退火调度器以最好的适配该模型；其他加入注意力模块的 ResNet 则使用 Adam 优化器，ReduceLROnPlateau 调度器，其中，mode='max'， factor=0.8， patience=5 以保持一致。

3.1 CIFAR 数据集

在该数据集下，不同的模型参数量、FLOPS 情况如表 3-1 所示。

模型	参数量(M)	FLOPS(G)
ResNet18	11.22	1.1122
ResNet18+SE	11.31	1.1128
ResNet18+ECA	11.22	1.1127
ResNet18+Coor	11.29	1.1137
ResNet18+scSE	11.31	1.1138
ResNet18+CBAM	11.27	1.1130
ViT	18.98	2.5100

表 3-1 不同模型在 CIFAR 下的基本信息

在 CIFAR10 数据集上，训练 100 个 Epoch，进行参数调优，得到的结果如表 3-3 所示，所有注意力变体的 Top1Acc 高于基准模型，注意力机制通过聚焦重要特征，有效增强了模型的特征提取能力，尤其在 Top1Acc 上提升显著。这验证了注意力机制在小型数据集上的适用性。

其中，通道注意力的提升有限，因仅关注通道维度，忽略空间信息，scSE 这样的空间注意力和通道注意力结合的性能最佳，因为它同时优化通道和空间维度，更适合 CIFAR10 数据集，坐标注意力次优，通过捕获空间位置提升特征提取能力，这表明在该数据集上，应用空间注意力可以有效的提升性能。ECA 作为轻量的设计，性能略低于 SE，但参数更少；Coor/scSE 虽然性能较优，但计算开销更高。

ViT 的 Top1Acc 和 Top5Acc 都是较低水平，原因为

（1）ViT 需要大规模预训练数据，CIFAR10 的 60k 图像不足以发挥其优势。

（2）CIFAR10 图像尺寸小（32x32），ViT 的 patch 大小为 4x4，这样的划分可能丢失局部信息。

（3）ViT 训练更复杂，100 Epoch 可能不足。

模型	Top1Acc	Top5Acc
ResNet18	92.74	99.85
ResNet18+SE	93.10	99.80
ResNet18+ECA	93.00	99.81
ResNet18+Coor	93.29	99.84
ResNet18+scSE	93.39	99.87
ResNet18+CBAM	93.01	99.85
ViT	81.33	99.06

表 3-3 CIFAR10 不同模型表现

在超参数调优过程中，观察到 ViT 模型相较于 ResNet18 模型，对初始学习率的设定表现出显著的敏感性。如表 3-4 所示，ViT 模型的性能随初始学习率的微小变动呈现出更大幅度的波动，而其他基于 ResNet18 实现的注意力机制的性能波动与 ResNet18 较为类似。

在 CIFAR100 数据集上，训练 100 个 Epoch，进行参数调优，得到的结果如表 3-5 所示，此时，注意力机制的性能提升不再普遍，仅有 Coord 和 scSE 的 Top1Acc 略高于基准，而 SE 和 ECA 的 Top1Acc 明显低于基准，Top5Acc 在几乎所有注意力变体上均略低于或接近基准。

Top1Acc	Top5Acc	初始学习率	模型
23.48	78.29	0.009	
29.13	90.32	0.003	
73.72	98.34	0.0007	ViT
80.49	99.06	0.0004	
81.33	99.06	0.0002	
92.74	99.82	0.009	
92.69	99.85	0.003	
92.58	99.84	0.0007	ResNet18
92.60	99.85	0.0004	
92.34	99.79	0.0002	
92.24	99.79	0.009	
92.67	99.81	0.003	
92.99	99.80	0.0007	+SE
93.01	99.81	0.0004	
91.62	99.77	0.0002	

表 3-4 不同初始学习率表现

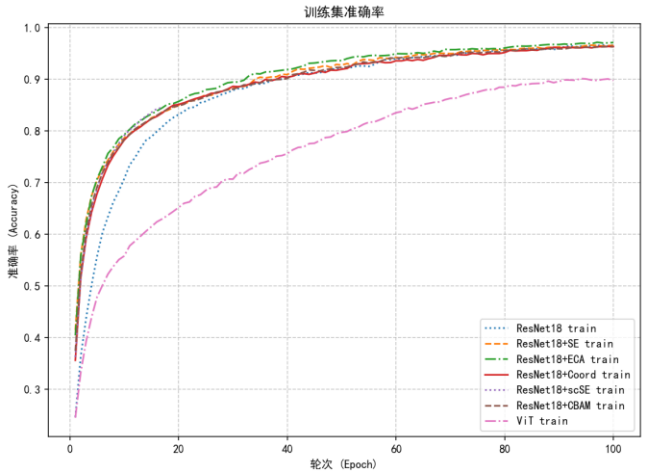

图 3-1 CIFAR10 训练集

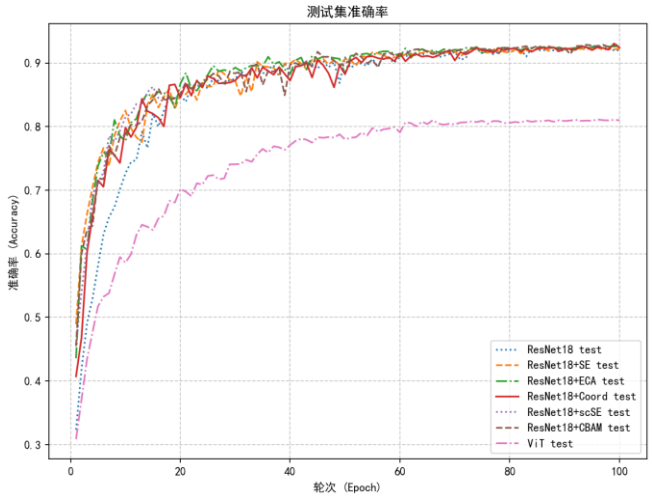

图 3-2 CIFAR10 测试集

注意力机制在 CIFAR100 上效果减弱，主要原因与 CIFAR100 的数据特性、注意力机制的设计以及训练设置相关。

CIFAR100 有 100 个类别，每个类别仅 500 张训练图像，而 CIFAR10 每个类有 6000 张，注意力机制通过添加参数增强了模型容量，但在数据稀缺时，这种额外容量可能放大噪声或无关特征，反而损害泛化能力，例如添加了 SE，ECA 模块反而减弱了性能；CIFAR100 的类别之间差异更小，空间位置信息变得更重要。纯通道注意力注重通道维度，忽略空间关系，在 CIFAR10 中尚可，但在细粒度任务中无法有效提取重要的区域，导致性能下降。相比之下，Coor 和 scSE 结合了空间信息，因此仍能略优于基准。CBAM 略低于基准，表现不如 Coor/scSE，因为它顺序处理通道和空间，可能信息在不断传递过程中损失。

CIFAR100 的各个类别间的差异较小，放大了注意力的缺陷，在数据不足时易导致过拟合或欠拟合，由图 3-3，3-4 所示，尤其对通道注意力。ViT 在小型数据集上始终表现差，CIFAR100 加剧了这一问题，验证了其需要大规模数据和大尺寸图像的假设[11]。

模型	Top1Acc	Top5Acc
ResNet18	69.52	90.79
ResNet18+SE	68.95	89.73
ResNet18+ECA	68.38	90.00
ResNet18+Coor	69.77	90.78
ResNet18+scSE	69.73	90.61
ResNet18+CBAM	69.49	90.46
ViT	54.62	80.21

表 3-5 CIFAR100 不同模型表现

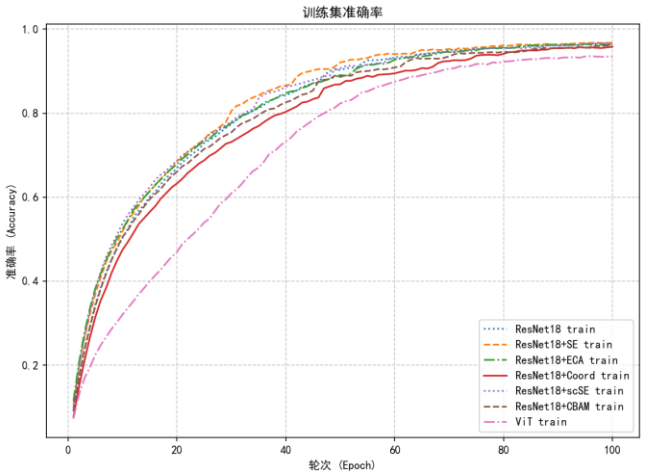

图 3-3 CIFAR100 训练集

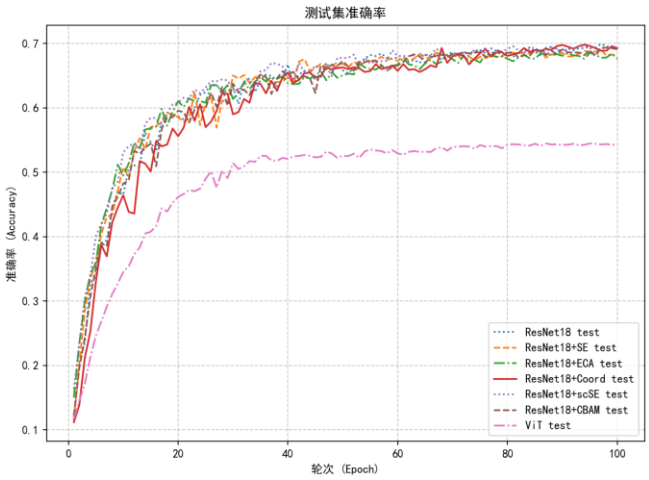

图 3-4 CIFAR100 测试集

3.2 TinyImageNet

在该数据集下，不同模型的参数量、FLOPS 情况如表 3-2 所示。

模型	参数量(M)	FLOPS(G)
ResNet18	11.27	4.4485
ResNet18+SE	11.36	4.4506
ResNet18+ECA	11.27	4.4504
ResNet18+Coor	11.33	4.4526
ResNet18+scSE	11.36	4.4545
ResNet18+CBAM	11.32	4.4516
ViT	19.15	2.5196

表 3-2 不同模型在 TinyImageNet 下的基本信息

模型	Top1Acc	Top5Acc
ResNet18	53.55	77.23
ResNet18+SE	54.04	78.20
ResNet18+ECA	54.35	77.77
ResNet18+Coor	54.06	77.13
ResNet18+scSE	54.86	77.95
ResNet18+CBAM	54.40	77.83
ViT	39.77	65.90

表 3-6 TinyImageNet 不同模型表现

在 TinyImageNet 数据集上，训练 50 个 Epoch，进行参数调优，得到的结果如表 3-6 所示，与 CIFAR10 类似，所有注意力变体都提升了基准模型的 Top1 准确率，这表明在 TinyImageNet 上，注意力机制能够有效提升模型的特征提取能力。虽然 TinyImageNet 的类别更多，但图像尺寸更大，可能提供了更丰富的空间信息，使得注意力机制能够发挥作用。scSE 的 Top1Acc 达到 54.86%，是注意力变体中最好的，这与 CIFAR10 的结果一致。说明同时考虑通道和空间的注意力机制在更复杂的数据集上仍然有效。ECA 作为轻量级通道注意力， Top1Acc 达到 54.35%，仅次于 scSE，且参数量和计算量几乎没有增加，表明 ECA 在保持高效的同时，也能有效提升性能。

ViT 表现最差，原因与之前类似[11]。

4. 结论

本报告系统性地研究并比较了多种主流注意力机制（通道域、空间域、混合域及自注意力）在图像分类任务中的性能表现。通过在 CIFAR-10、CIFAR-100 和 TinyImageNet 数据集上，以 ResNet18 为基准模型进行嵌入实现和对比实验，并基于分析结果提出了改进模型 scSE，得出以下主要结论：

在小型（CIFAR10）和中等规模（TinyImageNet）数据集上，scSE 能显著提升 CNN 模型的性能，同时优化通道和空间维度增强特征提取能力。ECA 以近乎零计算代价实现较稳定的增益，是资源受限场景的最优选择。在更细粒度任务（CIFAR100）中，注意力机制效果受数据规模制约，纯通道注意力因忽略空间信息从而性能降低，而空间-通道融合注意力，例如 scSE/Coord 仍可以有微弱的性能提升。

ViT 在小型数据集上表现大幅落后于 CNN，原因是：

（1）数据规模不足，无法满足预训练需求。

（2）图像尺寸过小，patch 划分丢失局部信息。

（3）训练周期不足，100/50 Epoch 低于 ViT 优化需求。

（4）ViT 对超参数极端敏感，实际应用需要进行较为复杂的调参。

本实验的不足为，训练周期未统一优化，仅有 100 和 50 两种，没有验证更长周期对 ViT 和不同注意力模块的影响；没有探索 Dropout/Weight Decay 等正则化策略对 CIFAR100 过拟合问题的缓解作用；缺乏更大规模数据集的对比，无法验证 ViT 在充足数据下的潜力等。

因此，未来的优化方向可以是，针对 CIFAR100 任务，设计专用于细粒度的注意力模块，以提高性能；探索使用 ImageNet 等大规模数据集预训练的模型进行知识蒸馏，指导在小数据集上训练的轻量级注意力模型或 ViT 变体，提升其泛化能力；研究专门为小规模、低分辨率图像设计的 ViT 变体架构或训练策略。

5. 参考文献

[1] 李玉洁, 马子航, 王艺甫, 王星河 & 谭本英. (2025). 视觉 Transformer(ViT)发展综述. 计算机科学, 52 (01), 194-209.

[2] 陈昶. (2024). 基于注意力机制的图像分类方法研究 (硕士 学位论文, 杭州电子科技大学). 硕士

[3] Guo, M. H., Xu, T. X., Liu, J. J., Liu, Z. N., Jiang, P. T., Mu, T. J., ... & Hu, S. M. (2022). Attention mechanisms in computer vision: A survey. Computational visual media, 8(3), 331-368.

[4] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, *30*.

[5] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).

[6] Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. (2023). *Dive into deep learning*. Cambridge University Press.

[7] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 7132-7141).

[8] Wang, Q., Wu, B., Zhu, P., Li, P., Zuo, W., & Hu, Q. (2020). ECA-Net: Efficient channel attention for deep convolutional neural networks. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 11534-11542).

[9] Hou, Q., Zhou, D., & Feng, J. (2021). Coordinate attention for efficient mobile network design. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 13713-13722).

[10] Woo, S., Park, J., Lee, J. Y., & Kweon, I. S. (2018). Cbam: Convolutional block attention module. In *Proceedings of the European conference on computer vision (ECCV)* (pp. 3-19).

[11] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*.