

3.4 共轭梯度法

由Taylor公式可知：一个函数在某一极小值点附近的性态与一个二次函数很接近. 因此，为了给出有效的算法，往往采用二次模型来尝试，再推广到一般的非线性函数. 本节首先介绍求解凸二次函数

$$f(x) = \frac{1}{2}x^{\top}Gx + q^{\top}x \quad (3.4.1)$$

极小化问题的共轭方向法，其中 $G \in \mathbb{R}^{n \times n}$ 为对称正定矩阵且 $q \in \mathbb{R}^n$ ，然后介绍共轭方向法中非常有效的共轭梯度法. 算法的计算效果介于最速下降法和牛顿法之间，既能克服最速下降法慢的收敛性，又避免了牛顿法计算量大的缺陷.

3.4 共轭梯度法 — 二次函数极小化的共轭方向法

§3.4.1 二次函数极小化的共轭方向法

首先介绍共轭方向的概念及其性质.

定义 3.4.1 设 G 为 n 阶对称正定矩阵, d^0, d^1, \dots, d^{k-1} ($k \leq n$)为 n 维向量组, 如果

$$(d^i)^\top G d^j = 0, \quad \forall i, j \in \{0, 1, \dots, k-1\}, i \neq j,$$

那么, 称向量组 d^0, d^1, \dots, d^{k-1} 关于 G 共轭.

若 $G = I$ 为单位矩阵, 则由共轭向量组的定义, 可以看出: 它们是正交的. 因此, 向量组的共轭性是其正交性的一种推广形式. 下面的定理描述了共轭向量组的性质.

3.4共轭梯度法 — 二次函数极小化的共轭方向法

§3.4.1 二次函数极小化的共轭方向法

首先介绍共轭方向的概念及其性质.

定义 3.4.1 设 G 为 n 阶对称正定矩阵, d^0, d^1, \dots, d^{k-1} ($k \leq n$)为 n 维向量组, 如果

$$(d^i)^\top G d^j = 0, \quad \forall i, j \in \{0, 1, \dots, k-1\}, i \neq j,$$

那么, 称向量组 d^0, d^1, \dots, d^{k-1} 关于 G 共轭.

若 $G = I$ 为单位矩阵, 则由共轭向量组的定义, 可以看出: 它们是正交的. 因此, 向量组的共轭性是其正交性的一种推广形式. 下面的定理描述了共轭向量组的性质.

3.4共轭梯度法 — 二次函数极小化的共轭方向法

定理 3.4.1 设 G 为 n 阶对称正定矩阵. 非零 n 维向量组 d^0, d^1, \dots, d^{k-1} ($k \leq n$)关于 G 共轭, 则

- 向量组 d^0, d^1, \dots, d^{k-1} 线性无关;
- 若 $k = n$, 则向量组 d^0, d^1, \dots, d^{n-1} 构成 \mathbb{R}^n 的一组基;
- 若 $k = n$, 且向量 v 与向量组 d^0, d^1, \dots, d^{n-1} 关于 G 共轭, 则 $v = 0$.

定义 3.4.2 设 n 维向量组 d^0, d^1, \dots, d^{k-1} ($k \leq n$)线性无关, 给定 $x^0 \in \mathbb{R}^n$. 称集合

$$H_k := \left\{ x^0 + \sum_{i=0}^{k-1} \lambda_i d^i \mid \lambda_i \in \mathbb{R}, i \in \{0, 1, \dots, k-1\} \right\}$$

为由点 x^0 与 d^0, d^1, \dots, d^{k-1} 生成的 k 维超平面.

3.4共轭梯度法 — 二次函数极小化的共轭方向法

引理 3.4.1 设 f 为连续可微的严格凸函数, d^0, d^1, \dots, d^{k-1} ($k \leq n$)为一组线性无关的 n 维向量, $x^0 \in \mathbb{R}^n$, 则

$$x^k = x^0 + \sum_{i=0}^{k-1} \hat{\lambda}_i d^i$$

是函数 f 在 x^0 与 d^0, d^1, \dots, d^{k-1} 所生成 k 维超平面 H_k 上的唯一极小值点的充要条件是

$$g_k^\top d^i = 0, \quad \forall i \in \{0, 1, \dots, k-1\}. \quad (3.4.2)$$

3.4共轭梯度法 — 二次函数极小化的共轭方向法

证明 定义函数

$$h(\lambda_0, \lambda_1, \dots, \lambda_{k-1}) := f\left(x^0 + \sum_{i=0}^{k-1} \lambda_i d^i\right).$$

那么,

- (i) $\nabla h(\hat{\lambda}_0, \hat{\lambda}_1, \dots, \hat{\lambda}_{k-1}) = (g_k^\top d^0, g_k^\top d^1, \dots, g_k^\top d^{k-1})^\top$;
- (ii) h 是 k 维空间 \mathbb{R}^k 上的严格凸函数;
- (iii) x^k 是函数 f 在 H_k 上的极小值点当且仅当 $(\hat{\lambda}_0, \hat{\lambda}_1, \dots, \hat{\lambda}_{k-1})^\top$ 是函数 $h(\lambda_0, \lambda_1, \dots, \lambda_{k-1})$ 在 \mathbb{R}^k 上的极小值点.

一方面, 若 x^k 是 f 在 H_k 上的极小值点, 则由定理3.1.1中的(i)可知, $\nabla h(\hat{\lambda}_0, \hat{\lambda}_1, \dots, \hat{\lambda}_{k-1}) = 0$. 这与上述结论(i)相结合可得: (3.4.2)成立.

另一方面, 若(3.4.2)成立, 则由上述结论(i)得 $\nabla h(\hat{\lambda}_0, \hat{\lambda}_1, \dots, \hat{\lambda}_{k-1}) = 0$. 又由上述结论(ii)知: h 是 k 维空间 \mathbb{R}^k 上的严格凸函数. 根据定理3.1.3, 可得 $(\hat{\lambda}_0, \hat{\lambda}_1, \dots, \hat{\lambda}_{k-1})^\top$ 是 h 在 \mathbb{R}^k 上的极小值点. 这与上述结论(iii)相结合可得: x^k 是 f 在 H_k 上的唯一极小值点. 引理得证. \square

3.4共轭梯度法 — 二次函数极小化的共轭方向法

定理 3.4.2 (子空间扩展定理) 设 G 为 n 阶对称正定矩阵, 非零 n 维向量组 d^0, d^1, \dots, d^{k-1} ($k \leq n$)关于 G 共轭, 且二次函数 f 由(3.4.1)式定义. 由任意初始点 x^0 开始, 依次进行 k 次精确一维线搜索, 得

$$x^{i+1} = x^i + \lambda_i d^i, \quad \forall i \in \{0, 1, \dots, k-1\}.$$

那么, x^k 是由(3.4.1)式所定义二次函数 f 在 H_k 上的极小值点.

证明 由引理3.4.1可知: 只需证明(3.4.2)式成立. 因为

$$\begin{aligned} g_k^\top d^i &= g_k^\top d^i - g_{k-1}^\top d^i + g_{k-1}^\top d^i - g_{k-2}^\top d^i + \cdots + g_{i+2}^\top d^i - g_{i+1}^\top d^i + g_{i+1}^\top d^i \\ &= g_{i+1}^\top d^i + \sum_{j=i+1}^{k-1} (g_{j+1} - g_j)^\top d^i, \quad \forall i \in \{0, 1, \dots, k-1\}, \end{aligned}$$

且 $g_{j+1} - g_j = G(x^{j+1} - x^j) = \lambda_j G d^j$, 所以,

$$g_k^\top d^i = g_{i+1}^\top d^i + \sum_{j=i+1}^{k-1} \lambda_j (d^j)^\top G d^i, \quad \forall i \in \{0, 1, \dots, k-1\}. \quad (3.4.3)$$

一方面, 利用精确一维线搜索可得: $g_{i+1}^\top d^i = 0$; 另一方面, 由向量组的共轭性可得: 对任意的 $j \in \{i+1, \dots, k-1\}$ 都有 $(d^j)^\top G d^i = 0$. 因此, 由(3.4.3)式可得(3.4.2)式成立. 定理得证. \square

3.4共轭梯度法 — 二次函数极小化的共轭方向法

算法 3.4.1 (二次函数极小化的共轭方向法)

设二次函数 f 由(3.4.1)式定义. 给定初始点 $x^0 \in \mathbb{R}^n$ 及初始下降方向 d^0 . 计算 g_0 . 如果 $g_0 = 0$, 算法终止. 否则, 置 $k := 0$.

步1 由精确一维线搜索 $f(x^k + \lambda_k d^k) = \min_{\lambda \geq 0} f(x^k + \lambda d^k)$, 计算步长 λ_k .

步2 置 $x^{k+1} := x^k + \lambda_k d^k$.

步3 计算 g_{k+1} . 如果 $g_{k+1} = 0$, 算法终止. 否则, 转步4.

步4 取共轭方向 d^{k+1} , 使对任意的 $i \in \{0, 1, \dots, k\}$ 有 $(d^{k+1})^\top G d^i = 0$.

步5 置 $k := k + 1$, 转步1.

注. (i) 由定理3.4.2知: 使用算法3.4.1求解由(3.4.1)式定义的严格凸二次函数极小化问题时, 至多 n 步迭代可达其极小值点. 因此, 算法3.4.1具有二次终止性. (ii) 算法3.4.1是一个概念性算法, 实现它的关键在于如何选择一组合适的共轭方向. 下一小节介绍一个基于目标函数梯度构造共轭方向的方法, 称之为共轭梯度法.

3.4 共轭梯度法 — 二次函数极小化的共轭梯度法

§3.4.2 二次函数极小化的共轭梯度法

假设二次函数 f 由(3.4.1)定义. 给定初始点 x^0 , 取初始下降方向:

$$d^0 = -g_0.$$

从 x^0 出发, 沿 d^0 进行精确一维线搜索得迭代点 x^1 , 完成第一次迭代. 不妨设 $g_1 \neq 0$, 考虑如何选取共轭方向 d^1 . 定义一维子空间

$$L_1 := \{\beta_0 d^0 \mid \beta_0 \in \mathbb{R}\},$$

将负梯度方向分解成 $-g_1 = u^1 + v^1$, 其中 $u^1 \in L_1$ 且 v^1 与 d^0 关于 G 共轭(由线性代数的知识, 这种分解是存在的). 令 $d^1 = v^1$, 关键在于如何求解 d^1 . 显然, 存在 $\beta_0 \in \mathbb{R}$ 使得 $-u^1 = \beta_0 d^0$. 因此,

$$d^1 = -g_1 + \beta_0 d^0.$$

用 $(d^0)^\top G$ 左乘上式两边, 并且利用共轭性, 可得 $0 = (d^0)^\top G d^1 = -(d^0)^\top G g_1 + \beta_0 (d^0)^\top G d^0$. 于是有

$$\beta_0 = \frac{g_1^\top G d^0}{(d^0)^\top G d^0}, \quad \text{进而 } d^1 = -g_1 + \frac{g_1^\top G d^0}{(d^0)^\top G d^0} d^0.$$

3.4 共轭梯度法 — 二次函数极小化的共轭梯度法

类似递推, 假设已沿 k 个共轭方向 d^0, d^1, \dots, d^{k-1} 进行了 k 次精确一维线搜索, 依次得到迭代点 x^1, x^2, \dots, x^k . 不失一般性, 假设 $g_k \neq 0$, 下面关键在于如何选取共轭方向 d^k . 定义 k ($k > 1$)维子空间

$$L_k := \left\{ \sum_{i=0}^{k-1} \beta_i d^i \mid \beta_i \in \mathbb{R}, i \in \{0, 1, \dots, k-1\} \right\},$$

将负梯度方向分解成

$$-g_k = u^k + v^k,$$

其中 $u^k \in L_k$ 且 v^k 与 L_k 的基 d^0, d^1, \dots, d^{k-1} 关于 G 共轭. 令 $d^k = v^k$, 关键在于如何求解 d^k . 类似于前面的推导, 可得

$$d^k = -g_k + \beta_{k-1} d^{k-1}, \quad \text{其中 } \beta_{k-1} = \frac{g_k^\top G d^{k-1}}{(d^{k-1})^\top G d^{k-1}},$$

并且可以得到下面的结论.

3.4 共轭梯度法 — 二次函数极小化的共轭梯度法

定理 3.4.3 设 G 为 n 阶对称正定矩阵且二次函数 f 由(3.4.1)式定义. 共轭梯度法的迭代方向为由以下公式产生的共轭方向 d^0, d^1, \dots, d^{k-1} ($k \leq n$):

$$\begin{cases} d^0 = -g_0, \\ d^k = -g_k + \beta_{k-1}d^{k-1}, \quad \text{其中 } \beta_{k-1} = \frac{g_k^\top G d^{k-1}}{(d^{k-1})^\top G d^{k-1}}, \quad k > 0, \end{cases} \quad (3.4.4)$$

且迭代步长由精确一维线搜索得到. 则共轭梯度法 $k-1$ ($k \leq n$)次迭代可求得二次函数 f 的极小点, 且对所有的 $i \in \{0, 1, \dots, k-1\}$, 有

- $(d^i)^\top G d^j = 0, g_i^\top g_j = 0, g_i^\top d^j = 0, \forall j \in \{0, 1, \dots, i-1\};$
- $g_i^\top d^i = -g_i^\top g_i.$

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

§3.4.3 一般函数极小化的共轭梯度法

利用迭代方向的校正公式(3.4.4)式和定理3.4.3的结论, 容易得到 β_{k-1} ($k > 0$)的一些等价公式. 以Fletcher-Reeves公式为例, 简单推导如下: 由于

$$Gd^{k-1} = G \left[\frac{1}{\lambda_{k-1}} (x^k - x^{k-1}) \right] = \frac{1}{\lambda_{k-1}} (g_k - g_{k-1}),$$

所以,

$$\begin{aligned} g_k^\top Gd^{k-1} &= \frac{1}{\lambda_{k-1}} g_k^\top (g_k - g_{k-1}) = \frac{1}{\lambda_{k-1}} g_k^\top g_k, \\ (d^{k-1})^\top Gd^{k-1} &= \frac{1}{\lambda_{k-1}} (-g_{k-1} + \beta_{k-2} d^{k-2})^\top (g_k - g_{k-1}) = \frac{1}{\lambda_{k-1}} g_{k-1}^\top g_{k-1}, \end{aligned}$$

故有

$$\beta_{k-1} = \frac{g_k^\top g_k}{g_{k-1}^\top g_{k-1}}.$$

以上公式是Fletcher和Reeves在1964年提出的, 所以称之为Fletcher-Reeves公式, 简称为FR公式.

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

类似的推导,可得到以下三个常用的等价公式:

$$\beta_{k-1} = \frac{g_k^\top (g_k - g_{k-1})}{g_{k-1}^\top g_{k-1}}, \quad (\text{Polak - Ribiere - Polyak公式, 简称为PRP公式});$$

$$\beta_{k-1} = -\frac{g_k^\top g_k}{g_{k-1}^\top d^{k-1}}, \quad (\text{Dixon公式});$$

$$\beta_{k-1} = \frac{g_k^\top g_k}{(g_k - g_{k-1})^\top d^{k-1}}. \quad (\text{Dai - Yuan公式, 简称为DY公式}).$$

虽然FR公式、PRP公式、Dixon公式和DY公式是依据二次函数极小化来推导得出的,但是公式中不显含二次函数的特有特征(如:不含矩阵 G),因此,这些公式常被应用于求解一般非线性函数的极小化问题(3.0.1). 另外,这些公式中主要的计算量只是计算一些向量的乘法,故计算量小,适合于求解大规模无约束优化问题.

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

以求解无约束优化(3.0.1)的FR共轭梯度法为例, 具体算法如下:

算法 3.4.2 (FR共轭梯度法) 设函数 f 由问题(3.0.1)给出. 给定初始点 $x^0 \in \mathbb{R}^n$. 置 $k := 0$.

步1 计算 g_k . 如果 $g_k = 0$, 算法终止. 否则, 转步2.

步2 取

$$d^k = \begin{cases} -g_k, & \text{若 } k = 0, \\ -g_k + \frac{g_k^\top g_k}{g_{k-1}^\top g_{k-1}} d^{k-1}, & \text{否则.} \end{cases}$$

步3 由线搜索计算步长 λ_k .

步4 置 $x^{k+1} := x^k + \lambda_k d^k$ 且 $k := k + 1$, 转步1.

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

注. (i) 在算法3.4.2中, 步长 λ_k 可由精确一维线搜索或非精确线搜索得到. 以下只考虑步长 λ_k 由精确一维线搜索得到的情况. (ii) 如果算法3.4.2中的FR公式被PRP公式、Dixon公式、DY公式来代替, 则分别得到PRP共轭梯度法、Dixon共轭梯度法、DY共轭梯度法. (iii) 采用精确一维线搜索的FR共轭梯度法、PRP共轭梯度法、Dixon共轭梯度法、DY共轭梯度法均为下降算法, 因为它们产生的搜索方向若非零, 则满足

$$\begin{cases} g_k^\top d^k = -g_0^\top g_0 < 0, & \text{若 } k = 0, \\ g_k^\top d^k = g_k^\top (-g_k + \beta_{k-1} d^{k-1}) = -g_k^\top g_k < 0, & \text{否则.} \end{cases}$$

以FR共轭梯度法为例, 其算法的全局收敛性结论如下:

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

定理 3.4.4 设问题(3.0.1)中函数 f 在有界水平集 $\mathcal{L}(f) := \{x \in \mathbb{R}^n \mid f(x) \leq f(x^0)\}$ 上连续可微且有下界, 序列 $\{x^k\}$ 是由采用精确一维线搜索的FR共轭梯度法产生的序列. 如果 $\{x^k\}$ 有限, 那么 $\{x^k\}$ 有限地终止于 f 的一个稳定点; 否则, $\{x^k\}$ 的每个聚点都是 f 的一个稳定点.

证明 不妨假设序列 $\{x^k\}$ 是无限点列. 由于迭代方向 d^k 是下降方向, 结合函数 f 的函数值在水平集上有下界, 因而 $\{f(x^k)\}$ 是单调下降且有下界的序列. 所以, $\lim_{k \rightarrow \infty} f(x^k)$ 存在. 又由于 $\{x^k\} \subseteq \mathcal{L}$ 且 \mathcal{L} 有界, 所以 $\{x^k\}$ 为有界点列, 因而存在收敛子列. 不失一般性, 不妨设 $\lim_{k \rightarrow \infty} x^k = x^*$. 那么由 f 的连续性可知: $\lim_{k \rightarrow \infty} f(x^k) = f(\lim_{k \rightarrow \infty} x^k) = f(x^*)$.

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

下面采用反证法证明 $g_* = 0$. 假设 $g_* \neq 0$. 那么必存在一下降方向 d^* , 使得对任意充分小的 $\lambda_* > 0$, 有

$$f(x^* + \lambda_* d^*) < f(x^*). \quad (3.4.5)$$

而利用精确一维线搜索可知: $f(x^{k+1}) = f(x^k + \lambda_k d^k) \leq f(x^k + \lambda_* d^k)$, 两边取极限可得

$$f(x^*) \leq f(x^* + \lambda_* d^*).$$

这与(3.4.5)式相矛盾. 定理得证. □

进一步, 可以证明: 在定理3.4.4的条件下, 采用精确一维线搜索的FR共轭梯度法所产生的迭代序列线性收敛于目标函数 f 的极小值点.

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

例 3.4.1 采用精确一维线搜索的FR共轭梯度法求解优化问题

$$\min f(x) = \frac{1}{2}x_1^2 + x_2^2,$$

其中初始点取为 $x^0 = (2, 1)^\top$.

解 简单计算可得 $g(x) = (x_1, 2x_2)^\top$. 由于 $g_0 = (2, 2)^\top \neq (0, 0)^\top$, 因而取 $d^0 = (-2, -2)^\top$.

从 x^0 出发沿 d^0 进行精确一维线搜索, 即求解

$$\min f(x^0 + \lambda d^0) = 6\lambda^2 - 8\lambda + 3,$$

得步长 $\lambda_0 = \frac{2}{3}$. 进而, $x^1 = x^0 + \lambda_0 d^0 = (\frac{2}{3}, -\frac{1}{3})^\top$, 且 $g_1 = (\frac{2}{3}, -\frac{2}{3})^\top$. 由FR公式得 $\beta_0 = g_1^\top g_1 / g_0^\top g_0 = \frac{1}{9}$. 从而, $d^1 = -g_1 + \beta_0 d^0 = (-\frac{8}{9}, \frac{4}{9})^\top$.

从 x^1 出发沿 d^1 进行精确一维线搜索, 即求解

$$\min f(x^1 + \lambda d^1) = \frac{1}{162}(96\lambda^2 - 144\lambda + 54),$$

得步长 $\lambda_1 = \frac{3}{4}$. 进而, $x^2 = x^1 + \lambda_1 d^1 = (0, 0)^\top$, 且 $g_2 = (0, 0)^\top$.

因此, 所求问题的最优解为 $x^* = (0, 0)^\top$, 最优值为 $f^* = 0$. \square

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

对于求解严格凸二次函数的极小化问题，FR共轭梯度法、PRP共轭梯度法、Dixon共轭梯度法、DY共轭梯度法都是等价的，但是，对于求解一般非线性函数的极小化问题，这些算法是不同的，并且目标函数的Hesse阵不是常数矩阵，迭代过程中所产生的迭代方向不再是共轭方向了。众所周知：在最优解附近，目标函数与一个严格凸二次函数很接近。因此，当迭代点进入目标函数逼近严格凸二次函数的区域后，如果能及时产生接近于共轭方向的搜索方向，那么算法就能迅速地收敛到最优解。所以，当迭代点进入目标函数逼近严格凸二次函数的区域时，重新取负梯度方向作为搜索方向，那么后面的迭代将产生近似的共轭方向，从而提高算法的效率。基于这一想法，共轭梯度法可修改如下：每迭代 n 次，就重新取负梯度方向作为搜索方向，得到的算法称为 n 步重新开始的共轭梯度法。以采用精确一维线搜索的FR共轭梯度法为例，具体算法如下：

3.4 共轭梯度法 — 一般函数极小化的共轭梯度法

算法 3.4.3 (n 步重新开始的FR共轭梯度法)

设函数 f 由问题(3.0.1)给出. 给定初始点 $x^0 \in \mathbb{R}^n$. 置 $k := 0$.

步1 计算 g_k . 如果 $g_k = 0$, 算法终止. 否则, 转步2.

步2 若 k 是 n 的倍数, 则取 $d^k = -g_k$, 否则, 取

$$d^k = -g_k + \frac{g_k^\top g_k}{g_{k-1}^\top g_{k-1}} d^{k-1}.$$

步3 由精确一维线搜索 $f(x^k + \lambda_k d^k) = \min_{\lambda \geq 0} f(x^k + \lambda d^k)$, 计算步长 λ_k .

步4 置 $x^{k+1} := x^k + \lambda_k d^k$ 且 $k := k + 1$, 转步1.

与共轭梯度法一样, n 步重新开始的共轭梯度法具有全局收敛性和线性收敛速度.

3.4 共轭梯度法 — 作业

3.12 (Gram-Schmidt共轭化) 假设 $G \in \mathbb{R}^{n \times n}$ 为对称正定矩阵. $u^1, u^2, \dots, u^n \in \mathbb{R}^n$ 线性无关. 假设 d^1, d^2, \dots, d^n 由以下方式产生:

$$d^1 = u^1; \quad d^{k+1} = u^{k+1} - \sum_{i=1}^k \frac{(u^{k+1})^\top G d^i}{(d^i)^\top G d^i} d^i, \quad \forall k \in \{1, 2, \dots, n-1\}.$$

试证明: d^1, d^2, \dots, d^n 关于 G 共轭.

3.13 考虑函数 $f(x) = \frac{1}{2}x_1^2 + \frac{1}{2}x_2^2$, 设初始点取为 $x^0 = (1, 1)^\top$, $d^0 = (-1, 0)^\top$. 沿方向 d^0 进行精确一维线搜索可得 λ_0 , 令 $x^1 = x^0 + \lambda_0 d^0$, 用FR公式求得方向 d^1 . 试证明: 方向 d^0 和 d^1 不是关于单位矩阵 I 共轭的.

3.14 用精确一维线搜索的FR共轭梯度法(及PRP共轭梯度法)求解下列无约束优化问题.

(1) $\min f(x_1, x_2) = x_1^2 - x_1 x_2 + x_2^2 + 2x_1 - 4$, 其中初始点取为 $x^0 = (2, 2)^\top$.

(2) $\min f(x_1, x_2) = x_1^2 + 2x_2^2$, 其中初始点取为 $x^0 = (1, 1)^\top$.