

(考试时间: 2022 年 6 月 14 日)

题号	一	二	三	四	五	六	七	成绩
得分								

一、不定项选择题 (共 20 分, 每小题 2 分)

1. 任给一个单目标约束优化问题, 以下结论正确的有 (A, D)
- (A) 每个全局最优解一定是局部最优解. (B) 若局部最优解存在, 则全局最优解一定存在.
(C) 若全局最优解存在, 则一定唯一. (D) 若全局最优解存在, 则最优值一定唯一.
2. 记 $[p] = \{1, \dots, p\}$. 令 $C_i \subseteq R^n$ ($i \in [p]$) 为凸集. 对任意的 $i \in [p]$, $f_i: R^n \rightarrow R$ 为 C_i 上的凸函数. 设 λ_i ($i \in [p]$) 为实数. 则以下结论正确的有 (A, B, C, D)
- (A) $\bigcap_{i=1}^p C_i$ 为凸集. (B) $\sum_{i=1}^p \lambda_i C_i$ 为凸集.
(C) $\sum_{i=1}^p \lambda_i f_i$ 为 $\bigcap_{i=1}^p C_i$ 上的凸函数. (D) $\sum_{i=1}^p f_i$ 为 $\bigcap_{i=1}^p C_i$ 上的凸函数.
3. 关于线性规划, 以下结论正确的有 (A, B)
- (A) 任意一个线性规划都可以转化为标准型.
(B) 若线性规划有两个相邻顶点是最优解, 则这两点连线上的点都是最优解.
(C) 求解线性规划的对偶单纯形算法, 是求解该问题对偶规划的单形算法.
(D) 若一个线性规划存在最优解, 则其最优解是该问题可行域的某个顶点.
4. 给定线性规划 (LP): $\min \{c^T x: Ax = b, x \geq 0\}$, 及其对偶规划 (DLP): $\max \{b^T y: A^T y \leq c\}$. 以下结论正确的有 (A, B, C, D)
- (A) 若 x^*, y^* 分别是 (LP) 和 (DLP) 的可行解, 则 $c^T x^* \geq b^T y^*$.
(B) 若 (LP) 和 (DLP) 都有可行解, 则它们都有最优解.
(C) 若 (LP) 可行但无下界, 则 (LP) 和 (DLP) 都没有最优解.
(D) 若 (LP) 的可行解 x^* 与 (DLP) 的可行解 y^* 满足 $(x^*)^T (c - A^T y^*) = 0$, 则 x^* 一定是 (LP) 的最优解.
5. 对于求解线性规划 (LP) 的单形算法, 以下结论正确的有 (A, C, D)
- (A) 算法设计的理论基础是: 若 (LP) 有最优解, 则存在某个顶点是最优解.
(B) 迭代点对应的目标函数值序列是严格单调下降的.
(C) 在求解 (LP) 的大 M 法中, 若辅助问题无最优解, 则 (LP) 也无最优解.
(D) 在求解 (LP) 的二阶段法中, 第一阶段的目的求出 (LP) 的一个基可行解.
6. 对于无约束优化问题 (UO): $\min_{x \in R^n} f(x)$, 以下结论正确的有 (A, B, C)
- (A) 求解 (UO) 的最速下降法中, 相邻两步的迭代方向一定垂直.
(B) 若 f 是一个严格凸二次函数, 则求解 (UO) 的 DFP 拟牛顿法至多迭代 n 步可达极小值点.
(C) 若 f 是严格凸二次函数, 则求解 (UO) 的 FR 共轭梯度法和 PRP 共轭梯度法都属于共轭方法.
(D) 求解 (UO) 的牛顿法、共轭梯度法、拟牛顿法都具有二次终止性.
7. 考虑无约束优化问题 (UO), 以下结论正确的有 (A, B, C, D)
- (A) 求解 (UO) 的非单调下降算法中, 迭代点对应的目标函数值序列的整体趋势是下降的.
(B) 求解 (UO) 的非单调下降算法中, 使用的是非单调线搜索.
(C) 求解 (UO) 的信赖域算法不是线搜索下降算法.
(D) 对于线性方程 $Ax = b$, 其中 $A \in R^{m \times n}$ 且 $b \in R^m$, 若 $Ax = b$ 有解, 则 $Ax = b$ 的最小二乘解也是该方程组的一个解.
8. 对 (NLP): $\min_{x \in D} f(x)$ 其中 $D = \{x \in R^n: c_i(x) \geq 0, i \in I \text{ 且 } c_i(x) = 0, i \in E\}$, 其 Lagrange 对偶问题记为 (DNLP). 以下结论正确的有 (A, B)
- (A) (DNLP) 是一个凸规划问题.
(B) 令 $x \in D$, 则 $f(x)$ 大于等于 (DNLP) 的任一可行点对应的目标函数值.
(C) 用内、外罚函数法求解 (NLP) 时, 得到的近似最优解不是 (NLP) 的可行解.
(D) 用外罚函数法求解 (NLP) 时, 罚函数序列是单调减少的.
9. 对于 (VMP): $V = \min_{x \in D} F(x) = (f_1(x), \dots, f_p(x))^T$, 以下结论正确的有 (A, C)
- (A) 若 (VMP) 有绝对最优解, 则 (VMP) 的每个有效解是其绝对最优解.
(B) (VMP) 不一定存在绝对最优解, 但它一定存在弱有效解.
(C) 若每个 f_i 在 D 上有相同的最优解, 则 (VMP) 一定存在有效解.
(D) 若每个 f_i 在 D 上有相同的最优解, 则 (VMP) 的弱有效解是其有效解.
10. 使用评价函数将 (MVP): $V = \min_{x \in D} F(x) = (f_1(x), \dots, f_p(x))^T$ 转化为单目标优化问题 (UP): $\min_{x \in D} U(F(x))$ 来求解. 以下结论正确的有 (A, B, C, D)
- (A) 若 U 为严格单调增函数, 则 (UP) 的最优解一定是 (MVP) 的有效解.
(B) 若 U 为单调增函数, 则 (UP) 的最优解一定是 (MVP) 的弱有效解.
(C) 若 $U(F(x)) = \sum_{i=1}^p \lambda_i f_i(x)$, 其中 $\sum_{i=1}^p \lambda_i = 1$ 且每个 $\lambda_i > 0$, 则 (UP) 的最优解一定是 (MVP) 的有效解.
(D) 若 $U(F(x)) = \max_{i \in \{1, \dots, p\}} \{\lambda_i f_i(x)\}$, 其中 $\sum_{i=1}^p \lambda_i = 1$ 且每个 $\lambda_i > 0$, 则 (UP) 的最优解一定是 (MVP) 的有效解.

二、填空题 (共 10 分, 每个空 1 分)

1. 令 $A = (a_{ij}) \in R^{n \times 2}$, 其中对任意的 $i, j \in \{1, 2\}$, 有 $a_{ij} = i + j$, 则 $\|A\| = 47$.
2. 设函数 $f: R^1 \rightarrow R$ 一阶连续可微, 则 $d \in R^n$ 为 f 在 $u \in R^n$ 处的下降方向当且仅当 $\nabla f(u)^T d < 0$.
3. 给定线性规划 $\min \{c^T x: Ax = b, x \geq 0\}$, 其中 $A \in R^{m \times n}$, $b \in R^m$ 且 $p \leq q$. 则该线性规划的基解的个数最多为 $\binom{q}{p}$ 个.
4. 设 x^* 为线性规划 (LP): $\min \{c^T x: Ax \geq b\}$ 的最优解, 则 (LP) 的对偶规划的最优值为 $(b^T)^T c^T x^*$.
5. 令 $f(x) = 2(x_1^2 + x_2^2) - 4x_1 x_2 + 1, \forall x \in R^2$, 则 $\min_{x \in R^2} f(x)$ 的最优值为 1.
6. 令 $A \in R^{m \times n}$, $b \in R^m$, 且 x^* 是 $Ax = b$ 的一个解, 则 $Ax = b$ 的最小二乘问题的最优值为 $\|Ax - b\|_2$.
7. 对 (NLP): $\min_{x \in D} f(x)$ 其中 $D = \{x \in R^n: c_i(x) \geq 0, i \in I \text{ 且 } c_i(x) = 0, i \in E\}$, 求解它的外罚函数法中, 惩罚函数为 $P(x, \sigma) = \frac{1}{2\sigma} \sum_{i \in I} [c_i(x)]_+^2 + \frac{1}{2\sigma} \sum_{i \in E} [c_i(x)]_+^2$.
8. 考虑变量的多目标优化问题 (MVP): $V = \min_{x \in D} F(x) = (f_1(x), \dots, f_p(x))^T$, 其中,
- $f_1(x) = \begin{cases} 1 & \text{若 } |x| \leq 1 \\ x^2 & \text{若 } |x| > 1 \end{cases}, f_2(x) = \begin{cases} 1 & \text{若 } |x-1| \leq 1 \\ |x-1| & \text{若 } |x-1| > 1 \end{cases}$
- 则 (VMP) 的绝对最优解集为 $\{0, 1\}$, 有效解集为 $\{0, 1\}$, 弱有效解集为 $\{0, 1, 2\}$.

三、(本题 18 分) 用二阶段法求解下面的线性规划的问题

- $$\begin{aligned} \min \quad & -3x_1 + x_2 + x_3 \\ \text{s.t.} \quad & x_1 - 2x_2 + x_3 \leq 11, \\ & -4x_1 + x_2 + 2x_3 \geq 6, \\ & -2x_1 + x_2 + x_3 = 1, \\ & x_1, x_2, x_3 \geq 0. \end{aligned}$$
- 解: 解法一: 为得到单位基, 对 x_2, x_3 即可.
- $$\begin{aligned} \min \quad & x_6 + x_7 \\ \text{s.t.} \quad & x_1 - 2x_6 + x_7 + x_8 = 11, \\ & -4x_1 + x_6 + 2x_7 - x_9 = 6, \\ & -2x_1 + x_6 = 1, \\ & x_1, x_6, x_7 \geq 0. \end{aligned}$$
- x_4, x_5, x_7 为基变量, $C_B^T = (0, 1, 1)$, $C_N^T = (0, 0, 0)$.
- $$N = \begin{pmatrix} 1 & -2 & 1 & 0 \\ -4 & 1 & 2 & -1 \\ -2 & 0 & 1 & 0 \end{pmatrix}, B = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = I = B^{-1}.$$
- 初始判别数 $\bar{C}_B^T = C_B^T - C_B^T B^{-1} B = (0, 0, 0)$, $\bar{C}_N^T = C_N^T - C_B^T B^{-1} B^T N$
- 制表, 初等行变换.
- 制表, 初等行变换.
- 至 $\bar{C}_j \geq 0$
- 还原.
- \Rightarrow 计算原问题最优解和最优值.



四、(本题 12 分) 用精确一维搜索的 FR 共轭梯度法求解无约束优化问题:

$$\min f(x_1, x_2) = x_1^2 - x_1 x_2 + x_2^2 + 2x_1 - 4,$$

其中初始点取为 $x^0 = (0, 0)^T$.

解: $g(x) = (2x_1 - x_2 + 2, -x_1 + 2x_2)^T$, $g_0 = (2, 0)^T \neq (0, 0)^T$

$$d_0 = -g_0 = (-2, 0)^T$$

$$\min_{\lambda \geq 0} f(x^0 + \lambda d_0) = f(x^0 + \lambda_0 d_0)$$

$$\lambda_0 = \frac{1}{2}$$

$$x^1 = x^0 + \lambda_0 d_0 = (-1, 0)^T, g_1 = (0, 1)^T \neq (0, 0)^T$$

$$d_1 = -g_1 + \beta_0 d^0, \text{ 其中 } \beta_0 = \frac{g_0^T g_0}{g_0^T g_0} = \frac{1}{4}$$

$$\Rightarrow d_1 = (-\frac{1}{2}, -1)^T$$

$$\min_{\lambda \geq 0} f(x^1 + \lambda d_1) = f(x^1 + \lambda_1 d_1)$$

$$\Rightarrow \lambda_1 = \frac{2}{3}$$

$$x^2 = x^1 + \lambda_1 d_1 = (-\frac{2}{3}, -\frac{2}{3})^T$$

$$\Rightarrow g_2 = (0, 0)^T$$

f 为凸集, $G(u) = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$ 对称正定, $\Rightarrow f$ 凸函数

\Rightarrow 凸函数

稳定点 $(-\frac{2}{3}, -\frac{2}{3})^T$ 为极小值点.

五、(本题 15 分) 求约束优化问题

$$\min g(x) = 2x_1 + 2x_2$$

$$\text{s.t. } h(x) := 2 - x_1^2 - x_2^2 \geq 0$$

的 K-T 点, 并证明它是该问题的一个严格全局最优解.

解: 其 Lagrange 函数为:

$$L(x, \lambda) = g(x) - \lambda h(x)$$

$$= 2x_1 + 2x_2 - 2\lambda + \lambda x_1^2 + \lambda x_2^2$$

由 K-T 条件:

$$\begin{cases} 2 + 2\lambda x_1 = 0 \\ 2 + 2\lambda x_2 = 0 \\ 2\lambda - \lambda x_1^2 - \lambda x_2^2 = 0 \\ \lambda \geq 0 \end{cases} \Rightarrow \lambda_1 = 0 (\text{舍}), \lambda_2 = 1, \lambda_3 = -1 (\text{舍})$$

$$\Rightarrow \text{K-T 点: } (-1, -1)$$

显然, $g(x)$ 为凸函数, $h(x)$ 为凹函数

$\Rightarrow g(x), h(x)$ 在 $(-1, -1)$ 处可微.

\Rightarrow 全局最优解



扫描全能王 创建

六、(本题 15 分) 用乘子法求解下列约束优化问题:

$$\min f(x) = x_1^2 - 3x_2 - x_2^2$$

$$\text{s.t. } c(x) = x_2 = 0.$$

解: 构造 Lagrange 乘子为:

$$L(x, \lambda) = f(x) - C(x, \lambda) = x_1^2 - 3x_2 - x_2^2 - \lambda x_2 = x_1^2 - (3+\lambda)x_2 - \frac{1}{2}\lambda^2$$

$$\frac{\partial L}{\partial x_1} = 2x_1, \frac{\partial L}{\partial x_2} = -(3+\lambda) - 2x_2, \frac{\partial L}{\partial \lambda} = -x_2 = 0$$

$$\Rightarrow \begin{cases} 2x_1 = 0 \\ -(3+\lambda) - 2x_2 = 0 \\ -x_2 = 0 \end{cases} \Rightarrow \begin{cases} x_1 = 0 \\ x_2 = -\frac{3+\lambda}{2} \end{cases}$$

构造增广 Lagrange 函数:

$$M(x, \lambda, \mu) = L(x, \lambda) + \frac{\mu}{2} C(x, \lambda) = x_1^2 - (2+\lambda)x_2 - \frac{\mu}{2}x_2^2 + \frac{\mu}{2}\lambda^2$$

$$\frac{\partial M}{\partial x_1} = 2x_1, \frac{\partial M}{\partial x_2} = -(2+\lambda) - \mu x_2, \frac{\partial M}{\partial \lambda} = -x_2 + \mu \lambda$$

$$\text{由一阶必要条件, } \begin{cases} 2x_1 = 0 \\ -(2+\lambda) - \mu x_2 = 0 \\ -x_2 + \mu \lambda = 0 \end{cases} \Rightarrow \begin{cases} x_1 = 0 \\ x_2 = \frac{2\lambda}{\mu-2} \end{cases} \quad (1)$$

$$\text{令 } x_1 = 0, x_2 = \frac{2\lambda}{\mu-2}, \text{ 代入乘子法公式: } \lambda^{\mu+1} = \lambda^{\mu} - \mu_2 \cdot \frac{2\lambda}{\mu-2}, \text{ 收敛.}$$

令 μ_2 趋于正无穷大, 则 $\lambda^{\mu+1} = \lambda^{\mu} - \mu_2 \cdot \frac{2\lambda}{\mu-2} \Rightarrow \lambda = -3$ 代入 (1),

得: $\begin{cases} x_1 = 0 \\ x_2 = 0 \end{cases}$ 故, $(0, 0)$ 为原约束优化问题的最优解.

七、(本题 10 分) 设 $f(x) = \frac{1}{2} x^T G x + p^T x + q$, 其中 G 是对称正定矩阵. 证明: 从任

意点 x^0 出发, 使用精确一维搜索的牛顿法至多一步迭代可达到函数 f 的全局极小值点.

证明: $\min_{x \in \mathbb{R}^n} f(x)$

d^0 为牛顿方向,

设全局极小值点为 x^* .

$$\text{s.t. } G d^0 = -g_0.$$

$$g(x) = Gx + p^T$$

$$\Rightarrow d^0 = -G^{-1} g_0 = -G^{-1} (Gx^0 + p^T)$$

$$Gx^0 = Gx^0$$

$$= -(x^0 + G^{-1} p^T)$$

$$\text{由 } G \text{ 对称正定,}$$

由 G 对称正定,

$$\Rightarrow f \text{ 为严格凸函数. } \Rightarrow x^* = -G^{-1} p^T$$

$$d^0 = -G^{-1} (Gx^0 + p^T)$$

若 $x^0 \neq x^*$,

$$\text{则 } x^1 = x^0 + \lambda_0 d^0$$

$$\min_{\lambda \geq 0} f(x^0 + \lambda d^0) = f(x^0 + \lambda_0 d^0)$$

$$0 = \nabla f(x^0 + \lambda_0 d^0)^T d^0$$

$$= \frac{x^0 + (d^0)^T g_0}{(d^0)^T G d^0} \cdot (x^0 + G^{-1} p^T)$$

$$= x^0 + d^0$$

$$= x^0 - x^0 - G^{-1} p^T$$

$$= -G^{-1} p^T = x^*$$

$$\Rightarrow 0 = [Gx^0 + \lambda_0 Gd^0 + p^T]^T d^0$$

$$= (d^0)^T Gx^0 + \lambda_0 (d^0)^T Gd^0 + (d^0)^T p^T$$

$$\Rightarrow \lambda_0 = -\frac{(d^0)^T Gx^0 + (d^0)^T p^T}{(d^0)^T Gd^0} = -\frac{(d^0)^T (Gx^0 + p^T)}{(d^0)^T Gd^0}$$

$$= -\frac{(d^0)^T g_0}{(d^0)^T Gd^0} = 1$$



扫描全能王 创建