

## 3.1 算法理论基础 — 问题

---

# 第三章 无约束优化方法

本章考虑无约束优化问题

$$\min_{x \in \mathbb{R}^n} f(x) \quad (3.0.1)$$

其中  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ . 在介绍问题(3.0.1)最优性条件之后, 着重介绍求解该问题的各种迭代算法及其收敛性. 下面的符号将被频繁地使用:

$$\begin{aligned} g(x) &:= \nabla f(x), & g_k &:= \nabla f(x^k), & g_* &:= \nabla f(x^*), \\ G(x) &:= \nabla^2 f(x), & G_k &:= \nabla^2 f(x^k), & G_* &:= \nabla^2 f(x^*). \end{aligned}$$

## §3.1 算法理论基础

## 3.1 算法理论基础 — 最优性条件

---

### §3.1.1 最优性条件

回忆一元函数  $\varphi: \mathbb{R} \rightarrow \mathbb{R}$  的极值问题, 有以下结论:

- (一阶必要条件) 若函数  $\varphi$  一阶连续可微且  $\lambda_*$  为  $\varphi$  的局部极小值点, 则  $\varphi'(\lambda_*) = 0$ ;
- (二阶必要条件) 若函数  $\varphi$  二阶连续可微且  $\lambda_*$  为  $\varphi$  的局部极小点值, 则  $\varphi'(\lambda_*) = 0$  并且  $\varphi''(\lambda_*) \geq 0$ ;
- (二阶充分条件) 若函数  $\varphi$  二阶连续可微,  $\varphi'(\lambda_*) = 0$  且  $\varphi''(\lambda_*) > 0$ , 则  $\lambda_*$  为函数  $\varphi$  的严格局部极小值点.

下面的引理给出了一元函数与多元实值函数极值之间的关系.

## 3.1 算法理论基础 — 最优性条件

---

**引理 3.1.1** 假设多元实值函数  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  是连续的. 给定  $x^* \in \mathbb{R}^n$  和任意的  $d \in \mathbb{R}^n \setminus \{0\}$ , 那么  $x^*$  是函数  $f$  的(严格)局部极小值点当且仅当  $\lambda_* = 0$  是一元函数  $\varphi(\lambda) = f(x^* + \lambda d)$  的(严格)局部极小值点.

**证明**  $\varphi(0) = f(x^*)$  是显然的.

- 假设  $x^*$  是多元实值函数  $f$  的局部极小值点, 那么对任意靠近  $x^*$  的  $x \in \mathbb{R}^n$  有  $f(x^*) \leq f(x)$ . 而对任意的  $d \in \mathbb{R}^n \setminus \{0\}$ , 当  $\lambda$  充分靠近 0 时,  $x^* + \lambda d$  将充分靠近  $x^*$ , 因此,  $f(x^*) \leq f(x^* + \lambda d)$ , 所以  $\lambda_* = 0$  是一元函数  $\varphi(\lambda) = f(x^* + \lambda d)$  的局部极小值点.

## 3.1 算法理论基础 — 最优性条件

---

- 假设 $\lambda_* = 0$ 是一元函数 $\varphi(\lambda) = f(x^* + \lambda d)$ 的局部极小值点, 那么存在 $\lambda_* = 0$ 的一个邻域

$\mathcal{N}^0(\delta) = (-\delta, \delta)$  其中 $\delta$ 是一个固定的正数

使得对任意的 $\lambda \in \mathcal{N}^0(\delta)$ , 都有 $\varphi(0) \leq \varphi(\lambda)$ . 为了证明 $x^*$ 是多元实值函数 $f$ 的局部极小值点, 我们构造以下邻域:

$$\mathcal{N}(\delta) = \{x \in \mathbb{R}^n \mid \|x - x^*\| < \delta\}.$$

对任意的 $x \in \mathcal{N}(\delta)$ , 存在 $\mu \in \mathbb{R}$ 和某个单位向量 $d \in \mathbb{R}^n$ , 使得 $x = x^* + \mu d$ . 由于 $x \in \mathcal{N}(\delta)$ , 所以

$$|\mu| = \|\mu d\| = \|x - x^*\| < \delta,$$

这表明:  $\mu \in \mathcal{N}^0(\delta)$ . 因此,

## 3.1 算法理论基础 — 最优性条件

---

$$f(x^*) = \varphi(0) \leq \varphi(\mu) = f(x).$$

由 $x$ 任意性知: 对于邻域 $N(\delta)$ 的任意点 $x$ , 都有 $f(x^*) \leq f(x)$ , 所以 $x^*$ 是多元实值函数 $f$ 的局部极小值点.

因此,  $x^*$ 是多元实值函数 $f$ 的局部极小值点当且仅当 $\lambda_* = 0$ 是一元函数 $\varphi(\lambda) = f(x^* + \lambda d)$ 的局部极小值点. 类似可得:  $x^*$ 是多元实值函数 $f$ 的严格局部极小值点当且仅当 $\lambda_* = 0$ 是一元函数 $\varphi(\lambda) = f(x^* + \lambda d)$ 的严格局部极小值点.  $\square$

借助于一元函数的极值条件和引理3.1.1, 下面来讨论无约束优化问题(3.0.1)的最优性条件.

## 3.1 算法理论基础 — 最优性条件

### 定理 3.1.1 (必要条件)

- (i) (一阶必要条件) 若函数  $f$  在  $x^* \in \mathbb{R}^n$  的某邻域内一阶连续可微且  $x^*$  为  $f$  的局部极小值点, 那么  $g_* = 0$ .
- (ii) (二阶必要条件) 若函数  $f$  在  $x^* \in \mathbb{R}^n$  的某邻域内二阶连续可微且  $x^*$  为  $f$  的局部极小值点, 那么  $g_* = 0$  且  $G_*$  对称半正定.

**证明** 只证明(ii)中的结论, (i)中的结论类似可得. 任取  $d \in \mathbb{R}^n \setminus \{0\}$ , 定义  $\varphi(\lambda) = f(x^* + \lambda d)$ . 由于函数  $f$  在  $x^*$  的某邻域内二阶连续可微, 所以函数  $\varphi$  在  $\lambda_* = 0$  的某邻域内二阶连续可微且

$$\varphi'(\lambda) = g(x^* + \lambda d)^\top d, \quad \varphi''(\lambda) = d^\top G(x^* + \lambda d)d.$$

由于  $x^*$  为  $f$  的局部极小值点, 由引理3.1.1知:  $\lambda_* = 0$  是一元函数  $\varphi$  的局部极小值点. 因此, 由一元函数的极值条件  $\varphi'(0) = 0$  和  $\varphi''(0) \geq 0$  可得

$$g_*^\top d = 0, \quad d^\top G_* d \geq 0.$$

由  $d$  的任意性进一步可得:  $g_* = 0$  且  $G_*$  半正定. 定理得证. □



## 3.1 算法理论基础 — 最优性条件

称满足一阶必要条件  $g_* = 0$  的点为 **稳定点（也称为驻点）**. 稳定点可分为三种类型: **极小值点, 极大值点和鞍点**. 所谓鞍点, 就是沿着某些方向它是极小值点; 而沿着另一些方向它是极大值点. 当  $n = 3$ , 即在立体空间中, 由于在该点附近函数的图象形如马鞍, 故称其为鞍点.

**定理 3.1.2 (二阶充分条件)** 假设函数  $f$  在  $x^* \in \mathbb{R}^n$  的某邻域内二阶连续可微. 如果  $g_* = 0$  并且  $G_*$  正定, 那么  $x^*$  为函数  $f$  的严格局部极小值点.

**证明** 任取  $d \in \mathbb{R}^n \setminus \{0\}$ , 定义  $\varphi(\lambda) = f(x^* + \lambda d)$ . 由于函数  $f$  在  $x^*$  的某邻域内二阶连续可微, 所以函数  $\varphi$  在  $\lambda_* = 0$  的某邻域内二阶连续可微且  $\varphi'(0) = g_*^\top d$ ,  $\varphi''(0) = d^\top G_* d$ .

由于  $g_* = 0$  且  $G_*$  正定, 所以可得

$$\varphi'(0) = g_*^\top d = 0 \quad \text{且} \quad \varphi''(0) = d^\top G_* d > 0, \quad \forall d \in \mathbb{R}^n \setminus \{0\}.$$

这表明:  $\lambda_* = 0$  是一元函数  $\varphi$  的严格局部极小值点. 所以由引理 3.1.1, 可知  $x^*$  为  $f$  的严格局部极小值点. 定理得证.  $\square$

## 3.1 算法理论基础 — 最优性条件

---

如果  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  为凸函数, 那么有以下更好的结论.

**定理 3.1.3** (无约束凸规划的最优性条件) 假设  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  是一阶连续可微的凸函数, 则  $x^*$  为函数  $f$  的全局极小值点当且仅当  $g_* = 0$ .

**证明** 必要性由定理3.1.1可得, 下证充分性. 由于  $f$  是  $\mathbb{R}^n$  上的一阶连续可微的凸函数, 根据凸函数的一阶判别定理(即: 定理1.3.4), 因而可得对任意的  $x \in \mathbb{R}^n$ , 有

$$f(x) - f(x^*) \geq g_*^\top (x - x^*).$$

结合上式和条件  $g_* = 0$ , 于是有: 对任意的  $x \in \mathbb{R}^n$  有  $f(x) \geq f(x^*)$ , 这表明:  $x^*$  为函数  $f$  的全局极小值点. 定理得证.  $\square$



## 3.1 算法理论基础 — 算法及其收敛性

---

### §3.1.2 线搜索迭代下降算法及其收敛性

线搜索迭代下降算法是求解无约束优化问题(3.0.1)的流行算法之一, 其**基本思想**为: 从某个初始点开始, 按照一定的规则不断地寻找迭代方向和(用线搜索)迭代步长进行迭代, 直到算法终止. 一般迭代框架如下:

**算法 3.1.1** (线搜索迭代下降算法) 选择初始点  $x^0 \in \mathbb{R}^n$ . 置  $k := 0$ .

**步1** 如果  $g_k = 0$ , 算法终止.

**步2** 确定下降方向  $d^k \in \mathbb{R}^n$ .

**步3** 使用线搜索确定步长  $\lambda_k > 0$ , 使得  $f(x^k + \lambda_k d^k) < f(x^k)$ .

**步4** 置  $x^{k+1} := x^k + \lambda_k d^k$  和  $k := k + 1$ , 并返回到步1.

## 3.1 算法理论基础 — 算法及其收敛性

下面讨论算法3.1.1的收敛性. 假设 $\theta_k$ 表示方向 $d^k$ 与 $-g_k$ 之间的夹角, 则

$$\cos \theta_k = -\frac{g_k^\top d^k}{\|g_k\| \|d^k\|}. \quad (3.1.1)$$

假设算法3.1.1中的步长 $\lambda_k$ 分别由精确一维线搜索、Armijo线搜索、Wolfe线搜索得到, 那么对应算法的全局收敛性分别由以下三个定理给出.

**定理 3.1.4** 假设函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 连续可微且有下界, 且其梯度函数 $g$ 具有Lipschitz连续性, 即存在常数 $\mathcal{L} > 0$ 使得对任意的 $x, y \in \mathbb{R}^n$ , 有 $\|g(x) - g(y)\| \leq \mathcal{L}\|x - y\|$ . 设无穷序列 $\{x^k\}$ 由算法3.1.1产生, 其中步长 $\lambda_k$ 由精确一维线搜索得到. 那么,

$$\sum_{k=0}^{\infty} \|g_k\|^2 \cos^2 \theta_k < \infty. \quad (3.1.2)$$

特别地, 若存在常数 $\beta > 0$ 使得 $\cos \theta_k \geq \beta$ , 则 $\lim_{k \rightarrow \infty} \|g_k\| = 0$ .

## 3.1 算法理论基础 — 算法及其收敛性

**证明** 由于最后的结论可由(3.1.2)式的结论直接得到, 因而下面只需证明(3.1.2)式的结论成立. 因为函数 $f$ 连续可微, 所以对任意的 $\lambda > 0$ , 存在 $\alpha_k \in (0, 1)$ 使得

$$\begin{aligned} f(x^k + \lambda d^k) &= f(x^k) + \lambda g(x^k + \alpha_k \lambda d^k)^\top d^k \\ &= f(x^k) + \lambda g_k^\top d^k + \lambda [g(x^k + \alpha_k \lambda d^k) - g_k]^\top d^k \\ &\leq f(x^k) + \lambda g_k^\top d^k + \lambda \|g(x^k + \alpha_k \lambda d^k) - g_k\| \|d^k\| \\ &\leq f(x^k) + \lambda g_k^\top d^k + \lambda^2 \mathcal{L} \|d^k\|^2, \end{aligned}$$

其中, 第一个等式成立是由于中值定理, 第一个不等式成立是由于Cauchy-Schwartz不等式. 特别地, 取 $\hat{\lambda}_k := -\frac{g_k^\top d^k}{2\mathcal{L}\|d^k\|^2}$ , 则由上式可得

$$f(x^k + \hat{\lambda}_k d^k) \leq f(x^k) - \frac{(g_k^\top d^k)^2}{4\mathcal{L}\|d^k\|^2}.$$

## 3.1 算法理论基础 — 算法及其收敛性

---

又由精确一维线搜索知：步长 $\lambda_k$ 满足 $f(x^{k+1}) = f(x^k + \lambda_k d^k) \leq f(x^k + \hat{\lambda}_k d^k)$ . 因此，

$$f(x^{k+1}) \leq f(x^k + \hat{\lambda}_k d^k) \leq f(x^k) - \frac{(g_k^\top d^k)^2}{4\mathcal{L}\|d^k\|^2}.$$

根据(3.1.1)式, 由上式可得

$$\|g_k\|^2 \cos^2 \theta_k \leq 4\mathcal{L}[f(x^k) - f(x^{k+1})].$$

由假设知：函数 $f$ 有下界. 因此, 对上式求和即可得到(3.1.2)式成立. 定理得证. □

## 3.1 算法理论基础 — 算法及其收敛性

---

**定理 3.1.5** 假设无穷序列 $\{x^k\}$ 由算法3.1.1产生, 其中迭代步长 $\lambda_k$ 是由Armijo线搜索得到, 并且定理3.1.4的其它条件成立. 如果存在常数 $c > 0$ 使得

$$\|g_k\| \leq c\|d^k\|. \quad (3.1.3)$$

那么定理3.1.4的结论成立.

**定理 3.1.6** 如果无穷序列 $\{x^k\}$ 由算法3.1.1产生, 其中迭代步长 $\lambda_k$ 是由Wolfe线搜索得到, 并且定理3.1.4的其它条件成立, 那么定理3.1.4的结论成立.

## 3.1 算法理论基础 — 算法及其收敛性

---

下面的定理给出算法3.1.1的收敛速度的有关性质.

**定理 3.1.7** 假设  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  二次连续可微, 无穷序列  $\{x^k\}$  由算法3.1.1 产生, 其中迭代步长  $\lambda_k$  由 *Armijo* 线搜索得到 (其中  $\sigma \in (0, 1/2)$ ) 或由 *Wolfe* 线搜索得到. 假定  $x^k \rightarrow x^*$ ,  $g_* = 0$  并且  $G_*$  对称正定. 如果

$$\lim_{k \rightarrow \infty} \frac{\|g_k + G_k d^k\|}{\|d^k\|} = 0, \quad (3.1.4)$$

那么, 当  $k$  充分大时有  $\lambda_k = 1$ . 进一步, 序列  $\{x^k\}$  局部超线性收敛于  $x^*$ .



## 3.1 算法理论基础 — 作业

---

### 3.1 求出函数

$$f(x) = 2x_1^2 + x_2^2 - 2x_1x_2 + 2x_1^3 + x_1^4$$

所有的稳定点, 并判断哪些稳定点是极小值点? 是否是整体极小值点?

### 3.2 试证明: 函数

$$f(x_1, x_2) = x_1^2 - 4x_2^2 + 20x_1 + 64x_2$$

存在唯一的稳定点, 但该点既不是函数 $f$ 的极大值点, 也不是函数 $f$ 的极小值点.

### 3.3 试讨论参数 $a$ 取何值时, 点 $x = (0, 0, 0)^\top$ 是函数 $f(x) = ax_1^2e^{x_2} + x_2^2e^{x_3} + x_3^2e^{x_1}$ 的极大值点, 极小值点, 鞍点?